

UNIVERSIDADE FEDERAL DE ALFENAS
INSTITUTO DE CIÊNCIAS EXATAS

Estatística Básica

Luiz Alberto Beijo

ALFENAS
Minas Gerais - Brasil
7 de novembro de 2025

DADOS DO MATERIAL: Notas de Aula de Estatística Básica

Este material tem por objetivo propiciar aos estudantes um roteiro para o curso de Estatística Básica. Ressalta-se que o texto aqui construído é apenas uma coleção das notas de aulas do professor e que havendo necessidade, as bibliografias referenciadas devem ser sempre consultadas.

Por se tratar de um texto em construção, erros podem ocorrer, por isso solicito, a gentileza, que sugestões e correções sejam encaminhadas para *luiz.beijo@unifal-mg.edu.br*.

BONS ESTUDOS!!!!

Elaboração:

Luiz Alberto Beijo

Licenciado em Ciências e Matemática pela PUC Minas. Mestre e Doutor em Estatística e Experimentação Agropecuária pela UFLA. Professor do Departamento de Estatística da Universidade Federal de Alfenas - UNIFAL-MG

Sumário

Lista de Tabelas	6
1 A ESTATÍSTICA NA CIÊNCIA	7
1.1 A cientificidade do conhecimento	7
1.2 Diferenças da atitude científica frente ao senso comum	10
1.3 Conceito de método	10
1.4 Reflexão	11
1.5 Estatística	12
1.5.1 Fases do trabalho estatístico	13
1.6 Fluxo da Estatística Descritiva	14
1.6.1 Coleta dos dados	14
1.7 Conceitos básicos	15
1.8 Uso do <i>Software R</i>	16
2 AMOSTRAGEM	17
2.1 Delimitar a pesquisa	17
2.2 População	17
2.2.1 Unidades elementares e unidades amostrais	17
2.2.2 População objetivo	18
2.3 Métodos de pesquisa descritiva (observacional)	18
2.4 Amostragem	19
2.5 Amostragem probabilística	20
2.5.1 Amostragem simples ao acaso (ASA) ou aleatória simples	20
2.5.2 Amostragem estratificada	21
2.5.3 Amostragem Sistemática	21
2.6 Amostragem não probabilística	22
2.6.1 Amostragem a esmo	23
2.6.2 Amostragem por julgamento	23
2.6.3 Amostragem por cotas	23
2.6.4 Amostragem por conveniência	24
2.7 Problemas de amostragem	24
2.7.1 Amostras tendenciosas	24
2.8 Exercícios	25
3 ESTATÍSTICA DESCRITIVA	27
3.1 Conceitos e definições importantes	27
3.2 Introdução	28
3.3 Exemplo: Projeto de criação de uma empresa de TI no Sul de Minas	29
3.4 Apresentação dos dados qualitativos	30
3.4.1 Construindo Gráficos no <i>Rcommander</i> a partir de um BANCO DE DADOS	32
3.5 Apresentação dos dados quantitativos discretos	34
3.6 Organização e apresentação de dados quantitativos Contínuos	38

3.6.1	Construção de uma tabela de distribuição de frequência (TDF)	38
3.6.2	Representação gráfica de dados quantitativos contínuos	41
3.6.3	Classificação das distribuições de frequências	41
3.7	Construindo a TDF e o Histograma no R	42
3.8	Exercícios	43
4	Medidas descritivas	44
4.1	Medidas de posição	44
4.1.1	Propriedades da média, mediana e moda	45
4.1.2	EXEMPLO	45
4.2	Medidas de variabilidade	47
4.2.1	Cálculo das medidas descritivas com a calculadora científica :	48
4.2.2	EXEMPLO	50
4.3	Medidas de separatriz (quantil)	50
4.4	Gráfico Boxplot ou Diagrama de caixas	52
4.4.1	EXEMPLO	53
4.5	Exercícios	55
5	Probabilidades	58
5.1	Introdução	58
5.2	Conceitos e definições	59
5.3	Probabilidade de um evento $P(E)$	61
5.4	Noção de probabilidade: axiomas e teoremas.	62
5.5	Probabilidade condicional e independência	63
5.6	Calculando a probabilidade condicional no Rcommander	65
5.7	Exercícios	66
6	Variável aleatória e distribuição de probabilidades	68
6.1	Distribuição de probabilidades	69
6.2	Distribuição Binomial (Discreta)	70
6.3	Distribuição Poisson (Discreta)	74
6.4	Exercícios	77
6.5	Distribuição de probabilidades Contínua	79
6.6	Distribuição Normal ou Gaussiana (Contínua)	81
6.6.1	Distribuição Normal Padrão	82
6.7	Calculando a probabilidade com Distribuição Normal	84
6.7.1	Exemplo	84
6.7.2	Construindo gráficos da Distribuição Normal	86
6.7.3	Calculando quantis da Distribuição Normal	86
6.8	Distribuições amostrais: principais Teoremas	87
6.9	Exercícios	89

7	TEORIA DA ESTIMAÇÃO	91
7.1	Introdução	91
7.2	Estimação	92
7.2.1	Exemplo	92
7.2.2	A natureza da estimação	93
7.3	Estimadores pontuais	94
7.4	Estimadores por intervalo (intervalos de confiança) para μ	94
7.4.1	Intervalo de 100 $(1 - \alpha)\%$ de confiança para a média populacional μ com a variância populacional σ^2 desconhecida será:	94
7.4.2	Exemplo	95
7.4.3	Fazendo IC para μ no R, com o Rcommander (Rcmdr)	95
7.4.4	Tabela t de Student	97
7.5	Intervalo de confiança para a proporção (π) - aproximado pela Normal	98
7.5.1	Exemplo	98
7.5.2	Fazendo IC para π no R	99
7.5.3	Construindo IC para μ e π no <i>Rcommander</i> a partir de um BANCO DE DADOS	101
7.6	Dimensionamento da Amostra	104
7.6.1	Dimensionamento da Amostra para a Proporção π	104
7.6.2	Dimensionamento da Amostra para a média μ	105
7.7	Exercícios	106
8	TEORIA DA DECISÃO	108
8.1	Introdução	108
8.2	Testes de hipóteses	108
8.2.1	Passos Gerais para a realização do teste	110
8.3	Teste sobre a média	110
8.3.1	Testes de Hipóteses no R	112
8.3.2	Decisão usando a Tabela t	113
8.3.3	Decisão usando o valor p	113
8.4	Testes sobre proporções	114
8.4.1	Testes de Hipóteses para PROPORÇÃO (π) no R	115
8.4.2	Decisão usando o valor p	116
8.4.3	Fazendo testes de hipóteses para μ e π no <i>Rcommander</i> a partir de um BANCO DE DADOS	117
8.5	Exercícios	120
8.6	Tabela t de Student	121
9	Teste de hipóteses para duas populações	122
9.1	Teste sobre razões de variâncias	122
9.1.1	Testes de Hipóteses para razão de variâncias no R	122
9.1.2	Exemplo	122
9.2	Comparação de duas médias- caso de amostras independentes	124
9.2.1	Exemplo	125

9.3	Comparação de duas médias - Caso de amostras <u>dependentes</u>	126
9.3.1	Testes de Hipóteses no R	127
9.3.2	Exemplo	127
9.4	Comparação de duas populações - BANCO DE DADOS implantação da empresa de TI . . .	128
9.5	Exercícios	131
9.6	Teste para comparar a proporção de duas populações (amostras independentes)	133
9.6.1	Testes de Hipóteses no R	133
9.6.2	Exemplo	133
9.7	Teste de Qui-Quadrado para tabelas de contingência	136
9.7.1	Exemplo	137
9.8	Exercícios	138
10	Correlação Linear	140
10.1	REGRESSÃO LINEAR	146
10.2	Regressão Linear Simples	146
10.2.1	Estimação de Parâmetros	147
10.2.2	Inferência na regressão	148
10.2.3	Coefficiente de determinação R^2	148
10.2.4	Aplicação	149
10.2.5	Exercício	152

Lista de Tabelas

- 1 Classificação servidores municipais da cidade de Campinas, segundo a renda mensal, em 2020 29
- 2 Quantis superiores da distribuição t de Student com (gl) graus de liberdade e para diferentes probabilidades (α) , com a notação - $P(|T| > t) = \alpha$ 97
- 3 Quantis superiores da distribuição t de Student com (gl) graus de liberdade e para diferentes probabilidades (α) , com a notação - $P(|T| > t) = \alpha$ 121

1 A ESTATÍSTICA NA CIÊNCIA

- **Comunicado:** Segundo orientações via OFÍCIO CONJUNTO CIRCULAR 1-2020-ProGrad-Reitoria-UNIFAL-MG.

"Este material é de uso exclusivo para estudo nesta disciplina e não pode ser compartilhado fora do ambiente desta turma. Baixar os textos aqui para estudar em casa não viola a lei dos direitos autorais. Entretanto, do mesmo modo que você não pode pegar o livro emprestado na biblioteca e fazer cópia para distribuir para outras pessoas, aqui no ambiente virtual de aprendizagem é igual. Portanto, não compartilhem os textos, vídeos e/ou podcasts fora do ambiente da turma, para evitar problemas com a lei do direito autoral."

Antes de abordarmos os conceitos fundamentais de Estatística, é importante situarmos a *Estatística* dentro do contexto do **método científico**. Para isto precisamos nos fundamentar em alguns conceitos e definições que são importantes tanto para pesquisas científicas quanto para o processo de gestão.

1.1 A cientificidade do conhecimento

Segundo Oliveira (2005)ⁱ, o conhecimento está ligado visceralmente à qualidade de vida do ser humano, qualquer que seja a sua forma, quer seja ele do tipo místico-religioso, filosófico-científico ou estético-artístico. Conhecer está no centro de uma vida plena e abundante (sucesso). Observa-se que a nossa sociedade contemporânea é uma sociedade do conhecimento, tal é o avanço dos conhecimentos neste tempo.

Contrastamos conhecimento com saber, para definirmos uma diferença sutil entre estes dois conceitos.

- **Conhecimento** é a forma que o ser humano faz a representação (ou compreensão, entendimento, ou ainda uma interpretação) atribuindo significado à realidade. Esta realidade, composta por sistemas, fenômenos e/ou processos, é dissecada sempre segundo três aspectos desejáveis: *verdade, beleza (harmonia) e justiça*.
- **Conhecer** é, portanto, a consciência da natureza e da medida destes três aspectos no fenômeno em foco. O conhecimento permite ao homem se mover corretamente num mundo marcado por bases *verdadeiras, belas e justas*, as quais ele discerne. Conhecimento é, pois a coincidência, é o encontro, é a confirmação entre o que é a realidade e o que o homem entende que deva ser a sua representação do mundo e da vida. O conhecimento que nós temos é que dá sentido, ou significado, à realidade.

A finalidade do conhecimento é **a predição ou previsão** dos efeitos que serão observados a partir da consciência das causas, o que permite o domínio das circunstâncias e, finalmente, a capacidade de gestão da vida e do mundo.

A gestão deve produzir em última instância o bem-estar e a felicidade coletiva e individual.

- **Saber** é o conhecimento potencializado pela arte de conseguir aplicá-lo (arte é a capacidade de fazer acontecer).

ⁱOLIVEIRA, M. S. **Orientações metodológicas para a construção de monografias**. Texto Acadêmico da Editora da UFLA: DEX-UFLA, 2005.

Enquanto o conhecimento pode existir apenas na mente de uma pessoa, *a sabedoria* necessariamente traduz-se em *palavras, gestos, ações, intervenções, com resultados concretos e observáveis*. O conhecedor é, portanto, aquele que percebe as coisas, conseguindo separar o que é belo (harmonioso), verdadeiro e justo do que não o é. O sábio porém, é aquele que **age** de modo belo (harmonioso), verdadeiro, e justo. O objetivo último **da educação é produzir sábios**.

Estes três modos de conhecer e de saber estão sempre presentes no ser humano, em qualquer situação. Porém, quando a **faculdade racional** está no comando das posturas e ações, destaca-se a forma de conhecimento chamada **científica**, ou, resumidamente, **Ciência**. A Ciência visa alcançar o **conhecimento provavelmente seguro e certo**, a fim de trazer o bem-estar e a felicidade nas experiências vividas.

Um importante resultado da conhecimento científico é a tecnologia.

- **Tecnologia** é a sabedoria científica, já que esta é a aplicação da ciência na construção artefatos (produtos, equipamento, métodos e modelos) que operam no mundo real externo ao ser humano (em alguns casos podemos denominar tecnologia como metodologia). Em outra definição, tecnologia é técnica com embasamento científico.

Assim como não podemos saber sem conhecer, não podemos gerar tecnologia sem ciência. Oliveira (2005) afirma que, para que um dado conhecimento seja considerado científico, é necessário que ele seja funcional, no sentido definido em seguida. A funcionalidade de um conhecimento consiste em ter **organicidade** (ser sistemático), **instrumentalidade** e intersubjetividade (ter aprovação de uma comunidade de cientistas).

A Ciência é, portanto, um conhecimento compartilhável, transferível, ensinável, julgável e criticável. Como afirmado, a sistematização do conhecimento é o que permite gerar a *teoria*.

- Teoria é a representação sistemática que o conhecimento científico faz do mundo e da vida. Das teorias é que derivamos os modelos e as hipóteses sobre o modo como funcionam o mundo e a vida.
- Modelos são representações organizadas de um dado fenômeno ou processo observado na realidade, com elementos constituintes justificados pela teoria utilizada, que faz pano-de-fundo ao modelo que está sendo proposto.
- Hipóteses são afirmações pontuais (não organizadas) sobre fenômenos ou processos reais, que providenciam uma resposta antecipada à um dado problema de pesquisa. Geralmente, precisam ser validadas.

Uma hipótese deve ser atrelada a uma teoria e a um modelo. Estes modelos e hipóteses definem a **gestão científica**, a qual é a utilização destes instrumentos conceituais derivados das teorias, para intervenção sobre os fenômenos, as organizações, os processos naturais e humanos, enfim, sobre todas as coisas que nos interessam.

As teorias, os modelos e as hipóteses recebem a homologação de uma comunidade legitimada para isto, reunidas em universidades e institutos de pesquisa, que se utilizam de defesas de documentos científicos perante bancas de pares, congressos científicos, simpósios, workshops, seminários, revistas científicas, entre outros, para proceder esta homologação. Tais eventos são os *eventos de comunicação e validação científica*, ou simplesmente **eventos científicos**.

A **pesquisa científica** é o modo como buscamos construir o conhecimento científico. Ela compreende *encontrar, selecionar, estruturar e resolver problemas* que interessam ao ser humano. Para apreender, representar e compreender problemas, o pesquisador lançará mão de hipóteses, modelos e teorias de modo crucial. Em outras palavras, antes de coletar dados, é necessário que nós tenhamos em mente um **referencial teórico**.

Conhecimento teórico é pré-requisito para se fazer uma pesquisa com qualidade, enquanto problemas são o ponto de partida para a pesquisa, percepção e a estruturação adequada destes problemas (que dependem essencialmente da postura filosófica e científica do pesquisador, ou grupo de pesquisa) são decisivos para o desenvolvimento da pesquisa.

O produto essencial de uma pesquisa científica é, portanto, um conhecimento que pretende ser seguro e certo (o conhecimento científico), apto para operar soluções para um problema humanamente relevante. A pesquisa científica deve ser conduzida segundo o método científico (veja Figura 6.5).




Figura 1: Pesquisa científica.

O **método científico** é o modo como nós devemos *entender logicamente* e como *devemos conduzir* todo o processo da pesquisa científica. Para entender por que precisamos de um método para guiar o pensamento e as práticas de pesquisa científica, vejamos como o conhecimento científico desenvolve-se.

Do ponto de vista dos artefatos redigidos, podemos dizer que a essência do método científico seria:

- i. Um problema verbalizado, que inicializa o processo da pesquisa.
- ii. A partir daí é feita uma revisão de literatura, definindo um referencial teórico para a pesquisa; este referencial é adicionado a todo o ser do cientista, que parte então para o processo da pesquisa em si, estudando o mundo e a vida, num movimento de mão-dupla. Neste momento o pesquisador estabelece uma estratégia, *um projeto, um delineamento* para o processo da pesquisa (de acordo com tipo).
- iii. Finalmente, o resultado da investigação é apresentado em uma obra científica (monografia, dissertação, tese, artigo, relatório, etc), que é escrita para mostrar a solução científica do problema.

OBSERVAÇÃO: Um profissional, com formação no Ensino Superior, mesmo que não vá realizar pesquisa científica, **com certeza**, ele utilizará conhecimentos advindos de pesquisas científicas. Então é muito importante que ele tenha conhecimentos básicos para compreender e criticar o resultado da investigação científica, de forma que possa utilizar ou aplicar aquele conhecimento ou tecnologia desenvolvida a partir dele.

Do ponto de vista das etapas de trabalho científico, apresenta esta essência como:

1. definição do problema (motivação);
2. delineamento ou projeto de pesquisa (revisão de literatura, ideias, possíveis soluções, elaboração das hipóteses);
3. obtenção dos dados (para certificação se as hipóteses são verdadeiras ou falsas);
4. análise dos dados (Descritiva, Inferencial, Modelagem);
5. conclusão e redação.

Define-se um **delineamento (ou projeto) de pesquisa** como a lógica que liga os dados, informações e fatos coletados (e as conclusões construídas) às questões iniciais, ao problema da pesquisa. Seria o método científico particularizado para uma pesquisa científica em especial. Todo estudo científico tem um projeto de pesquisa, explícito ou não.

1.2 Diferenças da atitude científica frente ao senso comum

Em uma formação para o "pensador em pesquisa" ou gestor, seja na graduação ou pós-graduação, é necessário que se diferencie o conhecimento científico do senso comum. Na filosofia, o *senso comum* (ou, conhecimento popular) é a primeira suposta compreensão do mundo resultante da herança fecunda de um grupo social e das experiências atuais que continuam sendo efetuadas. O senso comum descreve as crenças e proposições que aparecem como normal, sem depender de uma investigação detalhada para alcançar conhecimentos mais profundos como os científicos. São características do senso comum:

1. opiniões diferentes;
2. ausência de sistema e critérios para avaliação;
3. generalizam opiniões;
4. baseiam-se no que se acredita;
5. não questionam nem duvidam de forma organizada.

Por outro lado, a atitude científica pode ser retratada como a atitude daquele que busca o conhecimento de *forma metódica e sistemática*, ou seja, baseado em argumentos racionais que por meio de experiências empíricas atestam a provável "verdade" sobre algo no mundo. São características da atitude científica:

1. separam elementos objetivos dos subjetivos;
2. elaboram teorias racionais;
3. demonstram as teorias com experimentos práticos;
4. não consideram os conhecimentos definitivos, mas abertos a mudanças;
5. são metódicos e rigorosos.

1.3 Conceito de método

A preocupação em descobrir e, portanto, explicar a natureza vem desde os primórdios da humanidade, quando as duas principais questões referiam-se às forças da natureza, a cuja mercê viviam os homens.

No século XVI se iniciou uma linha de pensamento que propunha encontrar um conhecimento embasado em maiores garantias, na procura do real. Procura-se compreender as relações entre as causas na natureza, assim como a explicação dos acontecimentos, através da observação científica aliada ao raciocínio.

Com o passar do tempo, muitas modificações foram feitas nos métodos existentes, inclusive surgiram outros novos. No momento, o que nos interessa é o conceito moderno de método (independente do tipo). Para tal,

consideramos como Bunge, *que o método científico é a teoria da investigação. Esta alcança seus objetivos, de forma científica, quando cumpre ou se propõe a cumprir suas etapas.*

Todas as ciências caracterizam-se pela utilização de métodos científicos; em contrapartida, nem todos os ramos de estudo que empregam estes métodos são ciências. Dessas afirmações podemos concluir que a utilização de métodos científicos não é da alçada exclusiva da ciência, mas sem o emprego de métodos científicos, não há ciência. Assim, o método é o conjunto das atividades sistemáticas e racionais que, com maior segurança e economia, permite alcançar o objetivo - conhecimentos válidos e verdadeiros(provavelmente), traçando o caminho a ser seguido, detectando erros e auxiliando as decisões do cientista.

Mais detalhes sobre os métodos científicos podem ser encontrados no livro Fundamentos de metodologia científica, de autoria de Marina de A. Marconi e Eva M. Lakatos. - 5. ed. - São Paulo : Atlas 2003.

1.4 Reflexão

- Porque o método é utilizado?

Para fornecer um suporte metodológico e representacional (sistemático) ao pensamento, permitindo o uso de ferramentas objetivas que permitam a superação das limitações individuais do pesquisador em suas análises e sínteses.

- O que é pesquisa?

É o processo através do qual as pessoas adquirem um novo conhecimento sobre si mesmas ou sobre o mundo em que vivem, com a finalidade de: Responder a um questionamento, resolver um problema, realizar a gestão de processos (órgãos, ou produtos), satisfazer uma necessidade.

O planejamento de uma pesquisa depende do tema do problema a ser estudado, da sua natureza e situação em que se encontra, área de atuação e nível de conhecimento do pesquisador. Isso significa que pode haver vários tipos de pesquisa em função dos objetivos a serem alcançados. Objetivos teóricos e/ou práticos.

- Tipos de pesquisa quanto a natureza. A Ciência apresenta uma diferenciação em relação a forma investigativa.

Pesquisa básica: consiste na aquisição do conhecimento sobre a natureza sem finalidades práticas ou imediatas.

Pesquisa aplicada: Consiste na utilização do conhecimento da pesquisa básica e da tecnologia para se obter aplicações práticas como produtos ou processos.

A pesquisa aplicada (tecnológica) tem como objetivo alcançar a inovação em um produto ou processo, frente a uma demanda ou necessidade preestabelecida.

Classificação da pesquisa:

1. Quanto aos objetivos

- i. Pesquisa exploratória: é a coleta de dados e informações sobre um fenômeno (ou processo) de interesse sem grande teorização sobre o assunto, inspirando ou sugerindo uma hipótese explicativa;
- ii. Pesquisa Hipotético-Dedutiva de conhecimento: é a elaboração de uma ou mais hipóteses que relacione diversos fatos (variáveis), seguida da coleta de dados e da geração de informações que comprove ou não tal hipótese ou hipóteses.

2. Quanto a intervenção

- i. Estudo observacional: o pesquisador anota os dados e extrai informações, mas faz o possível para não influenciar na ocorrência do fenômeno;
- ii. Estudo experimental: o pesquisador interfere e influencia na pesquisa, objetivando verificar os efeitos da intervenção.

3. Classificação quanto ao tempo

- i. Estudo transversal: O pesquisador coleta os dados do experimento num único instante no tempo, obtendo um recorte momentâneo do fenômeno investigado;
- ii. Estudo longitudinal: o pesquisador coleta os dados do experimento em dois ou mais momentos, havendo um acompanhamento ao longo do tempo do fenômeno em estudo.

1.5 Estatística

Estatística é uma *Ciência* que fornece métodos para coleta, organização, descrição, análise e interpretação de dados (observacionais ou experimentais) e para a utilização dos mesmos na tomada de decisões.

Bioestatística: é a Estatística aplicada às ciências que estudam aspectos vitais (referentes à vida).

É importante destacar que a aplicação da Estatística não ocorre somente para a coleta e análise de dados na geração de conhecimento na Ciência, mas é largamente aplicada na Gestão (de empresas; órgãos; processos e produtos), como suporte na "tomada de Decisão".

A utilização de técnicas, destinadas à análise de situações complexas ou não, tem aumentado e faz parte do nosso cotidiano. O que tem levado a essa qualificação de nossas vidas no dia a dia?

Um fator importante é a popularização dos computadores. No passado, tratar uma grande massa de números era uma tarefa custosa e cansativa, que exigia horas de trabalho tedioso. Recentemente, no entanto, grandes quantidades de informações podem ser analisadas rapidamente com um computador pessoal e programas adequados.

Dessa forma o computador contribui, positivamente, na difusão e uso de métodos estatísticos. Por outro lado, o computador possibilita uma automação que pode levar um indivíduo sem preparo específico a utilizar técnicas inadequadas para resolver um dado problema.

Assim, é necessária a compreensão dos conceitos básicos da Estatística, bem como as suposições necessárias para o seu uso de forma criteriosa.

Podemos, de forma geral, dividir a Estatística em três áreas:

- Estatística Descritiva;
- Probabilidade;
- Inferência Estatística.

A **Estatística Descritiva** pode ser definida como um conjunto de técnicas destinadas a descrever e resumir dados, a fim de que possamos explorar as características de interesse. Em geral, utilizamos a Estatística Descritiva na etapa inicial da análise quando tomamos contato com os dados pela primeira vez.

Objetivando tirar conclusões de modo informal e direto, a maneira mais simples seria a observação dos valores colhidos. Entretanto ao depararmos com uma grande massa de dados percebemos, imediatamente, que

a tarefa pode *não ser simples*. Para tentar retirar dos dados informações a respeito do fenômeno sob estudo, é preciso **aplicar algumas técnicas** que nos permitam **simplificar** a informação daquele particular conjunto de valores. A finalidade da Estatística Descritiva é tornar as *coisas mais fáceis de entender, de relatar e discutir*.

A **Probabilidade** pode ser pensada como a teoria matemática utilizada para estudar a **incerteza** oriunda de fenômenos que *envolvem o acaso* (**fenômenos aleatórios, ou experimentos aleatórios**). A decisão de um fabricante de empreender uma grande campanha de propaganda visando a aumentar sua participação no mercado, a decisão de parar de imunizar pessoas contra determinada doença, a decisão de arriscar-se a atravessar uma rua no meio do quarteirão, todas utilizam a probabilidade consciente ou inconscientemente.

Inferência Estatística é o estudo de técnicas que possibilitam a **extrapolação** (inferir), a um grande conjunto de dados (população), das informações e conclusões obtidas a partir de *subconjuntos* de valores, usualmente de dimensões muito menores (Amostras).

Estudos complexos que envolvem o tratamento estatístico dos dados, usualmente incluem as três áreas citadas acima, principalmente em trabalhos científicos e na gestão para tomada de decisão. Esta é a parte na qual estão incluídos os chamados **testes estatísticos**.

A ciência, de uma forma geral, objetiva a coleta de informações (fatos) na natureza e a formulação de modelos (ou hipóteses) que expliquem parte dos fenômenos ou permitam a sua previsão. Esse processo é baseado em critérios bem definidos pelo método científico, pelo qual, hipóteses formuladas são verificadas posteriormente, com a coleta e interpretação de dados. Porém, esta metodologia é amplamente aplicada, além do Meio Científico.

As etapas da metodologia científica podem ser resumidas nos seguintes passos:

1. O problema a ser solucionado (Motivação);
2. Busca na teoria para fundamentar ideias, possíveis soluções;
3. Elaboração das hipóteses;
4. Verificação se as hipóteses são verdadeiras ou falsas;
Nesta etapa, faz-se necessário a utilização de dados, que podem ser observacionais ou experimentais.
5. Análise dos Resultados;
6. Comparação com as teorias existentes e Conclusões.

1.5.1 Fases do trabalho estatístico

Pela definição de Estatística apresentada anteriormente, podemos verificar a importância desta no método científico, chegando alguns pesquisadores a afirmarem que a Estatística é a "alma" do método científico.

Podemos descrever o trabalho estatístico em cinco etapas básicas:

1. Planejamento de como coletar os dados;
2. Coleta e crítica de dados;
3. Tratamento e apresentação dos dados;
4. Análise e interpretação dos resultados;
5. Conclusão.

O planejamento para a coleta dos dados está fortemente relacionado com os objetivos da pesquisa ou estudo, que, por sua vez, tem uma relação direta com o "Problema a ser solucionado". Portanto, qualquer "erro" em alguma das etapas do trabalho estatístico, levará a resultados equivocados e conseqüentemente a conclusões errôneas.

OBS: O Cientista de Dados é um profissional que não apenas coleta e relata dados, mas os analisa, sobre vários aspectos, determinando (relatando) as formas mais confiáveis (seguras) de aplicar as informações na tomada de decisões.

Para entendermos melhor as teorias envolvidas no trabalho estatístico, precisamos entender algumas definições e conceitos básicos.

1.6 Fluxo da Estatística Descritiva

A Estatística descritiva pode ser resumida de acordo com o diagrama apresentado na Figura 2:




Figura 2: Diagrama resumo da Estatística Descritiva.

1.6.1 Coleta dos dados

Com a definição do problema/objetivo a ser estudado e o estabelecimento do planejamento da pesquisa (maneira pela qual os dados serão coletados; cronograma das atividades; custos envolvidos, etc.), o próximo passo é a coleta dos dados. A coleta dos dados consiste na busca ou compilação dos dados, variáveis ou componentes do fenômeno a ser estudado.

A coleta desses dados, pode ser realizada de modo direto ou indireto. Em que, a coleta direta ocorre quando os dados são obtidos diretamente da fonte originária, como no caso da avaliação da pressão arterial de um indivíduo ou índice de glicemia. A coleta é indireta quando é inferida a partir dos elementos conseguidos pela coleta direta ou utiliza-se prontuários.

Após a coleta dos dados faz-se necessário uma avaliação dos mesmos, na qual pode-se observar a presença de informações que possam ter sido coletadas/digitadas/anotadas erroneamente e, com isso, distorcer as análises e conseqüentemente os resultados.

Os dados não devem ser coletados de um modo qualquer, são necessárias técnicas adequadas para a obtenção dos mesmos. Tais técnicas são denominadas por técnicas de amostragem e são apresentadas no Capítulo

2.

Posterior a coleta e a avaliação dos dados faz-se necessário a sua apresentação, a qual pode ser realizada por meio de tabelas, gráficos ou das medidas estatísticas, descritas no Capítulo 3.

1.7 Conceitos básicos

1. Estatística: é uma Ciência que estuda e desenvolve métodos para planejar experimentos, coleta de dados, organizá-los, resumi-lo, analisá-los, interpretá-los e deles extrair conclusões. Podendo ser dividida em:

$$\text{Estatística} \Rightarrow \begin{cases} \text{Dedutiva (descritiva)} \\ \text{Indutiva (inferencial)} \end{cases}$$

(a) A estatística dedutiva (descritiva): utilizada para descrever o conjunto de dados desde a elaboração da pesquisa até o cálculo de determinada medida.

(b) A estatística Indutiva (inferencial): relaciona-se com a incerteza, iniciando-se com o cálculo das Probabilidades e se desenvolve por todo a área da inferência.

2. **População:** conjunto de elementos (indivíduos ou objetos) que apresentam pelo menos uma característica em comum (pode ser finita ou infinita).

3. **Amostra:** subconjunto finito e representativo da população.

4. **Censo:** coleção de dados relativos a todos os elementos da população.

5. **Variável aleatória:** pode ser definida como uma característica qualquer de interesse que associamos a uma população ou amostra a ser estudada. Estas podem ser classificadas como:

$$6. \text{ Variáveis} \Rightarrow \begin{cases} \text{Qualitativa} \Rightarrow \begin{cases} \text{Ordinal} \\ \text{Nomial} \end{cases} \\ \text{Quantitativas} \Rightarrow \begin{cases} \text{Discreta} \\ \text{Contínua} \end{cases} \end{cases}$$

7. **Tipos de variáveis:** as variáveis podem ser:

a) Variável qualitativa: são aquelas variáveis que correspondem a atributos ou categorias, podem ser:

a.1) Variável qualitativa nominal: quando os atributos (ou categorias) **não são** possíveis de ordenação.

Exemplo: Cor dos olhos dos alunos de uma turma.

a.2) Variável qualitativa ordinal: quando os atributos (ou categorias) **são** possíveis de ordenação.

Exemplo: nível de conhecimento de inglês dos alunos de uma turma (baixo, médio, alto).

b) Variável quantitativa: são aquelas variáveis que correspondem a números resultantes de contagem ou medidas, podem ser:

b.1) Variável quantitativa discreta: são próprias de dados de contagem, isto é, estão definidas em um conjunto enumerável.

Exemplo: número de pessoas de um determinado grupo que já sofreram algum tipo de fratura.

b.2) Variável quantitativa contínua: são aquelas em que as realizações resultam de uma medida (uma mensuração) que podem assumir qualquer valor real entre dois extremos. (em um intervalo real).

Exemplo: peso e altura dos alunos de uma turma.

8. **Dado ou observação:** é o valor (ou atributo) que descreve uma característica da amostra.

9. **Parâmetro:** é a medida numérica que descreve uma característica da população.

1.8 Uso do *Software R*

Nesse curso de Estatística Básica será utilizado o *Software R*



O R é uma linguagem orientada a objetos criada em 1996 por **Ross Ihaka** e **Robert Gentleman**, do Departamento de Estatística da Universidade de Auckland na Nova Zelândia, como uma alternativa ao software S-Plus, o qual exigia o pagamento de uma licença para seu uso.

O programa R é de livre distribuição, foi inspirado no mesmo ambiente do S e permite a manipulação de dados, realização de cálculos e geração de gráficos. Seu uso tem aumentado nos últimos anos e usuários de todo o mundo têm contribuído com o desenvolvimento de novos recursos para o R.

Para instalar o programa R, siga os passos:

- (1) Entrar no site <https://www.r-project.org/>
- (2) Clicar no menu CRAN e escolher o espelho (mirror) Brasil;
- (3) Você verá que existem vários *mirrors* no Brasil. Escolha um, por exemplo o da Universidade Federal do Paraná, no link <http://cran-r.c3sl.ufpr.br/>;
- (4) Se o seu sistema operacional for Windows, clicar em *Download R for Windows*, subdiretório **base** e baixar o programa em *Download R 4.3.1 for Windows*.

OBS.: A versão do programa pode ser diferente, mas isso não representa problema algum. A versão correspondente aos passos acima é da data de 23/06/2023.

2 AMOSTRAGEM

Como comentamos anteriormente, em uma pesquisa qualquer, deve-se pensar antes de tudo em elaborar um projeto que possa garantir sua viabilidade. O projeto faz a previsão e a provisão dos recursos necessários para atingir o objetivo proposto de solucionar um problema e estabelece a ordem e a natureza das diversas tarefas a serem executadas dentro de um cronograma a ser observado.

Dentro dessas tarefas a delimitação da pesquisa, e posteriormente, a definição (identificação) da população e amostragem, com sua descrição e indicação dos critérios para sua constituição, são muito importantes para a uma conclusão (generalização) confiável dos resultados da pesquisa.

2.1 Delimitar a pesquisa

Delimitar a pesquisa é estabelecer limites para a investigação. Ela pode ser limitada em relação:

- a) ao assunto: selecionando um tópico, a fim de impedir que se torne muito extenso ou muito complexo;
- b) à extensão: porque nem sempre se pode abranger todo o âmbito onde o fato se desenrola;
- c) a uma série de fatores - meios humanos, econômicos e de exiguidade de prazo - que restringe a ação.

Nem sempre há necessidade de delimitação, pois o próprio assunto e seus objetivos podem estabelecer limites. Marconi e Lakatos (2003) apresentam três níveis de limites, quanto:

i) ao objeto - que consiste na escolha de maior ou menor número de variáveis que intervêm no fenômeno a ser estudado. Selecionado o objeto e seus objetivos, estes podem condicionar o grau de precisão e especialização do objeto;

ii) ao campo de investigação - que abrange dois aspectos: limite no tempo, quando o fato deve ser estudado em determinado momento, e limite no espaço, quando deve ser analisado em certo lugar. Trata-se, do quadro histórico e geográfico em cujo âmbito se localiza o assunto;

iii) ao nível de investigação - que engloba três estágios: exploratórios, de investigação, e de comprovação de hipóteses, já referidos anteriormente. Cada um deles exige rigor e refinamento metodológico.

Após a escolha do assunto, o pesquisador pode decidir ou pelo estudo de todo o universo da pesquisa (população) ou apenas sobre uma amostra. Neste caso, será aquele conjunto de informações que lhe possibilitará a escolha da amostra, que deve ser representativa ou significativa da população.

2.2 População

Antes de abordarmos população, é importante estar bem definido quais são as unidades elementares e unidades amostrais na população.

2.2.1 Unidades elementares e unidades amostrais

De acordo com Bolfarine e Bussab (2005)ⁱⁱ, **unidade elementar**, ou simplesmente elemento de uma população, é o objeto ou entidade portadora das informações que se pretende coletar. Pode ser uma pessoa, família, domicílio, animal, loja, empresa, estabelecimento, classe de alunos, Escola, produto, etc. É importante que a unidade elementar seja claramente definida para que o processo de coleta e análise tenha sempre um significado preciso e uniforme.

ⁱⁱBolfarine, H. Bussab, W. O. (2005), *Elementos de amostragem*, Edgard Blücher, São Paulo

Todo plano amostral fará recomendações para selecionar elementos da população por meio das **unidades amostrais**, as quais podem ser formadas por uma única unidade elementar ou por várias. Esta será a unidade que pode ser selecionada para compor a amostra.

A definição da unidade depende do objetivo da pesquisa. Ela deve ser estabelecida na fase inicial da pesquisa, ou seja, na **formulação do problema a pesquisar**. Algumas vezes, a definição da unidade parece óbvia, entretanto, muito frequentemente, a definição ou escolha da unidade não é tão óbvia.

A dificuldade da definição da unidade para uma pesquisa decorre do fato de existir na natureza uma hierarquia de sistemas, ou seja, sistemas dentro de sistemas, numa ordem decrescente de amplitude, tal que um determinado sistema é um subsistema em relação a nível hierárquico mais elevado e, por sua vez, contém subsistemas em nível mais baixo.

2.2.2 População objetivo

Em uma pesquisa científica, a população objetivo ou, mais simplesmente, população, é a coleção bem definida das unidades (elementos) de interesse para a qual é desejado estabelecer relações ou realizar inferência. O *número de unidades* é denominado **tamanho da população (N)**.

Uma população objetivo é definida pela especificação de suas unidades ou da caracterização das condições para que estas lhe integrem. A especificação da população, assim como de suas unidades, é determinada pelos objetivos da pesquisa e deve ser estabelecida na formulação do problema. Populações existentes na natureza são populações finitas, ou seja, de tamanho expresso por um número natural N , muito frequentemente elevado e desconhecido. Ademais, tais populações têm constituição dinâmica, em decorrência da mutabilidade dos sistemas que lhe integram ao longo do tempo.

Em algumas pesquisas, a população objetivo é constituída por unidades existentes no momento da execução da pesquisa. Uma população nessas circunstâncias, cujas unidades podem ser identificadas, é uma *população real*. Muito frequentemente, entretanto, a população objetivo compreende unidades que não existem no momento da execução da pesquisa, mas que, supostamente, poderão existir no futuro. Nessas circunstâncias, cujas unidades não são identificáveis, mas apenas definidas pela caracterização das condições para que lhe integrem, é uma *população conceitual* (ou, população infinita). Em uma pesquisa de melhoramento da eficiência de um remédio, por exemplo, as unidades da população objetivo não são, somente, as pessoas doentes existentes na região de interesse no momento da execução da pesquisa, mas as pessoas doentes que existirão nessa região no futuro.

2.3 Métodos de pesquisa descritiva (observacional)

Métodos de pesquisa descritiva ou observacional, também denominados levantamentos, são próprios para pesquisa descritiva, ou seja, pesquisa com propósito de prover a descrição do comportamento das unidades de uma população objetivo, através da identificação e descrição das características relevantes dessas unidades e das relações entre essas características. Podem ocorrer em dois níveis:

1. Nível elementar: a pesquisa descritiva detém-se apenas na mensuração de características e determinação de suas propriedades importantes, como médias e variâncias, ou distribuições de frequências.
2. Nível mais avançado: visa não apenas a descrição de características, mas, também, a identificação e descrição de relações de associação ou correlação de características (variáveis), ou seja, relações de características que variam conjuntamente.

Por envolver, muito frequentemente, a avaliação de relações de associação de características, métodos de pesquisa descritiva são algumas vezes denominados "métodos correlacionais". Entretanto, a pesquisa descritiva não tem propósito de derivar inferências sobre relações causais, ou seja, relações de causa e efeito entre variáveis. Em contraste com a flexibilidade da pesquisa exploratória, a pesquisa descritiva requer:

- as definições claras dos objetivos da pesquisa e da população objetivo,
- a especificação das questões que visa responder,
- o planejamento cuidadoso com respeito às unidades que serão as fontes de informação e,
- aos procedimentos para a coleta de informação.

Em uma pesquisa descritiva as características das unidades (variáveis) se manifestam sem interferência do pesquisador. O pesquisador limita-se à mensuração e registro das informações segundo o plano pré-estabelecido, muito frequentemente por meio de um questionário ou instrumento de registro.

2.4 Amostragem

Uma pesquisa pode ser conduzida sobre todas as unidades da população objetivo ou sobre uma fração dessa população, ou seja, sobre uma amostra da população objetivo.

Se a pesquisa envolve a observação de todas as unidades da população objetivo, o método de pesquisa é denominado **censo**. Se é conduzida sobre uma amostra da população objetivo, o método de pesquisa é denominado **levantamento por amostragem**.

Como nem sempre há possibilidade de pesquisar todos os indivíduos população que se deseja estudar, devido à escassez de recursos ou à premência do tempo. Nesse caso, utiliza-se o método da amostragem, que consiste em obter um juízo sobre o total (universo), mediante a compilação e exame de apenas uma parte, a amostra, selecionada por procedimentos científicos. O valor desse sistema vai depender da amostra:

- a) se ela for suficientemente representativa ou significativa;
- b) se contiver todos os traços característicos numa proporção relativa à população.

O censo somente é aplicável em situações em que a população objetivo é finita e suas unidades são identificáveis e disponíveis para coleta de informação. Mesmo nessas circunstâncias, por razões econômicas, éticas ou de outra origem, o levantamento por amostragem pode ser mais conveniente e apropriado. Por essa razão, o levantamento por amostragem é muito mais frequentemente utilizado.

A amostragem é preferível ao censo quando:

- **A população for infinita:** obviamente não seria possível examinar todos os itens da população o que tornaria então o censo impossível.
- **Aplicação de testes caráter destrutivo:** os itens examinados são destruídos no próprio ato do ensaio ou teste durante a pesquisa. Então o censo nos daria o panorama preciso de uma população que não existe mais.
- **O custo:** um censo pode apresentar um custo proibitivo.
- **O tempo:** uma amostra pode ser mais atualizada do que o censo. A necessidade de uma informação ser obtida mais rapidamente, um estudo de toda a população pode consumir demasiado tempo e perder

utilidade. Além disso, se a população tende a modificar-se com o tempo, um censo poderá, na realidade, combinar várias populações.

- **A precisão:** em alguns casos, nos quais há situações mais complexas para a coleta de dados, a amostragem envolve menor número de elementos e, conseqüentemente, menor número de coletores de dados. Com grande número de agentes, há menor coordenação e controle, aumentando a chance de erros. A amostragem pode revelar maior uniformidade nos métodos de coleta de dados, e *maior comparabilidade*, (*menor variabilidade*) entre os dados, do que um censo.
- O tipo de informação pode depender da utilização de uma amostra ou de um censo.

Entretanto, há certas situações em que é mais vantajoso fazer um censo. Entre essas situações destacamos:

a) A população pode ser tão pequena que o custo e o tempo de um censo sejam pouco maiores que para uma amostra.

b) Se o tamanho da amostra é grande em relação ao da população, o esforço adicional requerido por um censo pode ser pequeno, além disso, o censo eliminará a variabilidade amostral.

c) Se for exigida precisão completa, então o censo é o único método aceitável. Em face da variabilidade amostral, nunca podemos ter certeza de quais são os parâmetros verdadeiros da população. Um censo nos dará essa informação, embora erros na coleta dos dados e outros tipos de tendenciosidade possam afetar a precisão dos resultados.

O processo de amostragem determina o delineamento de amostragem, ou seja, a relação estrutural entre a amostra e a população objetivo e as chances de seleção das unidades da população objetivo. Há uma grande variedade de delineamentos de amostragem. A distinção mais importante entre esses delineamentos refere-se ao modo de seleção da amostra que pode ser objetivo e ter *base probabilista*, ou *subjetiva e não probabilista*.

2.5 Amostragem probabilística

Uma amostragem será probabilística se todos os elementos da população tiverem probabilidade conhecida, e diferente de zero, de pertencer à amostra. Desta forma, a amostragem probabilística implica um sorteio com regras bem determinadas, cuja realização só será possível se a população for finita e totalmente acessível.

Consideraremos aqui os seguintes planos de amostragem probabilística:

1. Amostragem Aleatória Simples.
2. Amostragem Proporcional Estratificada.
3. Amostragem Sistemática.

2.5.1 Amostragem simples ao acaso (ASA) ou aleatória simples

Objetivo: obter uma amostra representativa quando os elementos da população são *todos homogêneos* em relação às características que podem influenciar as variáveis que serão medidas ou identificadas.

Procedimento: enumeram-se todos os elementos da população $(1, 2, \dots, N)$ e sorteiam-se " n " elementos mediante um dispositivo aleatório (computador, calculadora, tabela de números aleatórios, entre outros).

Exemplo:

População: Lote K-2020 dos processadores Pentium III

Variável em estudo: o nível de desempenho do sistema de memória necessário para sustentar a velocidade com que o processador é capaz de executar as operações

Amostra: 10 processadores selecionados mediante um processo de Amostragem Simples ao Acaso.

Podemos avaliar esse parâmetro por meio de uma amostra simples ao acaso, devido a que todos os elementos da população são homogêneos.

2.5.2 Amostragem estratificada

Objetivo: melhorar a representatividade da amostra quando os elementos da população são heterogêneos, porém, podem ser agrupados em subpopulações (estratos) contendo elementos homogêneos.

Procedimento: a população é dividida em grupos ou estratos contendo elementos homogêneos e as amostras são retiradas separadamente de cada um desses grupos através de uma Amostragem Simples ao Acaso.

Exemplo: A diretora de uma determinada escola precisa de informação atualizada sobre determinadas variáveis dos seus 1803 alunos, sendo que por problemas de tempo e custo apenas é possível entrevistar 100 delas. As variáveis são: o interesse por tecnologias, relação peso-altura, número de irmãos, entre outras. A população foi dividida em 5 estratos, segundo o período e a série.

Estrato	Período (série)	Número de propriedades (N_i)	n_i
1	Ensino básico (1,2)	873	
2	Ensino básico (3,4)	386	
3	Ensino fundamental (1,2)	246	
4	Ensino fundamental (3,4)	186	
5	Ensino médio (1,2,3)	112	
		$N=1803$	$n=100$

Pergunta: qual deverá ser o tamanho da amostra retirado de cada estrato?

Resposta: a amostra de 100 alunos deverá ser retirada de maneira tal que os 5 estratos sejam considerados.

Existem 2 critérios para determinar o tamanho da amostra em cada estrato: Proporcional e Ótimo. **Critério**

Proporcional: o estrato " i " fornece uma quantidade n_i de elementos proporcional ao tamanho N_i do estrato. Isto é: $n_i = \frac{N_i}{N}n$, em que N tamanho da população e n o tamanho da amostra. Este critério é adequado quando existe a mesma variabilidade dentro de estratos: $\sigma_1 = \sigma_2 = \dots = \sigma_k$

Critério Ótimo: $n_i = \frac{N_i S_i}{\sum_{i=1}^k N_i S_i} n$ quando se conhece a variabilidade (S_i desvio padrão) dentro dos " k " estratos.

2.5.3 Amostragem Sistemática

Objetivo: aumentar a representatividade da amostra dando maior cobertura à população. É usada quando os elementos da população são heterogêneos e não podem ser agrupados em sub-populações homogêneas.

Procedimento: enumeram-se todos os elementos da população $(1, 2, \dots, N)$, calcula-se " r " e sorteia-se um primeiro elemento para formar parte da amostra, este entre 1 e o " r -ésimo" elemento. Os demais são retirados em uma progressão aritmética, saltando " r " elementos, até completar o total da amostra (n). O valor " r " é chamado passos de amostragem e é determinado por:

$$r = \frac{N}{n}$$

em que " r " deve ser inteiro.

Esquema: população enumerada: $1, 2, 3, \dots, i, \dots, N$.

Esquema da Amostra Sistemática:

Primeiro elemento:	i
Segundo elemento:	$i + r$
Terceiro elemento:	$i + 2r$
Quarto elemento:	$i + 3r$
$\vdots$	$\vdots$
n -ésimo elemento:	$i + (n-1)r$

Exemplo: Em uma linha de produção de fusíveis para computadores, produz-se 6000 fusíveis por turno, sendo necessário para garantir a qualidade analisar 30

$$r = \frac{N}{n} = \frac{6000}{30} = 200$$

- Enumeram-se todos : $1, 2, \dots, 60000$. (a ordem de produção já garante isso)
- Sorteia-se o primeiro fusível, ou seja, um valor entre 1 e 200. Digamos que o primeiro sorteado seja o número 10.
- Os fusíveis selecionadas serão:

Primeiro elemento:	10.
Segundo elemento:	210.
Terceiro elemento:	410.
Quarto elemento:	610.
$\vdots$	$\vdots$
Trigésimo elemento:	6810.

2.6 Amostragem não probabilística

Quando nem todos os elementos da população tiverem uma probabilidade diferente de zero de pertencerem à amostra, dizemos que a amostragem é não-probabilística. (ou seja, alguns elementos não terão chance fazer parte (compôr) da amostra, pois não é possível obter uma lista de todos os elementos da população a ser pesquisada).

Este processo de amostragem é *subjetivo* e seu regimento depende do *conhecimento que possui o pesquisador* a respeito da estrutura da população. É empregada, muitas vezes, por simplicidade ou pela impossibilidade de se obter amostragem probabilística.

Consideraremos aqui os seguintes planos de amostragem não probabilística:

1. Amostragem a esmo

2. Amostragem por julgamento
3. Amostragem por cotas
4. Amostragem por conveniência

2.6.1 Amostragem a esmo

É o caso em que o pesquisador procura ser "aleatório", sem, no entanto, utilizar um sorteio aleatório rigoroso.

Exemplo: Se tirarmos 100 comprimidos (analgésico) de uma caixa que contém 10000 comprimidos da mesma marca, de certo não faríamos uma amostragem aleatória simples, pois seria extremamente trabalhosa, mas faríamos retiradas a esmo.

Os resultados de uma amostragem a esmo são os mesmos de uma amostragem probabilística se a população é homogênea (elementos da população são *todos homogêneos* em relação à características que podem influenciar as variáveis) e se não existe a possibilidade do amostrador ser influenciado (mesmo que inconscientemente) por alguma característica dos elementos da população. Não seria o caso da amostra dos comprimidos, acima, se estes tivessem modelos e tamanhos diferentes, e isto afetasse a característica observada nos mesmos.

2.6.2 Amostragem por julgamento

Neste tipo de amostragem, a amostra é colhida na parte da população que é acessível. Então se faz uma distinção entre população-objetivo (aquela que se tem em mente ao realizar o estudo) e a população-amostrada (a parte da população que é acessível). Se essas duas populações tiverem as mesmas características, este tipo de amostragem vai ser equivalente a uma amostragem probabilística.

Ocasionalmente, os itens amostrais, se apresentam agrupados. Uma pesquisa médica deve trabalhar com os pacientes disponíveis. Este grupo não pode ser considerado como uma amostra aleatória do público em geral e seria perigoso tentar tirar conclusões gerais com base em tal estudo. Entretanto, os resultados poderiam proporcionar uma base para a elaboração de um plano de amostragem aleatória para validar os resultados básicos. Os perigos inerentes à pesquisa médica, bem como a outros tipos de pesquisa, frequentemente obrigam a limitar a pesquisa inicial a um pequeno grupo de voluntários. Outros exemplos similares seriam portadores de doenças fatais, cadáveres, animais, entre outros.

2.6.3 Amostragem por cotas

A amostra por cotas, é uma forma de amostragem muito utilizada em pesquisas de mercado, eleitorais e de opinião pública. Ela é uma amostra que, por meio de cotas, seleciona proporcionalmente pessoas com semelhantes características de uma população.

Para efetuar esse tipo de amostragem, deve-se primeiramente segmentar o universo estudado em características. Em pesquisas de mercado, as variáveis mais utilizadas são relacionadas a renda e ao consumo dos entrevistados, como renda familiar mensal, posse de bens, classe socioeconômica e estado civil. Já em pesquisas de eleitorais e de opinião pública, são utilizadas variáveis como gênero, faixa etária, local de domicílio e escolaridade.

2.6.4 Amostragem por conveniência

Amostras por conveniência, são um tipo de amostra que não exige um critério rigoroso na pré-seleção do público a ser pesquisado, ou seja, o universo da pesquisa não precisa estar totalmente definido para que essa seja efetuada.

Como exemplo pode-se imaginar um pesquisador que vá em um lugar público, como a portaria de uma Universidade ou a entrada de um estabelecimento (Shopping, Hospital, etc), e lá mesmo faz a sua pesquisa, sem muito critério de controle com o perfil da amostra. Assim, a seleção passa a ser apenas com pessoas que passaram por lá, foram abordadas e concordaram em responder a pesquisa.

Existem outros tipos de amostragem não probabilística que não serão abordadas aqui neste curso como: Amostra bola de neve e Amostra desproporcional.

Finalmente, a amostragem não probabilística pode ser mais rápida e menos custosa porque não é preciso construir uma listagem dos itens da população. Tenha-se em mente que este tipo de amostragem não permite a avaliação objetiva do erro amostral, de modo que é mais preciso (seguro) usar a amostragem probabilística sempre que possível.

2.7 Problemas de amostragem

2.7.1 Amostras tendenciosas

Talvez você nunca faça um trabalho que exija amostragem. Mas muito provavelmente você lerá ou usará resultados de trabalhos cujos dados foram obtidos por amostragem. Então saiba que é importante entender o que é uma *amostra tendenciosa*.

Primeiro, as inferências devem ser feitas apenas para a população de onde a amostra foi retirada.

Não tem sentido, por exemplo, estudar os hábitos de higiene dos índios bolivianos e fazer inferência para a população da periferia da cidade de São Paulo. Também é preciso verificar se a amostra foi retirada da população usando um processo delineado segundo *critérios estatísticos*. A amostra deve ter o tamanho usual da área em que a pesquisa se enquadra.

As amostras *muito pequenas* podem ser excelentes estudos de casos, mas não permitem fazer inferência estatística.

Pode ter surgido uma dúvida: Como definir o tamanho da amostra?

Quando se trabalha amostragem probabilística, existem diversas fórmulas estatísticas para definir o tamanho da amostra da pesquisa. Mas, como veremos em capítulos mais à frente, em todas, faz-se necessário o **conhecimento sobre probabilidade, a margem de erro e o nível de confiança**.

Por outro lado, desconfie de amostras muito grandes. Será que o pesquisador tinha tempo e dinheiro para fazer um bom levantamento de tantos dados? E veja como foi feita a coleta de dados (questionário, registros etc). São mais confiáveis as respostas obtidas através de entrevistas, desde que o entrevistador tenha sido treinado. Estude as perguntas. Elas eram claras? As respostas podem ser, por alguma razão, mentirosas? Leia o artigo e se pergunte:

1. Qual é a população?
2. Como a amostra foi selecionada?
3. Qual é o tamanho da amostra?

4. Como o questionário foi feito?
5. As perguntas eram claras?

Se estas perguntas não tiverem respostas satisfatórias, a amostra pode ser tendenciosa.

Exemplo: Para estimar o tamanho dos morangos de uma caixa, não seria correto examinar o tamanho dos 10 morangos que estão na parte de cima, pois provavelmente, a amostra seria tendenciosa uma vez que os vendedores de morango arrumam as caixas de maneira a colocar as frutas maiores nas camadas mais superficiais.

- É preciso cuidado na forma de tomar a amostra porque os erros de amostragem fazem com que os resultados da amostragem sejam diferentes dos resultados do censo.
- Quando a pesquisa exige que os participantes respondam a um questionário, é preciso especial atenção à forma de obter as respostas.

Ética é extremamente importante.

- Um estatístico conhecido disse, certa vez, que é possível mentir usando estatística, mas que se mente mais, e melhor, sem estatísticas. É preciso entender que as amostras podem levar a conclusões erradas. Contudo, as opiniões pessoais, sem base em dados, levam em geral, a conclusões *mais danosas*.

2.8 Exercícios

Lista: Exercícios de Amostragem

1. Para as situações descritas a seguir, indique a população e a amostra correspondente. Discuta a validade do processo de inferência estatística (generalização) para cada um dos casos, ou discuta sobre a representatividade da amostra em cada caso.^[1]
 - (a) Para avaliar a eficácia de uma campanha de vacinação no Estado de Minas Gerais, 200 mães de recém-nascidos, durante o primeiro semestre de um dado ano e em uma maternidade em Belo Horizonte, foram entrevistadas a respeito da última vez em que vacinaram seus filhos.
 - (b) Para verificar se um paciente com suspeita de anemia, uma amostra de sangue foi retirada para medir a taxa de ferro no sangue.
 - (c) Para analisar os hábitos de prática de atividade física dos estudantes de Alfenas, 163 discentes da UNIFAL-MG foram entrevistados na portaria da Universidade.
 - (d) A fim de avaliar a intenção de voto para presidente dos brasileiros, 122 pessoas foram entrevistadas em Alfenas.
2. Para cada uma das pesquisas consideradas a seguir caracterize a unidade, a população e a amostra^[2] :
 - (a) Levantamento da opinião dos produtores de café no Sul de Minas sobre as tecnologias geradas pela pesquisa nos últimos dez anos, através de questionário enviado a 100 produtores selecionados da lista de 500 produtores associados a uma cooperativa de produtores deste Estado.
 - (b) Levantamento da opinião sobre a qualidade do transporte urbano de uma cidade, através de consulta no terminal de ônibus dessa cidade.

(c) Estudo da relação entre saúde da criança aos cinco anos e amplitude do tempo de aleitamento materno, que foi conduzida nos hospitais e postos de saúde do Município de Varginha.

3. Num hospital com 1650 pacientes hipertensos, deseja-se calcular o percentual médio de gordura desses pacientes, porém, sabe-se que o peso do paciente pode interferir na resposta desta variável, criando-se então estratos por peso.

Estrato	Classes de peso (kg)	Número de Pacientes	Tamanho da amostra por estrato
1	Até 50	30	
2	51 a 65	120	
3	66 a 80	230	
4	81 a 95	380	
5	Mais de 95	890	
Total		1650	

Escreva os passos para selecionar uma amostra de tamanho 50, aplicando o processo de amostragem que melhor se adapte à informação que você possui.

4. O laboratório de Análises Clínicas da UNIFAL-MG deseja realizar uma pesquisa com o objetivo de caracterizar seus pacientes atendidos. Como forma de obter estas informações, foram distribuídos questionários para 80 pacientes do cadastro geral, por meio do qual procurou-se avaliar o nível de escolaridade (alto, médio, baixo), altura (em cm), idade, religião e número de filhos.

- (a) Qual é a população em estudo?
- (b) Qual é a amostra?
- (c) Quais foram as variáveis estudadas?
- (d) Classifique as variáveis quanto à sua natureza.

Referências

- [1] MAGALHÃES, M. N., LIMA, A. C. P. **Noções de Probabilidade e Estatística**. São Paulo: Edusp, 2010. 25
- [2] SILVA, J. G. C. da. **Estatística Experimental: Planejamento de Experimentos**. UFP, 2007. 25

3 ESTATÍSTICA DESCRITIVA

Para entendermos melhor a finalidade da Estatística Descritiva (Exploratória), vamos relembrar alguns conceitos e definições.

3.1 Conceitos e definições importantes

1. **População:** é um conjunto de elementos com pelo menos uma característica comum. Essa(s) característica(s) comum(s) deve(m) delimitar inequivocamente quais elementos que pertencem ou não à população.

"A população pode ser: finita (quando pode ser enumerada) ou infinita (quando não pode ser enumerada)."

2. **Amostra:** é um subconjunto de uma população. É necessariamente finita, pois todos seus elementos serão examinados para efeito da realização do estudo estatístico desejado.

Observação: os elementos de uma *pesquisa experimental* são considerados como sendo uma amostra.

3. **Variável:** é a característica pela qual se deseja que a *população* seja descrita. Essa característica pode assumir diferentes valores de elemento para elemento.

4. **Dados ou observação:** é o valor que assume a variável para um elemento em particular.

Notação:

Tamanho da população: número de elementos da população $\rightarrow "N"$.

Tamanho da amostra: número de elementos da amostra $\rightarrow "n"$.

Variável: X, Y, Z , ou X_i, Y_i, Z_i , etc. (serão letras maiúsculas, geralmente as últimas do alfabeto).

5. **Tipos de variáveis:** as variáveis podem ser:

a) Variável qualitativa: são aquelas variáveis que correspondem a atributos ou categorias, podem ser:

a.1) Variável qualitativa nominal: quando os atributos (ou categorias) não são possíveis de ordenação.

Exemplo: sexo dos alunos de uma turma.

a.2) Variável qualitativa ordinal: quando os atributos (ou categorias) são possíveis de ordenação.

Exemplo: nível de conhecimento de inglês dos alunos de uma turma (baixo, médio, alto).

b) Variável quantitativa: são aquelas variáveis que correspondem a números resultantes de contagem ou medidas, podem ser:

b.1) Variável quantitativa discreta: são próprias de dados de contagem, isto é, estão definidas em um conjunto enumerável.

Exemplo: número de pessoas de um determinado grupo que já sofreram algum tipo de fratura.

b.2) Variável quantitativa contínua: são aquelas em que as realizações resultam de uma medida (uma mensuração) que podem assumir qualquer valor real entre dois extremos. (em um intervalo real).

Exemplo: peso e altura dos alunos de uma turma.

6. De onde vem os dados?

- **Fonte de dados primárias:**

Estudo de caso.

Experimentos.

Pesquisas.

- **Fonte de dados secundários (já coletados).**

Registros administrativos.

Pesquisa bibliográfica.

Big Data (banco de dados corporativos, etc)

3.2 Introdução

Definição: Estatística descritiva é a parte da Estatística que preocupa-se com a organização, apresentação, e análise dos dados qualitativos, ou quantitativos, sejam eles amostrais ou experimentais.

A **apresentação de dados** é feita mediante alguma representação que pode por meio de tabelas ou gráficos.

A **análise dos dados** é realizada com o cálculo de algumas medidas de interesse, por exemplo: média e desvio padrão.

A **tabela** é uma ferramenta que possibilita uma inspeção rigorosa dos dados, sendo bastante eficiente para mostrar o comportamento dos dados, facilitar a compreensão das informações bem como a interpretação do fenômeno ou processo estudado.

Uma tabela deve ser autoexplicativa, isto é, as informações nela apresentadas devem ser compreendidas pelo leitor sem que o mesmo tenha que ler ou consultar o texto que a antecede ou precede. Assim, uma tabela deve ser composta pelos seguintes itens, (Figura 3):

1. Título: parte que aparece sempre na parte superior da tabela e contem as informações que respondam às perguntas do fenômeno estudado, tais como: O que? Onde? Quando? (deve ser explicativo, com a identificação da população, da variável).

2. Cabeçalho: indica a natureza do conteúdo de cada coluna: o que está sendo representado em cada coluna da tabela.

3. Corpo: representado por colunas nas quais são registradas as informações. Nessas colunas são apresentadas as frequências absolutas (F_i), frequências relativas (Fr) e frequências relativas em porcentagens (Fp). Sendo: F_i : indica quantas vezes (frequência) se repete uma categoria ou valor em um conjunto de dados.

$$Fr = \frac{F_i}{n}$$

$$Fp = Fr * 100\%$$

n : tamanho da amostra ou a soma de todas as frequências absolutas.

4. Caselas: espaço destinado a um só número.

5. Total: deve ser destacado de algum modo.

6. Fonte/Rodapé: espaço na parte inferior da tabela onde pode-se inserir notas ou fonte dos dados.

Tabela nº: Título				}	Cabeçalho
Variável	F_i	F_r	F_p		
				}	Corpo
Total	n	1	100		
Fonte:					

Figura 3: Representação de uma tabela de distribuição de frequências.

Note que toda tabela deve ser delimitada por traços horizontais, não devem ser feitos traços verticais para delimitar a tabela e o cabeçalho é separado do corpo por um traço horizontal.

Quando a variável é **qualitativa** ou **quantitativa discreta**, a distribuição de frequências consiste em atributos ou categorias com as contagens numéricas referentes a cada conjunto, como pode ser observado no exemplo a seguir:

Exemplo: Considere uma amostra de 2560 servidores municipais da cidade de Campinas e com suas respectivas classificações segundo a renda mensal.

Tabela 1: Classificação servidores municipais da cidade de Campinas, segundo a renda mensal, em 2020

Renda mensal	F_i
Baixa	1613
Média	701
Alta	246
Total	2560

Fonte:

3.3 Exemplo: Projeto de criação de uma empresa de TI no Sul de Minas

Para exemplificar a aplicação da estatística descritiva, iremos utilizar dados relacionados à situação problema sobre o Projeto de planejamento para a criação de uma empresa de TI no Sul de Minas, sendo que foram selecionadas, de forma aleatória, 50 empresas de cada setor (Comércio Agrícola (ComAgri), Logística/Transporte) e observadas diversas variáveis.

Como já comentado, para ter o perfil do "possível cliente" e prever os recursos humanos e os equipamentos necessários para atendê-los, faz-se necessário a obtenção de dados, para então, elaborar o projeto de implantação.

- i Setor da empresa ((ComAgri) e Log);
- ii Sexo do responsável (M, F);
- iii A empresa possui interesse em um software de gestão (S, N);
- iv A empresa possui dívida (S ou N);
- v Possui, na empresa, políticas de sustentabilidade (S, N);
- vi Número de novos funcionários na empresa;

- vii Renda mensal (salário) dos novos funcionários (em salários mínimos);
- viii Número de novos novos funcionários empresa.
- ix Faturamento anual (em 100 mil reais);
- x vpreço sobre o valor patrimonial do entrevistado (em pontos);

	A	B	C	D	E	F	G	H	I	J
1	ID	Setor	sexo_resp	interesse_sof	dívida	Preoc_sustentabilidade	n_Funcionarios	renda_func	n_novos_funcio	Faturamento
2	1	ComAgri	F	S	N	S	2	4,00	1	0,5
3	2	ComAgri	M	N	N	S	2	1,50	1	1,9
4	3	ComAgri	F	S	N	S	1	2,10	0	1,5
5	4	ComAgri	F	S	N	S	3	2,30	2	1,5
6	5	ComAgri	F	S	S	N	1	2,30	1	2,2
7	6	ComAgri	M	S	N	S	2	2,80	1	0,6
8	7	ComAgri	F	N	N	S	1	3,40	0	2,5
9	8	ComAgri	M	S	N	S	1	2,80	0	1,7
10	9	ComAgri	F	S	N	S	0	2,90	0	2,5
11	10	ComAgri	F	S	N	N	1	1,70	0	0,9
12	11	ComAgri	F	S	N	S	5	2,90	3	3,3
13	12	ComAgri	F	N	N	S	3	4,00	2	2,1
14	13	ComAgri	M	S	N	S	3	2,70	2	1,1
15	14	ComAgri	M	S	N	S	4	4,20	2	0,5
16	15	ComAgri	F	S	S	N	1	1,10	0	0,7

Figura 4: Representação da estrutura (parcial) do banco de dados referente ao estudo de caso: implantação de uma empresa de TI no Sul de Minas.

3.4 Apresentação dos dados qualitativos

Para dados qualitativos a enumeração (contagem), é a forma mais simples de representá-los.

Observação: toda tabela e gráfico deve ter um título explicativo (identificação da população, da variável).

Representação tabular

Tabela 1: Ocorrência de dívida nas empresas da área de implantação de uma empresa de TI no Sul de Minas.

Dívida	Número de empresas(Fi)
Sim	15
Não	85
Total	100

Geralmente após a apresentação de uma tabela ou gráfico, devem ser feitos comentários sobre os resultados apresentados nestes, sempre referenciando sua numeração.

Exemplo: Pode-se observar, na Tabela 1, que nas na área de implantação de uma empresa de TI no Sul de Minas têm uma maior ocorrência de empresas que não possuem dívida.

Representação gráfica

O gráfico de barras é um gráfico no qual as barras retangulares tem comprimento proporcional aos valores que ele representa (frequência). As barras podem ser desenhadas verticalmente ou horizontalmente. O gráfico de barras vertical é chamado de gráfico de colunas.




Figura 5: Gráfico de colunas referente à ocorrência dívida nas empresas da área de implantação da uma empresa de TI

O gráfico de setores, comumente chamado gráfico de pizza, é um diagrama circular em que os valores de cada categoria estatística representada são proporcionais à porcentagem da área ocupada, ou seja, cada "fatia" representa uma categoria de dados e o tamanho é proporcional à quantidade que representa.




Figura 6: Gráfico de setores referente à ocorrência dívida nas empresas da área de implantação de uma empresa de TI no Sul de Minas.

Os resultados devem ser apresentados apenas de uma forma, portanto, deve-se escolher entre o gráfico ou tabela.

OBS: Cuidado com variáveis que tenham uma quantidade elevada de respostas (categorias).

3.4.1 Construindo Gráficos no Rcommander a partir de um BANCO DE DADOS

Nesse caso, deve-se, primeiramente, carregar o banco de dados no *Rcommander* (ver passos no Vídeo: **importar para o R commander um arquivo Excel (xlsx)**). Depois basta seguir os passos apresentados na Figura 7 nas quais se tem a sequência de comandos no Rcommander para a construção dos gráficos de barras e de setores (pizza) utilizando um banco de dados.




Figura 7: Sequência de comandos para a construção dos gráficos de barras e de setores (pizza) para a variável ocorrência dívida na empresa, utilizando um banco de dados.

Exemplo de gráfico pouco informativo




Figura 8: Gráfico de setores como exemplo de uma representação pouco informativa

Fonte: Tesouro Nacional 2018

3.5 Apresentação dos dados quantitativos discretos

Na maioria das situações em que temos dados referentes a variáveis quantitativas discretas (característico de contagens), é comum construir uma Tabela de frequência mais simples, na qual se representa a **frequência absoluta de cada valor assumido pela variável** (Fi); as **frequências relativas** (Fr); $Fr = Fi/n$; e as **frequências percentuais** (Fp); $Fp = Fr \times 100$.

Exemplo: Considerando o estudo de caso: implantação de uma empresa de TI no Sul de Minas, desejamos analisar a variável *Número de novos funcionários por empresa*.

Efetuada-se a contagem, e organizando os resultados temos:

Tabela 1.1: Frequências do número novos funcionários por empresa da área de implantação da de uma empresa de TI

N^o de novos funcionários	Fi	Fr	$Fp(\%)$
0	40	0,400	40,0
1	32	0,320	32,0
2	18	0,180	18,0
3	5	0,050	5,0
4	3	0,030	3,0
5	2	0,020	2,0
TOTAL	100	1,00	100,0

Observação: quando a quantidade de resposta assumida pela variável discreta for muito elevada *deve-se criar classes* como para dados contínuos, que será visto à frente.

Perguntas interpretativas da Tabela 1.1.

1. Qual a porcentagem de empresas com mais de um novo funcionário?
2. Qual a porcentagem de empresas com no mínimo três novos funcionários?
3. Qual a porcentagem de empresas com no máximo um novo funcionário?

Para obter a contagem dos dados, basta seguir os passos apresentados na Figura 9 nas quais se tem a sequência de comandos no Rcommander para a obtenção das frequências de cada resposta, utilizando um banco de dados.




Figura 9: Sequência de comandos para a obtenção das frequências de cada resposta da variável "Número de novos funcionários na empresa", utilizando um banco de dados.

O gráfico adequado para frequências absolutas, relativas, ou acumuladas de uma variável discreta é parecido com um gráfico de barras, mas nesse caso, as frequências são indicadas por linhas.




Figura 10: Gráfico das frequências do número de novos funcionários por empresa da área de implantação de uma empresa de TI

Os resultados devem ser apresentados apenas de uma forma, portanto, deve-se escolher entre um gráfico ou tabela.

Sequência de comandos no Rcommander para a construção do gráfico para a variável discreta utilizando um banco de dados.




Figura 11: Sequência de comandos para a construção do gráfico para a variável discreta, número de novos funcionários por empresa, utilizando um banco de dados.

3.6 Organização e apresentação de dados quantitativos Contínuos

Como nos dados qualitativos, também é feita mediante uma representação. A forma mais simples e utilizada é a distribuição de frequências, definida a seguir.

Distribuição de frequência: é a distribuição dos dados em classes ou categorias. O número de elementos associados a cada classe representa a frequência de classe.

3.6.1 Construção de uma tabela de distribuição de frequência (TDF)

Exemplo: Informações sobre os resultados de 100 empresas, referente ao preço sobre o valor patrimonial (P/VPA, em pontos), em uma amostra de empresas da área de implantação da uma empresa de TI.

86.6	88.6	99.4	90.4	90.8	100.3	92.8	82.4	85.9	87.3	97.3	92.2	92.4	90.7	86.7
100.7	93.0	78.2	94.2	87.2	83.6	88.7	83.8	85.6	86.2	79.9	95.0	90.9	83.2	97.5
92.6	88.2	95.4	95.3	94.9	94.1	93.3	89.6	88.2	87.7	85.8	88.8	82.4	103.0	97.2
83.3	87.6	87.2	94.7	89.5	91.5	89.8	89.7	98.2	88.6	99.1	80.7	93.5	90.7	91.3
92.3	87.0	88.0	83.9	83.6	91.8	92.7	90.3	95.5	102.3	87.1	76.1	96.0	85.7	85.9
96.2	88.3	82.7	91.1	89.2	90.0	92.3	87.8	93.9	88.7	92.0	96.6	92.6	88.0	96.9
96.0	93.3	91.4	86.2	98.2	86.4	103.1	99.2	88.6	83.8					

- Você consegue extrair alguma informação útil destes valores?
- Seria interessante apresentar desta forma?
- Você já imaginou se fossem analisados 5000 elementos?

Solução: o ideal então seria sumarizar os dados por Construindo uma Tabelas e/ou um Gráfico.

Para de construir uma tabela, com critérios estatísticos, deve-se seguir os seguintes passos:

- Determinar o número de classes (K), para a qual podem-se os seguintes critérios:
 - A familiaridade do pesquisador com os dados.
 - Critério baseado no número de observações (n): qual é o número ideal de classes? Oliveira, M. S (1994).

Número de observações (n)	Número de classes (K)
Até 100	$\sqrt{n}$ (se decimal, usar o inteiro superior)
Acima de 100	$5\log(n)$

- Determinar amplitude da classe será determinada por um critério estatístico: Encontrar a amplitude total (A);

A amplitude total é a diferença entre a maior e a menor observação.

3. Encontrar a amplitude de cada classe (C);

A amplitude de cada classe a razão entre a amplitude total e o número de classes menos 1.

$$C = \frac{A}{K - 1}$$

4. Determinar as classes: sejam LI_i e LS_i os limites inferior e superior da classe " i ", respectivamente.

(a) $LI_1 = \text{menor Observação} - C/2$.

(b) LI_1 conhecido, logo $LS_1 = LI_1 + C$.

(c) $LI_2 = LS_1$.

(d) $LS_2 = LI_2 + C$.

Continuar os passos anteriores até completar " K " classes.

5. Determinar o ponto médio da classe (X_i):

$$X_i = (LI_1 + LS_1)/2;$$

6. Calcular os valores das frequências absolutas (F_i);

Para cada classe, o valor de F_i é o número de observações contidas na classe.

7. Calcular os valores das frequências relativas (Fr_i); $Fr_i = F_i/n$

8. Calcular os valores das frequências percentuais (Fp_i); $Fp_i = Fr_i \times 100$

9. Calcular os valores das frequências percentuais ACUMULADAS ($FACp_i$); $FACp_i$ =soma das frequências percentuais até a classe " i ". Quando de interesse.

IMPORTANTE: Para fins de cálculos de algumas medidas, todas as observações contidas num intervalo de classe serão considerados *iguais ao ponto médio da classe*. Essa é chamada a Hipótese Tabular Básica (HTB).

Tabela 1.2: Distribuição de frequência dos resultados referente ao preço sobre o valor patrimonial (P/VPA), em pontos, das empresas da área de implantação da uma empresa de TI

Classes	X_i	F_i	F_{ri}	F_{pi}	FACP
74,6 ┤ 77,6	76,1	1	0,01	1,00	1,00
77,6 ┤ 80,6	79,1	2	0,02	2,00	3,00
80,6 ┤ 83,6	82,1	6	0,06	6,00	9,00
83,6 ┤ 86,6	85,1	13	0,13	13,00	22,00
86,6 ┤ 89,6	88,1	23	0,23	23,00	45,00
89,6 ┤ 92,6	91,1	20	0,20	20,00	65,00
92,6 ┤ 95,6	94,1	17	0,17	17,00	82,00
95,6 ┤ 98,6	97,1	10	0,10	10,00	92,00
98,6 ┤ 101,6	100,1	5	0,05	5,00	97,00
101,6 ┤ 104,6	103,1	3	0,03	3,00	100,00
TOTAL		100	1,00	100,00%	-

Perguntas interpretativas da Tabela 1.2.

1. Qual o número de empresas com preço sobre o valor patrimonial mínima de 83,6 pontos?
2. Qual a porcentagem de empresas com preço sobre o valor patrimonial mínima de 98,6 pontos?
3. Qual a porcentagem de empresas com preço sobre o valor patrimonial maiores que 80,6 pontos?
4. Qual a porcentagem de empresas com preço sobre o valor patrimonial de no máximo que 83,6 pontos?

3.6.2 Representação gráfica de dados quantitativos contínuos

a) **Histograma**: gráfico representado por retângulos cujas bases são proporcionais às *amplitudes de classe* e as alturas proporcionais às *frequências das classes* (as frequências podem ser F_i , Fr_i , ou Fp_i).

b) **Gráfico de densidade do kernel** : Gráfico que representa a estimativa de densidade por Kernel (EDK) é uma forma não-paramétrica para estimar a Função densidade de probabilidade de uma variável aleatória.




Figura 12: Histograma e polígono dos resultados do preço sobre o valor patrimonial (pontos), empresas da área de implantação de uma empresa de TI

3.6.3 Classificação das distribuições de frequências

A forma do histograma de frequência permite classificar a distribuição de frequências em: simétrica, assimétrica à direita, assimétrica à esquerda. Para isto, deve ser comparada com as seguintes curvas, chamadas curvas de frequência, conforme Figuras 13





Figura 13: Exemplo de frequências em: simétrica, assimétrica à direita, assimétrica à esquerda.

3.7 Construindo a TDF e o Histograma no R

Basta copiar e colar a rotina R, no R Script, digitar (informar), o nome do arquivo com a variável a ser analisada. Depois, selecionar as linhas de comando e clicar em "Submeter" conforme Figuras 14 e 15.



```

dados<-Dataset$vvpa;dados #armazenando as observações no objeto dados
n<-length(dados); n #número de observações
k<-sqrt(n)+0.5; k<-round(k,0) #número de classes
C<-(max(dados)-min(dados))/(k-1);C<-round(C,2) #Amplitude de classe duas casas decimais
limites<-round(min(dados)-C/2,2)+C*(0:k);#limites
TDF<-hist(dados,breaks=limites,plot=FALSE,right=FALSE)
tabela<-matrix(c(rep(6*k)),k,6)
for(i in 1:k)
{tabela[i,1]<-round(TDF$breaks[i],2);tabela[i,2]<-round(TDF$breaks[i+1],2)
tabela[i,3]<-round(TDF$mids[i],2);tabela[i,4]<-(TDF$counts[i])
tabela[i,5]<-round((TDF$counts[i])/n,4);tabela[i,6]<-round((100*TDF$counts[i])/n,2)
}


> colnames(tabela)<-c("LI","LS","Xi","Fi","Fr","Fp")

> tabela

```

	LI	LS	Xi	Fi	Fr	Fp
[1,]	74.6	77.6	76.1	1	0.01	1
[2,]	77.6	80.6	79.1	2	0.02	2
[3,]	80.6	83.6	82.1	6	0.06	6
[4,]	83.6	86.6	85.1	13	0.13	13
[5,]	86.6	89.6	88.1	23	0.23	23
[6,]	89.6	92.6	91.1	20	0.20	20
[7,]	92.6	95.6	94.1	17	0.17	17
[8,]	95.6	98.6	97.1	10	0.10	10
[9,]	98.6	101.6	100.1	5	0.05	5
[10,]	101.6	104.6	103.1	3	0.03	3

Figura 14: Sequência de comandos para a construção da Tabela de Distribuição de Frequência na resolução do exemplo.



```

dados<-Dataset$vvpa;dados #armazenando as observações no objeto dados
n<-length(dados); n #número de observações
k<-sqrt(n)+0.5; k<-round(k,0) #número de classes
C<-(max(dados)-min(dados))/(k-1);C<-round(C,2) #Amplitude de classe duas casas decimais
limites<-round(min(dados)-C/2,2)+C*(0:k);#limites
TDF<-hist(dados,breaks=limites,plot=FALSE,right=FALSE)
hist(dados,xlab="VVP Ae (pontos)", ylab="Frequência absoluta",
label=FALSE,col="gray",main="",right=FALSE,
xlim=c(min(TDF$mids)-C,max(TDF$mids)+C),ylim=c(0,(max(TDF$counts)+1)),breaks=limites,axes=FALSE)
axis(1,at=limites,pos=c(0,0))

```

Figura 15: Sequência de comandos para a construção do Histograma e Polígono na resolução do exemplo.

3.8 Exercícios

- 1 Informações sobre os resultados de 36 exames de sangue, referente à fração de colesterol de muito baixa densidade (VLDL), em miligramas por decilitro (pontos), em indivíduos do sexo feminino.

5,25	9,57	7,59	13,85	11,06	17,26
4,56	9,55	7,39	13,60	10,76	16,61
6,66	9,80	8,46	15,99	12,79	22,00
5,73	9,65	7,44	14,69	11,59	18,75
4,00	9,54	6,86	13,23	10,53	16,22
6,26	9,77	8,12	14,71	12,00	19,40

- Construa a tabela de distribuição de frequência, o polígono e histograma.
 - Qual o número de exames que apresentaram valores de VLDL de pelo menos 16,6 pontos?
 - Qual o a percentagem de exames que apresentaram valores de VLDL menores que 13,0 pontos?
 - Qual o a percentagem de exames que apresentaram valores de VLDL menores que 7,6 pontos?
- 2 Foi contado o número de novos funcionários que cada uma de 50 famílias escolhidas aleatoriamente no Bairro Pinheirinhos em Alfenas, encontrando-se o seguinte resultado:

5	1	5	3	1	2	2	1	1	0
4	2	0	4	4	4	4	3	3	2
1	1	3	2	3	1	2	3	4	3
4	0	2	0	5	2	3	4	3	4
0	0	4	3	2	2	4	3	4	3

- Estes dados são de uma população ou de uma amostra?
 - Classifique a variável em questão.
 - Construa tabela de distribuição de frequência e o gráfico.
- 3 Seja os dados abaixo referentes à taxa de proteína (g/kg) na carne analisadas em 18 leitões de um experimento.

10,0	10,4	10,7	11,4	11,6	12,2
12,2	12,4	12,4	12,5	13,4	13,5
13,9	14,0	14,6	15,0	15,3	15,6

- Construa a tabela de distribuição de frequência, o polígono e histograma.
- Qual o número de animais que apresentaram taxa de proteína menor que 13,5g/kg?
- Que percentagem de animais apresentaram taxa de proteína menor que 14 g/kg?

4 Medidas descritivas

Uma vez que os dados são organizados e apresentados por meio de Tabelas e Gráficos, para se fazer uma melhor análise e interpretação dos mesmos faz-se necessário que as observações sejam bem representadas, sendo para isto utilizadas as chamadas *medidas descritivas*, sendo elas formadas por medidas de posição (média, mediana e moda), medidas de variabilidade ou dispersão (variância, desvio padrão e coeficiente de variação) e medidas separatrizes (quartis, decis e percentis).

Notação

	Medida	Amostra	População
Medidas de Posição	Média	$\bar{X}$	μ (mi)
	Mediana	M_d	$\tilde{\mu}_d$
	Moda	M_o	$\tilde{\mu}_o$
Medidas de Variabilidade	Variância	S^2	σ^2
	Desvio padrão	S	σ (sigma)
	Coeficiente de variação	CV	σ_R

4.1 Medidas de posição

Medidas de posição ou de tendência central são aquelas que procuram sintetizar as informações (os dados ou observações) em um único e informativo valor. Tais medidas têm tendência a posicionar-se no centro das distribuições. Estudaremos a média, moda e mediana.

- Média

É a medida mais usada por ser a mais comum e compreensível delas, bem como pela relativa simplicidade do seu cálculo, além de prestar-se bem ao tratamento algébrico.

A **média aritmética** ou simplesmente **média** de uma população de tamanho N é, por definição:

$$\mu = \frac{\sum_{i=1}^N x_i}{N}.$$

E, para uma amostra de tamanho n é, por definição:

$$\bar{X} = \frac{\sum_{i=1}^n x_i}{n}.$$

1. Influenciada pelos valores extremos da distribuição; (Desvantagem)
2. Na sua determinação são considerados todos os dados (é tratável matematicamente);
3. É única para um conjunto de dados;

- Mediana

Para um conjunto de dados ordenados (Rol), a mediana é o valor que é precedido e seguido pelo mesmo número de dados (observações). Isto é 50% dos dados são superiores à mediana e 50% são inferiores. Cálculo da mediana:

Quando o número de dados (n) for **ímpar**:

$$Md = x_{(\frac{n+1}{2})}$$

Ou seja, se "n" for ímpar, a mediana será o elemento da série ordenada que ocupa a posição $((n + 1)/2)$.

Quando o número de dados for **par**:

$$Md = \frac{x_{(\frac{n}{2})} + x_{(\frac{n+2}{2})}}{2}$$

Quando o número de elementos da série for par, nunca haverá coincidência da mediana com um dos elementos da série. A mediana será sempre a média aritmética dos dois elementos centrais da série, ou seja, a média dos elementos que estão nas posições $(n/2)$ e $(n + 2)/2$.

- Moda

É o valor que ocorre com maior frequência no conjunto de dados, isto é, o valor mais comum. Quando o conjunto de dados apresentar dois valores com a mesma frequência máxima, cada um deles é uma moda, e o conjunto diz-se bimodal. Caso mais de dois valores ocorram com a mesma frequência máxima, o conjunto é multimodal. No entanto, quando nenhum valor é repetido, o conjunto de dados não tem moda, sendo dito ser amodal.

OBSERVAÇÃO: Quando os dados forem contínuos (sem repetições) para calcular a moda os dados devem estar em classes. Uma aproximação pode ser de calcular a moda, *obtendo o ponto central da classe (intervalo) de maior frequência*, ou, no histograma, a coluna mais alta.

4.1.1 Propriedades da média, mediana e moda

Vantagens e desvantagens da média, mediana e moda

Embora a **média aritmética** seja amplamente utilizada como medida descritiva na ciência e para a tomada de decisão, deve-se ter cuidado com seu uso em situações em que a série apresenta "valores extremos".

	Média	Mediana	Moda
VANTAGENS	É tratável matematicamente	Não é influenciada por valores extremos	Não é influenciada por valores extremos
DESVANTAGENS	É influenciada por valores extremos	Não é tratável matematicamente	Não é tratável matematicamente

Portanto todas as vezes que não existirem "**valores extremos**"(outliers) no conjunto de dados deve-se usar a **média**.

4.1.2 EXEMPLO

Exemplo: Informações sobre os resultados de 100 empresas, referente ao preço sobre o valor patrimonial (P/VPA, em pontos), em uma amostra de empresas da área de implantação da uma empresa de TI.

86.6	88.6	99.4	90.4	90.8	100.3	92.8	82.4	85.9	87.3	97.3	92.2	92.4	90.7	86.7
100.7	93.0	78.2	94.2	87.2	83.6	88.7	83.8	85.6	86.2	79.9	95.0	90.9	83.2	97.5
92.6	88.2	95.4	95.3	94.9	94.1	93.3	89.6	88.2	87.7	85.8	88.8	82.4	103.0	97.2
83.3	87.6	87.2	94.7	89.5	91.5	89.8	89.7	98.2	88.6	99.1	80.7	93.5	90.7	91.3
92.3	87.0	88.0	83.9	83.6	91.8	92.7	90.3	95.5	102.3	87.1	76.1	96.0	85.7	85.9
96.2	88.3	82.7	91.1	89.2	90.0	92.3	87.8	93.9	88.7	92.0	96.6	92.6	88.0	96.9
96.0	93.3	91.4	86.2	98.2	86.4	103.1	99.2	88.6	83.8					

Calcule e interprete a média, a mediana e a moda. Indique qual a melhor medida de posição para representar o conjunto de dados.

a) Média

$$\bar{X} = \frac{\sum_{i=1}^n x_i}{n} = \frac{9054,1}{100} = 90,54 \text{ pontos}$$

Interpretação: A média do p/vp da amostra de empresas da área de implantação da uma empresa de TI é 90,54 pontos.

b) Mediana

Como temos $n=100$, tomaremos os elementos que estão na posição x_{50} e x_{51} , dos dados ordenados.

$$Md = \frac{90,3 + 90,4}{2} = 90,35 \text{ pontos}$$

Interpretação: 50% dos valores de p/vp da amostra de empresas da área de implantação da uma empresa de TI estão acima de 90,35 pontos e 50% estão abaixo.

c) Moda

Com base na Tabela 1.2:

$$Mo = 88,1 \text{ pontos}$$

Interpretação: O valor de p/vp da amostra de empresas da área de implantação da uma empresa de TI com maior frequência é de 88,1 pontos.

No caso do exemplo, **a Média é a melhor medida** de posição para representar o conjunto de dados, pois não há valores extremos e ela é tratável matematicamente.

Para obter a contagem dos dados, basta construir a Tabela de Distribuição de Frequência (TDF), como feito anteriormente, ou seguir os passos apresentados na Figura 16, onde se tem a sequência de comandos no Rcommander para a obtenção das frequências de cada resposta, bem como obter as medidas de posição, utilizando o banco de dados.




Figura 16: Sequência de comandos para a obtenção da estatísticas descritivas (medidas de posição), na resolução do exemplo

4.2 Medidas de variabilidade

São medidas que informam sobre a dispersão dos dados e são necessárias para, junto com a média, representar bem um conjunto de observações.

a) **Amplitude Total (A)** É a diferença entre o maior e menor dos valores da série. Ou seja:

$$A = X_{max} - X_{min}$$

A utilização da amplitude total como medida de dispersão é limitada, pois é uma medida que depende apenas dos valores extremos, não sendo afetada pela variabilidade interna dos valores da série.

b) **Variância e desvio padrão:** medem a variabilidade absoluta de um conjunto de observações.

São as duas medidas de dispersão mais usadas na ciência, sendo calculadas considerando-se todas as observações da série de dados. Elas são fundamentadas nos **desvios em relação à média**:

$$d_i = x_i - \bar{x}$$

Observação: A variância é a soma de quadrados dos desvios em relação à média dividido por " $n-1$ "(amostral) ou " N "(populacional).

Variância amostral

$$S^2 = \frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n-1} \text{ ou } S^2 = \frac{1}{n-1} \left[\sum_{i=1}^n x_i^2 - \frac{\left(\sum_{i=1}^n x_i \right)^2}{n} \right]$$

em que:

- n é o tamanho da amostra.
- $S = \sqrt{S^2}$ (desvio padrão amostral).

Variância Populacional

$$\sigma^2 = \frac{\sum_{i=1}^N (x_i - \mu)^2}{N} = \frac{1}{N} \left[\sum_{i=1}^N x_i^2 - \frac{\left(\sum_{i=1}^N x_i \right)^2}{N} \right]$$

Observação 1: a unidade da variância refere-se ao **quadrado da unidade dos dados**. O desvio padrão é expresso na mesma unidade dos dados originais. Para o exemplo: dados originais (g), desvio Padrão (g) e a variância (g^2). Por isso, o desvio padrão possui uma interpretação mais realística dos dados.

Observação 2: a expressão $\sum_{i=1}^n (x_i - \bar{x})^2$ é conhecida como soma de quadrados dos desvios em relação à média, porém, na prática aplicar esta fórmula é mais trabalhoso que utilizar a seguinte expressão:

$$\sum_{i=1}^n x_i^2 - \frac{\left(\sum_{i=1}^n x_i \right)^2}{n},$$

em que $\sum_{i=1}^n x_i^2$ e $\sum_{i=1}^n x_i$ podem ser obtidos com certa facilidade em uma calculadora científica realizando os seguintes passos (para o modelo CASIO ou modelo semelhante):

4.2.1 Cálculo das medidas descritivas com a calculadora científica :

1. Ativar o módulo estatístico: tecla "mode" → "2(SD)". No visor deve aparecer SD.
2. Com o módulo estatístico ativado digite cada dado e "guarde" na memória teclando "M+". No visor vai aparecer a contagem dos dados. Repita o processo do primeiro até o último dado.
3. Com os dados na memória podemos obter os somatórios:

$$\sum_{i=1}^n x_i^2: \text{ tecla "shift" } \rightarrow \text{ "1 (S-SUM)" } \rightarrow \text{ "1" } \rightarrow \text{ "=" }.$$

$$\sum_{i=1}^n x_i: \text{tecle "shift"} \rightarrow "1 \text{ (S-SUM)}" \rightarrow "2" \rightarrow "=".$$

Para obter quantos dados estão na memória: tecla "shift" → "1 (S-SUM)" → "3" → "=".

4. Com os dados na memória podemos, também, obter de forma direta a média e o desvio padrão amostral:

média: tecla "shift" → "2 (S-VAR)" → "1" → "=".

desvio padrão amostral: tecla "shift" → "2 (S-VAR)" → "3" → "=".

5. PARA APAGAR A MEMÓRIA: Para sair deste módulo, e conseqüentemente "apagar" a memória, Tecla "mode" → "1(comp)".

c) Coeficiente de variação: também conhecido como desvio padrão relativo (DPR), é uma medida de variabilidade relativa. Refere-se à variabilidade dos dados em relação à média.

$$CV = \frac{S \times 100\%}{\bar{x}}$$

em que S é o desvio padrão amostral e $\bar{x}$ é a média amostral. Ou seja, expressa percentualmente a variação dos dados em relação à média.

Sua **vantagem** é permitir a comparação de grandezas diferentes, que estão em unidades diferentes. Porém, possui algumas **restrições de uso**:

I) Quando a média da variável em estudo tende a zero, o CV tende ao infinito (o que não tem sentido prático).

E, pode ser interpretado como:

- i Baixa variabilidade $\Rightarrow CV < 10\%$: dados homogêneos.
- ii Média variabilidade $\Rightarrow 10\% \leq CV < 20\%$.
- iii Alta variabilidade $\Rightarrow 20\% \leq CV < 30\%$.
- iv Muito alta variabilidade $\Rightarrow CV \geq 30\%$: dados heterogêneos.

Observação: Essa interpretação é apresentada por Garcia (1989) ⁱⁱⁱ e tem-se a ressalva de que esses valores podem ser **diferentes para cada área de pesquisa**. Deste modo, **aconselha-se a realizar uma revisão de literatura**.

d) Erro padrão da média: refere-se à variabilidade dos dados em relação ao tamanho da amostra (n).

$$EP = \frac{S}{\sqrt{n}}$$

em que S é o desvio padrão amostral e n é tamanho amostral.

Observação: como estaremos trabalhando com dados resultantes de experimentos, vamos sempre trabalhar com medidas amostrais.

ⁱⁱⁱGARCIA, C.H. Tabelas para classificação do coeficiente de variação. Piracicaba: IPEF, 1989. 12p. (Circular técnica, 171).

4.2.2 EXEMPLO

Considerando o exemplo, [Subsubseção 4.1.2](#), calcule a variância, o desvio padrão e o Coeficiente de variação (CV). Interprete o CV.

$$\text{a) Variância: } S^2 = \frac{1}{n-1} \left[\sum_{i=1}^n x_i^2 - \frac{\left(\sum_{i=1}^n x_i \right)^2}{n} \right]$$

$$S^2 = \frac{1}{100-1} \left[822737,7 - \frac{(9054,1)^2}{100} \right] S^2 = \frac{2970,46}{99} = 30,00(\text{pontos})^2$$

b) Desvio padrão

$$S = \sqrt{30,00(\text{pontos})^2} S = 5,478\text{pontos}$$

c) Coeficiente de variação Lembrando que: $\bar{X} = 90,54\text{pontos}$

$$CV = \frac{5,478}{90,54} \times 100 = 6,05\%$$

Interpretação: Os valores de p/vp da amostra de empresas da área de implantação da uma empresa de TI apresentam uma variabilidade de 6,05% em relação à média, ou seja, apresentam baixa variabilidade.

d) Amplitude Total (A) $A = 103,1 - 76,1$

$$A = 27\text{pontos}$$

Interpretação: A amplitude total dos valores de p/vp da amostra de empresas da área de implantação da uma empresa de TI foi de 27 pontos.

4.3 Medidas de separatriz (quantil)

A mediana é uma medida separatriz, pois divide a série em duas partes iguais. Assim como há o interesse em dividir a série em duas partes iguais, pode haver interesse em dividi-la em 4, 10 ou 100 partes iguais. Surgiram então os Quartis, Decis e Percentis.

Dentre as medidas de separatriz, as mais utilizadas são os quartis. Os **Quartis** (Q_1 , Q_2 e Q_3), são três valores que dividem a série em quatro partes iguais. São as medidas de separatriz mais utilizadas.

1. Primeiro Quartil (Q_1): valor situado de tal modo na série de dados que 25% das observações são menores que ele e 75% são maiores.
2. Segundo Quartil (Q_2): valor situado de tal modo na série de dados que 50% das observações são menores que ele e 50% são maiores.
3. Terceiro Quartil (Q_3): valor situado de tal modo na série de dados que 75% das observações são menores que ele e 25% são maiores.

O cálculo desses elementos segue o mesmo procedimento de mediana (que é igual ao Q_2). Ordenam-se os dados de forma crescente (rol) e calcula-se a posição p^* em que está a medida desejada, em que a posição p^* é dada por:

$$p^* = \frac{\text{Numero de dados}}{\text{Numero de partes}} \times \text{ordem}$$

$$Q_o = x_{p^*}, \text{ se } p^* \text{ for inteiro ou}$$

$$Q_o = \frac{(x_{p^*} + x_{p^*+1})}{2}, \text{ se } p^* \text{ for não for inteiro.}$$

Os Centis ou Percentis são 99 valores que dividem a série em cem partes iguais;

Exemplo: Considerando os dados do exemplo [Subsubseção 4.1.2](#), calcular e interpretar os Quartis (Q_1 e Q_3)

$Q_1 = 87,1$ pontos, isto indica que, 25% da amostra de empresas da área de implantação da uma empresa de TI tem p/vp menores que 87,1 pontos.

$Q_3 = 94,1$ pontos, isto indica que, 25% da amostra de empresas da área de implantação da uma empresa de TI tem p/vp maiores 94,1 pontos.

Para obter as medidas de variabilidade e os quartis, basta seguir os passos apresentados na Figura 17, onde se tem a sequência de comandos no R Commander para a obtenção das frequências de cada resposta, bem como para obter as medidas de variabilidade e quartis, utilizando o banco de dados.




Figura 17: Sequência de comandos para a obtenção da estatísticas descritivas (medidas de variabilidade e quartis), na resolução do exemplo

4.4 Gráfico Boxplot ou Diagrama de caixas

O BOXPLOT é a forma gráfica de representar a distribuição dos dados por meio de cinco medidas estatísticas (MÍNIMO, Q_1 , MEDIANA, Q_3 e MÁXIMO), e permite obter um conjunto mais completo de informações sobre a forma da distribuição, conforme o exemplo:

O gráfico Boxplot nos fornece informações sobre a posição central, dispersão e assimetria da respectiva distribuição de frequências dos dados.

Eles também são usados para identificar valores discrepantes (**outliers**). O objetivo é analisar a distribuição dos dados. Assim, as conclusões que tiramos ao analisar um box plot são: centro dos dados (a média ou mediana), a amplitude dos dados (máximo - mínimo), a simetria ou assimetria do conjunto de dados e a presença de outliers.

Para identificar valores discrepantes (outliers), usa-se a média com o desvio padrão ou o **Desvio Interquartilico (DQI)**, também conhecido por, Intervalo Interquartilico (IQR).

a) Caso com o primeiro e o terceiro quartis

Dados o primeiro Q_1 e o terceiro quartis (Q_3), são possíveis *outliers* os valores da série de dados que são:

- menores que $Q_1 - 1.5 \times DQI$, ou;
- maiores que $Q_3 + 1.5 \times DQI$.

Em que, o Desvio Interquartilico (DQI), também conhecido por, Intervalo Interquartilico (IQR) é dado por:

$$DQI = Q_3 - Q_1$$

b) Caso com a média e o desvio padrão.

Dados a média ($\bar{X}$) e o desvio padrão (S), são possíveis *outliers* os valores da série de dados que são:

- menores que $\bar{X} - 3 \times S$, ou;
- maiores que $\bar{X} + 3 \times S$.

4.4.1 EXEMPLO

Considerando o exemplo, [Subsubseção 4.1.2](#), construir e interpretar o boxplot.

86.6	88.6	99.4	90.4	90.8	100.3	92.8	82.4	85.9	87.3	97.3	92.2	92.4	90.7	86.7
100.7	93.0	78.2	94.2	87.2	83.6	88.7	83.8	85.6	86.2	79.9	95.0	90.9	83.2	97.5
92.6	88.2	95.4	95.3	94.9	94.1	93.3	89.6	88.2	87.7	85.8	88.8	82.4	103.0	97.2
83.3	87.6	87.2	94.7	89.5	91.5	89.8	89.7	98.2	88.6	99.1	80.7	93.5	90.7	91.3
92.3	87.0	88.0	83.9	83.6	91.8	92.7	90.3	95.5	102.3	87.1	<u>76.1</u>	96.0	85.7	85.9
96.2	88.3	82.7	91.1	89.2	90.0	92.3	87.8	93.9	88.7	92.0	96.6	92.6	88.0	96.9
96.0	93.3	91.4	86.2	98.2	86.4	103.1	99.2	88.6	83.8					




Figura 18: Boxplot dos resultados referentes ao preço sobre o valor patrimonial (pontuação), da amostra de empresas da área de implantação da uma empresa de TI

Interpretação: Observa-se na Figura 18, que os dados de preço sobre o valor patrimonial, da amostra de 100 empresas da área de implantação da uma empresa de TI, se distribuem de forma simétrica e apresentam um *outlier* inferior.

Os passos para a criação do boxplot no Rcommander são apresentados na Figura 19.




Figura 19: Sequência de comandos para a construção do gráfico boxplot para avariável p/vp, utilizando o banco de dados.

4.5 Exercícios

- 1 Seja os dados abaixo referentes à taxa de proteína (g/kg) na carne de suínos analisadas em 18 amostras.

10,0 10,4 10,7 11,4 11,6 12,2
 12,2 12,4 12,4 12,5 13,4 13,5
 13,9 14,0 14,6 15,0 15,3 15,6

- Construa a tabela de distribuição de frequência e o histograma.
 - Qual o número de animais que apresentaram taxa de proteína menor que 13,5g/kg?
 - Que percentagem de animais apresentaram taxa de proteína menor que 14 g/kg?
 - Calcule e interprete a média, a mediana e a moda. Indique qual a melhor medida de posição para representar o conjunto de dados.
 - Calcule e interprete o quartil 1 ,quartil 3 e o coeficiente de variação.
 - Construa o box-plot e interprete.
- 2 Foi contado o número de crianças não-vacinadas em cada uma das 50 famílias escolhidas aleatoriamente no Bairro Pinheirinhos em Alfenas, encontrando-se o seguinte resultado:

5 1 5 3 1 2 2 1 1 0
 4 2 0 4 4 4 4 3 3 2
 1 1 3 2 3 1 2 3 4 3
 4 0 2 0 5 2 3 4 3 4
 0 0 4 3 2 2 4 3 4 3

- Construa o box-plot e interprete.
 - Calcule: a média, a moda, a mediana e o coeficiente de variabilidade e interprete.
- 3 Um laboratório que fabrica comprimidos analgésicos anuncia que seu remédio contra dor de cabeça tem a mesma média e uma variação menor na quantidade do princípio ativo em relação ao analgésico tradicional. Avaliaram se 8 amostras aleatórias de cada analgésico, obtendo-se os seguintes resultados (em mg).

Novo	6	5	8	5	6	7	6	6
Tradicional	8	6	5	7	4	9	5	6

Pode-se afirmar que o fabricante tem razão? Calcule as medidas de interesse e conclua.

- 4 Para estudar o rendimento de proteína de certo cultivar de aveia branca um pesquisador coletou 12 amostras, cujo rendimento de proteína foi medido. Os resultados obtidos, (em mg/g), foram os seguintes:

148 116 126 148 135 144 129 128 120 146 140 146

- Determine a média, a mediana, a moda, e o Q_1 e Q_3 do rendimento de proteína.
- Qual é a medida de posição mais apropriada para representar esse conjunto de dados? Justifique.
- Você acha que a variabilidade dos dados é grande ou pequena? Por quê?

- 5 Examinou-se um lote de 100 caixas de um fármaco, escolhidas aleatoriamente num carregamento de 10000 caixas prontas para exportação, anotando o número de "vidros" com pH maior que o permitido (fora do padrão) por caixa (cada caixa contém 20 vidros). Os resultados foram os seguintes:

Número de vidros fora do padrão	0	1	2	3	4	5
Número de caixas (frequência)	40	28	12	10	6	4

- a) Qual é o número médio, mediano e modal, de vidros "Fora do Padrão" por caixa?
- b) Qual deverá ser o número total de vidros "fora do padrão" no carregamento?
- 6 Um medicamento utilizado em enfermidades decorrentes de contraturas musculares dolorosas contém em sua formulação a cafeína que é um estimulante do sistema nervoso central que atua sobre a musculatura estriada tornando-a menos susceptível à fadiga. Um pesquisador com o intuito de verificar a quantidade de cafeína (em mg) num "medicamento A" analisou uma amostra aleatória de 12 comprimidos obtendo os seguintes resultados:

3 4 5 4 3 6 3 4 2 4 4 3

- a) Calcule a média, mediana, moda, o terceiro quartil (Q_3), o erro padrão e o coeficiente de variação.
- 7 Considere os conjuntos de dados da quantidade de um determinado exame realizado em dois laboratórios:

Laboratório A 380 360 370 1000 320

Laboratório B 720 750 740 730 760 720 770

Calcule (somente) a medida de posição mais apropriada para cada conjunto de dados. Comente o porque.

- 8 Considere os conjuntos de dados a seguir referentes aos preços (em reais) de um remédio em diferentes farmácias de cidades.

Cidade A	58	56	57	60	62	62	
Cidade B	72	75	74	73	74	72	77
Cidade C	48	49	45	47	43		

Qual é a cidade com maior variabilidade nos preços?

- 9 Para verificar o número de lesões musculares que os atletas de um clube já sofreram foram entrevistados aleatoriamente 50 atletas obtendo os seguintes resultados:

Número de lesões (x_i)	0	1	2	3	4	5
Frequência de atletas	14	20	9	4	2	1

- a) Calcule a média, mediana, moda e o coeficiente de variação do número de lesões musculares por atleta.

5 Probabilidades

5.1 Introdução

Anteriormente vimos como organizar e resumir os dados a respeito de certas variáveis para algumas análises de forma a extrair informações de interesse, porém, em nenhuma situação foi realizado o processo de "inferência".

A maioria dos resultados da chamada "evolução científica", como por exemplo, a descoberta de novos remédios, equipamentos e técnicas cirúrgicas na área da saúde, novas tecnologias computacionais, de novos equipamentos eletrônicos e produtos no meio industrial para o uso da sociedade, entre outros, são resultados obtidos a partir de pesquisas que empregam **experimentos científicos** ou **processos de amostragem**.

Na atividade científica, quando tudo que se dispõe é de uma parte dos elementos de uma população que se queira descrever (ou seja, uma amostra ou experimento), então a obtenção de informações e/ou conclusões a respeito da *população* não é direta, mas sim estará fortemente relacionada à amostra (ou experimento).

O ato de generalizar o resultado que temos de uma parte (dados experimentais) para o todo, é chamado de *inferir*. A **Inferência Estatística** é definida como o processo de obtenção de informações sobre uma população a partir de amostras (ou experimento). Ou seja, deve ficar claro que só tem sentido falar-se em Inferência Estatística quando não se "tem conhecimento" sobre todos os elementos da população. A descrição populacional geralmente é feita mediante distribuições de frequência e através de medidas descritivas. Estas últimas são chamadas de *Parâmetros Populacionais*. Em geral os parâmetros são medidas de posição (média, mediana, proporção, taxas) e de dispersão (variância, desvio padrão, coeficiente de variação), porém, pode haver o interesse em outras medidas.

Quando se dispõe apenas de uma parte dos elementos da população (uma amostra), o máximo que se pode conseguir são **valores aproximados** para **os parâmetros desconhecidos**, os quais são chamados de *Estimativas*. Assim, podemos definir **Estimativa** como o valor aproximado, calculado a partir de uma amostra, de um parâmetro populacional desconhecido.

- *Qual a importância da probabilidade neste contexto?*

Diante do processo de inferência, o pesquisador tem um "enorme" problema; **as incertezas** que surgem ao generalizar o resultado obtido em uma amostra ou experimento para toda uma população.

Como **exemplo**, vamos imaginar que um pesquisador descobriu uma nova substância para combater uma determinada doença. Um laboratório interessado em explorar esta nova substância, com o objetivo de lançar um remédio no mercado, realiza um experimento, de acordo com os órgãos competentes, e analisa o efeito do novo remédio em 1000 pessoas que portadoras da doença. Os resultados indicam que o "novo remédio" realmente "cura" a doença. O laboratório, então, lança o remédio no mercado. Uma determinada pessoa que possui a doença adquire o remédio. Surge aqui um questionamento.

- É certeza que o remédio vai curar esta pessoa??

Como os resultados obtidos pelo laboratório foram baseados em um experimento com 1000 pessoas, realmente fica alguma dúvida!

O que fazer então??

Eis que entra uma importante "área" da Estatística: **a Probabilidade**. Esta teoria passa a ser utilizada para *quantificar as incertezas existentes no processo de inferência*.

5.2 Conceitos e definições

Antes de discutirmos mais detalhadamente probabilidade precisamos compreender alguns conceitos de definições importantes.

- Na vida (e na Ciência) tudo é variável? Sim, Não !!!! Por quê ??????

Não podemos esquecer que nossa "realidade de vida" é cercada de fenômenos e/ou processos. Para os alguns casos podem ser estabelecidas *leis* ou modelos que expliquem as situações dos fatos desses fenômenos e/ou processos, estes são chamados *modelos determinísticos*.

Exemplos:

1. Se uma maçã for lançada para o ar, com certa força, ela cai de volta ao solo depois de certo tempo, em qual aceleração?;
2. Se aquecida até 100°C, a água ferve (pois este é seu ponto de ebulição sob pressão de 1 atm).
3. Qual a dilatação térmica linear do Silício (Si), se for aumentada a temperatura em 1°C? ($2,6 \times 10^{-6} \text{ } ^\circ\text{C}^{-1}$)

Por outro lado, se o *fenômeno* não está sujeito a lei alguma (ou melhor, se as leis que o regem ainda não são totalmente conhecidas), nada pode, a princípio ser *afirmado* sobre ele. Nesses casos, dizemos que ele está sujeito às *leis do acaso* e o único modelo possível para o seu estudo é o chamado **modelo probabilístico**.

Na Pesquisa Científica um dos principais objetivos é a retirada de conclusões a partir de experimentos (ou amostras) que envolvem incertezas, ou seja, situações em que os *modelos probabilísticos são aplicáveis*. Por isso, sempre no processo de selecionar amostras ou montagem de um experimento deve-se sempre utilizar, em alguma etapa, um mecanismo de sorteio (**escolha aleatória dos elementos**).

Para um melhor entendimento dos modelos probabilísticos faz-se necessário o conhecimento de conceitos básicos de Probabilidades. Neste material é realizada apenas uma abordagem simplificada sobre o conceito de probabilidade.

IMPORTANTE: Todos nós conhecemos e aplicamos probabilidade no nosso dia a dia. O que precisamos praticar é a sistematização lógica desse conhecimento.

Noções de respostas intuitivas a questões de probabilidade são comuns no nosso dia a dia. Qualquer pessoa, por menos conhecimento estatístico que tenha é capaz de responder à pergunta:

1. Se lançarmos uma moeda e verificar sua face superior, qual é a probabilidade de ser "cara"?
2. Se uma mulher está grávida, qual é a probabilidade do bebê que vai nascer ser "do sexo feminino"?

Mas existem muitas situações em que não é tão simples termos uma resposta confiável.

3. Se alguém está com "dor de cabeça" e ingere um analgésico, qual é a probabilidade da dor ser eliminada em menos de 10 minutos?
4. Qual é a probabilidade de um software, fundamentado em AI, destinado à detecção do câncer de mama e de pulmão em análises de radiografia, acertar todos os diagnósticos ?
5. Qual é a probabilidade de um celular novo não apresentar defeito em 6 meses de uso?

No meio científico **é evidente a presença da incerteza**. Qual é a importância da probabilidade então? Na Ciência, de forma geral, essa incerteza é quantificada **por meio de probabilidades**.

Para um melhor entendimento precisamos de algumas definições básicas.

Definição 1: Experimentos aleatórios

São fenômenos e/ou processos observados pelo homem em que os *resultados não são previsíveis*, mesmo que haja um grande número de repetições do mesmo fenômeno. **Exemplos:**

E1: lançamento de um dado e registrar do número de pontos que sai na face superior;

E2: lançamento de duas moedas e verificar a face superior de cada uma delas;

E3: o tempo de duração de uma bateria;

E4: registrar o número de pessoas usuárias de uma tecnologia;

E5: Observar o nascimento de 3 animais, considerando a ordem, e verificar o sexo deles.

Observação: nos experimentos aleatórios, mesmo que as condições iniciais sejam as mesmas, os resultados finais de cada tentativa poderão ser diferentes e *não previsíveis*.

Em oposição aos **experimentos aleatórios**, existem os **experimentos determinísticos**, que são aqueles cujos resultados são previsíveis, ou seja, temos certeza dos resultados a serem obtidos.

Exemplo: temperatura de solidificação da água.

Como nos experimentos aleatórios os resultados são não previsíveis, o que a Estatística faz é expressar a ocorrência destes resultados mediante probabilidades (este é o conceito de probabilidade).

As probabilidades classificam-se conceitualmente em três tipos:

1. Probabilidade a priori ou Clássica: quando a probabilidade de ocorrência de um possível resultado pode ser conhecida antes da realização do experimento.
2. Probabilidade a Posteriori (ou frequentista): quando a probabilidade de ocorrência de um possível resultado é determinada a partir de um experimento prévio. Este tipo de probabilidade está relacionada com tabela de distribuição de frequência, em que as frequências relativas são consideradas probabilidades de ocorrência.
3. Probabilidade Bayesiana: quando a probabilidade de ocorrência de um possível resultado é determinada a partir da introdução de uma informação prévia, que pode ser atualizada, ou complementada pelos dados amostrais por meio do Teorema de Bayes, permitindo a combinação entre informação dos dados e a probabilidade *a priori*, levando à probabilidade *a posteriori*.

Definição 2: Espaço amostral

Designa-se por Espaço Amostral e representa-se por Ω (ou S), o conjunto de todos os resultados possíveis associados a um experimento aleatório. Os elementos de Ω são chamados de **elementos amostrais**.

Exemplos de Espaços Amostrais:

E1: lançamento de um dado e registrar do número de pontos que sai na face superior;

$\Omega_1 = \{1, 2, 3, 4, 5, 6\}$;

E2: lançamento de duas moedas e verificar a face superior de cada uma delas;

$\Omega_2 = \{CC, FC, FF, CF\} = \{(C, C), (F, C), (F, F), (C, F)\}$

E3: o tempo de duração de uma bateria;

$\Omega_3 = \mathbb{R}^+$;

E4: registrar o número de pessoas usuárias de uma tecnologia;

$$\Omega_4 = \mathbb{N};$$

E5: Observar o nascimento de 3 animais, considerando a ordem, e verificar o sexo deles.

$$\Omega_5 = \{MMM, MMF, MFM, MFF, FMM, FMF, FFM, FFF\}$$

A partir destes exemplos iniciais observamos que um espaço amostral pode ser discreto finito (Ω_1) ou discreto infinito (Ω_4) ou contínuo (Ω_3).

Definição 3: Evento

"É um conjunto de possíveis resultados do qual desejamos conhecer sua probabilidade de ocorrência. É qualquer subconjunto do espaço amostral, podendo ser um único ponto amostral ou uma reunião deles". É denotado por uma letra maiúscula (A, B, C, etc).

Os exemplos são óbvios mas, interessa destacar os seguintes casos:

- i) Acontecimento Elementar: quando o acontecimento é constituído por um único elemento;
- ii) Acontecimento Certo: é outra designação para o espaço amostral Ω ;
- iii) Acontecimento Impossível: quando o acontecimento não contém nenhum elemento, isto é, na realidade "não aconteceu".

Exemplo: para o experimento 5 - observar o nascimento de 3 animais e verificar o sexo deles.

Evento A: nascer exatamente duas fêmeas $A = \{MFF, FFM, FMF\}$.

5.3 Probabilidade de um evento $P(E)$

A probabilidade de ocorrência de um evento "E" é definida segundo o conceito de probabilidade.

Probabilidade a Priori: é a razão entre o número de elementos do evento "E", $n(E)$, e o número de elementos de Ω , $n(\Omega)$:

$$P(E) = \frac{n(E)}{n(\Omega)}$$

em que $n(E)$ é o número de casos favoráveis e $n(\Omega)$ é o número de casos possíveis.

Probabilidade frequentista: é definida pelas frequências relativas da tabela de distribuição de frequência.

$$P(E) = \frac{n(E)}{n}$$

em que $P(E)$ é a frequência relativa, $n(E)$ é o número de vezes que ocorreu E e n é o número de vezes que a experiência foi realizada.

Sabemos que a cada experiência aleatória podemos associar (infinitos) acontecimentos aleatórios. Para distinguirmos os vários acontecimentos, torna-se necessário associar a cada acontecimento aleatório A, um número que de alguma maneira medirá o quanto verossímil (possível) é que o acontecimento A venha a ocorrer. Este número necessário é a probabilidade do acontecimento A, $P(A)$.

Exemplos:

1. Considere o lançamento de um dado. Calcule a probabilidade de:

A. sair o número 3.

Temos $\Omega = \{1, 2, 3, 4, 5, 6\}$ pelo que $n(\Omega) = 6$. Seja $A = 3$ pelo que $n(A) = 1$. Portanto, a probabilidade procurada será igual a $P(A) = 1/6$.

B. sair um número par.

Agora o acontecimento é $A = \{2, 4, 6\}$ com 3 elementos. Logo a probabilidade procurada será $P(A) = 3/6 = 1/2$.

2. Considere o experimento 5. $\Omega_5 = \{MMM, MMF, MFM, MFF, FMM, FMF, FFM, FFF\}$ e $n(\Omega) = 8$.

Evento C: nascer exatamente duas fêmeas $C = \{MFF, FFM, FMF\}$ e $n(C) = 3$.

Qual é a probabilidade de ocorrer o evento C. Logo, $P(C) = 3/8$.

5.4 Noção de probabilidade: axiomas e teoremas.

O nosso objetivo é encontrar um meio de obter o tal número, sem recorrer à experiência. E a característica que lhe exigimos e que tenha o valor que encontraríamos se realizássemos a experiência em causa um grande número de vezes. Este aspecto está na base de uma outra teoria a Teoria Frequentista das Probabilidades. Esta surgiu no início do século XX e segundo ela a probabilidade de um acontecimento pode ser determinada observando a frequência relativa desse acontecimento numa sucessão numerosa de experiências aleatórias.

Axiomas da Probabilidade

Probabilidade: Uma função $P(\cdot)$ é denominada probabilidade se satisfaz às condições:

Sob um ponto de vista puramente matemático, suporemos que para cada acontecimento **A**, pertencente ao conjunto de todos os acontecimentos possíveis, existe um número, que designaremos por $P(A)$, satisfazendo:

i. $0 \leq P(A) \leq 1$, $\forall A \subset \Omega$;

ii. $P(\Omega) = 1$, em que Ω é o acontecimento certo;

iii. Sejam $A_1, A_2, \dots, A_n$, eventos disjuntos (intersecção nula) pertencentes a Ω , então

$P(\bigcup_{i=1}^n A_i) = \sum_{i=1}^n P(A_i) = P(A_1) + P(A_2) + \dots + P(A_n)$, se $A_i \cap A_j = \emptyset$ com $i \neq j$ (disjuntos).

Com estes três axiomas mesmo sem sabermos ainda calcular $P(A)$ sabemos já as suas características, com as quais se demonstram todas as propriedades seguintes.

Propriedades:

P₁: Se $\emptyset$ for o conjunto vazio então $P(\emptyset) = 0$.

P₂: Se A^c é o acontecimento complementar de A então $P(A^c) = 1 - P(A)$.

P₃: Se A é um acontecimento qualquer então $P(A) \leq 1$.

P₄: Se A e B forem acontecimentos quaisquer então $P(A \cup B) = P(A) + P(B) - P(A \cap B)$.




Figura 20: Diagrama de Venn, a intersecção dos dois conjuntos é representada pela área que pertence ao conjunto A e ao conjunto B simultaneamente.

Regras de probabilidade:

(1) "Dois acontecimentos aleatórios, A e B de Ω , designam-se mutuamente exclusivos se não puderem ocorrer simultaneamente, em linguagem de conjuntos, $A \cap B = \emptyset$ ".

A probabilidade de ocorrência de A "ou" B é igual a soma de suas probabilidades individuais. Isto é, se:

$$A \cap B = \emptyset \Rightarrow P(A \cup B) = P(A) + P(B)$$

Podemos verificar que se existir intersecção devemos aplicar a propriedade 4 (P_4).

(2) "Dois eventos são independentes se a ocorrência de um deles não afeta a probabilidade de ocorrência do outro. A probabilidade de ocorrência de 2 eventos independentes é igual ao produto de suas probabilidades individuais. Isto é:

$$\text{Se } A \text{ e } B \text{ são independentes} \Rightarrow P(A \cap B) = P(A) \times P(B).$$

5.5 Probabilidade condicional e independência

Em muitas situações práticas, o fenômeno aleatório com o qual trabalhamos pode ser separado em etapas. A informação do que ocorreu em uma determinada etapa pode influenciar nas probabilidades de ocorrências das etapas sucessivas. Isto caracteriza a **dependência** entre os eventos.

Nesses casos, dizemos que ganhamos informação e podemos "recalcular" as probabilidades de interesse. Essas probabilidades "recalculadas" recebem o nome de probabilidade condicional, cuja definição apresentamos a seguir.

Definição 5: Probabilidade condicional

Dados dois eventos A e B , a probabilidade condicional de A dado que ocorreu B é representada por $P(A|B)$ é dada por:

$$P(A|B) = \frac{P(A \cap B)}{P(B)}, \quad P(B) > 0.$$

Caso $P(B) = 0$, $P(A|B)$ pode ser definido arbitrariamente, neste texto usaremos $P(A|B) = P(A)$.

Definição 6: Independência:

Dizemos que dois eventos são **independentes** se $P(A|B) = P(A)$ e $P(B|A) = P(B)$.

Exemplo: No processo de fabricação de chips semi-condutores, os mesmos são expostos a certos níveis de contaminação, inerentes ao processo. Considere uma situação em que 100 chips foram analisados, sendo 60 pelo processo tradicional e 40 por um "novo", para verificar a eficiência em não "falhar".

Resposta	Novo	Tradicional	Total
Falhou	10	20	30
Não falhou	30	40	70
Total	40	60	100

Se um chip é escolhido ao acaso:

- I) Qual a probabilidade de falhar dado que foi produzido pelo novo processo?
- II) Qual a probabilidade de falhar dado que foi produzido pelo processo tradicional?
- III) A novo processo tem eficiência na redução das falhas.

5.6 Calculando a probabilidade condicional no Rcommander

Para tratarmos deste assunto vamos recordar o conceito de tabela com duas variáveis, sendo uma variável apresentada nas linhas e outra nas colunas, esse tipo de representação é chamado de tabela de contingência. Para esse caso as tabelas de contingência são chamadas de tabelas 2x2.

A Figura 21 apresenta a sequência de comandos no R para a calcular a probabilidade condicional, caso exemplo 5.5




Figura 21: Passos a serem executados no R para o cálculo da probabilidade condicional, no exemplo 5.5.

OBS: Para calcular a **probabilidade condicional no Rcommander** deve-se indicar se vai ser o percentual nas linhas ou nas colunas. Isto vai depender da condicionalidade (ou seja, o que já se sabe), no exemplo pediu a probabilidade de falhar **dado que foi produzido pelo novo processo**, e isto está na coluna, por isso marcada a opção percentual nas colunas.

5.7 Exercícios

1. A probabilidade que um homem esteja vivo daqui a 30 anos é $\frac{2}{5}$ e a de sua mulher é de $\frac{2}{3}$. Determine a probabilidade de que daqui a 30 anos:
 - a) Ambos estejam vivos;
 - b) Somente o homem esteja vivo;
 - c) Somente a mulher esteja viva;
 - d) Nenhum esteja vivo;
 - e) Pelo menos um esteja vivo.
2. Uma companhia de seguros analisou a frequência com que 2.000 segurados (1.000 homens e 1.000 mulheres) usaram o hospital. Os resultados são apresentados na tabela:

Resposta	Homens	Mulheres
Usaram	120	200
Não usaram	880	800

- (a) Qual a probabilidade de que uma pessoa segurada use o hospital?
 - (b) Qual a probabilidade de ser mulher dado que usou o hospital?
 - (c) Qual a probabilidade de ser homem dado que usou o hospital?
 - (d) O uso do hospital independe do sexo do segurado?
3. Em uma estufa, o pesquisador verifica que existem plantas doentes ou resistentes. Para amostras de 3 plantas selecionadas ao acaso. Escreva o espaço amostral e determine qual é a probabilidade que:
 - a) Mais de uma planta seja resistente.
 - b) No máximo duas plantas sejam resistentes.
 - c) Nenhuma planta resistente.
 - d) Suponha que a probabilidade que uma planta seja resistente a uma determinada doença é 75%.
 - d1) Mais de uma planta seja resistente.
 - d2) No máximo duas plantas sejam resistentes.
 4. O responsável pelo restaurante de uma empresa suspeitou que o feijão que estava armazenado poderia estar contaminado com fungos, e realizou um experimento. Ele pegou aleatoriamente uma amostra de 5 saquinhos do produto e observou a presença ou não de fungos.
 - i) Determine (escreva) o espaço amostral.
 - ii) Qual a probabilidade de termos os eventos:
 - a) E_1 : Ter exatamente 2 saquinhos contaminados.
 - b) E_2 : Ter 2 ou mais saquinhos não contaminados.
 - c) E_3 : Ter pelo menos um saquinho não contaminado.
 - d) E_4 : Ter a primeiro ou o segundo saquinho contaminado.

- e) Considerando que a probabilidade de um saquinho estar contaminado seja de 0,30. Qual a probabilidade de termos:
- e₁) Exatamente 2 saquinhos Contaminados.
- e₂) Exatamente 1 saquinho Não Contaminado.
5. A probabilidade de que um médico faça o diagnóstico correto de uma doença é de 0,7. Dado que o médico fez um diagnóstico incorreto, a probabilidade de que o paciente entre com um processo é de 0,9. Qual é a probabilidade de que o médico erre o diagnóstico e seja processado pelo paciente?
6. De um total de 500 empregados, 200 possuem plano pessoal de aposentadoria complementar, 400 contam com o plano de aposentadoria complementar oferecido pela empresa e 200 empregados possuem ambos os planos. Sorteia-se aleatoriamente um empregado dessa empresa.
- a) Qual é a probabilidade de que ele tenha algum plano de aposentadoria complementar?
- b) Qual é a probabilidade de que ele não possua qualquer plano de aposentadoria complementar?
- c) Se o empregado conta com o plano de aposentadoria complementar oferecido pela empresa, qual é a probabilidade de que ele tenha plano pessoal de aposentadoria complementar?
- d) Se o empregado tem plano pessoal de aposentadoria complementar, qual é a probabilidade de que ele conte com o plano de aposentadoria complementar da empresa?

6 Variável aleatória e distribuição de probabilidades

Vimos que utilizando uma **Tabela de frequência**, podemos obter os valores possíveis para uma dada variável e suas respectivas frequências. Evita-se, dessa forma, sem grande perda de informação, a repetição, às vezes muito grande, dos valores da variável. De forma análoga, vamos formalizar, com a ajuda da Teoria das Probabilidades, o comportamento de variáveis na população, associando a cada possível valor sua probabilidade de ocorrência.

Como já mencionado no capítulo anterior, além da probabilidade poder ser obtida a partir do estudo das frequências, ela também pode ser deduzida a partir de suposições feitas a respeito da realização do fenômeno. Na formalização que foi realizada com a introdução de probabilidades, ocupou-se apenas das variáveis quantitativas. Vamos distinguir entre os casos discreto e contínuo, pois a atribuição de probabilidades será diferente em cada situação. As variáveis qualitativas podem ser em algumas ocasiões e com o devido cuidado, tratadas como discretas na atribuição de probabilidades.

Uma quantidade X , associada a cada possível resultado do espaço amostral, é denominada de **variável aleatória discreta**, se assume valores num conjunto enumerável ($X \in \mathbb{N}$), com certa probabilidade. Por outro lado, será denominada **variável aleatória contínua**, se seu conjunto de valores é qualquer intervalo dos números reais ($X \in \mathbb{R}$), o que seria um conjunto não enumerável.

Porém, essa atribuição (**discretas** ou **contínuas**) não é absoluta e depende do instrumento de medida e do estudo que está sendo feito. Por exemplo, a variável: número de filhos em famílias é discreta, enquanto tempo de reação de certo medicamento, é contínua. A discussão sobre classificação de variáveis, feita no Capítulo 1, será utilizada em todo o texto e a palavra aleatória é acrescida aqui para indicar que, a cada possível valor, atribuímos uma probabilidade de ocorrência. No caso discreto, a atribuição é similar à tabela de frequência: já no caso contínuo, utilizaremos uma generalização da ideia de histograma.

Para facilitar o desenvolvimento da teoria das probabilidades é importante associarmos **um número** a um evento aleatório e calcularmos a probabilidade de ocorrência desse número em vez da probabilidade do evento.

Exemplo: Observar o estado de 3 equipamentos de um laboratório e determinar sua condição (DEFEITO - D ou BOM - B)

$S = (BBB), (BBD), (BDB), (DBB), (BDD), (DBD), (DDB), (DDD)$

Eventos:

E_1 : Ter exatamente 2 equipamentos em bom estado.

$E_1: \{(BBD), (BDB), (DBB)\}$

E_2 : Ter 2 ou mais equipamentos em bom estado.

$E_2: \{(BBB), (BBD), (BDB), (DBB)\}$

E_3 : Ter pelo menos 1 equipamento em bom estado (Complemento de ter 3 defeituosos).

$E_3: \{(BBB), (BBD), (BDB), (DBB), (BDD), (DBD), (DDB)\};$

$E_3^c: \{(DDD)\}.$

X = Número de equipamentos em bom estado, $\Rightarrow x = 0, 1, 2, 3$. (Observação: Normalmente a variável aleatória é representada por uma letra maiúscula e o valor que ela assume pela mesma letra minúscula).

$$P(E_1) = P(X = 2)$$

$$P(E_2) = P(X \geq 2)$$

$$P(E_3) = P(X \geq 1) = 1 - P(E_3^c) = 1 - P(X = 0)$$

Mediante uma variável previamente definida, estamos associando um número, ou uma série de números, a cada evento aleatório do espaço amostral e em lugar de calcularmos a probabilidade de ocorrência de um evento, calcularemos $\Rightarrow$ a probabilidade de ocorrência daquele número (ou números).

A variável definida acima é chamada de variável aleatória.

Definição 6: variável aleatória

É uma variável qualquer que associa a cada evento do espaço amostral um único número real (ou uma série de números). Como cada evento aleatório está relacionando com uma probabilidade de ocorrência, então cada um dos possíveis valores da variável aleatória estará também relacionado com uma probabilidade de ocorrência.

O conjunto de valores que pode assumir uma variável aleatória é denominado **domínio de uma v.a.**

Notação: variável aleatória: X, Y, Z (maiúsculo)

Valores que assume: $x_1, x_2, x_3, \dots, y_1, y_2, y_3, \dots, e z_1, z_2, z_3, \dots$

Probabilidade que a variável aleatória X assuma o valor x : representa-se por $P(X = x)$.

Probabilidade que a variável aleatória X seja menor ou igual a x : representa-se por $P(X \leq x)$.

Observação: Por convenção as variáveis aleatórias são sempre **quantitativas**, mesmo referindo-se a atributos ou categorias (ou seja, Variáveis qualitativas).

6.1 Distribuição de probabilidades

Definição: é uma função que relaciona os valores que assume uma variável aleatória com suas respectivas probabilidades de ocorrência.

$$f : X \rightarrow P(X = x)$$

a) **Distribuição de probabilidades Discreta:** É a distribuição de probabilidades associada a uma variável aleatória discreta. Em muitos casos é possível construir uma expressão analítica (modelo) para esta função da forma:

$$P(X = x) = f(x), \text{ com } x_1, x_2, \dots, x_k$$

em que $f(x)$ é chamada de **função de probabilidade**.

Nos casos em que não seja possível, a distribuição de probabilidades fica representado por uma tabela na forma:

X	x_1	x_2	x_3	$\dots$	x_k
$P(X = x_i)$	P_1	P_2	P_3	$\dots$	P_k

Em qualquer um dos casos, a distribuição de probabilidades discreta deve satisfazer:

$$\sum_{i=1}^k P(X = x_i) = P_1 + P_2 + \dots + P_k = 1 \Leftrightarrow P(\Omega) = 1$$

Observação: a fórmula $P(E) = \frac{n(E)}{n(\Omega)}$, em que $n(E)$ é o número de casos favoráveis e $n(\Omega)$ é o número de casos possíveis, só é válida para o caso em que os acontecimentos tenham a mesma probabilidade. Além disso, à medida que "n" aumenta, torna-se difícil determinar todo espaço amostral, para contar os elementos, já que, por exemplo no caso de um experimento aleatório com duas respostas possíveis $n(\Omega) = 2^n$.

As variáveis aleatórias que assumem valores em um conjunto enumerável serão denominadas **discretas**.

6.2 Distribuição Binomial (Discreta)

A distribuição binomial é aplicada frequentemente para descrever situações em que a variável de uma população em estudo **tem duas respostas possíveis (sucesso e fracasso)**. Tem-se interesse principalmente em duas categorias: item defeituoso ou insatisfatório versus item bom ou satisfatório e sucesso e falha que tenham ocorrido em uma amostra de tamanho fixo. A distribuição binomial é aplicada a eventos provenientes de uma série de experimentos aleatórios, que constituem o chamado Processo de Bernoulli (respostas sim e não).

Processo de Bernoulli

Esse processo é análogo àquele de jogar uma moeda. As seguintes suposições se aplicam:

- a) Cada experimento é dito ser uma tentativa. Existe uma série de tentativas, cada uma tendo dois resultados: sucesso ou falha;
- b) A probabilidade de sucesso é igual a algum valor constante para todas as tentativas;
- c) Os resultados sucessivos são estatisticamente independentes. A probabilidade de sucesso na próxima tentativa não pode variar, não importando quantos sucessos ou falhas tenham sido obtidos.

O processo de Bernoulli é comumente utilizado em aplicações da área de controle de qualidade. Cada novo item criado no processo de produção pode ser considerado como uma tentativa resultando em uma unidade com ou sem defeito. Esse processo não se limita a objetos; podendo ser usado em pesquisas eleitorais e de preferências dos consumidores por determinados produtos.

Distribuição Binomial

Quando um experimento aleatório com apenas 2 resultados possíveis (sucesso ou fracasso) é repetido " n " vezes, a variável aleatória discreta se torna uma variável Binomial, definida como:

X : número de sucessos ocorridos em " n " tentativas (ou experimentos).

Tem uma distribuição da forma:

$$P(X = x) = C_{n,x} p^x (1 - p)^{n-x}; \quad x = 0, 1, 2, \dots, n$$

em que $C_{n,p} = \binom{n}{x} = \frac{n!}{x!(n-x)!}$ e p é a probabilidade de obter sucesso em uma única tentativa.

Importante: toda variável aleatória com a forma definida acima diz-se ter uma **distribuição Binomial** com parâmetros " n " e " p ". (notação $X \sim B(n, p)$).

A média e variância de uma variável aleatória com distribuição binomial são respectivamente:

Média = valor esperado = $E(X) = np$;

Variância = $\sigma^2 = V(X) = np(1-p)$

Exemplo: Sabe-se que a probabilidade de eficiência da vacina anti-gripal para idosos é de 80%. Num grupo de 10 idosos imunizados com a vacina anti-gripal, determine a probabilidade dos eventos:

- A- De que exatamente 6 idosos imunizados não tenham gripe.
- B- De que no máximo 5 idosos imunizados não tenham gripe.
- C- De que mais de 7 idosos imunizados não tenham gripe.

IMPORTANTE:

1- Identificar a variável aleatória, sua distribuição com respectivos parâmetros:

2- Escrever a questão na notação de probabilidade.

Vamos resolver o exemplo utilizado o R. Primeiramente, é necessário definir a variável aleatória. Uma variável aleatória adequada no cálculo das probabilidades solicitada é:

X : número de idosos que não contraíram gripe em um grupo de 10 idosos imunizados.

Essa variável aleatória é adequada pois se relaciona diretamente com as probabilidades pedida. Por exemplo: No item A, calcular a probabilidade de que 6 idosos não tenham gripe é calcular a $P(X = 6)$, devido à definição da variável aleatória.

Após a definição da variável aleatória, é preciso determinar a sua distribuição. A aplicação da vacina em cada idoso pode ser considerado como um ensaio que pode produzir apenas dois resultados: o idoso ter gripe ou o idoso não ter gripe. O fato de um idoso imunizado ter ou não gripe não interfere na chance de outro idoso imunizado contrair ou não a gripe, ou seja, os ensaios são independentes. É possível (e razoável) considerar a eficiência da vacina como a probabilidade de cada idoso imunizado não contrair a gripe.

Resumindo: o experimento consiste na realização de 10 ensaios independentes (a vacinação dos 10 idosos), que pode produzir apenas dois resultados (ter ou não gripe) e cada ensaio tem a mesma probabilidade de produzir o resultado não ter gripe, que é 0,8 (80%). Portanto, todas as condições para utilizar a distribuição binomial para a variável aleatória X definida anteriormente são atendidas. Portanto, $X \sim B(n, p)$. Para descobrir os valores dos parâmetros n e p da distribuição binomial, basta observar que são 10 os idosos imunizados e que, a probabilidade de sucesso em cada imunização é de 0,8, pois, da forma como a variável aleatória foi definida, o sucesso é o idoso não ter gripe. Portanto, $n = 10$ e $p = 0,8$. Logo, $X \sim B(10; 0,8)$.

Definidos a variável aleatória, a sua distribuição e os seus parâmetros, estamos prontos para calcular as probabilidades solicitadas. O item A do exemplo pede para calcular a probabilidade de exatamente 6 idosos não terem gripe. Considerando-se a variável aleatória X definida anteriormente, deseja-se então calcular $P(X = 6)$. Na Figura 22 são apresentados os passos para a realização do cálculo dessa probabilidade.




Figura 22: Passos a serem executados no R para o cálculo de probabilidades por meio da distribuição Binomial com $n = 10$, $x = 6$ e $p = 0,8$.

Como deseja-se calcular $P(X = 6)$, basta consultar o valor na janela correspondente e obter o resultado $P(X = 6) = 0,0881$. Ou seja: a probabilidade de exatamente 6 idosos não terem gripe é igual a 0,0881.

No item B do exemplo é solicitado que se obtenha a probabilidade de que no máximo 5 idosos não tenham gripe. Pelas mesmas razões explicadas anteriormente, é possível definir X : número de idosos que não contraíram gripe em um grupo de 10 idosos imunizados e $X \sim B(10; 0,8)$. A probabilidade solicitada é $P(X \leq 5)$. Na Figura 23 são apresentados os comandos a serem executados no R para o cálculo da probabilidade requerida.




Figura 23: Passos a serem executados no R para o cálculo de probabilidades por meio da distribuição Binomial com $n = 10$, $x \leq 5$ e $p = 0,8$.

Observando-se a resposta conveniente na saída do R, apresentada na Figura 23, conclui-se que $P(X \leq 5) = 0,0328$. Logo, a probabilidade de que no máximo 5 idosos em um grupo de 10 imunizados não tenham gripe é igual a 0,0328.

No item C do exemplo é solicitado que se obtenha a probabilidade de que mais de 7 idosos não tenham gripe. A variável aleatória X : número de idosos que não contraíam gripe em um grupo de 10 idosos imunizados e $X \sim B(10; 0,8)$. A probabilidade solicitada é $P(X > 7)$. Na Figura 25 são apresentados os passos a serem executados no R para o cálculo dessa probabilidade.




Figura 24: Passos a serem executados no R para o cálculo de probabilidades por meio da distribuição Binomial com $n = 10$, $x > 7$ e $p = 0,8$.

Observando-se a resposta conveniente na saída do R ($P(X > 7)$), apresentada na Figura 25, conclui-se que $P(X > 7) = 0,6778$. Logo, a probabilidade de que mais de 7 idosos em um grupo de 10 imunizados não tenham gripe é igual a 0,6778.

OBSERVAÇÃO: A função do R, faz o acumulado abaixo, logo, quando se escolhe "cauda superior", o número indicado não entra no cálculo. Portanto, se desejássemos calcular a probabilidade de ser no mínimo 7 idosos, ou seja, $P(X \geq 7)$, deveria digitar no campo "Valores da Variável" o 6, como apresentado na Figura 25.




Figura 25: Passos a serem executados no R para o cálculo de probabilidades por meio da distribuição Binomial com $n = 10$, $x \geq 7$ e $p = 0,8$.

6.3 Distribuição Poisson (Discreta)

É usada quando se deseja determinar probabilidades de variáveis aleatórias discretas definidas como:

X : número de elementos (indivíduos) que ocorrem em um volume, um intervalo de tempo ou uma superfície determinada. (número de elementos por área, volume ou tempo, etc).

Neste caso X tem uma função de probabilidade da forma:

$$P(X = x) = e^{-\lambda} \frac{\lambda^x}{x!}; \quad x = 0, 1, 2, \dots$$

em que e é a base do logaritmo neperiano, sendo $e = 2,7172\dots$ e λ é o número médio de elementos (ou indivíduos que ocorrem no intervalo de tempo, superfície ou volume definido na variável aleatória X).

Média = valor esperado = $E(X) = \lambda$;

Variância = $\sigma^2 = V(X) = \lambda$.

OBS: Se tiver uma variável aleatória: número de elementos (indivíduos) que ocorrem em um intervalo, na qual, $E(X)$ apresente valor distante de $V(X)$, a Poisson não deve utilizada.

Exemplo: Sabe-se que o número médio de interrupções do serviço de internet a cada mês (4 semanas) é de 10 interrupções, qual é a probabilidade de que:

A: em uma semana ocorra, exatamente, 1 interrupção do serviço de internet ?

B: em uma semana ocorram, no máximo, 2 interrupções do serviço de internet?

C: em uma semana ocorram mais de 2 interrupções do serviço de internet?

Resolução do exemplo:

Em todos os itens do exemplo, é solicitada a probabilidade da ocorrência de interrupções do serviço de internet em uma semana.

Portanto, a variável aleatória X : número de interrupções do serviço de internet por semana, tem distribuição Poisson com algum parâmetro λ , ou seja, $X \sim \text{Poisson}(\lambda)$.

O parâmetro λ da distribuição Poisson é a média de ocorrências (elementos, indivíduos, ...) no intervalo considerado. Deseja-se encontrar a probabilidade de ocorrer uma certa quantidade interrupções em um semana. O valor de λ será, portanto, o número médio interrupções por semana. Sabe-se que a cada mês (4 semanas), em média, é de 10 interrupções. Logo, para se obter o valor de λ , será necessário fazer uma regra de 3, pois é conhecido o número médio 10 interrupções em 4 semanas e deseja-se obter o número médio o número médio de interrupções em 1 (uma) semana. Dessa forma, tem-se que 10 interrupções está para 4, assim como λ interrupções está para 1. Ou seja:

$$\frac{10}{4} = \frac{\lambda}{1} \implies 4\lambda = 10 \implies \lambda = 2,5.$$

A variável aleatória associada a esse experimento tem distribuição Poisson de parâmetro 2,5, ou seja, $X \sim \text{Poisson}(2,5)$.

O item A pede que seja calculada a probabilidade de se encontrar exatamente 1 interrupção do serviço de internet, na semana. Escrevendo em linguagem matemática, pede-se $P(X = 1)$. Para o cálculo dessa probabilidade usando o R, deve-se usar os comandos no R para o cálculo de probabilidades envolvendo a distribuição Poisson (Figura 26).




Figura 26: Sequência de comandos no R para o cálculo de probabilidades envolvendo a distribuição Poisson, quando X é exatamente igual a um valor.

Na Figura 27 são apresentados a sequência de comandos no R para o cálculo de probabilidades envolvendo

a distribuição Poisson, quando a variável é menor ou igual a um valor (cauda inferior); ou maior que um valor (cauda superior);.




Figura 27: Cálculo de probabilidades envolvendo a distribuição Poisson na resolução do exemplo e as respostas obtidas pelo programa R.

Observando-se as Figuras 26 e 27 é possível perceber que :

- a $P(X = 1) = 0,2565$. Portanto, a probabilidade de ocorrer exatamente, 1 interrupção do serviço de internet, na semana, é igual a 0,2565.

O item B do exemplo pede a probabilidade de ocorrer, no máximo, 2 interrupções do serviço de internet, na semana, Considerando-se a mesma variável aleatória definida anteriormente, conclui-se que $X \sim Poisson(2, 5)$ e pede-se $P(X \leq 2)$. Observando-se a Figura 27, percebe-se que:

- b $P(X \leq 2) = 0,5438$, ou seja, a probabilidade de ocorrer, no máximo, 2 interrupções do serviço de internet, na semana, é igual a 0,5438.
- c Já no item C é necessário calcular a probabilidade de se ter mais de 2 interrupções do serviço de internet, na semana, ou seja, $P(X > 2)$. Esse resultado também é apresentado na saída do R, como pode ser observado na Figura 27. Temos que $P(X > 2) = 0,4562$. Portanto, a probabilidade de se ter mais de 2 interrupções do serviço de internet, na semana é 0,4562.
- d OBS: se fosse pedido a probabilidade de se ter, **no mínimo**, 2 interrupções do serviço de internet, na semana, para calcular $P(X \geq 2)$, deve-se encontrar $P(X > 1)$ ou calcular $P(X = 2) + P(X > 2)$.

6.4 Exercícios

Para todos os exercícios, identificar a variável aleatória, sua distribuição com respectivos parâmetros e escrever a questão na notação de probabilidade.


1. Um laboratório químico encomendou uma remessa de 400 pHmetros. O fabricante sabe que 40 pHmetros enviados estão defeituosos. O laboratório inspecionará de 20 pHmetros escolhidos aleatoriamente e somente aceitará a remessa se ocorrer no máximo um pHmetro defeituoso. Qual a probabilidade de:
 - a) A remessa ser aceita?
 - b) Ter nenhum defeituoso?
 - c) Ter mais de 5 defeituosos?
2. Uma determinada fisioterapeuta atende, em média, 3 pacientes por hora. Qual a probabilidade dessa fisioterapeuta atender:
 - (a) Nenhum paciente em 30 minutos?
 - (b) No máximo dois paciente em 1 hora?
 - (c) Exatamente 5 paciente em 2 horas?
 - (d) Mais de 3 pacientes em 1 hora?
3. Em um livro de 600 páginas há 1200 erros de impressão. Qual a probabilidade que uma página contenha pelo menos 3 erros?
4. Um laboratório realiza 2 exames a cada 10 minutos. Qual a probabilidade de que em:
 - (a) 25 min realizem pelo menos 3 exames?
 - (b) 30 min realizem exatamente 5 exames?
 - (c) Não realizem exames em 15 min?
5. Uma remessa de 800 estabilizadores de tensão é recebida pelo controle de qualidade de uma empresa. São inspecionados 20 aparelhos da remessa, que será aceita se ocorrer no máximo um defeituoso. Há 80 defeituosos no lote. Qual a probabilidade do lote ser aceito?
6. Em momentos de pico chegam, em média, 1 avião por minuto em um determinado aeroporto.
 - (a) Determine a probabilidade de 3 chegadas em um minuto qualquer do horário de pico.
 - (b) Determine a probabilidade de que nenhum avião chegue nesse aeroporto no horário de pico.
 - (c) Se o aeroporto pode atender 2 aviões por minuto, qual a probabilidade de haver aviões sem atendimento imediato?
7. Sabe-se que 60% dos camundongos inoculados com soro estão protegidos contra determinada doença. Se cinco camundongos são inoculados, determine a probabilidade de que:
 - (a) nenhum camundongo tenha a possibilidade de contrair a doença.
 - (b) menos de dois camundongos tenham a possibilidade de contrair a doença.

- (c) mais de três camundongos tenham a possibilidade de contrair a doença.
 - (d) pelo menos 4 camundongos tenham a possibilidade de contrair a doença.
8. Uma certa doença pode ser curada através de procedimento cirúrgico em 80% dos casos. Dentre os que têm essa doença, sorteamos 15 paciente que serão submetidos à cirurgia. Fazendo alguma suposição adicional que julgar necessária, responda qual é a probabilidade de:
- (a) Todos serem curados?
 - (b) Pelo menos dois não serem curados?
 - (c) Ao menos 10 fiquem livres da doença?
9. Uma indústria de seringas garante que em 95% dos pedidos atendidos, os clientes ficam plenamente satisfeitos com o prazo de entrega e com a qualidade do produto. Uma drogaria fez 10 pedidos a essa indústria.
- (a) Qual a probabilidade de que fique plenamente satisfeito nos dez pedidos?
 - (b) Qual a probabilidade de que fique plenamente satisfeito em oito pedidos?
 - (c) Qual a probabilidade de que fique plenamente satisfeito, no mínimo, em seis pedidos?
 - (d) Qual a probabilidade de que fique plenamente satisfeito, no mínimo, em oito pedidos?
10. Numa cidade ouviu-se a opinião de 60 adultos sobre um projeto de lei proposto pela prefeitura. Os adultos pesquisados só poderiam responder "a favor" ou "contra". Como resultado, observou-se que 40 dos adultos pesquisados foram a favor do projeto. Se na realidade as opiniões pró e contra são igualmente divididas, qual é a probabilidade de ter obtido tal resultado?
11. Sabe-se que 20% dos animais submetidos a um certo tratamento não sobrevivem. Se esse tratamento foi aplicado em 20 animais e se X é o número de não sobreviventes:
- (a) Qual é a distribuição de X ?
 - (b) Calcule $P(X = 0)$
 - (c) Calcule $P(2 < X \leq 4)$
 - (d) Calcule $P(X \geq 2)$

6.5 Distribuição de probabilidades Contínua

É a distribuição de probabilidades associada a uma variável aleatória contínua. Neste caso não é possível associar diretamente uma probabilidade de ocorrência a cada valor da variável aleatória, devido à própria natureza da variável, são infinitos valores. Porém, mediante os gráficos construídos a partir da tabela de distribuição de frequências, é possível encontrar uma **função de densidade de probabilidades** (fdp) que permite determinar a probabilidade que os valores da variável aleatória estejam dentro de intervalos de interesse.

A distribuição de frequência baseada em histograma e polígonos de frequências usando uma ordenada com as densidades de frequências relativas: $dFri = \frac{Fri}{c}$.



Para variáveis dessa natureza, os elementos do contradomínio da função $f(\cdot)$ são os infinitos valores possíveis pertencentes a um intervalo. Além disso, valores específicos da variável correspondem a eventos de probabilidade nula. Com essa motivação é que foi concebida a função densidade de probabilidade (fdp), ou simplesmente função densidade, pela qual tais probabilidades podem ser calculadas. As condições que ela deve obedecer são:


- i) $f(x) \geq 0$, para qualquer valor de x ;
- ii) $\int_{-\infty}^{\infty} f(x) dx = 1$;
- iii) $P[a \leq x \leq b] = \int_a^b f(x) dx$, para quaisquer a e b .

Observe, assim, que se trata de uma função propositadamente elaborada de maneira que a área sob ela (pois $f(x) \geq 0$) seja igual a 1. Além disso, áreas abaixo da curva (referentes a um certo intervalo) são interpretadas diretamente como probabilidade.

I) A **Esperança** da v. a. **contínua** X , é denotada por $E(X)$ e definida por:

$$E(X) = \int_{-\infty}^{\infty} x f(x) dx; \text{ se } X \text{ for uma v.a. contínua;}$$

$$E(X^2) = \int_{-\infty}^{\infty} x^2 f(x) dx.$$



6.6 Distribuição Normal ou Gaussiana (Contínua)

É a mais importante distribuição de variáveis aleatórias contínuas, devido à sua enorme aplicação nos mais variados campos do conhecimento.

"Qualquer que seja a variável aleatória em estudo, é necessário reconhecer primeiro, qual é a *função de densidade de probabilidades* (fdp) associada a ela."

O reconhecimento da fdp é feito mediante algumas técnicas estatísticas que não são partes desta disciplina. Portanto, definimos uma distribuição Normal da seguinte maneira.

Seja X uma variável aleatória contínua; diz-se que X tem distribuição Normal (ou está distribuída normalmente ou distribuição Gaussiana) com parâmetros (média) e (desvio padrão), se ela tem uma função de densidade de probabilidade da forma:

$$f(x) = \frac{1}{\sqrt{2\pi}\sigma} \exp \left\{ -\frac{(x - \mu)^2}{2\sigma^2} \right\}; \quad -\infty < x < \infty \quad (1)$$


em que $\pi = 3,1416\dots$; $\mu = E(x)$ é a média da v.a. X , $\sigma^2 = V(x)$ é a variância da v.a. X .

Notação: $X \sim N(\mu, \sigma^2) \Rightarrow$ Lê-se: A variável aleatória X tem distribuição Normal com média μ e variância σ^2 .


A distribuição Normal é uma curva em forma de sino (ver figura) com as seguintes propriedades:

- a) $f(x)$ é simétrica em relação a μ ($\mu = Md = Mo$);
- b) $f(x) \rightarrow 0$ quando $x \rightarrow \pm\infty$ (assintótica em relação ao eixo x)
- c) O valor máximo de $f(x)$ ocorre para $x = \mu$.

Exemplo: Considere que a quantidade de princípio ativo (Dipirona Sódica), de certo analgésico, tenha distribuição Normal com média 500mg e desvio padrão 20mg.



(a) Normal com média 500 e desvio padrão 20



(b) Área cinza indicando a probabilidade de X ser maior que 525

Características importantes da distribuição Normal.

$$\int_{\mu-\sigma}^{\mu+\sigma} f(x)dx = 0,6826$$

$$\int_{\mu-2\sigma}^{\mu+2\sigma} f(x)dx = 0,9546$$



6.6.1 Distribuição Normal Padrão

A distribuição normal padrão é aquela com média nula ($\mu = 0$) e desvio padrão unitário ($\sigma = 1$). Seja $X : N(\mu, \sigma^2)$, então a variável aleatória Z definida por $Z = \frac{X-\mu}{\sigma}$ tem distribuição normal padrão. Indica-se por: $Z: N(0,1)$.

A probabilidade de que a variável $X : N(\mu, \sigma^2)$ pertença a um dado intervalo $[a, b]$ é convertida em termos da variável normal padronizada $Z : N(0, 1)$:

$$P(a < X < b) = P\left(\frac{a-\mu}{\sigma} < \frac{X-\mu}{\sigma} < \frac{b-\mu}{\sigma}\right) = P\left(\frac{a-\mu}{\sigma} < Z < \frac{b-\mu}{\sigma}\right) = (z_1 < Z < z_2)$$

em que $z_1 = \frac{a-\mu}{\sigma}$ e $z_2 = \frac{b-\mu}{\sigma}$.



(c) Área cinza indicando a probabilidade de $-1 < Z < 1$.

(d) Área cinza indicando a probabilidade de $-2 < Z < 2$.

A probabilidade $P(z_1 < Z < z_2)$ pode ser obtida através do cálculo integral da área hachurada, mas somente através de métodos numéricos, não tendo solução analítica, necessitando-se de recursos computacionais. Porém, quando não estiver à disposição um recurso computacional, pode-se utilizar a estratégia de padronização, pois para as áreas sob a distribuição normal padrão **existem tabelas** (Tabela 28).

TABELA DA DISTRIBUIÇÃO NORMAL PADRÃO : $P(Z > Z_\alpha) = \alpha$

Z	0	1	2	3	4	5	6	7	8	9
-3,0	0,9987	0,999	0,9993	0,9995	0,9997	0,9998	0,9998	0,9999	0,9999	1,000
-2,9	0,9981	0,9982	0,9982	0,9983	0,9984	0,9984	0,9985	0,9985	0,9986	0,9986
-2,8	0,9974	0,9975	0,9976	0,9977	0,9977	0,9978	0,9979	0,9979	0,998	0,9981
-2,7	0,9965	0,9966	0,9967	0,9968	0,9969	0,9970	0,9971	0,9972	0,9973	0,9974
-2,6	0,9953	0,9955	0,9956	0,9957	0,9959	0,9960	0,9961	0,9962	0,9963	0,9964
-2,5	0,9938	0,9940	0,9941	0,9943	0,9945	0,9946	0,9948	0,9949	0,9951	0,9952
-2,4	0,9918	0,9920	0,9922	0,9925	0,9927	0,9929	0,9931	0,9932	0,9934	0,9936
-2,3	0,9893	0,9896	0,9898	0,9901	0,9904	0,9906	0,9909	0,9911	0,9913	0,9916
-2,2	0,9861	0,9864	0,9868	0,9871	0,9874	0,9878	0,9881	0,9884	0,9887	0,989
-2,1	0,9821	0,9826	0,983	0,9834	0,9838	0,9842	0,9846	0,985	0,9854	0,9857
-2,0	0,9772	0,9778	0,9783	0,9788	0,9793	0,9798	0,9803	0,9808	0,9812	0,9817
-1,9	0,9713	0,9719	0,9726	0,9732	0,9738	0,9744	0,975	0,9756	0,9762	0,9767
-1,8	0,9641	0,9648	0,9656	0,9664	0,9671	0,9678	0,9686	0,9693	0,9700	0,9706
-1,7	0,9554	0,9564	0,9573	0,9582	0,9591	0,9599	0,9608	0,9616	0,9625	0,9633
-1,6	0,9452	0,9463	0,9474	0,9484	0,9495	0,9505	0,9515	0,9525	0,9535	0,9545
-1,5	0,9332	0,9345	0,9357	0,937	0,9382	0,9394	0,9406	0,9418	0,943	0,9441
-1,4	0,9192	0,9207	0,9222	0,9236	0,9251	0,9265	0,9278	0,9292	0,9306	0,9319
-1,3	0,9032	0,9049	0,9066	0,9082	0,9099	0,9115	0,9131	0,9147	0,9162	0,9177
-1,2	0,8849	0,8869	0,8888	0,8907	0,8925	0,8944	0,8962	0,8980	0,8997	0,9015
-1,1	0,8643	0,8665	0,8686	0,8708	0,8729	0,8749	0,8770	0,8790	0,8810	0,8830
-1,0	0,8413	0,8438	0,8461	0,8485	0,8508	0,8531	0,8554	0,8577	0,8599	0,8621
-0,9	0,8159	0,8186	0,8212	0,8238	0,8264	0,8289	0,8315	0,834	0,8365	0,8389
-0,8	0,7881	0,791	0,7939	0,7967	0,7995	0,8023	0,8051	0,8078	0,8106	0,8133
-0,7	0,7580	0,7611	0,7642	0,7673	0,7703	0,7734	0,7764	0,7794	0,7823	0,7853
-0,6	0,7257	0,7291	0,7324	0,7357	0,7389	0,7422	0,7454	0,7486	0,7517	0,7549
-0,5	0,6915	0,695	0,6985	0,7019	0,7054	0,7088	0,7123	0,7157	0,719	0,7224
-0,4	0,6554	0,6591	0,6628	0,6664	0,6700	0,6736	0,6772	0,6808	0,6844	0,6879
-0,3	0,6179	0,6217	0,6255	0,6293	0,6331	0,6368	0,6406	0,6443	0,648	0,6517
-0,2	0,5793	0,5832	0,5871	0,591	0,5948	0,5987	0,6026	0,6064	0,6103	0,6141
-0,1	0,5398	0,5438	0,5478	0,5517	0,5557	0,5596	0,5636	0,5675	0,5714	0,5753
0,0	0,5000	0,5040	0,5080	0,5120	0,5160	0,5199	0,5239	0,5279	0,5319	0,5359
0,0	0,5000	0,4960	0,4920	0,4880	0,4840	0,4801	0,4761	0,4721	0,4681	0,4641
0,1	0,4602	0,4562	0,4522	0,4483	0,4443	0,4404	0,4364	0,4325	0,4286	0,4247
0,2	0,4207	0,4168	0,4129	0,4090	0,4052	0,4013	0,3974	0,3936	0,3897	0,3859
0,3	0,3821	0,3783	0,3745	0,3707	0,3669	0,3632	0,3594	0,3557	0,3520	0,3483
0,4	0,3446	0,3409	0,3372	0,3336	0,3300	0,3264	0,3228	0,3192	0,3156	0,3121
0,5	0,3085	0,3050	0,3015	0,2981	0,2946	0,2912	0,2877	0,2843	0,2810	0,2776
0,6	0,2743	0,2709	0,2676	0,2643	0,2611	0,2578	0,2546	0,2514	0,2483	0,2451
0,7	0,2420	0,2389	0,2358	0,2327	0,2297	0,2266	0,2236	0,2206	0,2177	0,2148
0,8	0,2119	0,2090	0,2061	0,2033	0,2005	0,1977	0,1949	0,1922	0,1894	0,1867
0,9	0,1841	0,1814	0,1788	0,1762	0,1736	0,1711	0,1685	0,1660	0,1635	0,1611
1,0	0,1587	0,1562	0,1539	0,1515	0,1492	0,1469	0,1446	0,1423	0,1401	0,1379
1,1	0,1357	0,1335	0,1314	0,1292	0,1271	0,1251	0,1230	0,1210	0,1190	0,1170
1,2	0,1151	0,1131	0,1112	0,1093	0,1075	0,1056	0,1038	0,1020	0,1003	0,0985
1,3	0,0968	0,0951	0,0934	0,0918	0,0901	0,0885	0,0869	0,0853	0,0838	0,0823
1,4	0,0808	0,0793	0,0778	0,0764	0,0749	0,0735	0,0722	0,0708	0,0694	0,0681
1,5	0,0668	0,0655	0,0643	0,0630	0,0618	0,0606	0,0594	0,0582	0,0570	0,0559
1,6	0,0548	0,0537	0,0526	0,0516	0,0505	0,0495	0,0485	0,0475	0,0465	0,0455
1,7	0,0446	0,0436	0,0427	0,0418	0,0409	0,0401	0,0392	0,0384	0,0375	0,0367
1,8	0,0359	0,0352	0,0344	0,0336	0,0329	0,0322	0,0314	0,0307	0,0300	0,0294
1,9	0,0287	0,0281	0,0274	0,0268	0,0262	0,0256	0,0250	0,0244	0,0238	0,0233
2,0	0,0228	0,0222	0,0217	0,0212	0,0207	0,0202	0,0197	0,0192	0,0188	0,0183
2,1	0,0179	0,0174	0,0170	0,0166	0,0162	0,0158	0,0154	0,0150	0,0146	0,0143
2,2	0,0139	0,0136	0,0132	0,0129	0,0126	0,0122	0,0119	0,0116	0,0113	0,0110
2,3	0,0107	0,0104	0,0102	0,0099	0,0096	0,0094	0,0091	0,0089	0,0087	0,0084
2,4	0,0082	0,0080	0,0078	0,0075	0,0073	0,0071	0,0069	0,0068	0,0066	0,0064
2,5	0,0062	0,0060	0,0059	0,0057	0,0055	0,0054	0,0052	0,0051	0,0049	0,0048
2,6	0,0047	0,0045	0,0044	0,0043	0,0041	0,0040	0,0039	0,0038	0,0037	0,0036
2,7	0,0035	0,0034	0,0033	0,0032	0,0031	0,0030	0,0029	0,0028	0,0027	0,0026
2,8	0,0026	0,0025	0,0024	0,0023	0,0023	0,0022	0,0021	0,0020	0,0020	0,0019
2,9	0,0019	0,0018	0,0017	0,0017	0,0016	0,0016	0,0015	0,0015	0,0014	0,0014
3,0	0,0013	0,0010	0,0007	0,0005	0,0003	0,0002	0,0002	0,0001	0,0001	0,0000

Figura 28: Tabela da distribuição normal padrão $P(Z > z_\alpha)$.

6.7 Calculando a probabilidade com Distribuição Normal

6.7.1 Exemplo

Sabe-se que o tempo de duração de uma certa bateria (Marca WW) têm uma distribuição Normal com média 200 horas e desvio padrão 20 horas. Qual a probabilidade de que uma bateria escolhida ao acaso desta população tenha:

- um tempo de duração inferior a 225h.
- um tempo de duração superior a 225h.
- tempo de duração entre 200h e 225h .

Identificar a variável:

X : tempo de duração das baterias da marca WW e $X \text{ segue } Normal(\mu = 200, \sigma = 20)$

- $P(X < 225)$.
- $P(X > 225)$.
- $P(200 < X < 225)$.




Figura 29: Sequência de comandos no R para o cálculo de probabilidades, $P(X < x)$, envolvendo a distribuição Normal.




Figura 30: Sequência de comandos no R para o cálculo de probabilidades, $P(X > x)$ envolvendo a distribuição Normal.

Nas Figuras 29 e 30 são apresentados os comandos no Rcommander para o cálculo de probabilidades envolvendo a distribuição Normal.

Solução manual da questão (b), usando a Tabela Normal Padrão (Tabela 28):

X : tempo de duração das baterias da marca WW e $X : N(\mu = 200, \sigma = 20)$

$$\begin{aligned} P(X > 225) &= P\left(\frac{X - \mu}{\sigma} > \frac{225 - 200}{20}\right) \\ &= P(Z > 1,25) = 0,1056 \end{aligned}$$

Resolução da questão c) probabilidade de que tenha entre 200h e 225h de duração.

$$P(200 < X < 225) = P(X > 200) - P(X > 225) = 0,5000 - 0,1056 = 0,3944.$$

6.7.2 Construindo gráficos da Distribuição Normal

Se tivermos o interesse de construir os gráficos da Distribuição Normal associados às probabilidades dos casos a) $P(X < 225)$, b) $P(X > 225)$ e c) $P(200 < X < 225)$ do Exemplo 6.7.1 basta seguir os seguintes passos.




Figura 31: Sequência de comandos no R para construir gráficos da Distribuição Normal




Figura 32: Gráficos da Distribuição Normal associados às probabilidades dos casos a) $P(X < 225)$, b) $P(X > 225)$ e c) $P(200 < X < 225)$ do Exemplo 6.7.1

Uma interpretação do gráfico (b) da Figura 32 é a seguinte, existe 10,56% de probabilidade de que uma bateria escolhida ao acaso tenha tempo de duração maior que 225h.

6.7.3 Calculando quantis da Distribuição Normal

Algumas vezes, pode existir o interesse de saber qual valor da variável está associado a determinada probabilidade (quantil). No Exemplo 6.7.1, poderíamos estar interessado em saber que nível de valor de tempo deixa 5% da população acima.

$$P(X > x_q) = 0,05$$

Usando o R, obtemos que $x_q = 232,897h$, ou seja, 5% da população de baterias tem tempo de duração acima 232,9h.




Figura 33: Sequência de comandos no R para o cálculo de quantil envolvendo a distribuição Normal.

6.8 Distribuições amostrais: principais Teoremas

Uma **estatística** é uma variável aleatória que depende somente **da amostra** observada, e geralmente tem (segue) uma distribuição de probabilidade.

A distribuição de probabilidade de uma estatística é chamada **distribuição amostral**.

- Distribuição Amostral das Médias

Teorema 1: seja uma população infinita descrita por uma variável X com distribuição normal $N(\mu, \sigma^2)$. Se infinitas amostras de **tamanho n** são coletadas nessa população, então a **média $\bar{X}$** dessas amostras terá distribuição normal com **média μ** e **variância σ^2/n** .

Teorema 2 (Teorema Central do Limite): seja uma população descrita por uma **variável X com distribuição Qualquer** com uma **média μ** , e **variância σ^2** diferente da normal. Se infinitas amostras de **tamanho n (grande)** são coletadas nessa população, então a **média $\bar{X}$** dessas amostras terá **distribuição normal** com **média μ** e **variância σ^2/n** .

Exemplo 6.5: Sabe-se que a concentração de princípio ativo de um antibiótico (população) têm uma distribuição Normal com média 250 mg e desvio padrão 30 mg (variância de $900mg^2$). Qual a probabilidade de que a média de uma amostra de 9 comprimidos, escolhidos ao acaso desta população, tenha uma concentração de princípio ativo inferior a 220 mg.

Pelo Teorema 1, temos que a **média $\bar{X}$** segue uma distribuição normal e $\bar{X} \sim N\left(\mu_{\bar{X}} = \mu, \sigma_{\bar{X}}^2 = \frac{\sigma^2}{n}\right)$, logo,

$$\mu_{\bar{X}} = 250mg \text{ e } \sigma_{\bar{X}}^2 = \frac{900}{9} = 100mg^2, \text{ logo, } \sigma_{\bar{X}} = 10mg$$

$$P(\bar{X} < 220) = 0,00135, \text{ ou seja de } 1,35\%.$$




Figura 34: Sequência de comandos no R para o cálculo de probabilidades, $P(\bar{X} < 220)$ envolvendo a distribuição Normal.

- Distribuição amostral para a proporção

Em várias situações no meio científico o parâmetro de interesse pode ser a proporção. Da mesma forma que a média, conclusões sobre a **proporção populacional** serão tomadas com base em resultados de uma *amostra*, ou seja, na **proporção amostral**. Fundamentando-se no **Teorema 2** podemos ter a seguinte condição:

Se a v.a. $X \sim \text{Qualquer}(\mu, \sigma^2)$ e seja P a proporção relacionada a X , então a v.a.

$P \sim N\left(\mu_P = p, \sigma_P^2 = \frac{p(1-p)}{n}\right)$, para **amostras grandes**.

Teorema 3: seja uma população descrita por uma variável X com distribuição normal $N(\mu, \sigma^2)$. E sejam infinitas amostras de tamanho n coletadas nessa população, a partir das quais são calculadas $\bar{X}$ e S^2 . Então a variável,

$$t = \frac{\bar{X} - \mu}{\sqrt{\frac{S^2}{n}}}$$

tem uma distribuição conhecida como **t de Student**, e que tem como único parâmetro a constante $v = (n - 1)$ graus de liberdade (gl.).

- Distribuição amostral das variâncias

Teorema 4: seja uma população infinita descrita por uma variável X com distribuição normal $N(\mu, \sigma^2)$. E seja uma amostra aleatória de tamanho n coletada nessa população, a partir da qual é calculada s^2 . Então a estatística:

$$\chi^2 = \frac{(n-1)s^2}{\sigma^2} = \sum_{i=1}^n \frac{(X_i - \bar{X})^2}{\sigma^2},$$

tem uma distribuição conhecida Qui-quadrado, e que tem como único parâmetro a constante $v = (n - 1)$ graus de liberdade (gl.).

Teorema 5: sejam X e Y variáveis aleatórias independentes com distribuição Qui-quadrado com v_1 e v_2 graus de liberdade, respectivamente. Então a estatística:

$$F = \frac{X/v_1}{Y/v_2},$$

tem uma distribuição conhecida F de Snedecor com v_1 graus de liberdade no numerador e v_2 graus de liberdade no denominador.

6.9 Exercícios

1. Seja a seguinte distribuição de probabilidade discreta da v.a. X :

X	0	1	2	3	4	5
$P(X = x)$	0	p^2	p^2	p	p	p^2

- Ache o valor de " p ".
 - Calcule: $P(X \geq 4)$, $P(X < 3)$ e $P(x = 3)$.
2. Um jogador de basquete converte 90% dos lances livres. Se numa partida ocorrerem dez lances livres:
- Qual a probabilidade do jogador acertar oito lances livres?
 - Qual a probabilidade do jogador acertar todos os lances livres?
 - Qual é o número médio de acertos do jogador? Interprete.
3. Um pesquisador desenvolveu um teste para detectar um certo tipo de câncer. Ele usa o teste em pacientes com câncer e pacientes sem câncer e obtém uma taxa de falsos positivos de 5% (isto é, resultados positivos para pacientes sem câncer). Qual é a probabilidade de que em um grupo de 15 pessoas:
- Nenhuma pessoa tenha resultado positivo sem ter câncer?
 - No máximo 3 tenham resultados positivos sem ter câncer?
4. O peso de um produto tem distribuição Normal com média 500g e desvio padrão 36g. Qual a probabilidade de que um item deste produto escolhido ao acaso desta população tenha peso.
- Superior a 520g.
 - Superior a 550g.
 - Entre 450 e 550g.
 - Inferior a 520g.
 - Inferior a 380g.
 - Qual o peso do produto que deixa 5% acima.
 - Qual o peso do produto que deixa 5% abaixo.
 - Qual o peso do produto que deixa 75% abaixo.
5. O volume dos frascos de matéria prima para cosméticos tem distribuição normal com média 240ml e desvio padrão 25ml.
- Qual a probabilidade de um frasco ter menos de 243ml?
 - Qual a probabilidade de um frasco ter menos de 237ml?
 - Qual o volume que 55% dos frascos possuem quantidade acima desta?

6. Um instrumento de laboratório tem diâmetro distribuído normalmente com média $\mu = 5\text{mm}$ e variância $\sigma^2 = 0,04\text{mm}^2$. Suponha que o instrumento seja considerado defeituoso se o seu diâmetro diferir da média em mais de $0,1\text{mm}$. Qual é a probabilidade de encontrar-se um instrumento defeituoso?
7. Sabe-se que 80% das crianças de uma escola possuem cárie.
 - a) Qual é a probabilidade de uma amostra de 100 crianças mais de 70 tenham cárie?
 - b) Qual é a probabilidade de uma amostra de 50 crianças menos de 40 tenham cárie?
8. O tamanho dos peixes distribui-se normalmente com média 52cm e desvio padrão 16cm . Qual a probabilidade de que a média de uma amostra aleatória de 4 peixes tenha:
 - a) Menos de 40cm ?
 - b) Mais de 45cm ?
 - c) Entre 48 e 60cm ?
 - d) Entre 58 e 70cm ?
9. A probabilidade de ser necessária a correção de acidez de um produto químico é de 60%. Encomendou-se a análise 50 vidros deste produto. Qual é a probabilidade que:
 - a) Mais de 40 vidros necessitem de correção de acidez?
 - b) No máximo 10 vidros necessitem de correção de acidez?

7 TEORIA DA ESTIMAÇÃO

7.1 Introdução

A maioria dos resultados da chamada "evolução científica", como por exemplo, a descoberta de novos remédios, equipamentos e técnicas cirúrgicas na área da saúde, de novas tecnologias, novos materiais e novos produtos no meio industrial, são resultados obtidos a partir de **experimentos científicos**.

Na atividade científica, quando tudo que se dispõe é **de uma parte** dos elementos de uma população que se queira descrever (ou seja, uma amostra ou experimento), então a obtenção de informações e/ou conclusões a respeito da população não é direta, mas sim estará fortemente relacionada à *amostra*.

O ato de generalizar o resultado que temos de uma "parte" para o "todo", é chamado de *inferir*. **Inferência Estatística** é definida como o processo de obtenção de informações sobre uma população a partir de amostras. Ou seja, deve ficar claro que só tem sentido falar-se em Inferência Estatística quando não se conhecem (não foram analisados) todos os elementos da população.

A descrição populacional geralmente é feita mediante distribuições de frequência e através de medidas descritoras. Estas últimas são chamadas de *parâmetros populacionais*. Em geral os parâmetros são medidas de posição (média, mediana, proporção) e de dispersão (variância, desvio padrão), mas, pode haver o interesse em outras medidas.

Quando se dispõe apenas de uma parte dos elementos da população (uma amostra), o máximo que se pode conseguir são valores aproximados para os parâmetros desconhecidos (θ), conhecidos como *estimativas*. Assim, podemos definir **estimativa** como o valor aproximado, calculado a partir de uma amostra, de um parâmetro populacional desconhecido. Vale ressaltar que podemos ter estimativas **pontuais** ou **intervalares**.

Mas onde entra a **probabilidade** neste contexto?

Diante do processo de inferência, o pesquisador tem um desafio: a incerteza de generalizar o resultado, obtido em uma amostra ou experimento, para toda uma população. Como exemplo, vamos imaginar que um pesquisador descobriu uma nova substância para uma determinada doença. Um laboratório interessado em explorar esta nova substância, com o objetivo de lançar um remédio no mercado, realiza um experimento, de acordo com os órgãos competentes, e analisa o efeito do novo remédio em 1000 pessoas que tinham a doença. Os resultados indicam que o "novo" remédio realmente "cura" a doença. O laboratório, então, lança o remédio no mercado. Uma determinada pessoa que tem a doença compra o remédio. Surge aqui um questionamento.

- É certeza que o remédio vai curar esta pessoa?

Como os resultados obtidos pelo laboratório foram baseados em um experimento (1000 pessoas), realmente fica alguma dúvida!


- O que fazer então?

Eis que entra uma importante área da Estatística: a **Probabilidade**. Esta teoria passa a ser utilizada para *quantificar as incertezas existentes no processo de inferência*.

7.2 Estimação

Como comentado anteriormente, a descrição populacional pode se dar, mediante a distribuições de frequência e através de medidas descritoras. Estas últimas são chamadas de *parâmetros populacionais*.

Inferência Estatística



Logo, veremos alguns conceitos importantes para o entendimento geral.

Conceito 1: *Parâmetro populacional:* constante (na visão frequentista) que descreve uma população, em geral desconhecida.

Em geral, os parâmetros são medidas de posição (média, proporção, mediana) e de dispersão (variância), mas pode haver o interesse em outras medidas como contrastes e coeficientes (de correlação, de regressão). Quando se dispõe apenas de uma parte dos elementos da população (resultados de uma amostra ou experimento), o máximo que se pode conseguir são valores aproximados para os parâmetros desconhecidos, conhecidos como **Estimativas**. Assim, define-se o conceito a seguir.

Conceito 2: *Estimativa:* valor aproximado, calculado a partir de uma amostra, para um parâmetro populacional desconhecido.

Conceito 3: *Estimação:* processo pelo qual pode se obter uma estimativa.

Conceito 4: *Estimador:* corresponde à uma expressão algébrica utilizada para obter um valor aproximado de um parâmetro (fazer inferências sobre um parâmetro).

7.2.1 Exemplo

Mediante uma pesquisa queremos conhecer o gasto médio com internet móvel, dos jovens entre 15 e 25 anos que habitam em Alfenas.

População: todos os jovens entre 15 e 25 anos que habitam em Alfenas e são usuários de internet móvel (N).

Parâmetro: gasto médio com internet móvel (μ).

Amostra: por exemplo, 500 jovens, selecionados aleatoriamente (n).

Estimador: $\bar{X} = \frac{\sum_{i=1}^n x_i}{n}$.

Estimativa: 40,00 reais.

Usualmente, o estimador de um parâmetro é representado usando-se o símbolo desse parâmetro, com um "chapéu". No exemplo do estimador da média populacional, ele poderia, além da notação $\bar{X}$, ser representado por $\hat{\mu}$.

A inferência estatística lida essencialmente com a *estimação de parâmetros* e com a realização de *testes de hipóteses* referentes a esses parâmetros. Para a realização de **inferências** sobre os **parâmetros** faz-se necessário a quantificação das incertezas, que é feita por meio da **distribuição de probabilidades**.

7.2.2 A natureza da estimação

Existem dois tipos de estimação: *por ponto* e *por intervalo*. Quando simplesmente obtém-se uma estimativa para um parâmetro, diz-se que se trata de uma estimação *por ponto* ou *pontual*.

No entanto, **quase sempre a estimação por ponto, sozinha, é pouco informativa, porque ela não fornece uma ideia do grau de erro que se comete ao assumir o valor da estimativa como sendo igual ao do parâmetro desconhecido.**

Esse erro pode ser quantificado da seguinte forma. A partir da distribuição de amostragem dos estimadores, ou de funções apropriadas dos estimadores, é possível elaborar um intervalo $[a, b]$, de tal maneira que a probabilidade de que uma dada amostra contenha o verdadeiro valor do parâmetro desconhecido seja estabelecida, ou seja:

$$P[a < \theta < b] = \gamma \quad (2)$$

em que $\gamma = 1 - \alpha$ e α é a probabilidade de se cometer o erro tipo I, também chamado nível de significância e θ é o parâmetro sendo estimado.

A probabilidade γ mede o grau de confiança que se tem na estimação de θ , e é, portanto chamada de **coeficiente de confiança**. Os intervalos $[a, b]$ são denominados intervalos de confiança, e a sua elaboração é chamada de estimação por intervalo.

A interpretação do intervalo de confiança é a seguinte. Os valores $[a, b]$, obtidos com base em um certo critério a ser visto adiante, variam de amostra para amostra. Acredita-se, com a quantidade γ de confiança que o intervalo, conteria o verdadeiro valor do parâmetro populacional de interesse.

O ideal é que se tenham, para um valor de γ alto, intervalos os menores possíveis (mais estreitos), pois assim tem-se uma ideia muito próxima do valor de θ , que é **desconhecido**. Os valores de γ mais usuais, no meio científico, são: 90%, 95% ou 99%.

7.3 Estimadores pontuais

Seja X uma variável aleatória associada a uma população com média μ e variância σ^2 . Os estimadores pontuais mais apropriados para μ e σ^2 , obtidos a partir de uma amostra de tamanho " n ", retirada dessa população são:

Parâmetro	Estimador
μ	$\hat{\mu} = \bar{X} = \frac{\sum_{i=1}^n x_i}{n}$
σ^2	$\hat{\sigma}^2 = S^2 = \frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n-1}$
π	$\hat{\pi} = \hat{p} = \frac{ns}{n}$

Em que, ns é número de sucessos e n é o tamanho da amostra.

7.4 Estimadores por intervalo (intervalos de confiança) para μ

A seguir são apresentados os intervalos de confiança para a média μ e a proporção π populacional.

Considerando que se deseja a construção do intervalo seguindo o princípio da expressão (Equação 2) e usando-se o TEOREMA 2, (teorema central do limite na seção 6.8) pode-se chegar que o Intervalo de 100 $(1 - \alpha)\%$ de confiança para a média populacional μ será:

$$IC_{(1-\alpha)}(\mu) = \left[\bar{X} - z_{\left(\frac{\alpha}{2}\right)} \sqrt{\frac{\sigma^2}{n}} ; \bar{X} + z_{\left(\frac{\alpha}{2}\right)} \sqrt{\frac{\sigma^2}{n}} \right]$$

em que, $z_{\left(\frac{\alpha}{2}\right)} \sqrt{\frac{\sigma^2}{n}}$ pode ser chamada margem de erro (me) e/ou erro de estimação.

Teorema 2 (Teorema Central do Limite): *seja uma população descrita por uma variável X com distribuição Qualquer com uma média μ , e variância σ^2 diferente da normal. Se infinitas amostras de tamanho n (grande) são coletadas nessa população, então a média $\bar{X}$ dessas amostras terá distribuição normal com média μ e variância σ^2/n .*

Como nas situações práticas, no meio da pesquisa, **não conhecemos a variância populacional σ^2** , então a alternativa é usar o variância amostral S^2 . Nessa condição, conforme o **TEOREMA 3**, a média segue uma distribuição conhecida como **t de Student**, e que tem como único parâmetro a constante $v = (n - 1)$ graus de liberdade (gl.).

Então, para obter o $IC_{(1-\alpha)}(\mu)$ basta substituir σ^2 por S^2 e $z_{\frac{\alpha}{2}}$ por $t_{(n-1; \frac{\alpha}{2})}$, obtendo-se o seguinte intervalo.

7.4.1 Intervalo de 100 $(1 - \alpha)\%$ de confiança para a média populacional μ com a variância populacional σ^2 desconhecida será:

$$IC_{(1-\alpha)}(\mu) = \left[\bar{X} - t_{(n-1; \frac{\alpha}{2})} \frac{S}{\sqrt{n}} ; \bar{X} + t_{(n-1; \frac{\alpha}{2})} \frac{S}{\sqrt{n}} \right] \quad (3)$$

em que, $t_{(n-1; \alpha/2)} \frac{S}{\sqrt{n}}$ pode ser chamada margem de erro (me) e/ou erro de estimação.

Interpretação:

Existe $100(1 - \alpha)\%$ probabilidade de confiança que μ esteja contida no intervalo $[A, B]$, ou seja, esteja entre A e B.

7.4.2 Exemplo

Exemplo: Um fabricante deseja determinar o tempo médio de duração das baterias para notebook, por ele produzidas. Para tanto, o setor de qualidade analisou uma amostra de 8 baterias encontrando os seguintes resultados em horas:

6; 7; 7; 3; 4; 5; 4 e 2.

Encontrado uma média amostral igual a 4,75h e um desvio padrão de 1,83h. Assim:

Assumindo que tempo de duração das baterias segue uma distribuição Normal, encontre o intervalo de 95% para o tempo **médio** de duração das baterias e interprete.

Primeiramente deve-se identificar a média e desvio padrão amostral:

$$\bar{X} = 4,75h \text{ e } s = 1,83h$$

Um nível de confiança de 95% requer que $\alpha = 0,05$ e, portanto, que $\frac{\alpha}{2} = 0,025$

Assim, $t_{(n-1; \frac{\alpha}{2})} = t_{(7; 0,025)} = 2,365$, valor obtido na Tabela *t* (2), logo *me* será:

$$me = 2,365 \times \frac{1,83}{\sqrt{8}} = 1,53h$$

Portanto,

$$\begin{aligned} IC_{(1-\alpha)}(\mu) &= \left[\bar{X} - t_{(n-1; \frac{\alpha}{2})} \frac{S}{\sqrt{n}} ; \bar{X} + t_{(n-1; \frac{\alpha}{2})} \frac{S}{\sqrt{n}} \right] \\ &= [4,75 - 1,53; 4,75 + 1,53] \\ &= [3,22; 6,28] \end{aligned}$$

Interpretação:

Existe 95% de confiança de que tempo **médio** de duração das baterias esteja entre 3,22h e 6,28h.

7.4.3 Fazendo IC para μ no R, com o Rcommander (Rcmdr)

Na Figura 35 são apresentados a sequência de comandos no R para a construção do intervalo de confiança para a média populacional μ para a resolução do exemplo anterior.

Basta copiar e colar a rotina R, no R Script, digitar (informar), a média, o desvio padrão e tamanho amostral, bem como o nível de confiança. Depois, selecionar **todas as linhas de comando** e clicar em "Submeter" conforme Figura 35.

The screenshot shows the R Commander window. The 'Conjunto de Dados' (Data Set) field is empty, displaying '<Não há conjunto de dados ativo>'. The 'Modelo' (Model) field is also empty, displaying '<sem modelo ativo>'. The 'R Script' tab is active, showing the following code:

```
My= 4.75      # média amostral
DPy= 1.83     # desvio padrão amostral
ny= 8        # tamanho da amostra
conf=0.95    # nível de confiança#
alfa=1-conf;alfa # nível de significância#
me_mi=qt((alfa/2),ny-1,lower.tail = FALSE)*(DPy/sqrt(ny));me_mi #calculando a margem de erro#
IC_mi=cbind(My-me_mi,My+me_mi);IC_mi
```

The 'Output' tab shows the results of the commands:

```
> My= 4.75      # média amostral
> DPy= 1.83     # desvio padrão amostral
> ny= 8        # tamanho da amostra
> conf=0.95    # nível de confiança#
> alfa=1-conf;alfa # nível de significância#
[1] 0.05
> me_mi=qt((alfa/2),ny-1,lower.tail = FALSE)*(DPy/sqrt(ny));me_mi #calculando a margem de erro#
[1] 1.529918
> IC_mi=cbind(My-me_mi,My+me_mi);IC_mi
      [,1]      [,2]
[1,] 3.220082 6.279918
```

The final output for the confidence interval is highlighted with a black box.

Figura 35: Sequência de comandos para a construção do intervalo de confiança para a média populacional μ para a resolução do exemplo.

Se for calcular o intervalo de confiança manualmente (com calculadora), os quantis superiores da distribuição t de Student podem ser obtidos na tabela a seguir.

7.4.4 Tabela t de StudentTabela 2: Quantis superiores da distribuição t de Student com (gl) graus de liberdade e para diferentes probabilidades (α), com a notação - $P(|T| > t) = \alpha$.

α					α				
gl	0,05	0,025	0,01	0,005	gl	0,05	0,025	0,01	0,005
1	6,314	12,706	31,821	63,656	21	1,721	2,080	2,518	2,831
2	2,920	4,303	6,965	9,925	22	1,717	2,074	2,508	2,819
3	2,353	3,182	4,541	5,841	23	1,714	2,069	2,500	2,807
4	2,132	2,776	3,747	4,604	24	1,711	2,064	2,492	2,797
5	2,015	2,571	3,365	4,032	25	1,708	2,060	2,485	2,787
6	1,943	2,447	3,141	3,707	26	1,706	2,056	2,479	2,779
7	1,895	2,365	2,998	3,499	27	1,703	2,052	2,473	2,771
8	1,860	2,306	2,896	3,355	28	1,701	2,048	2,467	2,763
9	1,833	2,262	2,821	3,250	29	1,699	2,045	2,462	2,756
10	1,812	2,228	2,764	3,169	30	1,697	2,042	2,457	2,750
11	1,796	2,201	2,718	3,106	40	1,684	2,021	2,423	2,704
12	1,782	2,179	2,681	3,055	50	1,676	2,009	2,403	2,678
13	1,771	2,160	2,650	3,012	60	1,671	2,000	2,390	2,660
14	1,761	2,145	2,624	2,977	70	1,667	1,994	2,381	2,648
15	1,753	2,131	2,602	2,947	80	1,664	1,990	2,374	2,639
16	1,746	2,120	2,583	2,921	90	1,662	1,987	2,368	2,632
17	1,740	2,110	2,567	2,898	100	1,660	1,984	2,364	2,626
18	1,734	2,101	2,552	2,878	120	1,658	1,980	2,358	2,617
19	1,729	2,093	2,539	2,861	130	1,657	1,978	2,355	2,614
20	1,725	2,086	2,528	2,845	1000	1,646	1,962	2,330	2,581

7.5 Intervalo de confiança para a proporção (π) - aproximado pela Normal

Observação: A proporção equivale a uma média, e o intervalo de confiança será parecido com pequenas mudanças.

Uma das aplicações mais conhecidas da Inferência Estatística é a estimação de proporções, que pode ser de duas formas: estimação pontual, por meio de uma Estatística da amostra; ou intervalar, com a construção de intervalos de confiança. Com relação ao último caso, a ideia é construir intervalos de confiança, que estimam e representam incerteza ou imprecisão estatística associada a estimativas de proporções populacionais a partir de dados de uma amostra.

Um exemplo típico de intervalo de confiança é a apresentação dos resultados de uma pesquisa, em que se tem 95% de confiança de que a proporção de votos para um candidato político fica entre 0,38 e 0,44, com base em uma amostra da população votante. Os pesquisadores geralmente consideram uma “margem de erro” para determinar os limites de 0,38 e 0,44 para a proporção de interesse.

Em termos estatísticos, o intervalo de 0,38 a 0,44 é um intervalo com 95% de confiança e 95% é o nível de confiança.

Para construir o intervalo de confiança (IC) para uma certa proporção π , inicialmente consideramos o estimador $\hat{\pi} = \hat{p} = \frac{ns}{n}$, em que ns é a quantidade de sucessos e n é o tamanho da amostra.

Considerando $\bar{x} = \hat{p}$ e $s^2 = \hat{p}(1 - \hat{p})$ e o TEOREMA 2 (teorema central do limite), um intervalo de $100(1 - \alpha)\%$ de confiança para a proporção π de uma população será:

$$IC_{(\gamma)}(\pi) = \left[\hat{p} - z_{(\frac{\alpha}{2})} \sqrt{\frac{\hat{p}(1 - \hat{p})}{n}} ; \hat{p} + z_{(\frac{\alpha}{2})} \sqrt{\frac{\hat{p}(1 - \hat{p})}{n}} \right]. \quad (4)$$

7.5.1 Exemplo

Um instituto promoveu uma pesquisa para saber as intenções de voto para prefeito de uma cidade. Foi realizada a uma amostragem aleatória obtendo 1000 respostas de eleitores, das quais 410 eram em favor do candidato A. Construa um intervalo de 95% de confiança $IC_{[95\%]}$ para a proporção de votos (π) do candidato A nesta cidade.

Assim, tem-se $\hat{p} = \frac{410}{1000} = 0,41$, logo

$$\frac{\sqrt{\hat{p}(1 - \hat{p})}}{\sqrt{n}} = \frac{\sqrt{0,41(1 - 0,41)}}{\sqrt{1000}} = 0,0155.$$

Um nível de confiança de 95% requer que $\alpha = 0,05$ e, portanto, que $\frac{\alpha}{2} = 0,025$

Assim, $z_{\frac{\alpha}{2}} = z_{0,025} = 1,96$ (tomando o valor na Tabela 37, ou usando a função *qnorm* do R), logo *me* será:

$$me = z_{\frac{\alpha}{2}} \cdot \frac{\sqrt{\hat{p}(1 - \hat{p})}}{\sqrt{n}} = (1,96)(0,0155) = 0,0305$$

Ou seja, apresentou uma margem de erro de 3,05%.

Portanto,

$$\begin{aligned} IC_{(95\%)}(\pi) &= \left[\hat{p} - z_{\frac{\alpha}{2}} \cdot \frac{\sqrt{\hat{p}(1-\hat{p})}}{\sqrt{n}}; \hat{p} + z_{\frac{\alpha}{2}} \cdot \frac{\sqrt{\hat{p}(1-\hat{p})}}{\sqrt{n}} \right] \\ &= [0,41 - 0,0305; 0,41 + 0,0305] \\ &= [0,3795; 0,4405] \end{aligned}$$

Interpretação:

Existe 95% de confiança de que proporção de votos do candidato A nesta cidade esteja entre 37,95% e 44,05%.

7.5.2 Fazendo IC para π no R

Na Figura 36 são apresentados a sequência de comandos R para a construção do intervalo de confiança para a **proporção** populacional π , pela aproximação da distribuição Normal, na resolução do exemplo anterior.

Figura 36: Sequência de comandos para a construção do intervalo de confiança para a **proporção** populacional π na resolução do exemplo.

TABELA DA DISTRIBUIÇÃO NORMAL PADRÃO : $P(Z > Z_\alpha) = \alpha$

Z	0	1	2	3	4	5	6	7	8	9
-3,0	0,9987	0,999	0,9993	0,9995	0,9997	0,9998	0,9998	0,9999	0,9999	1,000
-2,9	0,9981	0,9982	0,9982	0,9983	0,9984	0,9984	0,9985	0,9985	0,9986	0,9986
-2,8	0,9974	0,9975	0,9976	0,9977	0,9977	0,9978	0,9979	0,9979	0,998	0,9981
-2,7	0,9965	0,9966	0,9967	0,9968	0,9969	0,9970	0,9971	0,9972	0,9973	0,9974
-2,6	0,9953	0,9955	0,9956	0,9957	0,9959	0,9960	0,9961	0,9962	0,9963	0,9964
-2,5	0,9938	0,9940	0,9941	0,9943	0,9945	0,9946	0,9948	0,9949	0,9951	0,9952
-2,4	0,9918	0,9920	0,9922	0,9925	0,9927	0,9929	0,9931	0,9932	0,9934	0,9936
-2,3	0,9893	0,9896	0,9898	0,9901	0,9904	0,9906	0,9909	0,9911	0,9913	0,9916
-2,2	0,9861	0,9864	0,9868	0,9871	0,9874	0,9878	0,9881	0,9884	0,9887	0,989
-2,1	0,9821	0,9826	0,983	0,9834	0,9838	0,9842	0,9846	0,985	0,9854	0,9857
-2,0	0,9772	0,9778	0,9783	0,9788	0,9793	0,9798	0,9803	0,9808	0,9812	0,9817
-1,9	0,9713	0,9719	0,9726	0,9732	0,9738	0,9744	0,975	0,9756	0,9762	0,9767
-1,8	0,9641	0,9648	0,9656	0,9664	0,9671	0,9678	0,9686	0,9693	0,9700	0,9706
-1,7	0,9554	0,9564	0,9573	0,9582	0,9591	0,9599	0,9608	0,9616	0,9625	0,9633
-1,6	0,9452	0,9463	0,9474	0,9484	0,9495	0,9505	0,9515	0,9525	0,9535	0,9545
-1,5	0,9332	0,9345	0,9357	0,937	0,9382	0,9394	0,9406	0,9418	0,943	0,9441
-1,4	0,9192	0,9207	0,9222	0,9236	0,9251	0,9265	0,9278	0,9292	0,9306	0,9319
-1,3	0,9032	0,9049	0,9066	0,9082	0,9099	0,9115	0,9131	0,9147	0,9162	0,9177
-1,2	0,8849	0,8869	0,8888	0,8907	0,8925	0,8944	0,8962	0,8980	0,8997	0,9015
-1,1	0,8643	0,8665	0,8686	0,8708	0,8729	0,8749	0,8770	0,8790	0,8810	0,8830
-1,0	0,8413	0,8438	0,8461	0,8485	0,8508	0,8531	0,8554	0,8577	0,8599	0,8621
-0,9	0,8159	0,8186	0,8212	0,8238	0,8264	0,8289	0,8315	0,834	0,8365	0,8389
-0,8	0,7881	0,791	0,7939	0,7967	0,7995	0,8023	0,8051	0,8078	0,8106	0,8133
-0,7	0,7580	0,7611	0,7642	0,7673	0,7703	0,7734	0,7764	0,7794	0,7823	0,7853
-0,6	0,7257	0,7291	0,7324	0,7357	0,7389	0,7422	0,7454	0,7486	0,7517	0,7549
-0,5	0,6915	0,695	0,6985	0,7019	0,7054	0,7088	0,7123	0,7157	0,719	0,7224
-0,4	0,6554	0,6591	0,6628	0,6664	0,6700	0,6736	0,6772	0,6808	0,6844	0,6879
-0,3	0,6179	0,6217	0,6255	0,6293	0,6331	0,6368	0,6406	0,6443	0,648	0,6517
-0,2	0,5793	0,5832	0,5871	0,591	0,5948	0,5987	0,6026	0,6064	0,6103	0,6141
-0,1	0,5398	0,5438	0,5478	0,5517	0,5557	0,5596	0,5636	0,5675	0,5714	0,5753
0,0	0,5000	0,5040	0,5080	0,5120	0,5160	0,5199	0,5239	0,5279	0,5319	0,5359
0,0	0,5000	0,4960	0,4920	0,4880	0,4840	0,4801	0,4761	0,4721	0,4681	0,4641
0,1	0,4602	0,4562	0,4522	0,4483	0,4443	0,4404	0,4364	0,4325	0,4286	0,4247
0,2	0,4207	0,4168	0,4129	0,4090	0,4052	0,4013	0,3974	0,3936	0,3897	0,3859
0,3	0,3821	0,3783	0,3745	0,3707	0,3669	0,3632	0,3594	0,3557	0,3520	0,3483
0,4	0,3446	0,3409	0,3372	0,3336	0,3300	0,3264	0,3228	0,3192	0,3156	0,3121
0,5	0,3085	0,3050	0,3015	0,2981	0,2946	0,2912	0,2877	0,2843	0,2810	0,2776
0,6	0,2743	0,2709	0,2676	0,2643	0,2611	0,2578	0,2546	0,2514	0,2483	0,2451
0,7	0,2420	0,2389	0,2358	0,2327	0,2297	0,2266	0,2236	0,2206	0,2177	0,2148
0,8	0,2119	0,2090	0,2061	0,2033	0,2005	0,1977	0,1949	0,1922	0,1894	0,1867
0,9	0,1841	0,1814	0,1788	0,1762	0,1736	0,1711	0,1685	0,1660	0,1635	0,1611
1,0	0,1587	0,1562	0,1539	0,1515	0,1492	0,1469	0,1446	0,1423	0,1401	0,1379
1,1	0,1357	0,1335	0,1314	0,1292	0,1271	0,1251	0,1230	0,1210	0,1190	0,1170
1,2	0,1151	0,1131	0,1112	0,1093	0,1075	0,1056	0,1038	0,1020	0,1003	0,0985
1,3	0,0968	0,0951	0,0934	0,0918	0,0901	0,0885	0,0869	0,0853	0,0838	0,0823
1,4	0,0808	0,0793	0,0778	0,0764	0,0749	0,0735	0,0722	0,0708	0,0694	0,0681
1,5	0,0668	0,0655	0,0643	0,0630	0,0618	0,0606	0,0594	0,0582	0,0570	0,0559
1,6	0,0548	0,0537	0,0526	0,0516	0,0505	0,0495	0,0485	0,0475	0,0465	0,0455
1,7	0,0446	0,0436	0,0427	0,0418	0,0409	0,0401	0,0392	0,0384	0,0375	0,0367
1,8	0,0359	0,0352	0,0344	0,0336	0,0329	0,0322	0,0314	0,0307	0,0300	0,0294
1,9	0,0287	0,0281	0,0274	0,0268	0,0262	0,0256	0,0250	0,0244	0,0238	0,0233
2,0	0,0228	0,0222	0,0217	0,0212	0,0207	0,0202	0,0197	0,0192	0,0188	0,0183
2,1	0,0179	0,0174	0,0170	0,0166	0,0162	0,0158	0,0154	0,0150	0,0146	0,0143
2,2	0,0139	0,0136	0,0132	0,0129	0,0126	0,0122	0,0119	0,0116	0,0113	0,0110
2,3	0,0107	0,0104	0,0102	0,0099	0,0096	0,0094	0,0091	0,0089	0,0087	0,0084
2,4	0,0082	0,0080	0,0078	0,0075	0,0073	0,0071	0,0069	0,0068	0,0066	0,0064
2,5	0,0062	0,0060	0,0059	0,0057	0,0055	0,0054	0,0052	0,0051	0,0049	0,0048
2,6	0,0047	0,0045	0,0044	0,0043	0,0041	0,0040	0,0039	0,0038	0,0037	0,0036
2,7	0,0035	0,0034	0,0033	0,0032	0,0031	0,0030	0,0029	0,0028	0,0027	0,0026
2,8	0,0026	0,0025	0,0024	0,0023	0,0023	0,0022	0,0021	0,0020	0,0020	0,0019
2,9	0,0019	0,0018	0,0017	0,0017	0,0016	0,0016	0,0015	0,0015	0,0014	0,0014
3,0	0,0013	0,0010	0,0007	0,0005	0,0003	0,0002	0,0002	0,0001	0,0001	0,0000

Figura 37: Tabela da distribuição normal padrão $P(Z > z_\alpha)$.

7.5.3 Construindo IC para μ e π no Rcommander a partir de um BANCO DE DADOS

Nas Figuras 35 e 36 foram apresentados a sequência de comandos R (Rcommander) para a construção do intervalo de confiança para os parâmetros populacionais μ e π , considerando a situação onde se **tem o resumo amostral (medidas descritivas)**. Porém, em alguns casos, o que se possui é um banco de dados, como apresentado como apresentado na Figura 38, referente ao estudo de caso: Projeto de criação de uma empresa de TI no Sul de Minas. Sendo que foram selecionadas, de forma aleatória, 50 empresas de cada setor (Comércio Agrícola (ComAgri), Logística/Transporte) e observadas diversas variáveis:

- i Setor da empresa ((ComAgri) e Log);
- ii Sexo do responsável (M, F);
- iii A empresa possui interesse em um software de gestão (S, N);
- iv A empresa possui dívida (S ou N);
- v Possui, na empresa, políticas de sustentabilidade (S, N);
- vi Número de funcionários na empresa;
- vii Renda mensal (salário) dos funcionários (em salários mínimos, sm);
- viii Número de novos funcionários na empresa.
- ix Faturamento anual (em 100 mil reais);
- x preço sobre o valor patrimonial da empresa (em pontos);

	A	B	C	D	E	F	G	H	I	J
1	ID	Setor	sexo_resp	interesse_sof	dívida	Preoc_sustentabilidade	n_Funcionarios	renda_func	n_novos_funcio	Faturamento
2	1	ComAgri	F	S	N	S	2	4,00	1	0,5
3	2	ComAgri	M	N	N	S	2	1,50	1	1,9
4	3	ComAgri	F	S	N	S	1	2,10	0	1,5
5	4	ComAgri	F	S	N	S	3	2,30	2	1,5
6	5	ComAgri	F	S	S	N	1	2,30	1	2,2
7	6	ComAgri	M	S	N	S	2	2,80	1	0,6
8	7	ComAgri	F	N	N	S	1	3,40	0	2,5
9	8	ComAgri	M	S	N	S	1	2,80	0	1,7
10	9	ComAgri	F	S	N	S	0	2,90	0	2,5
11	10	ComAgri	F	S	N	N	1	1,70	0	0,9
12	11	ComAgri	F	S	N	S	5	2,90	3	3,3
13	12	ComAgri	F	N	N	S	3	4,00	2	2,1
14	13	ComAgri	M	S	N	S	3	2,70	2	1,1
15	14	ComAgri	M	S	N	S	4	4,20	2	0,5
16	15	ComAgri	F	S	S	N	1	1,10	0	0,7

Figura 38: Representação da estrutura (parcial) do banco de dados referente ao estudo de caso: implantação de uma empresa de TI no Sul de Minas.

Nesse caso, deve-se, primeiramente, carregar o banco de dados no Rcommander (**ver passos no Vídeo: importar dados do Excel (XLSX) no Rcommander - no moodle**). Depois basta seguir os passos apresentados nas Figuras 40 e 39 nas quais se tem a sequência de comandos no Rcommander para a construção do intervalo de confiança para a **média** μ e **proporção** π populacionais, utilizando um banco de dados.

Consideremos a situação, na qual, o gestor deseja saber a renda média dos funcionários e a proporção de empresas que não possuem dívida, nos dois setores. Lembrando que, os dados do arquivo são referentes a uma amostra de 100 empresas.




Figura 39: Sequência de comandos para a construção do intervalo de confiança para a **média** populacional μ da variável *renda dos funcionários*, do banco de dados

$$IC_{(95\%)}(\mu) = [2,37; 2,77]$$

Interpretação:

Existe 95% de confiança que a renda média dos funcionários, das empresas da área de implantação da empresa de TI no Sul de Minas, esteja entre 2,37 e 2,77 salários mínimos.




Figura 40: Sequência de comandos para a construção do intervalo de confiança para a **proporção** populacional π da variável *presença de dívida*, do banco de dados.

$$IC_{(95\%)}(\pi) = [0,7647; 0,9135]$$

Interpretação:

Existe 95% de confiança que a proporção de empresas *sem* dívida, na área de implantação da empresa de TI, esteja entre 76,47% e 91,35%.

OBSERVAÇÃO: O resultado do intervalo de confiança fornecido pelo RCommander (Figura 40), foi construído de forma exata, a não pela aproximação da distribuição Normal. O intervalo de confiança construído pela aproximação da distribuição Normal, embora muito usado, pode apresentar resultados precários, **quando se tem pequenos valores de n ou, valores de p que se afastam de $1/2$** . A fórmula para o intervalo exato para a proporção, envolve um conhecimento mais complexo e não será tratada aqui, informações mais detalhadas podem ser encontradas em Ferreira (2005, pág. 273)^{iv}.

^{iv}FERREIRA, D.F. *Estatística Básica*, Editora UFLA, 2005

7.6 Dimensionamento da Amostra

7.6.1 Dimensionamento da Amostra para a Proporção π

Quando se deseja determinar o tamanho de uma amostra “ n ” que permita estimar π com margem de erro desejada me_d , sendo que a estimação será feita com $100(1 - \alpha)\%$ de confiança, pode-se utilizar a seguinte expressão:

$$n = \frac{\left(z_{\frac{\alpha}{2}}\right)^2 \cdot \hat{p}(1 - \hat{p})}{(me_d)^2}$$

Exemplo

Considerando $\hat{p} = \frac{410}{1000} = 0,41$, como no Exemplo 7.5.1, qual deverá ser o tamanho da amostra para se ter um erro de estimação (me_d : margem de erro desejada) de no máximo 2% (ou seja, 0,02), considerando um nível de confiança de 95%?

Com um nível de confiança de 95%, o nível de significância α é 5%, assim

$$\alpha = 0,05 \implies \frac{\alpha}{2} = 0,025 \implies z_{\frac{\alpha}{2}} = 1,96.$$

E como se deseja ter um erro de no máximo 0,02, então $me_d = 0,02$


Logo,

$$n = \frac{(1,96^2) \times 0,41(1 - 0,41)}{(0,02)^2} = 2323,2 = 2324 \text{ eleitores}$$

Observação 1: Sempre que for trabalhar com proporção deve-se usar para os cálculos o valor decimal e não em porcentagem.

Observação 2: Quando se deseja analisar em nível de proporção pode-se considerar o pior caso possível em relação à variância “ $S^2 = \hat{p}(1 - \hat{p})$ ”, quando $\hat{p} = 0,5$ que geraria a variância máxima.

Na Figura 41 são apresentados a sequência de comandos R para a para calcular tamanho amostral para estimar a **proporção** populacional π com uma margem de erro desejada, na resolução do exemplo anterior.



```

R Commander
Arquivo Editar Dados Estatísticas Gráficos Modelos Distribuições Ferramentas Ajuda
Conjunto de Dados: <Não há conjunto de dados ativo> Editar conjunto de dados Ver conjunto de dados Modelo: <sem modelo ativo>

R Script R Markdown

pap= 0.41      # proporção na amostra piloto#
merrod= 0.02   #margem de erro desejada, deve sempre ser em DECIMAL#
alfa=0.05     # nível de significância#
n_novo_pi=((qnorm(alfa/2,lower.tail = FALSE)*(sqrt(pap*(1-pap)))/merrod))^2 ; n_novo_pi

Output

> pap= 0.41      # proporção na amostra piloto#
> merrod= 0.02   #margem de erro desejada, deve sempre ser em DECIMAL#
> alfa=0.05     # nível de significância#
> n_novo_pi=((qnorm(alfa/2,lower.tail = FALSE)*(sqrt(pap*(1-pap)))/merrod))^2 ; n_novo_pi
[1] 2323.122
  
```

Figura 41: Sequência de comandos para calcular tamanho amostral para estimar a **proporção** populacional π na resolução do exemplo.

7.6.2 Dimensionamento da Amostra para a média μ

O termo $t_{(n-1; \alpha/2)} \times \frac{S}{\sqrt{n}}$ pode ser interpretado como uma margem de erro do estimador $\bar{X}$ em relação a μ , considerando, é claro, que a estimação foi feita com $100(1 - \alpha)\%$ de confiança. Tal margem de erro é denotada por "me". Portanto:

$$me = t_{(n-1; \alpha/2)} \times \frac{S}{\sqrt{n}}$$

Pode-se verificar que "me" depende de "n". A medida que "n" cresce "me" diminui, isto é, quanto maior for o tamanho da amostra maior será a **precisão** da estimativa.

Pergunta: Qual deveria ser o tamanho da amostra "n", que permita estimar μ com margem de erro me_d , sendo que a estimação será feita com $100(1 - \alpha)\%$ de confiança?

Resposta:

$$n = \left(\frac{t_{(n_1-1; \alpha/2)} \times S_1}{me_d} \right)^2$$

em que me_d é a margem de erro desejada, S_1 é o desvio padrão obtido a partir de uma amostra piloto (prévia) e n_1 é o tamanho da amostra piloto.

Exemplo

Considerando o Exemplo 7.4.2, o pesquisador achou a margem de erro (erro de estimação, $me=1,53$ horas,) de valor muito elevado e aceita cometer um erro de estimação de 0,7 horas. Qual deverá ser o tamanho da amostra para se ter um erro de estimação de no máximo 0,7 horas, considerando um nível de confiança de 95%?

Com um nível de confiança de 95%, o nível de significância α é 5%, assim

$$\alpha = 0,05 \implies \frac{\alpha}{2} = 0,025 \implies t_{(7,0,025)} = 2,365.$$

E como se deseja ter um erro de no máximo 0,7 horas, então $me = 0,7$. (sempre na mesma unidade da média)

Logo,

$$n = \left(\frac{2,365 \times 1,83}{0,7} \right)^2 = 38,2 \implies 39 \text{ baterias}$$

Caso de pequenas populações

Existem situações em que a população na qual será retirada a amostra é finita e pequena (quando $n/N < 0,05$). Nestas situações recomenda-se utilizar um fator de correção:

$$FC = \frac{N - n}{N - 1}.$$

- Para proporção tem-se:

$$n = \left(\frac{z_{\alpha/2} \sqrt{\hat{p}(1 - \hat{p})}}{me_d} \right)^2 \times FC.$$

- Para a média:

$$n = \left(\frac{t_{(n_1-1; \alpha/2)} \times s_1}{me_d} \right)^2 \times FC.$$

7.7 Exercícios

1. Uma determinada vacina foi testada num grupo de 100 pessoas e verificou-se que 75 delas **não** contraíram a doença.
 - a) Calcule a estimativa pontual para a proporção de pessoas vacinadas que contraíram a doença.
 - b) Construa um intervalo de confiança 95% para a proporção de pessoas vacinadas que contraíram a doença.
 - c) Se desejássemos um erro de estimação igual a 0,02, para uma confiança de 99% e poder de 80%, qual deveria ser o tamanho da amostra? (Considere os dados do problema, resultados de uma amostra piloto).
2. Um medicamento utilizado em enfermidades decorrentes de contraturas musculares dolorosas contém em sua formulação a *caféina* que é um estimulante do sistema nervoso central que atua sobre a musculatura estriada tornando-a menos susceptível à fadiga. Um pesquisador com o intuito de verificar a quantidade de *caféina* (em mg) num "medicamento A" analisou uma amostra aleatória de 18 comprimidos obtendo os seguintes resultados:

25	28	24	32	30	38	22	27	31
40	23	28	34	30	29	31	26	38

- a) Determine um $IC_{95\%}$ para a média da quantidade de *caféina*. Interprete os resultados.
3. A empresa de internet TUPI, de uma cidade, deseja saber o seu percentual de aprovação quanto à sua prestação de serviço. Para tanto realizou uma pesquisa onde foram entrevistadas 500 clientes das quais 200 aprovavam sua prestação de serviço..
 - a) Calcule a estimativa pontual para a proporção de clientes que a aprovam prestação de serviço.
 - b) Construa e interprete o intervalo de confiança 95% a proporção de clientes que a aprovam prestação de serviço da empresa
 - c) Se desejássemos ter um erro de estimação igual a 0,03, para uma confiança de 95% , qual deveria ser o tamanho da amostra?(Considere os dados do problema, resultados de uma amostra piloto).
 4. Um pesquisador tomou uma amostra de 20 pacientes com artrite para observar a concentração de fósforo no sangue (em mg/dL). Ele quer verificar se a concentração é igual a média dos indivíduos normais $\mu=3,0$ mg/dL. Ele obteve os seguintes resultados:

3,9	3,9	4,0	4,4	3,9	4,4	3,1	4,5	3,1	3,1
3,8	4,6	2,5	2,6	2,7	2,9	2,7	2,8	3,1	2,7.

- (a) Construa o intervalo de 95% de confiança para a média da concentração de fósforo no sangue de pacientes com artrite.
 - (b) Verifique, com nível de significância de 5%, se a média da concentração de fósforo no sangue de pacientes com artrite é igual a média da concentração dos indivíduos normais.
5. Numa pesquisa eleitoral, entrevistou-se 400 pessoas (eleitores), sendo que 240 delas preferiam o candidato A.

- a) Estime a proporção de eleitores que preferem o candidato A.
- b) Encontre um intervalo de confiança de 95% para a proporção π de eleitores de A. Interprete.
- c) Qual é o erro da estimativa para a estimação de π com 99% de confiança?
- d) Se desejássemos ter um erro de estimação igual a 2 %, qual deveria ser o tamanho da amostra?(Considere os dados do problema, resultados de uma amostra piloto).
6. Um médico deseja saber o tempo que um remédio contra dor de cabeça leva, em média, para aliviar a dor. Para isto selecionar aleatoriamente 25 pacientes e pede a eles que tomem tais pílulas quando tiverem dor de cabeça e anotem o tempo em minutos até o alívio da dor. O tempo médio de alívio da dor para esses pacientes foi de 13 min com desvio padrão de 5 min. Construa um intervalo de confiança de 95%. Interprete os resultados.
7. Uma cidade de interior de Minas Gerais conta com 532 relógios de medida de consumo de eletricidade (padrão CEMIG). Uma amostra aleatória simples de $n = 20$ empresas e comércios forneceu os seguintes dados de consumo mensal de energia, em kwh:

231	81	318	68	161	175	112	435	283	87
360	143	54	311	170	168	176	202	176	250

- a) Estime o consumo médio mensal por padrão na cidade e seu intervalo de confiança de 95%, e interprete. Qual foi o erro da estimativa (margem de erro)?
- b) Se desejássemos ter um erro de estimação igual a 35 kwh com uma confiança de 95% , qual deveria ser o tamanho da amostra?(Considere os dados do problema, resultados de uma amostra piloto).
8. Numa amostra de 12 microempresas do setor de tecnologia, encontrou-se que a média e o desvio padrão do número de horas trabalhadas por empregado por semana foi: média = 44 e desvio padrão = 6.
- a) Determine um IC_{95%} para a média do número de horas trabalhadas Interprete os resultados.
- b) Qual é o tamanho amostral necessário para se estimar o verdadeiro número médio de horas trabalhadas por empregado por semana com uma margem de erro de 2 horas, sendo que a estimação será feita com 95% de confiança? (Considere os dados do problema, resultados de uma amostra piloto).

8 TEORIA DA DECISÃO

8.1 Introdução

Vimos que, por meio da inferência estatística, informações acerca de uma população de interesse são obtidas, a partir de uma amostra.

Algumas vezes, no entanto, o interesse do pesquisador reside na verificação de **determinadas hipóteses, frequentemente para a tomada de alguma decisão acerca da população.**

A verificação de hipóteses de interesse, acerca da população, é chamada **teste de hipóteses**, ou **testes estatísticos**. A teoria de testes de hipóteses também é chamada **Teoria da Decisão**, pois frequentemente a rejeição ou não de hipóteses implicam em algum tipo de decisão.

8.2 Testes de hipóteses

Conceito 1 - Teste de hipóteses: verificação de hipóteses sobre a população, mediante critérios estatísticos.

Conceito 2 - Teoria da Decisão: corresponde à teoria de testes de hipóteses, pois a aceitação ou a rejeição de hipóteses frequentemente implicam em alguma **decisão** acerca da população.

Os testes de hipóteses podem se referir ao modelo utilizado para descrever a população de interesse, ou ainda, admitindo que o modelo seja satisfatório, podem se referir aos **parâmetros** do modelo. Por outro lado, as hipóteses podem se referir ao(s) parâmetro(s) do modelo probabilístico, por sua vez tido como satisfatório.

- Elementos de um teste de hipóteses

Geralmente (mas não necessariamente), os testes de hipóteses têm a seguinte estrutura: existe uma hipótese principal sob julgamento, chamada de **hipótese de nulidade**, representada pela notação H_0 . Se rejeitada, então uma outra hipótese candidata é considerada como, provavelmente verdadeira, a chamada hipótese alternativa, representada por H_1 ou H_a . Neste curso, somente serão abordados testes com duas hipóteses sob consideração simultaneamente.

Na prática, a aceitação ou rejeição de H_0 são feitas mediante a resultados de **uma amostra (ou experimento)**, com os quais, estimativas apropriadas são calculadas.

Se a distribuição de amostragem dos estimadores correspondentes for conhecida, então se pode calcular a probabilidade da estimativa observada ter ocorrido, **admitindo** a hipótese de nulidade H_0 **como verdadeira**. Ou seja, o valor do teste avalia a chance de ocorrerem os resultados encontrados nas amostras, assumindo que a hipótese nula seja verdadeira.

Se esta probabilidade for baixa, então existem bons motivos para **rejeitar essa hipótese** (H_0) e assumir H_1 .

Conceito 3 - Valor p : também denominado "nível descritivo", corresponde à probabilidade de se observar valores tão ou mais extremos (contra H_0) que o valor obtido na amostra, dado que hipótese nula H_0 seja verdadeira.

Se ocorrer "**pequeno**" Valor p , isto **evidencia** que a hipótese nula H_0 é **falsa**, pois a amostra fornece uma estimativa que teria uma probabilidade muito pequena de acontecer, se H_0 for verdadeira. O conceito

"pequeno" fica a cargo do pesquisador que decidirá qual nível de significância α adotar para comparar com o Valor p .

Então, na prática, o valor p é comparado ao nível de significância α predeterminado para decidir se a hipótese nula deve ser rejeitada. Aplica-se a seguinte regra de decisão:

- i) Se $p \leq \alpha$, rejeitamos H_0 ;
- ii) Se $p > \alpha$, não rejeitamos H_0 .

OBS: Quanto menor o valor p maior é a evidência contra a hipótese nula H_0 , contida nos dados.

Como para o cálculo do valor p faz-se necessário o uso de softwares (computadores), os testes de hipóteses, na ausência destes, eram realizados utilizando-se tabelas de probabilidade das respectivas estatísticas de teste, como será visto posteriormente.

- Erros Associados

Outros elementos importantes de um teste de hipóteses são os possíveis erros que se pode cometer, ao se utilizar determinada regra de decisão. São eles:

Conceito 4 - Erro Tipo I: consiste no erro que se comete ao **rejeitar** H_0 , sendo que ela é verdadeira.

Conceito 5 - Erro Tipo II: consiste no erro que se comete ao **aceitar** H_0 , sendo que ela é falsa.

A probabilidade de se cometer o erro tipo I é, em geral, representada pela letra grega α , e comumente também é chamada de *nível de significância do teste*. A probabilidade de ocorrência do erro tipo II é representada pela letra β .

Quando se rejeita H_0 , e ela de fato é falsa, isto consiste em uma decisão correta. Isto ocorre com probabilidade $1 - \beta$, valor esse que por sua vez recebe o nome de *poder do teste*.

Conceito 6 - Nível de significância: consiste no valor da probabilidade de se cometer um Erro Tipo I.

Conceito 7 - Poder do teste: consiste na probabilidade de rejeição de H_0 , quando de fato ela é falsa.

Já a probabilidade de não rejeição de H_0 , quando ela é verdadeira, corresponde ao valor $1 - \alpha$, que por sua vez não recebe um nome especial. Estes aspectos podem ser sumarizados, como na Tabela 7.1.

Tabela 7.1. Resultados possíveis em um teste de hipóteses, e suas probabilidades de ocorrência.

Decisão tomada	A verdade na população	
	H_0 é VERDADEIRA	H_0 é FALSA
H_0 é aceita	Decisão correta Probabilidade = $1 - \alpha$	Decisão errada (Erro Tipo II) Probabilidade = β
	Decisão errada (Erro Tipo I) Probabilidade = α	Decisão correta Probabilidade = $1 - \beta$
Probabilidade total	$(1 - \alpha) + \alpha = 1$	$(1 - \beta) + \beta = 1$

Para a realização de um teste de hipóteses é importante observar algumas condições:

1. A hipótese nula (H_0) é a hipótese que é sempre testada.
2. A hipótese alternativa (H_1) é desenvolvida como o complemento da hipótese nula, e representa a conclusão apoiada, se a hipótese nula for rejeitada.
3. A hipótese nula sempre se refere a um valor especificado do parâmetro da população (tal como μ), e não da estatística da amostra (tal como $\bar{X}$).
4. A afirmativa da hipótese nula H_0 **sempre contém um sinal de igualdade** com relação ao valor do parâmetro especificado.
5. A afirmativa da hipótese alternativa (H_1) nunca contém um sinal de igualdade com relação ao valor do parâmetro especificado.

8.2.1 Passos Gerais para a realização do teste

Dentro do contexto prático, estando evidentes o fenômeno e a variável em pesquisa, um teste de hipóteses pode ser realizado conforme os seguintes passos:

1. Identificar a afirmação, com o respectivo parâmetro em estudo e representar em notação matemática.
2. Montar as hipóteses alocando a afirmação, obedecendo o critério de que a hipótese nula (H_0) **irá conter o sinal de igualdade** com relação ao valor do parâmetro. Ou seja, toda afirmação que consistir em: $\theta = k$ ou $\theta \geq k$ ou $\theta \leq k$, entrará em (H_0) e, caso contrário em (H_1).
3. Adotar o nível de significância α , desejado.
4. Calcular a estatística do teste, de acordo com a distribuição do parâmetro testado.
5. Comparar a estatística do teste com o valor tabelado e aplicar a regra de decisão, ou calcular o valor p e aplicar a regra de decisão de **rejeitar** H_0 se $p \leq \alpha$.

8.3 Teste sobre a média

Em certas situações, decisões precisam ser tomadas a respeito de uma população, com base no valor de sua média μ .

Importante: Quando se **estima** a média de uma população, esse valor não é conhecido; entretanto, nos testes de hipóteses que envolvem a média da população, esse valor é supostamente conhecido (ou afirmado).

Os dois procedimentos usam de amostras para estimar ou para confirmar o parâmetro da população.

Passos para a realização do teste posterior a elaboração das hipóteses:

1. Identificar a afirmação prática e a afirmação **estatística** em relação a μ .
2. Escrever as hipóteses, lembrando que se a afirmação **estatística** contém um sinal de igualdade com relação ao valor do parâmetro a mesma será a hipótese nula (H_0), caso contrário será alocada na hipótese alternativa (H_1).
3. Adotar o nível de significância α , desejado.

4. Calcule a média e a variância amostral da variável em estudo.
5. Calcule o valor de t_c que em distribuição t com $n - 1$ graus de liberdade.

$$t_c = \frac{\bar{X} - \mu_0}{\frac{S}{\sqrt{n}}}$$

6. Aplique a **regra de decisão**:

CAMINHO I- Usando a Tabela:

- a) **Rejeitar** H_0 se $|t_c| > t_{(n-1; \frac{\alpha}{2})}$ quando, $\begin{cases} H_0 : \mu = \mu_0 \\ H_1 : \mu \neq \mu_0 \end{cases}$
- b) **Rejeitar** H_0 se $t_c < -t_{(n-1; \alpha)}$ quando, $\begin{cases} H_0 : \mu \geq \mu_0 \\ H_1 : \mu < \mu_0 \end{cases}$
- c) **Rejeitar** H_0 se $t_c > t_{(n-1; \alpha)}$ quando, $\begin{cases} H_0 : \mu \leq \mu_0 \\ H_1 : \mu > \mu_0 \end{cases}$

Não se rejeita H_0 , caso contrário.

CAMINHO II- Usando o valor p (que usaremos nas atividades):

Rejeitar H_0 se valor $p \leq \alpha$.

Não se rejeita H_0 , caso contrário.

Assim, os critérios de decisão para os testes unilaterais e bilaterais são:




Figura 42: Ilustração do critério de decisão de um teste de hipóteses sobre H_0 .

No caso do teste Bilateral, o valor de t tabelado deve ser procurado com probabilidade $\frac{\alpha}{2}$, pois a soma das duas "caudas" da distribuição corresponderá ao nível de significância do teste α .




Figura 43: Ilustração de critério de decisão para teste bilateral.

8.3.1 Testes de Hipóteses no R

Para todos os casos, sempre que possível e para fins didáticos os recursos do R pode-se ter três possíveis soluções:

1. fazendo as contas passo a passo, utilizando o R como uma calculadora;
2. usando uma função `t.test()` do existente no R. Pode ser usando rotina ou o Rcommander.

Exemplo: Um fabricante afirma que o tempo que as baterias para um equipamento eletrônico, por ele produzidas, duram em média, mais de 4,5 horas. Para saber se a afirmação do fabricante era verdadeira, uma empresa cliente analisou uma amostra de 8 baterias encontrando os seguintes resultados em horas:

6; 7; 7; 3; 4; 5; 4 e 2.

Fazer um teste de hipóteses, adotando um nível de significância de $\alpha = 0,05$ e concluir.

Afirmação: $\mu > 4,5h$.

A Figura 44 apresenta a sequência de comandos no R para a realização do teste de hipóteses sobre a média, considerando os dados do tempo de duração das baterias utilizado no exemplo anterior.

```
> #=====
> # USANDO A Função t.test() para MEDIA populacional
> # Realiza o teste t-Student para uma ou duas amostras.
> #=====
> # Exemplo secao 8.3.1
> amostra=c(6, 7, 7, 3, 4, 5, 4 , 2)
> mu0=4.5
> t.test(amostra,mu=mu0,alternative="greater")

One Sample t-test

data: amostra
t = 0.38592, df = 7, p-value = 0.3555
alternative hypothesis: true mean is greater than 4.5
95 percent confidence interval:
 3.522695      Inf
sample estimates:
mean of x
 4.75

> # usar alternative="greater", quando H1 tiver sinal de maior (>)
> # usar alternative="less", quando H1 tiver sinal de menor (<)
> # usar alternative="two.side" quando H1 tiver sinal de diferente (!=)
```

Figura 44: Passos a serem executados no R para a realização do teste de hipóteses bilateral para a média considerando os dados do tempo de duração das baterias.

$$H_0 : \mu \leq 4,5h$$

$$H_1 : \mu > 4,5h$$

Encontrado uma média amostral igual a 4,75h e um desvio padrão de 1,83h. Assim:

$$t_c = \frac{X - \mu_0}{s/\sqrt{n}} = \frac{4,75 - 4,5}{1,83/\sqrt{8}} = 0,386$$

8.3.2 Decisão usando a Tabela t

Adotando um nível de significância de $\alpha = 0,05$, e consultando a Tabela da distribuição t (Apêndice), com 7 graus de liberdade, encontra-se $t_{(gl,\alpha)} = t_{(7;0,05)} = 1,895$. Como, $0,386 < 1,895$, então **não há evidências** para se rejeitar H_0 , com 5% de significância.

Conclusão: Não existem evidências para rejeitar $H_0 : \mu \leq 4,5h$, ao nível de significância de 5%. Portanto, a afirmação do fabricante de que o tempo de duração das baterias, por ele produzidas, é maior que 4,5h é falsa.

8.3.3 Decisão usando o valor p

- Que deverá ser adotada para a solução das atividades.

Como comentado anteriormente o valor p deve ser comparado ao nível de significância α predeterminado para decidir se a hipótese nula deve ser rejeitada, e:

i) Se $p \leq \alpha$, **rejeitamos** H_0 ;

ii) Se $p > \alpha$, **não** rejeitamos H_0 .

Como $p > \alpha$ ($0,356 > 0,05$).

Conclusão: Não existem evidências para rejeitar $H_0 : \mu \leq 4,5h$ ($p=0,356$), ao nível de significância de 5%. Portanto, a afirmação do fabricante de que o tempo que as baterias, por ele produzidas, duram em média mais de 4,5h, é falsa.

Usando o Rcommander

Com base nestas informações, podemos obter os mesmos resultados usando o Rcommander, basta criar o banco de dados, como já apreendido e seguir os passos da Figura 45. A conclusão é a mesma colocada anteriormente.




Figura 45: Sequência de comandos para a execução do teste de hipóteses para a **média** populacional μ do exemplo

8.4 Testes sobre proporções

Para testar hipóteses sobre proporções, é necessário que se disponha de uma amostra com n elementos, a partir dos quais é calculada uma proporção amostral $\hat{p}$.

Nas situações em que a aproximação normal à distribuição binomial é adequada, então os critérios para os testes aproximados para proporções são:

Passos para a realização do teste:

1. Identificar a afirmação prática e a afirmação **estatística** e escrever as hipóteses, lembrando que se a afirmação **estatística** contém um sinal de igualdade a mesma será alocada na hipótese nula (H_0), caso contrário será alocada na hipótese alternativa (H_1).

2. Adotar o nível de significância α , desejado.
3. Calcule a proporção amostral da variável em estudo.
4. Calcule o valor de Z_c que em distribuição Normal Padrão e/ou respectivo valor- p .

$$z_c = \frac{\hat{p} - P_0}{\sqrt{\frac{\hat{p}(1-\hat{p})}{n}}}$$

5. Aplique a **regra de decisão**:

CAMINHO I - Usando a Tabela.

a) **Rejeitar** H_0 se $|z_c| > z_{\frac{\alpha}{2}}$ quando $\begin{cases} H_0 : \pi = P_0 \\ H_1 : \pi \neq P_0 \end{cases}$

b) **Rejeitar** H_0 se $z_c < -z_\alpha$ quando $\begin{cases} H_0 : \pi \geq P_0 \\ H_1 : \pi < P_0 \end{cases}$

c) **Rejeitar** H_0 se $z_c > z_\alpha$ quando $\begin{cases} H_0 : \pi \leq P_0 \\ H_1 : \pi > P_0 \end{cases}$

Não se rejeita H_0 , caso contrário.

CAMINHO II- Usando o valor p :

Rejeitar H_0 se valor $p \leq \alpha$.

Não se rejeita H_0 , caso contrário.

Exemplo: Um empresário desconfia que a proporção de pessoas satisfeitas com o tempo de espera para atendimento de seus clientes não está de acordo com sua meta, que é de no mínimo de 90%. Para testar essa hipótese ele entrevistou 50 pessoas e questionou quanto a satisfação sobre o tempo de demora para ser atendido. Dos 50 entrevistados 42 afirmaram estarem satisfeitos. A empresa está atingindo a meta? Teste com $\alpha = 5\%$.

Deseja-se realizar o seguinte teste de hipóteses com $\alpha = 5\%$

$$\begin{cases} H_0 : \pi \geq 0,9 \\ H_1 : \pi < 0,9 \end{cases}$$

8.4.1 Testes de Hipóteses para PROPORÇÃO (π) no R

Para o caso da proporção usaremos duas soluções:

1. fazendo as contas passo a passo, utilizando o R como uma calculadora, para aproximação Normal;
2. usando a função já existente no R, *binom.test* que faz o teste EXATO para PROPORÇÃO (π).

A Figura 46 apresenta a sequência de comandos no R para a realização do teste de hipóteses sobre a proporção, considerando os dados da proporção de pessoas satisfeitas com o tempo de espera para o atendimento dos clientes.

```

> #=====
> #          USANDO A FUNÇÃO binom.test
> #          Teste EXATO para PROPORÇÃO (PI)
> #=====
> # Cuidado: entrada com número de sucessos (ns) e tamanho da amostra (n)
>
> n=50
> ns=42
> p0<-0.90 # Valor a ser testado (assumido) para Pi#
>
> binom.test(ns, n, p = p0,alternative="less")

      Exact binomial test

data:  ns and n
number of successes = 42, number of trials = 50, p-value = 0.1221
alternative hypothesis: true probability of success is less than 0.9
95 percent confidence interval:
 0.0000000 0.9178149
sample estimates:
probability of success
          0.84

>
> # usar alternative="greater", quando H1 tiver sinal de maior (>)
> # usar alternative="less", quando H1 tiver sinal de menor (<)
> # usar alternative="two.side", quando H1 tiver sinal de diferente (!=)

```




Figura 46: Passos a serem executados no R para a realização do teste de hipóteses bilateral para a proporção considerando os dados da proporção de pessoas satisfeitas com o tempo de espera para o atendimento dos clientes.

8.4.2 Decisão usando o valor p

Como comentado anteriormente o valor p deve ser comparado ao nível de significância α predeterminado para decidir se a hipótese nula deve ser rejeitada, e:

- i) Se $p \leq \alpha$, **rejeitamos** H_0 ;
- ii) Se $p > \alpha$, **não** rejeitamos H_0 .

Conclusão: Não existem evidências para rejeitar $H_0 : \pi \geq 0,9$ ($p=0,1221$), ao nível de significância de 5%. Portanto, a proporção de pessoas satisfeitas com o tempo de espera para atendimento, está de acordo com a meta da empresa, que é de no mínimo de 90%.

OBS: É importante ressaltar que o resultado apresentado pelo R, com a função *binom.test*, é exato e vai ser um valor próximo do valor p obtido com estatística (z calculado) da aproximação pela Distribuição Normal.

8.4.3 Fazendo testes de hipóteses para μ e π no Rcommander a partir de um BANCO DE DADOS

Nas Figuras 44 e 46 foram apresentados a sequência de comandos R (Rcommander) para a execução dos testes de hipóteses para os parâmetros populacionais μ e π , considerando a situação onde se **tem o resumo amostral (medidas descritivas)**.

Porém, em alguns casos, o que se possui é um banco de dados, como apresentado como apresentado na

	A	B	C	D	E	F	G	H	I	J
1	ID	Setor	sexo_resp	interesse_sof	dívida	Preoc_sustentabilidade	n_Funcionarios	renda_func	n_novos_funcio	Faturamento
2	1	ComAgri	F	S	N	S	2	4,00	1	0,5
3	2	ComAgri	M	N	N	S	2	1,50	1	1,9
4	3	ComAgri	F	S	N	S	1	2,10	0	1,5
5	4	ComAgri	F	S	N	S	3	2,30	2	1,5
6	5	ComAgri	F	S	S	N	1	2,30	1	2,2
7	6	ComAgri	M	S	N	S	2	2,80	1	0,6
8	7	ComAgri	F	N	N	S	1	3,40	0	2,5
9	8	ComAgri	M	S	N	S	1	2,80	0	1,7
10	9	ComAgri	F	S	N	S	0	2,90	0	2,5
11	10	ComAgri	F	S	N	N	1	1,70	0	0,9
12	11	ComAgri	F	S	N	S	5	2,90	3	3,3
13	12	ComAgri	F	N	N	S	3	4,00	2	2,1
14	13	ComAgri	M	S	N	S	3	2,70	2	1,1
15	14	ComAgri	M	S	N	S	4	4,20	2	0,5
16	15	ComAgri	F	S	S	N	1	1,10	0	0,7

Figura 47: Representação da estrutura (parcial) do banco de dados referente ao estudo de caso: implantação de uma empresa de TI no Sul de Minas.

Nesse caso, deve-se, primeiramente, carregar o banco de dados no Rcommander (ver passos no Vídeo: importar dados do Excel (XLSX) no Rcommander - no moodle).

Depois basta seguir os passos apresentados nas Figuras 48 e 49, nas quais se tem a sequência de comandos no Rcommander para a execução dos testes de hipóteses para a **média μ e proporção π** populacionais, utilizando um banco de dados.

Consideremos a situação, na qual, o gestor deseja saber a renda média dos funcionários e a proporção de empresas *sem* dívida, na área de implantação da empresa de TI. Lembrando que, os dados do arquivo são referentes a uma amostra de 100 empresas.

Caso para a Média

O gestor deseja saber se a renda média dos funcionários, das empresas da área de implantação da empresa de TI no Sul de Minas é maior que a média nacional, que é de 2,5 salários mínimos (sm). Fazer um teste de hipóteses, adotando um nível de significância de $\alpha = 0,05$ e concluir.

Resolução:

Afirmção: $\mu > 2,5sm$.

$$H_0 : \mu \leq 2,5$$

$$H_1 : \mu > 2,5$$

Com base nestas informações e seguindo os passos da Figura 48




Figura 48: Sequência de comandos para a execução do teste de hipóteses para a **média** populacional μ da variável *renda familiar*, do banco de dados

Observando na saída do R, Figura 48, valor- $p = 0,2361$. Como $p > \alpha$ ($0,2361 > 0,05$), temos a seguinte conclusão.

Conclusão: Não existem evidências para rejeitar $H_0 : \mu \leq 2,5$ ($p=0,2361$), ao nível de significância de 5%. Portanto, renda média dos funcionários, das empresas da área de implantação da empresa de TI no Sul de Minas, **não** é maior que a média nacional.

Caso para a Proporção

O gestor deseja saber se a proporção de empresas tem ações da sustentabilidade, na área de implantação da empresa de TI é maior que a proporção no estado, que é de 12%. Fazer um teste de hipóteses, adotando um nível de significância de $\alpha = 0,05$ e concluir.

Resolução:

Afirmção: $\pi > 0,12$.

$$H_0 : \pi \leq 0,12$$

$$H_1 : \pi > 0,12$$

Com base nestas informações, escolher a variável "Preoc_sustentabilidade" clicar em "Opções" e seguir os passos da Figura 49.




Figura 49: Sequência de comandos para a execução do teste de hipóteses para a **proporção** populacional π da variável *empresas com ações da sustentabilidade*, do banco de dados.

Observando na saída do R, Figura 49, valor- $p = 0,0147$. Como $p < \alpha$ ($0,0147 < 0,05$), temos a seguinte conclusão.

Conclusão: Existem evidências para rejeitar $H_0 : \pi \leq 0,12$ ($p=0,0147$), ao nível de significância de 5%. Portanto, a proporção de empresas com ações de sustentabilidade, na área de implantação da empresa de TI é maior que a proporção no estado, que é de 12%.

8.5 Exercícios

- Um fabricante de um determinado produto alimentício afirma que a quantidade de calorias de seu produto não supera os 130kcal. Tomou-se uma amostra de 40 pacotes deste produto, encontrando-se uma média de 134 Kcal e um desvio padrão igual a 10Kcal.
a) Pode-se dizer que a afirmação do fabricante é correta? (Teste suas hipóteses com $\alpha = 5\%$).
- Um fabricante garante que mais 92% dos equipamentos que fornece a uma fabrica estão de acordo com as especificações exigidas. O exame de uma amostra de 200 peças desse equipamento revelou 15 defeituosas.
a) Teste a afirmativa do fabricante, ao nível de 1%, e conclua sobre a afirmativa.
- Um pesquisador tomou uma amostra de 20 pacientes com artrites para observar, a concentração de fósforo no sangue (em mg/dl). Ele quer verificar se a concentração é igual a média dos indivíduos normais que é $\mu=3,0$ mg/dl. Obteve os seguintes resultados:

3,9	3,8	4,0	2,5	4,4	2,6	3,9	2,7	4,4	3,1
3,9	4,6	3,1	2,7	4,5	2,8	3,1	2,9	3,1	2,7

Teste as hipóteses (com $\alpha = 5\%$).

- A infecção *E. canis* é uma doença canina, produzida por um carrapato e possível de ser transmitida para humanos. Na população geral a contagem média de células brancas no sangue é de 7,3 mil/mm. Acredita-se que pessoas infectadas com o *E. canis* possuam, em média, uma contagem mais baixa de células brancas no sangue. Para uma amostra de 15 pessoas infectadas, obteve-se os seguintes resultados. Teste a hipótese de que pessoas infectadas com o *E. canis* possuam, em média, uma contagem mais baixa de células brancas no sangue, (use $\alpha = 1\%$)

6,0	7,3	6,8	7	6,9	7,3	7,2	7	6,7	6,6	7,8	7	6,3	7,3	7,1
-----	-----	-----	---	-----	-----	-----	---	-----	-----	-----	---	-----	-----	-----

- Um laboratório que fabrica remédios para artrite afirma que a porcentagem de efeitos colaterais é de no máximo 9%. Um pesquisador examinou uma amostra de 73 pacientes tratados com a droga e observou que 8 apresentaram efeitos colaterais indesejáveis. Com base nesse resultado pode-se dizer que a afirmação do laboratório está correta? Use $\alpha = 0,1$.
- Os produtores de uma certa semente de milho afirmam que seu poder de germinação é de no mínimo 92%. Um fazendeiro tomou 80 sementes e plantou-as para testar se é verdadeira tal afirmação, 68 sementes germinaram. Este fato pode substituir cientificamente a acusação de que as sementes não têm no mínimo 92% de germinação? (Use $\alpha = 0,05$).

8.6 Tabela *t* de Student

Tabela 3: Quantis superiores da distribuição *t* de Student com (*gl*) graus de liberdade e para diferentes probabilidades (α), com a notação - $P(|T| > t) = \alpha$.

α					α				
gl	0,05	0,025	0,01	0,005	gl	0,05	0,025	0,01	0,005
1	6,314	12,706	31,821	63,656	21	1,721	2,080	2,518	2,831
2	2,920	4,303	6,965	9,925	22	1,717	2,074	2,508	2,819
3	2,353	3,182	4,541	5,841	23	1,714	2,069	2,500	2,807
4	2,132	2,776	3,747	4,604	24	1,711	2,064	2,492	2,797
5	2,015	2,571	3,365	4,032	25	1,708	2,060	2,485	2,787
6	1,943	2,447	3,141	3,707	26	1,706	2,056	2,479	2,779
7	1,895	2,365	2,998	3,499	27	1,703	2,052	2,473	2,771
8	1,860	2,306	2,896	3,355	28	1,701	2,048	2,467	2,763
9	1,833	2,262	2,821	3,250	29	1,699	2,045	2,462	2,756
10	1,812	2,228	2,764	3,169	30	1,697	2,042	2,457	2,750
11	1,796	2,201	2,718	3,106	40	1,684	2,021	2,423	2,704
12	1,782	2,179	2,681	3,055	50	1,676	2,009	2,403	2,678
13	1,771	2,160	2,650	3,012	60	1,671	2,000	2,390	2,660
14	1,761	2,145	2,624	2,977	70	1,667	1,994	2,381	2,648
15	1,753	2,131	2,602	2,947	80	1,664	1,990	2,374	2,639
16	1,746	2,120	2,583	2,921	90	1,662	1,987	2,368	2,632
17	1,740	2,110	2,567	2,898	100	1,660	1,984	2,364	2,626
18	1,734	2,101	2,552	2,878	120	1,658	1,980	2,358	2,617
19	1,729	2,093	2,539	2,861	130	1,657	1,978	2,355	2,614
20	1,725	2,086	2,528	2,845	1000	1,646	1,962	2,330	2,581

9 Teste de hipóteses para duas populações

9.1 Teste sobre razões de variâncias

Algumas vezes existe a importância de se saber se duas populações podem ser consideradas como tendo variâncias semelhantes. Isso corresponde em uma hipótese, dado que raramente as populações sob comparação são conhecidas em sua totalidade. Assim, um teste de hipóteses de interesse seria:

$$\begin{aligned} H_0 : \frac{\sigma_1^2}{\sigma_2^2} &= 1 \\ H_1 : \frac{\sigma_1^2}{\sigma_2^2} &\neq 1 \end{aligned}$$

Testes sobre razões de duas variâncias de populações diferentes, nas quais se pressupõe distribuição Normal, podem ser feitos mediante a distribuição F .

Regra de decisão: rejeitar H_0 se $F_c > F_{(n_1-1, n_2-1; \alpha/2)}$, em que, $F_c = \frac{S_1^2}{S_2^2}$, sempre adotando o maior valor (variância amostral) no numerador.

Ou,

CAMINHO II- Usando o valor p (que usaremos nas atividades):

Rejeitar H_0 se valor $p \leq \alpha$.

Não se rejeita H_0 , caso contrário.

9.1.1 Testes de Hipóteses para razão de variâncias no R

1. fazendo as contas passo a passo, utilizando o R como uma calculadora;
2. usando a função já existente no R, `var.test` que faz o teste F (distribuição de Fisher-Snedecor).

9.1.2 Exemplo

Um pesquisador deseja saber se um remédio produzido por dois laboratórios tem a mesma variabilidade na quantidade de princípio ativo. Para tanto retira uma amostra aleatória de 10 comprimidos do remédio vindo do Laboratório A e uma amostra aleatória de 10 comprimidos do Laboratório B, obtendo os seguintes resultados;

amostra A	16.6	13.4	14.6	15.1	12.9	15.2	14.0	16.6	15.4	13.0
amostra B	15.8	17.9	18.2	20.2	18.1	17.8	18.3	18.6	17.0	18.4

Pode-se afirmar que a **variância** da quantidade de princípio ativo dos remédios de A e B são iguais? Teste a hipótese usando um nível de significância $\alpha = 0,05$.

Deseja-se realizar o seguinte teste de hipóteses:

$$\begin{cases} H_0 : \frac{\sigma_A^2}{\sigma_B^2} = 1 \\ H_1 : \frac{\sigma_A^2}{\sigma_B^2} \neq 1 \end{cases}$$

A Figura 50 apresenta a sequência de comandos no R para a realização do teste de hipóteses para comparar a variância da quantidade de princípio ativo dos remédios de A e B.

The figure illustrates the steps to perform an F-test in R Commander. It shows the menu path: **Estatísticas** → **Variâncias** → **Teste F p/ 2 variâncias**. The 'Dados' tab in the dialog box is configured with 'Lab' as the group variable and 'quantidade' as the response variable. The 'Hipótese alternativa' is set to 'Bilateral'. The R console output shows the command `var.test(quantidade ~ Lab, alternative='two.sided', conf.level=.95, data=Dataset)` and the resulting p-value of 0.5928.

rowname	Lab	quantidade
1	1	16.6
2	2	13.4
3	3	14.6
4	4	15.1
5	5	12.9
6	6	15.2
7	7	14.0
8	8	16.6
9	9	15.4
10	10	13.0
11	11	15.8
12	12	17.9
13	13	18.2
14	14	20.2
15	15	18.1
16	16	17.8
17	17	10.3
18	18	18.6

```

> var.test(quantidade ~ Lab, alternative='two.sided', conf.level=.95, data=Dataset)

F test to compare two variances

data:  quantidade by Lab
F = 1.4442, num df = 9, denom df = 9, p-value = 0.5928
alternative hypothesis: true ratio of variances is not equal to 1
95 percent confidence interval:
 0.3587092 5.8141850
sample estimates:
ratio of variances
 1.444161

```

Figura 50: Sequência de comandos para a execução do teste de hipóteses para razão de variâncias da da quantidade de princípio ativo dos remédios de A e B, exemplo 9.1.2

$$\alpha = 0,05$$

$$\text{Valor } p = 0,5928$$

Como, Valor p não é menor que α .

Conclusão: Não existem evidências para rejeitar $H_0 : \frac{\sigma_A^2}{\sigma_B^2} = 1$ ($p=0,5928$), ao nível de significância de 5%.

Portanto, variância da quantidade de princípio ativo dos remédios produzidos nos laboratórios A e B são iguais.

9.2 Comparação de duas médias- caso de amostras independentes

Frequentemente deseja-se comparar duas populações, com relação às suas médias, para verificar simplesmente se são iguais ou diferentes. Nesse caso, embora de deseja verificar a hipótese ($\mu_1 = \mu_2$) é interessante perfazer um teste de hipóteses sobre ($\mu_1 - \mu_2 = 0$), pois a diferença ($\bar{X}_1 - \bar{X}_2$) também se relaciona com a distribuição t, o que permite compor critérios de decisão para testes de hipóteses.

Admitindo que as variâncias de ambas as populações sejam iguais, então o teste *t de Student* é indicado para testar igualdade de duas médias quando os grupos são independentes.

Passos para a realização do teste:

1. Identificar a afirmação prática e a afirmação **estatística** e escrever as hipóteses, lembrando que se a afirmação **estatística** contém um sinal de igualdade a mesma será alocada na hipótese nula (H_0), caso contrário será alocada na hipótese alternativa (H_1).
2. Adotar o nível de significância α , desejado.
3. Calcule a média e a Variância amostral de cada Grupo;
4. Calcule a variância ponderada, dada pela seguinte expressão:

$$S_p^2 = \frac{(n_1 - 1)S_1^2 + (n_2 - 1)S_2^2}{n_1 + n_2 - 2}$$

5. Calcule o valor de t_c que em distribuição t com ($v = n_1 + n_2 - 2$) graus de liberdade.

$$t_c = \frac{(\bar{x}_1 - \bar{x}_2) - 0}{\sqrt{S_p^2 \left[\frac{1}{n_1} + \frac{1}{n_2} \right]}}$$

6. Aplique a **regra de decisão**:

$$\text{a) Rejeitar } H_0 \text{ se } |t_c| > t_{(v; \frac{\alpha}{2})} \text{ quando, } \begin{cases} H_0 : (\mu_1 - \mu_2) = 0 \\ H_1 : (\mu_1 - \mu_2) \neq 0 \end{cases}$$

em que $v = n_1 + n_2 - 2$.

$$\text{b) Rejeitar } H_0 \text{ se } t_c < -t_{(v; \alpha)} \text{ quando, } \begin{cases} H_0 : (\mu_1 - \mu_2) \geq 0 \\ H_1 : (\mu_1 - \mu_2) < 0 \end{cases}$$

$$\text{c) Rejeitar } H_0 \text{ se } t_c > t_{(v; \alpha)} \text{ quando, } \begin{cases} H_0 : (\mu_1 - \mu_2) \leq 0 \\ H_1 : (\mu_1 - \mu_2) > 0 \end{cases}$$

Ou,

CAMINHO II- Usando **o valor p** (que usaremos nas atividades):

Rejeitar H_0 se valor $p \leq \alpha$.

Não se rejeita H_0 , caso contrário.

9.2.1 Exemplo

Um pesquisador deseja saber se um remédio produzido por dois laboratórios tem mesma média de quantidade de princípio ativo. Para tanto retira uma amostra de 10 comprimidos de A e uma amostra de 10 comprimidos de B, obtendo os seguintes resultados;

amostra A	16.6	13.4	14.6	15.1	12.9	15.2	14.0	16.6	15.4	13.0
amostra B	15.8	17.9	18.2	20.2	18.1	17.8	18.3	18.6	17.0	18.4

Pode-se afirmar que os remédios produzidos nos laboratórios A e B possuem mesma média de quantidade de princípio ativo? Teste a hipótese usando um nível de significância $\alpha = 0,01$.

Deseja-se realizar o seguinte teste de hipóteses:

$$\begin{cases} H_0 : \mu_A - \mu_B = 0 \\ H_1 : \mu_A - \mu_B \neq 0 \end{cases}$$

$$\alpha = 0,01$$

A Figura 51 apresenta a sequência de comandos no R para a realização do teste de hipóteses para a comparação de duas médias- caso de amostras independentes, no exemplo 9.2.1.




Figura 51: Passos a serem executados no R para a realização do teste de hipóteses bilateral para a comparação de duas médias- caso de amostras independentes, no exemplo 9.2.1

Valor $p = 0,00001$

Como, Valor p é menor que α .

Conclusão: Existem evidências para rejeitar $H_0 : \mu_A - \mu_B = 0$ ($p=0,00001$), ao nível de significância de 1%. Portanto, a quantidade média de princípio ativo dos remédios produzidos nos laboratórios A e B são diferentes.

OBSERVAÇÃO: Quando as variâncias das duas populações forem consideradas **diferentes**, deve-se marcar **Não** na Figura 51.

Nesse caso existem aproximações da estatística do teste, que são usadas no R, mas não serão mostradas teoricamente neste curso.

9.3 Comparação de duas médias - Caso de amostras dependentes

Teste t para dados EMPARELHADOS (ou pareados)

Algumas vezes pode existir o interesse em comparar tratamentos que são aplicados na mesma *unidade amostral*. Neste caso, cada unidade é utilizada duas vezes e, portanto os resultados são *dependentes*, deve-se nesta situação trabalhar com as *diferenças*.

Passos para a realização do teste:

1. Identificar a afirmação prática e a afirmação **estatística** e escrever as hipóteses, lembrando que se a afirmação **estatística** contém um sinal de igualdade a mesma será alocada na hipótese nula (H_0), caso contrário será alocada na hipótese alternativa (H_1).
2. Adotar o nível de significância α , desejado.
3. Calcule a média e a variância da *diferença*;
4. Calcule o valor de t_c que em distribuição t com $n - 1$ graus de liberdade.

$$t_c = \frac{\bar{X}_d - d_0}{\frac{S_d}{\sqrt{n}}}$$

5. Aplique a **regra de decisão**:

$$6. \text{ Rejeitar } H_0 \text{ se } |t_c| > t_{(n-1; \frac{\alpha}{2})} \text{ quando, } \begin{cases} H_0 : \mu_d = d_0 \\ H_1 : \mu_d \neq d_0 \end{cases}$$

$$7. \text{ Rejeitar } H_0 \text{ se } t_c < -t_{(n-1; \alpha)} \text{ quando, } \begin{cases} H_0 : \mu_d \geq d_0 \\ H_1 : \mu_d < d_0 \end{cases}$$

$$8. \text{ Rejeitar } H_0 \text{ se } t_c > t_{(n-1; \alpha)} \text{ quando, } \begin{cases} H_0 : \mu_d \leq d_0 \\ H_1 : \mu_d > d_0 \end{cases}$$

Ou,

CAMINHO II- Usando o valor p (que usaremos nas atividades):

Rejeitar H_0 se valor $p \leq \alpha$.

Não se rejeita H_0 , caso contrário.

O teste t aqui aplicado é chamado "teste t pareado ou emparelhado".

9.3.1 Testes de Hipóteses no R

É possível e para fins didáticos os recursos do R pode-se ter possíveis soluções:

1. fazendo as contas passo a passo, utilizando o R como uma calculadora;
2. usando uma função já existente no R: `t.test`. **O que será adotado, tendo o cuidado de se ter o comando:**

paired=TRUE

`t.test(a,b,paired=TRUE,alternative="....")`

`alternative="greater" ou "less" ou "two.side"`, dependendo de H_1 .

9.3.2 Exemplo

Considere que um médico desejasse saber de duas marcas de termômetros têm resultados iguais, e analisou em 6 pacientes:

Marca A	Marca B	Diferença (A-B)
38	37	1
41	37	4
39	36	3
38	38	0
39	37	2
39	36	3

Pode-se afirmar os termômetros A e B são, em média, iguais? Teste a hipótese usando um nível de significância $\alpha = 0,05$.

Considerando a diferença das temperaturas indicadas pelos termômetros A e B, na seguinte ordem, tem-se, $X_{dif} = X_A - X_B$. Logo a afirmação "duas marcas de termômetros têm resultados iguais", corresponde em $\mu_{Dif} = 0$

Deseja-se realizar o seguinte teste de hipóteses:

$$\begin{cases} H_0 : \mu_{Dif} = 0 \\ H_1 : \mu_{Dif} \neq 0 \end{cases}.$$

Calculando a média e a variância amostral das diferenças temos:

$$\bar{X}_d = 2,17^\circ C \text{ e } S_d = 1,472(^\circ C).$$

A Figura 52 apresenta a sequência de comandos no R para a realização do teste de hipóteses para a comparação de duas médias, com dados emparelhados, considerando os dados das temperaturas dos termômetros. Atenção deve ser direcionada ao banco de dados, no qual, as amostras devem ficar lado a lado, conforme Figura 52.




Figura 52: Sequência de comandos para a execução do teste de hipóteses bilateral para a comparação de duas médias com dados emparelhados, considerando os dados das temperaturas dos termômetros

$$\alpha = 0,05$$

Observando na saída do R, Figura 52, valor- $p=0,0154$. Como, Valor p é menor que α .

Conclusão: Existem evidências para rejeitar $H_0 : \mu_{Dif} = 0$, ao nível de significância de 5% ($p=0,0154$). Portanto, pode-se afirmar que os termômetros das marcas A e B fornecem, em média, resultados diferentes.

9.4 Comparação de duas populações - BANCO DE DADOS implantação da empresa de TI

Foram apresentados, anteriormente, a sequência de comandos R (Rcommander) para a execução dos testes de hipóteses para a comparação de parâmetros populacionais, duas variâncias e duas médias, considerando a situação onde se **tem o poucos dados**, e a entrada dos mesmos pode ser direta. Porém, em alguns casos, o que se possui é um banco de dados, como o referente ao estudo de caso: Projeto de criação de uma empresa de TI no Sul de Minas. Sendo que foram selecionadas, de forma aleatória, 50 empresas de cada setor (Comércio Agrícola (ComAgri), Logística/Transporte) que possui diversas variáveis observadas.

Nesse caso, deve-se, primeiramente, carregar o banco de dados no Rcommander (ver passos no Vídeo: importar dados do Excel (XLSX) no Rcommander - no moodle).

Depois basta seguir os passos apresentados nas Figuras 53 e 54, nas quais se tem a sequência de comandos no Rcommander para a execução dos testes de hipóteses para a **razão de variâncias** ($\frac{\sigma_A^2}{\sigma_B^2}$) e para a **diferença de médias** ($\mu_A - \mu_B$) populacionais, utilizando um banco de dados.

Caso para a razão de variâncias

O gestor deseja saber se a **variância** da renda dos empregados das empresas do setor de Comércio Agrícola é **igual** à dos empregados das empresas do setor de Logística. Fazer um teste de hipóteses, adotando um nível de significância de $\alpha = 0,05$ e concluir.

Resolução:

Afirmação: $H_0 : \frac{\sigma_A^2}{\sigma_B^2} = 1$.

A: setor de Comércio Agrícola ; B: setor de Logística.

$$H_0 : \frac{\sigma_A^2}{\sigma_B^2} = 1$$

$$H_1 : \frac{\sigma_A^2}{\sigma_B^2} \neq 1$$

Com base nestas informações e seguindo os passos da Figura 53




Figura 53: Sequência de comandos para a execução do teste de hipóteses para razão de variâncias da variável *renda dos empregados* em relação aos setores, do banco de dados

Observando na saída do R, Figura 53, valor- $p = 0,2567$. Como $p > \alpha$; ($0,2567 > 0,05$), temos a seguinte

conclusão.

Conclusão: Não existem evidências para rejeitar $H_0 : \frac{\sigma_A^2}{\sigma_B^2} = 1$ ($p=0,2567$), ao nível de significância de 5%. Portanto, a **variância** da renda dos empregados das empresas do setor de Comércio Agrícola **é igual** à dos empregados das empresas do setor de Logística, na região de implantação da empresa de TI.

Caso para a diferença de médias

O gestor deseja saber se a renda média dos empregados das empresas do setor de Comércio Agrícola **é igual** à dos empregados das empresas do setor de Logística. Fazer um teste de hipóteses, adotando um nível de significância de $\alpha = 0,05$ e concluir.

Resolução:

Afirmiação: $\mu_{CA} = \mu_{LT}$

$$H_0 : \mu_{CA} - \mu_{LT} = 0$$

$$H_0 : \mu_{CA} - \mu_{LT} \neq 0$$

Com base nestas informações e seguindo os passos da Figura 54




Figura 54: Sequência de comandos para a execução do teste de hipóteses para diferença de médias da variável *renda*, do banco de dados.

Observando na saída do R, Figura 54, valor- $p = 0,2747$. Como $p > \alpha$ ($0,2747 > 0,05$), temos a seguinte conclusão.

Conclusão: Não existem evidências para rejeitar $H_0 : \mu_{CA} - \mu_{LT} = 0$ ($p=0,2747$), ao nível de significância de 5%. Portanto, a renda média dos empregados das empresas do setor de Comércio Agrícola **é igual** à dos empregados das empresas do setor de Logística.

9.5 Exercícios

1. Uma amostra de 8 cobaias foi tratada com uma ração especial (para ganho de peso) durante 10 dias. Os pesos (em kg), antes e depois do tratamento foram:

Peso	1	2	3	4	5	6	7	8
Antes (X_i)	52	45	61	54	51	48	42	57
Depois (Y_i)	60	50	59	63	54	54	49	57

- a) Pelos resultados você afirmaria que a ração é eficiente? Faça um teste de hipótese e conclua. Use $\alpha=0,01$.
2. Uma empresa de computadores planejou um curso "novo e melhorado" para treinar seus representantes sobre como preparar computadores pessoais. Vinte estagiários foram divididos aleatoriamente em dois grupos: 10 fizeram o curso usual e 10 frequentaram o novo curso. Ao final de seis semanas, todos os vinte estagiários foram submetidos ao mesmo exame final (escores mais altos indicam maior habilidade nos reparos). Diante dos resultados que se seguem, teste a hipótese de que o novo curso não foi melhor do que o curso usual em seu objetivo de ensinar os representantes a reparar computadores pessoais. Teste a hipótese de que o novo curso não apresenta variabilidade diferente da variabilidade do curso usual. Use $\alpha=0,05$.

Usual	3	5	7	9	8	9	7	4	9	9
Novo	8	5	9	3	2	6	4	5	2	5

3. Um administrador coletou dados sobre produtividade no último ano para uma amostra de empresas que produzem equipamentos eletrônicos. As firmas foram classificadas de acordo com o nível (baixo e alto) de investimentos em pesquisa e desenvolvimento, nos últimos 3 anos. Os resultados do estudo seguem abaixo, a produtividade é medida numa escala de 0 à 10 (teste usado $\alpha = 1\%$).

Baixo investimento	7,6	8,2	6,8	5,8	6,9	6,6
Alto investimento	8,5	9,7	10	7,8	9,6	9,5

- a) Pode considerar as variâncias populacionais diferentes?
- b) Pode-se afirmar que a média de produtividade das firmas com alto investimento é maior?

4. Uma médica desejava saber se técnicas de relaxamento ajuda a diminuir as pressões sanguíneas sistólicas para a população de mulheres hipertensas com idade entre 30 e 34 anos. Para tanto realizou um experimento com 12 mulheres e analisou a pressão antes e depois de realizar a aplicação da técnica por 2 meses, e obteve os seguintes resultados.

	1	2	3	4	5	6	7	8	9	10	11	12
Antes	170	154	162	188	155	145	167	154	177	148	160	150
Depois	165	152	164	167	154	142	162	152	165	151	153	152

Pode-se afirmar que a técnica é eficiente? (use $\alpha = 0,05$).

5. A curva de tolerância à glicose foi medida em 10 pacientes com Doenças de Huntington e em 10 indivíduos-controle e mostraram, respectivamente, os seguintes resultados. Pode-se afirmar que as

Doentes	120	119	89	103	122	108	105	102	122	132
Controle	115	110	90	110	105	113	98	104	125	111

variâncias e as médias das curvas de tolerância à glicose podem ser consideradas iguais? ($\alpha = 0,05$).

9.6 Teste para comparar a proporção de duas populações (amostras independentes)

Em várias áreas da ciência pode-se ter o interesse em comparar proporções de duas populações. Este teste nos assegura se duas proporções são estatisticamente iguais :

$$\begin{cases} H_0 : \pi_1 = \pi_2, \text{ ou } \pi_1 - \pi_2 = 0 \\ H_1 : \pi_1 \neq \pi_2, \text{ ou } \pi_1 - \pi_2 \neq 0 \end{cases}$$

Passos para a realização do teste:

1. Identificar a afirmação prática e a afirmação **estatística**
2. Escrever as hipóteses, lembrando que se a afirmação **estatística** contém um sinal de igualdade a mesma será alocada na hipótese nula (H_0), caso contrário será alocada na hipótese alternativa (H_1).
3. Calcule o valor da estatística do teste ou o **valor-p**
4. Aplique a **regra de decisão**:

I- Usando **valor tabelado (z)**:

$$\text{a) Rejeitar } H_0 \text{ se } |z_c| > z_{\frac{\alpha}{2}} \text{ quando } \begin{cases} H_0 : \pi_1 - \pi_2 = 0 \\ H_1 : \pi_1 - \pi_2 \neq 0 \end{cases}$$

$$\text{b) Rejeitar } H_0 \text{ se } z_c < -z_{\alpha} \text{ quando } \begin{cases} H_0 : \pi_1 - \pi_2 \geq 0 \\ H_1 : \pi_1 - \pi_2 < 0 \end{cases}$$

$$\text{c) Rejeitar } H_0 \text{ se } z_c > z_{\alpha} \text{ quando } \begin{cases} H_0 : \pi_1 - \pi_2 \leq 0 \\ H_1 : \pi_1 - \pi_2 > 0 \end{cases}$$

II- Usando o valor p:

Rejeitar H_0 se valor $p \leq \alpha$.

Não se rejeita H_0 , caso contrário.

OBSERVAÇÃO: Este procedimento é válido quando n_1 é igual ou próximo de n_2 .

Lembrando que a aproximação pela Normal só é válida quando:

$$\text{i} - n * \hat{p} > 5, \text{ e;}$$

$$\text{ii} - n * \hat{p} * (1 - \hat{p}) > 5.$$

9.6.1 Testes de Hipóteses no R

usando uma função o prop.test (aproxima por uma Qui-quadrado).

9.6.2 Exemplo


Para testar a eficácia de um medicamento no combate a um certo tipo de infecção efetuou-se o seguinte experimento. Foram formados dois grupos de portadores da moléstia, o primeiro com 160 pacientes e o segundo com 140 pacientes. Ao primeiro grupo foi ministrado o medicamento, enquanto os pacientes do segundo grupo

receberam apenas placebo. No primeiro grupo observou-se melhora em 150 pacientes. No segundo grupo o número de pacientes curados foi igual a 118. Pode-se afirmar, com 5% de significância, que o medicamento é eficaz ?

Resolução do Exemplo:

Afirmção: o medicamento é eficaz, implica que a proporção de pacientes curados que receberam o medicamento (π_1) é maior que a proporção de pacientes curados que receberam apenas placebo (π_2), ou seja, $\pi_1 > \pi_2$ ou $\pi_2 < \pi_1$, logo $\pi_2 - \pi_1 < 0$. Então, deseja-se realizar o seguinte teste de hipóteses:

$$\begin{cases} H_0 : \pi_2 - \pi_1 \geq 0 \\ H_1 : \pi_2 - \pi_1 < 0 \end{cases}$$



The screenshot shows the R Commander interface. The menu bar includes Arquivo, Editar, Dados, Estatísticas, Gráficos, Modelos, Distribuições, Ferramentas, and Ajuda. The 'Conjunto de Dados' dropdown is set to 'Dataset'. The 'Modelo' dropdown is set to 'Σ'. The 'R Script' tab is active, displaying the following R code:

```
n1=160
ns1=150 # número de sucesso na amostra da pop_1

n2=140
ns2=118 # número de sucesso na amostra da pop_2
p0<-0

prop.test(c(ns2,ns1),c(n2,n1),alternative="less")

## Ficar atento com a hipóteses alternativa H1.
```

The 'Output' pane shows the execution results:

```
> n2=140
> ns2=118 # número de sucesso na amostra da pop_2
> p0<-0
> prop.test(c(ns2,ns1),c(n2,n1),alternative="less")

      2-sample test for equality of proportions with continuity correction

data:  c(ns2, ns1) out of c(n2, n1)
X-squared = 6.0607, df = 1, p-value = 0.006911
alternative hypothesis: less
95 percent confidence interval:
 -1.00000000 -0.02836105
sample estimates:
   prop 1   prop 2 
0.8428571 0.9375000
```

In the output, the text 'Cuidado com a ordem' is written in red above the `prop.test` command. The p-value `p-value = 0.006911` is highlighted with a red rectangle.

Figura 55: Passos a serem executados no R para a realização do teste de hipóteses para a comparação de duas proporções, considerando os dados do exemplo.

- Como, valor- $p = 0,0069$ é menor que $0,05$, então, **há evidências** para se rejeitar $H_0 : \pi_2 - \pi_1 \geq 0$, com 5% de significância.
- Temos a seguinte **conclusão estatística**:
Existem evidências para rejeitar $H_0 : \pi_2 - \pi_1 \geq 0$, ($p = 0,0069$), ao nível de significância de 5%.
- Que permite a seguinte **conclusão prática**:
Logo, pode-se afirmar que o medicamento apresenta uma maior proporção de curados que o placebo e, portanto, **é eficaz**.

9.7 Teste de Qui-Quadrado para tabelas de contingência

É um teste de hipóteses muito usado em várias áreas da ciência que se destina a comparar proporções, para verificar a relação entre duas variáveis qualitativas (categóricas). Este teste nos assegura se duas ou mais proporções são estatisticamente iguais ou se pelo menos duas dentre várias proporções são diferentes entre si, ou seja, é usado para:

$$\begin{cases} H_0 : \text{Todas as proporções, numa mesma coluna (ou linha), são iguais} \\ H_1 : \text{pelo menos uma das proporções, numa mesma coluna (ou linha), difere das demais} \end{cases}$$

Dada a matriz de valores observados:

		Categoria B				
		B ₁	B ₂	...	B _s	
Categoria A	A ₁	O ₁₁	O ₁₂	...	O _{1s}	Total A ₁
	A ₂	O ₂₁	O ₂₂	...	O _{2s}	Total A ₂
	⋮	⋮	⋮	...	⋮	⋮
	A _r	O _{r1}	O _{r2}	...	O _{rs}	Total A _r
		Total B ₁	Total B ₂	...	Total B _s	Total Geral

- I- Primeiro passo consiste em construir a matriz de valores esperados de dimensões $r \times s$, a partir dos valores observados, obtendo-se os valores esperados pela seguinte expressão:

$$E_{ij} = \frac{\text{Total } A_i \times \text{Total } B_j}{\text{Total Geral}}$$

- II- Posteriormente, obtidos os valores da matriz observada e da matriz esperada, e calcula-se a estatística do teste,

$$\chi_c^2 = \sum_{i,j=1}^{r,s} \frac{(O_{ij} - E_{ij})^2}{E_{ij}}$$

em que O_{ij} = frequência observada para a célula ij , E_{ij} = frequência esperada para a célula ij .

- III- Aplica a **Regra de decisão**: rejeita-se H_0 se $\chi_c^2 > \chi_{(gl; \alpha)}^2$, em que $gl(r-1)(s-1)$, sendo r o número de linhas e s o número de colunas.

Ou, **Regra de decisão**: Rejeitar H_0 se $p \leq \alpha$.

Observação: o teste χ^2 não pode ser usado indiscriminadamente, respeitando os seguintes casos:

- Não deve ser usado quando $n < 20$. Quando n estiver entre 20 e 40 deve usar uma correção, sugerida por Yates.

$$\chi_c^2 = \sum_{i,j=1}^{r,s} \frac{(|O_{ij} - E_{ij}| - 0,5)^2}{E_{ij}}$$

- Não deve ser usado quando mais de 20% das frequências esperadas for menor 5.
- Caso se tenha poucas observações ou frequências esperadas baixas ocorrerem em muitas caselas, recomenda-se agrupar as categorias ou recorrer a um outro teste (Exato de Fisher).

9.7.1 Exemplo

Uma pesquisadora desejava saber se existe influência da área do curso dos estudantes na preferência pelo tipo de ensino: se totalmente online, híbrido ou presencial. Entrevistaram-se 250 estudantes obtendo-se as seguintes informações:

Curso	totalmente online	híbrido	presencial
Humanas	50	61	39
Saúde	30	29	41

Teste a hipótese de que "a preferência do tipo de ensino não está relacionada com a área do curso", considerando um nível de 5% de significância.

A Figura 56 apresenta a sequência de comandos no R para a realização do teste Qui-quadrado na comparação de proporções, para verificar se existe relação (dependência) entre duas ou mais variáveis categóricas, caso exemplo 9.7.1.




Figura 56: Passos a serem executados no R para a realização do teste Qui-quadrado, no exemplo 9.7.1 .

$\alpha = 0,05$.

Valor $p = 0,0351$

Como, Valor p é menor que α .

Conclusão: Existem evidências para rejeitar H_0 : *proporções iguais*, ($p=0,0351$), ao nível de significância de 5%. Portanto, a preferência pelo tipo de ensino está relacionada com a área do curso.

9.8 Exercícios

1. O Proprietário de uma lanchonete desejava saber se existe influência do turno dos estudantes na preferência pelo tipo salgado. Entrevistaram-se 200 estudantes obtendo-se as seguintes informações:
Teste a hipótese de que "a preferência está relacionada com o turno de estudo". ($\alpha = 5\%$).

Turno	Frito	Assado
Noturno	65	36
Diurno	41	58

2. Foi realizada uma pesquisa o objetivo de verificar aspectos epidemiológicos do Transtorno do Déficit de Atenção com Hiperatividade (TDAH) em uma amostra representativa de crianças e adolescentes brasileiros, bem como explorar eventuais associações entre o sexo do participante e o diagnóstico de TDAH, obtendo os seguintes resultados.

Sexo	Tem TDAH	Não Tem TDAH
Masculino	1200	136
Feminino	1400	88

Teste a hipótese de que "a ocorrência de TDAH está relacionada com o sexo das crianças/adolescentes". (Use $\alpha = 5\%$).

3. Com o objetivo de identificar fatores que influenciam na ocorrência de quedas de idosos foi realizada uma pesquisa na qual para a coleta de dados foram aplicados questionários estruturados em visitas domiciliar com idosos da cidade de Alfenas- MG. Foram analisados os fatores: Tapetes espalhados e o fato de Morar sozinho, obtendo os seguintes resultados

Tapetes espalhados	Queda - Não	Queda - Sim
Não	47	10
Sim	12	9

Morar sozinho	Queda - Não	Queda - Sim
Não	40	11
Sim	18	9

Para cada fator estudado, verificar se a ocorrência de queda de idosos está relacionada com os mesmos, considerando um nível de 5% de significância.

10 Correlação Linear

O termo correlação representa, sob o ponto de vista da estatística, uma medida de associação entre duas variáveis quantitativas. Como definição, se forem considerados numa população, os pares de valores de duas variáveis (x_i, y_i) , a correlação linear delas é definida por:

$$\rho_{x,y} = \frac{\text{cov}(xy)}{\sqrt{\sigma_x^2 \sigma_y^2}}$$

O valor da correlação linear $\rho_{x,y}$, conhecido como coeficiente de correlação linear, assume valores no intervalo de -1 a 1 , conforme o grau de associação entre as duas variáveis em questão. É o mesmo que dizer $-1 \leq \rho_{x,y} \leq 1$.

- Se $\rho > 0$, então a correlação é positiva (Figura 1 A).
- $\rho < 0$, então a correlação é negativa (Figura 1B).
- Se o valor de ρ é próximo de 0 , não há correlação linear entre as variáveis (Figura 1C).




Figura 16: Gráfico de dispersão representando uma correlação linear positiva entre tempo de estudo (nível de escolaridade) e renda (A), negativa entre PIB e taxa de mortalidade infantil (B) e duas variáveis não correlacionadas linearmente (C)

Alguns exemplos de variáveis que podem ser correlacionadas.

- Tempo que uma pessoa passa correndo em uma esteira, e a quantidade de calorias que são queimadas.
- Altura de uma pessoa e tamanho dos sapatos.
- Tempo de exposição ao sol e grau de queimadura por conta do sol
- Diâmetro do tronco e altura de uma árvore.
- Tempo de uso e duração de uma bateria.
- Altura das crianças em função da idade.

Coeficiente de Correlação Amostral

Na prática, como acontece na maioria dos estudos e análises estatísticas, trabalha-se com amostras ao invés de populações. Em quase todos os casos estudados, o uso da amostragem é o critério adotado, em função da dificuldade, impossibilidade ou outra razão para não se dispor dos dados da população. Assim, o coeficiente da correlação se define da mesma forma que foi definido para a população, com as devidas alterações ocorridas na covariância e variâncias amostrais.

$$r_{x,y} = \frac{SPXY}{\sqrt{SQX \cdot SQY}}$$

em que:

$SPXY$ é a soma de quadrados de produtos de x e y , dada por:

$$SPXY = \sum_{i=1}^n x_i y_i - \frac{\sum_{i=1}^n x_i \sum_{i=1}^n y_i}{n}$$

SQX é a soma de quadrados de x , dada por:

$$SQX = \sum_{i=1}^n x_i^2 - \frac{(\sum_{i=1}^n x_i)^2}{n}$$

SQY é a soma de quadrados de y , dada por:

$$SQY = \sum_{i=1}^n y_i^2 - \frac{(\sum_{i=1}^n y_i)^2}{n}$$

Inferência sobre o Coeficiente de Correlação

A partir cálculo coeficiente de correlação amostral, obtém-se uma estimativa da correlação populacional. Assim, é possível verificar se existe correlação linear entre as variáveis. Para isso, realiza-se um teste de hipóteses sobre o coeficiente de correlação linear, com base nos resultados de uma amostra, o qual pode ser definido como:

$$\begin{cases} H_0 : \rho_{x,y} = 0 \\ H_1 : \rho_{x,y} \neq 0 \end{cases}$$

$$\text{Estatística do teste: } t_c = \frac{r-0}{\sqrt{\frac{1-r^2}{n-2}}}$$

Critério de decisão: Rejeita-se H_0 , a um nível de significância α , se $|t_c| > t(\alpha/2, v)$, em que v são $n - 2$ graus de liberdade da distribuição $t - Student$. Ou rejeita-se H_0 se valor $-p \leq \alpha$.

Utilizando o R: Após entrar com os vetores de x e y , é possível realizar o teste de hipóteses para o coeficiente de correlação no *software R* com a função `cor.test(x, y)`, a qual apresenta o valor $-p$ e a estimativa do coeficiente de correlação.

Exemplo:

Considere que os dados abaixo são referentes ao tempo de estudo (x) e nota de prova (y). Um professor distribuiu 8 discentes, que tinham desempenho parecidos, de forma aleatória para os seguintes tempos de estudo.

Considere que os dados abaixo são referentes ao tempo de estudo (x) e nota de prova (y).

Tempo de estudo (h)	5	14	3	7	2	1,5	12
Nota	5,5	9,4	4,5	6,5	3,7	4,0	9,3

1. Fazer o diagrama de dispersão e obtenha a estimativa da correlação linear entre tempo de estudos (em horas) e a nota da prova.
2. Realize o teste de hipóteses, considerando um nível de 5% de significância, sobre o coeficiente de correlação linear entre tempo de estudos (em horas) e a nota da prova.
3. Conclua sobre o teste, fazendo a interpretação prática.

Na Figura 58 é apresentado o diagrama de dispersão da relação entre o tempo de estudo (em horas) e a nota de prova.




Figura 17: Diagrama de dispersão da Nota de prova em função do tempo de estudo (em horas).

Depois de importar os dados do excel para o Rcommander, como feito nas aulas anteriores, basta seguir os passos apresentados na Figura 59 para construir o Diagrama de dispersão da Nota de prova em função do tempo de estudo (em horas).




Figura 18: Passos a serem executados no R para construir o Diagrama de dispersão, no exemplo.

Usando a função **cor.test** no R, obtemos: A Figura 60 apresenta a sequência de comandos no R para a calcular e inferir sobre o coeficiente de correção linear, caso exemplo.




Figura 19: Passos a serem executados no R para o cálculo do coeficiente de correção linear, no exemplo.

- $r = 0,9922$.
- Regra de decisão: Rejeita-se H_0 se valor $p \leq \alpha$.
Temos que: $\alpha = 0,05$.
valor $p = 0,00001$.
- Como valor $p \leq \alpha = 0,05$, então **há evidências** para se rejeitar $H_0 : \rho = 0$, com 5% de significância.
- Que permite a seguinte **conclusão prática**: Portanto, pode-se afirmar que **existe** correlação linear **positiva** entre tempo de estudos (em horas) e a nota da prova, ou seja, quando se aumenta o tempo de estudos, aumenta-se a nota da prova.

Observação: A correlação entre duas variáveis pode ser causal, isto é, o aumento (ou diminuição) de uma delas pode ser a causa do aumento (ou diminuição) da outra. Por exemplo, a correlação entre o consumo de

combustível dos automóveis e o número de quilômetros rodados é causal, porque os automóveis precisam de mais combustível para percorrer distâncias maiores. Da mesma forma, a correlação entre danos nas rodovias e quantidade de tráfego é explicada por uma relação de causa e efeito.

Existem, porém, situações em que duas variáveis **têm correlação estatística**, mas **não há relação de causa e efeito entre elas**. É o que os estatísticos chamam de correlação espúria. Na maioria das vezes, a correlação espúria é explicada por uma terceira variável que não foi observada, mas modifica as duas variáveis em estudo. Um exemplo clássico de correlação espúria é a correlação entre a velocidade de leitura e o comprimento dos pés das crianças do curso fundamental. Mesmo sem dados, é razoável considerar que existe forte correlação positiva entre duas variáveis, que é explicada por uma terceira variável, a idade. É preciso, portanto, cuidado ao interpretar uma correlação. Podemos concluir que existe relação entre duas variáveis quando, na verdade, essa relação não existe.

Exercícios

1. A vacinação de crianças é um mecanismo importante para melhorar a qualidade da saúde e diminuir as taxas de mortalidade infantil. Considerando que os dados abaixo referem-se à porcentagem de crianças imunizadas e às taxas de mortalidade infantil (por 1000 nascidos vivos) de crianças menores que cinco anos de uma amostra de 10 países.

País	Imunização	Mortalidade
1	40,42	140,04
2	64,30	87,76
3	54,34	107,99
4	24,85	172,47
5	81,16	50,83
6	26,51	167,15
7	65,62	85,60
8	68,51	78,66
9	48,72	120,40
10	65,43	85,60

- (a) Obtenha a estimativa do coeficiente da correlação linear entre a porcentagem de imunização e a taxa de mortalidade.
 - (b) Realize o teste de hipóteses, considerando um nível de 1% de significância, sobre o coeficiente de correlação linear entre a porcentagem de imunização e a taxa de mortalidade.
 - (c) Conclua sobre o teste, fazendo a interpretação prática.
 - (d) Caso o coeficiente de correlação seja significativo, faça a interpretação do intervalo de confiança de 90% (gerado com a partir da função *cor.test*) para o coeficiente de correlação.
2. A tabela abaixo mostra os resultados de uma pesquisa a respeito de investimento em qualidade e quantidade de vendas: (Utilizar $\alpha = 5\%$).
- (a) Obtenha a estimativa do coeficiente de correlação linear entre investimento em qualidade e quantidade de vendas.

Investimento	8	10	11	13	15	16	20
Vendas	1,2	1,5	1,6	2	2,1	2,4	3

- (b) Realize o teste de hipóteses, considerando um nível de 5% de significância, sobre o coeficiente de correlação linear entre investimento em qualidade e quantidade de vendas.
- (c) Conclua sobre o teste, fazendo a interpretação prática.
- (d) Caso o coeficiente de correlação seja significativo, faça a interpretação do intervalo de confiança de 99% (gerado com a partir da função *cor.test*) para o coeficiente de correlação.

10.1 REGRESSÃO LINEAR

Em estudos que procuram determinar a relação existente entre duas ou mais variáveis quantitativas, dois tipos de situação podem ocorrer:

- uma variável (X) pode ser medida acuradamente e seu valor escolhido pelo pesquisador. Por exemplo, a dose de uma droga a ser administrada no animal. Esta variável é chamada de variável independente (ou regressora ou covariável). A outra variável (Y), chamada variável dependente ou variável resposta, está sujeita a erro experimental, e seu valor depende do valor escolhido para a variável independente. Assim, a variável resposta (Y) é uma variável dependente da variável independente (X). Este é o caso da regressão.
- As duas variáveis estão sujeitas a erros aleatórios, isto é, erros de natureza aleatória, inerentes ao estudo. Por exemplo, produção de leite e produção de gordura medidas em vacas em lactação. Este tipo de associação entre duas variáveis constitui o **caso da correlação** (para estabelecer uma equação para essa associação faz-se necessário um estudo de **regressão aleatória**).

Uma vez que se sabe (ou se suspeita) de uma relação existente entre duas ou mais variáveis quantitativas, pode-se estabelecer uma função (modelo) que descreva esta relação, estes são chamados de modelos de regressão.

Existem dois casos de regressão mais usuais:

1. **Correlação e Regressão Simples:** envolve somente duas variáveis (um Y e um X)
2. **Correlação e Regressão Múltipla:** envolve mais de duas variáveis (um Y e duas ou mais X 's)

10.2 Regressão Linear Simples

O termo regressão é usado para designar a expressão de uma variável dependente (Y) em função de outra (X), considerada independente. Diz-se regressão de Y sobre X . Se a relação funcional entre elas é expressa por uma equação de 1º grau, cuja a representação geométrica é uma linha reta, **a regressão é dita Linear Simples**.

Postulada a existência de uma relação linear entre duas variáveis, pode-se representar aquele conjunto de pontos pela equação da reta:

$$y_i = \beta_0 + \beta_1 x_i, \quad (1)$$

que expressa que o valor de y está em função de x , sendo que:

y é a variável dependente, ou regredida ou resposta;

x é a variável independente, ou regressora ou explanatória.

β_0 e β_1 são constantes, em que:

β_0 é o intercepto e expressa o valor de y quando x é zero;

β_1 é o coeficiente de regressão, coeficiente angular ou inclinação da reta.

O problema consiste em estimar os parâmetros β_0 e β_1 para que se conheça a equação da reta. Se b_0 é uma estimativa de β_0 e b_1 é uma estimativa de β_1 , a equação estimada é dada por:

$$\hat{y}_i = b_0 + b_1 x_i. \quad (2)$$

Dizemos então que o problema consiste em ajustar uma regressão linear simples, isto é, a equação de uma reta ajustada aos dados.

Quando $x = 0$, $\hat{y} = b_0$ e quando $b_0 = 0$ a reta corta a origem. O coeficiente b_0 é o ponto em que a equação da reta cruza o eixo de y . Uma unidade de mudança em x resulta em uma b_1 unidades de mudança em y . Assim, b_1 é uma medida de inclinação da reta.

Matematicamente $y = b_0 + b_1x$ é denominada de relação funcional.

10.2.1 Estimação de Parâmetros

Suponhamos que para cada uma das variáveis (X e Y), temos " n " valores. Cada valor x_i de X corresponde a um valor y_i de Y segundo a equação:

$$y_i = \beta_0 + \beta_1 x_i + \varepsilon_i \quad (3)$$

ε_i = desvio ou erro aleatório (com média zero, variância σ^2 e não correlacionados)

O problema que devemos resolver, antes de mais nada, é estimar b_0 e b_1 que são estimadores de β_0 e β_1 .

A teoria mostra que a melhor maneira de estimar β_0 e β_1 é por meio do **Método dos Quadrados Mínimos**, o qual consiste em minimizar a soma de quadrados dos desvios $y_i - \hat{y}_i$. Sendo $y_i - \hat{y}_i$ a diferença entre o valor observado e o estimado pela equação de regressão para cada observação, procura-se, então, estimar β_0 e β_1 , de tal modo que $\sum (y_i - \hat{y}_i)^2$ seja mínima. As diferenças $y_i - \hat{y}_i$ são chamadas "desvios da regressão" ou "erro de estimativas".

A solução do Sistema de Equações Normais resulta em:

$$b_0 = \frac{\sum y_i}{n} - \frac{b_1 \sum x_i}{n} = \bar{y} - b_1 \bar{x}$$

$$b_1 = \frac{n \sum x_i y_i - (\sum x_i)(\sum y_i)}{n \sum x_i^2 - (\sum x_i)^2} = \frac{SPXY}{SQX}$$

em que, b_0 e b_1 são os estimadores dos parâmetros β_0 e β_1 ;

$SPXY$: soma de produtos de x e y , dada por:

$$SPXY = \sum_{i=1}^n x_i y_i - \frac{\sum_{i=1}^n x_i \sum_{i=1}^n y_i}{n} \quad (4)$$

SQX : soma de quadrados de x , dada por:

$$SQX = \sum_{i=1}^n x_i^2 - \frac{\left(\sum_{i=1}^n x_i \right)^2}{n} \quad (5)$$




Figura 20: Representação gráfica da reta de regressão $\hat{y} = b_0 + b_1x$.

- Quando se constata que o coeficiente de regressão de uma variável sobre outra **não difere significativamente de zero**, significa que as duas variáveis em estudo **não estão relacionados**.
- Quando b_1 difere significativamente de zero, seja $b_1 < 0$ ou $b_1 > 0$, existe associação as entre duas variáveis quantitativas.
- Quando $b_1 > 0$ as variáveis em estudo estão correlacionadas positivamente; o valor da variável (Y) aumentará com o aumento da outra (X) e diminuirá com a diminuição da outra.
- Quando $b_1 < 0$, as variáveis estão correlacionadas negativamente, portanto variam em sentidos opostos, o valor da variável (Y) diminuirá com o aumento da outra (X).

10.2.2 Inferência na regressão

Nas pesquisas, em geral, o modelo estimado é obtido utilizando-se os dados amostrais, logo faz-se necessário testes estatísticos para verificar se as estimativas dos parâmetros **são significativas** (ser diferentes de zero) ou se são valores gerados ao acaso.

Teste t para os parâmetros

$$\begin{cases} H_0 : \beta_0 = 0 \\ H_1 : \beta_0 \neq 0 \end{cases}$$

$$\begin{cases} H_0 : \beta_1 = 0 \\ H_1 : \beta_1 \neq 0 \end{cases}$$

Critério de decisão: Rejeita-se H_0 , a um nível de significância α , se valor $-p \leq \alpha$.

O Teste t mais frequentemente usado em uma regressão é aquele que avalia a importância (significância) dos coeficientes individuais, ou seja: $H_0 : \beta_j = 0$ contra a $H_1 : \beta_j \neq 0$.

Se a decisão for de **não se Rejeitar** H_0 , tem que o parâmetro populacional β_j **é não significativo** (pois é considerado igual a 0).

10.2.3 Coeficiente de determinação R^2

O coeficiente de determinação R^2 é uma medida utilizada para quantificar a proporção da variabilidade da variável dependente (Y) que é explicada pelo modelo, e é dado por:

$$R^2 = \left(1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2} \right) \times 100\% = \left(1 - \frac{SQE}{SQT} \right) \times 100\% \quad (6)$$

O ajuste é perfeito se todos os resíduos forem 0 (zero), neste caso, $R^2 = 1$.

10.2.4 Aplicação

Consideremos os dados abaixo resultantes de um estudo, no qual o pesquisador desejava verificar a relação entre o tempo de estudo (x) e nota de prova (y).

Tempo de estudo (hs)	5,0	14,0	3,0	7,0	2,0	1,5	12,0
Nota	5,5	9,4	4,5	6,5	3,7	4,0	9,3

(a) Encontre a equação de regressão, o coeficiente de determinação e interprete.

(b) Faça um diagrama de dispersão para os dados.

(c) Qual será a nota média esperada para uma aluno que estude 10 horas?

Usando a função $lm(y \sim x)$ no R, ajusta-se um modelo linear simples: A Figura 62 apresenta a sequência de comandos no R para ajustar e inferir sobre o modelo de regressão linear, caso exemplo.




Figura 21: Passos a serem executados no R para ajustar e inferir sobre o modelo de regressão linear, no exemplo.

Na Figura 63 é apresentado o diagrama de dispersão e modelo ajustado ($\hat{y} = 3,07 + 0,48x$) que descreve a relação entre o tempo de estudo (em horas) e a nota de prova.




Figura 22: Retra de regressão ajustada, $\hat{y} = 3,07 + 0,48x$, para a nota de prova em função do tempo de estudo (em horas).

Como valor- $p = 0,00001$, menor que $\alpha = 0,05$, temos que o modelo é significativo, ao nível de 5% de significância. Para avaliar o efeito do tempo de estudo foi ajustado um modelo linear simples. Pode-se fazer as seguintes interpretações:

Considerando a Figura 63 e a reta de regressão ajustada, $\hat{y} = 3,07 + 0,48x$, para a nota na prova em função do tempo de estudo (em horas), apresentou um $R^2 = 98,45\%$, que pode ser interpretado da seguinte maneira:

98,45% da variabilidade das notas na prova é explicada pelo modelo.

$b_0 = 3,07$, indica que se um aluno não estuda nenhuma hora (tempo de estudos = 0), a nota da prova será, em média, 3,07 pts ($p=0,00002$).

$b_1 = 0,48$, indica que a cada uma hora que aumenta no tempo de estudos a nota da prova aumenta, em média, em 0,48 pts ($p=0,00001$).

Qual será a nota média esperada para uma aluno que estude 10 horas?

Como $\hat{y} = 3,07 + 0,48x$ temos : $\hat{y}_{10} = 3,07 + 0,48 \times 10$

Ou seja, se um aluno estuda 10 horas, espera-se que a nota dele seja de 7,88 pts.

Para construir o gráfico, com a reta ajustada, Figura 63, deve-se seguir a sequência de comandos no R conforme apresentado na Figura 64 .




Figura 23: Passos a serem executados no R para construir o gráfico ajustado do modelo de regressão linear, no exemplo.

10.2.5 Exercício

1. Foi feito um estudo sobre o peso final (Y) de peixes tratados com doses extras de ração (X). Os resultados obtidos foram os seguintes:

Dose (%)	1,0	1,5	1,5	1,5	2,5	4,0	5,0	5,0	7,0	8,0	8,5	9,0
Ganho de Peso (g/dia)	2,00	1,95	2,27	2,17	2,42	2,27	2,15	2,46	2,47	2,19	2,26	2,20

em que X é a dose de ração (%) e Y é o ganho de peso/dia (em g) do indivíduo.

- (a) Faça um diagrama de dispersão para os dados.
- (b) Encontre a equação de regressão, o coeficiente de determinação e interprete.
- (c) Qual seria o peso se fosse aplicado 7,5% de ração?
2. A tabela abaixo mostra os resultados de uma pesquisa a respeito de investimento em qualidade e quantidade de vendas: (Utilizar sempre que preciso $\alpha = 5\%$).

Investimento (R\$)	8000	10000	11000	13000	15000	16000	20000
Vendas (unidades)	1200	1500	1600	2000	2100	2400	3000

- a) Faça um diagrama de dispersão para os dados.
- b) Encontre a equação de regressão, o coeficiente de determinação e interprete.
- c) Qual seria o número de vendas se fosse investido 12300 reais?
3. As quantidades de um composto químico y dissolvido em cem gramas de água sob várias temperatura x foram registradas a seguir:

Temperatura (°C)	0	15	30	45	60	75	90
Massa dissolvida (g)	8	12	25	31	44	48	50

- (a) Encontre a equação linear e interprete as estimativas calculadas.
- (b) Verifique se o intercepto e a inclinação são significativamente diferente de zero, ao nível de 10% de significância.
- (c) Encontre o coeficiente de determinação e interprete-o.
- (d) Encontre o coeficiente de correlação e teste $\begin{cases} H_0 : \rho = 0 \\ H_1 : \rho \neq 0 \end{cases}$ ao nível de 10% de significância.
- (e) Estime a massa do composto químico dissolvido em cem gramas de água à temperatura de 37°C.