

UNIVERSIDADE FEDERAL DE ALFENAS

Instituto de Ciências Exatas

Trabalho de Estatística

Jeann Victor Batista

Prof. Luiz A. Beijo

Alfenas – MG

04 de Dezembro de 2025

Introdução

A estimativa de esforço é uma das etapas mais sensíveis no planejamento de projetos de software. Pressman (2016) destaca que erros nessa fase podem gerar atrasos, custos adicionais e queda na qualidade do produto, tornando o processo de estimar horas de trabalho um componente central do gerenciamento de projetos. Por esse motivo, métodos quantitativos baseados em dados históricos têm ganhado espaço, buscando reduzir a subjetividade típica de estimativas feitas apenas por especialistas.

Modelos de Regressão como Ferramenta Preditiva

Entre as técnicas disponíveis, os modelos de regressão linear se consolidaram como alternativas eficazes para explicar e prever o esforço necessário no desenvolvimento. Esses modelos utilizam características mensuráveis do sistema para identificar padrões — uma abordagem alinhada ao movimento de engenharia de software baseada em evidências. Estudos como os de Shepperd e Kadoda (2001) mostram que o uso de dados históricos melhora significativamente a capacidade de previsão, enquanto Jørgensen (2007) reforça que modelos estatísticos aumentam a confiabilidade dos processos de estimativa.

Variáveis relacionadas ao tamanho e complexidade do software, como número de transações, quantidade de entidades, tamanho da base de dados e tempo de máquina, são frequentemente utilizadas. Trabalhos clássicos — como o de Albrecht (1979), com Pontos de Função, e o modelo COCOMO, de Boehm (1981) — consolidaram a aplicação dessas medidas em modelos de regressão.

Objetivo e Relevância do Estudo

Este estudo analisa a aplicação da regressão linear para estimar a variável QET-ht (Quantidade de Esforço Total em homens/hora) a partir de métricas estruturais do projeto. A compreensão dessas relações permite:

- Estimativas mais realistas de prazos e custos;
- Alocação mais eficiente de equipes;
- Redução de riscos associados a sub ou superestimativas;

- Construção de modelos preditivos adaptados ao contexto organizacional.

Pesquisas empíricas confirmam que organizações que utilizam modelos formais tendem a produzir estimativas consideravelmente mais precisas do que aquelas baseadas apenas no julgamento de especialistas.

Referências

- ALBRECHT, A. J. Measuring Application Development Productivity. Proceedings of the Joint SHARE/GUIDE/IBM Application Development Symposium, 1979.
- BOEHM, B. W. Software Engineering Economics. Prentice-Hall, 1981.
- JØRGENSEN, M. Forecasting of software development work effort. International Journal of Forecasting, v. 23, n. 3, 2007.
- PRESSMAN, R. S. Engenharia de Software: Uma Abordagem Profissional. 8. ed. McGraw-Hill, 2016.
- SHEPPERD, M.; KADODA, G. Using simulation to evaluate prediction systems. Proceedings of the 7th International Software Metrics Symposium, IEEE, 2001.

1 Questão A

Para cada variável, calcular a média, mediana e coeficiente de variação e interpretar (apresentar em uma ÚNICA Tabela).

Tabela 1: Medidas descritivas para as variáveis analisadas

Variável	Média	Mediana	Coeficiente de Variação
Y1_QET	493,100	488,500	0,511
X1_TRANSACTIONS	111,600	105,000	0,500
Y2_QET	119,625	106,500	0,460
X2_DATA	42,550	35,500	0,542

Interpretação das Medidas Descritivas

Médias

Y1_QET = 493,100: A quantidade média de esforço total despendido no desenvolvimento dos projetos da primeira relação é de 493,100 homens/hora.

X1_TRANSACTIONS = 111,600: O número médio de transações lógicas nos sistemas analisados é de 111,600 transações.

Y2_QET = 119,625: A quantidade média de esforço total despendido no desenvolvimento dos projetos da segunda relação é de 119,625 homens/hora.

X2_DATA = 42,550: O tamanho médio da base de dados dos projetos é de 42,550 unidades.

Medianas

Y1_QET = 488,500: Cerca de 50% dos projetos da primeira relação apresentam quantidade de esforço total superior a 488,500 homens/hora e 50% inferior a este valor.

X1_TRANSACTIONS = 105,000: Cerca de 50% dos sistemas analisados possuem mais de 105,000 transações lógicas e 50% possuem menos que este valor.

Y2_QET = 106,500: Cerca de 50% dos projetos da segunda relação apresentam quantidade de esforço total superior a 106,500 homens/hora e 50% inferior a este valor.

X2_DATA = 35,500: Cerca de 50% dos projetos apresentam tamanho de base de dados superior a 35,500 unidades e 50% inferior a este valor.

Coeficientes de Variação

Y1_QET = 0,511: A quantidade de esforço total dos projetos da primeira relação apresenta variabilidade de 51,107% em relação à média, caracterizando muito alta variabilidade (dados heterogêneos), de acordo com Garcia (1989).

X1_TRANSACTIONS = 0,500: O número de transações lógicas nos sistemas apresenta variabilidade de 49,951% em relação à média, caracterizando muito alta variabilidade (dados heterogêneos), de acordo com Garcia (1989).

Y2_QET = 0,460: A quantidade de esforço total dos projetos da segunda relação apresenta variabilidade de 45,962% em relação à média, caracterizando muito alta variabilidade (dados heterogêneos), de acordo com Garcia (1989).

X2_DATA = 0,542: O tamanho da base de dados dos projetos apresenta variabilidade de 54,2% em relação à média, caracterizando muito alta variabilidade (dados heterogêneos), de acordo com Garcia (1989).

2 Questão B

Construa e interprete o gráfico Boxplot para Y1 e Y2 (interpretar juntamente com os resultados da Tabela em (a)).




Figura 1: Boxplot da variável Y1 - Quantidade de Esforço Total

Interpretação: Observa-se no BoxPlot do Y1_QUET que a quantidade de esforço total, em número de homens/hora despendido no desenvolvimento do projeto, da amostra de 20 projetos, se distribui de forma simétrica e não apresenta nenhum outlier.




Figura 2: Boxplot da variável Y2 - Quantidade de Esforço Total

Interpretação: Observa-se no BoxPlot do Y2_QUET que a quantidade de esforço total, em número de homens/hora despendido no desenvolvimento do projeto, da amostra de 20 projetos, é levemente assimétrica à direita e não há presença de nenhum outlier.

3 Questão C

Faça um diagrama de dispersão para os dados.




Figura 3: Diagrama de dispersão: Esforço Total (Y1) $\times$ Transações Lógicas (X1)

Análise: O diagrama de dispersão mostra a relação entre a quantidade de esforço total (Y1) e o número de transações lógicas do sistema (X1). Observa-se uma dispersão dos pontos sem padrão linear aparente, o que corrobora com o baixo coeficiente de correlação encontrado.




Figura 4: Diagrama de dispersão: Esforço Total (Y2) × Tamanho da Base de Dados (X2)

Análise: O diagrama de dispersão apresenta a relação entre a quantidade de esforço total (Y2) e o tamanho da base de dados (X2). Nota-se uma tendência linear positiva entre as variáveis, confirmando a correlação positiva significativa encontrada.

4 Questão D

Encontre o coeficiente de correlação. Efetue o Teste de hipótese e tire as conclusões necessárias.

Relação Y1 × X1

Tabela 2: Análise de correlação entre Y1 e X1

Parâmetro	Valor
Coeficiente de correlação (r)	-0,145
Valor-p	0,542
Hipótese nula (H)	$\rho = 0$
Hipótese alternativa (H)	$\rho \neq 0$

Conclusão: Como valor-p $> \alpha$ ($0,542 > 0,05$), NÃO se rejeita H_0 . Portanto, **não há evidências estatísticas** de correlação linear entre o número de transações lógicas do sistema (X1) e a quantidade de esforço total (Y1).

Relação Y2 × X2

Tabela 3: Análise de correlação entre Y2 e X2

Parâmetro	Valor
Coeficiente de correlação (r)	0,657
Valor-p	0,002
Hipótese nula (H)	$\rho = 0$
Hipótese alternativa (H)	$\rho \neq 0$

Conclusão: Como valor-p $\leq \alpha$ ($0,002 \leq 0,05$), **rejeita-se** H_0 . Portanto, há evidências estatísticas de correlação linear positiva entre o tamanho da base de dados (X2) e a quantidade de esforço total (Y2). Projetos com bases de dados maiores tendem a requerer mais esforço de desenvolvimento.

5 Questão E

Encontre a equação linear, realize os testes e faça a interpretação prática. Apresente o gráfico com modelos ajustados.

Relação $Y1 \times X1$

Tabela 4: Parâmetros do modelo de regressão $Y1 \times X1$

Parâmetro	Estimativa	Valor-p
Intercepto (b)	566,252	0,000
Inclinação (b)	-0,655	0,542
R^2	0,021 (2,1%)	
R^2 ajustado	-0,033 (-3,3%)	

Equação:

$$\hat{Y}_1 = 566,252 - 0,655 \times X_1$$

Interpretação:

Considerando a reta de regressão ajustada, $\hat{Y}_1 = 566,252 - 0,655 \times X_1$, para o esforço total em função do número de transações lógicas, apresentou um R^2 ajustado = $-3,336\%$, que pode ser interpretado da seguinte maneira: A variável $X1_TRANSACTIONS$ explica apenas 2,1% da variabilidade do esforço total, e o modelo ajustado tem poder explicativo praticamente nulo.

$b_0 = 566,252$: indica que se um projeto tem zero transações lógicas ($X_1 = 0$), o esforço estimado será, em média, 566,252 homens/hora ($p = 0,000406$ — significativo).

$b_1 = -0,655$: indica que, para cada transação lógica adicional, o esforço total diminui em média 0,655 homens/hora, porém este efeito não é estatisticamente significativo ($p = 0,541919$).




Figura 5: Modelo ajustado: $Y1 \times X1$

Relação $Y2 \times X2$

Tabela 5: Parâmetros do modelo de regressão $Y2 \times X2$

Parâmetro	Estimativa	Valor-p
Intercepto (b)	52,906	0,018
Inclinação (b)	1,568	0,002
R^2	0,432 (43,2%)	
R^2 ajustado	0,401 (40,1%)	

Equação:

$$\hat{Y}_2 = 52,906 + 1,568 \times X_2$$

Interpretação:

Considerando a reta de regressão ajustada, $\hat{Y}_2 = 52,906 + 1,568 \times X_2$, para o esforço total em função do tamanho da base de dados, apresentou um R^2 ajustado = 40,08%, que pode ser interpretado da seguinte maneira: 40,08% da variabilidade do esforço total é explicada pelo tamanho da base de dados através do modelo ajustado.

$b_0 = 52,906$: indica que se um projeto tem tamanho de banco de dados = 0 ($X_2 = 0$), o esforço estimado será, em média, 52,906 homens/hora ($p = 0,018$ — significativo).

$b_1 = 1,568$: indica que, a cada unidade adicional no tamanho do banco de dados, o esforço total aumenta em média 1,568 homens/hora ($p = 0,002$ — altamente significativo).




Figura 6: Modelo ajustado: $Y_2 \times X_2$

6 Questão F

Encontre o coeficiente de determinação e interprete.

Tabela 6: Coeficientes de determinação

Relação	R^2	R^2 Ajustado
$Y1 \times X1$	0,021 (2,1%)	-0,033 (-3,3%)
$Y2 \times X2$	0,432 (43,2%)	0,401 (40,1%)

Interpretação

Para $Y1 \times X1$:

$$R^2 = 0,021 (2,1\%) \mid R^2 \text{ ajustado} = -0,033 (-3,3\%)$$

A variável $X1_TRANSACTIONS$ explica apenas 2,1% da variabilidade do esforço total ($Y1_QET$), indicando que o modelo tem poder explicativo praticamente nulo.

Para $Y2 \times X2$:

$$R^2 = 0,432 (43,2\%) \mid R^2 \text{ ajustado} = 0,401 (40,1\%)$$

O tamanho da base de dados ($X2_DATA$) explica 43,2% da variabilidade do esforço total ($Y2_QET$), indicando um poder explicativo moderado do modelo.

7 Questão G

Qual é a quantidade de esforço total quando as variáveis X1 e X2 têm o valor do quartil3 (Q3)?

Para X1 (Transações Lógicas)

Valor do quartil 3 da variável X1 = 164,75

Portanto, a quantidade de esforço total quando a variável X1 possui valor de 164,75 é:

$$\hat{Y}_1 = 566,252 - 0,655 \times X_1$$

$$\hat{Y}_1 = 566,252 - 0,655 \times 164,75$$

$$\hat{Y}_1 = 566,252 - 107,91125$$

$$\hat{Y}_1 = 458,34075$$

$$\hat{Y}_1 = 458,341 \text{ homens/hora}$$

Interpretação: Quando o número de transações lógicas (X1) está no seu terceiro quartil (164,75), o esforço previsto é de 458,341 homens/hora.

Para X2 (Base de Dados)

Valor do quartil 3 da variável X2 = 64,25

Portanto, a quantidade de esforço total quando a variável X2 possui valor de 64,25 é:

$$\hat{Y}_2 = 52,906 + 1,568 \times X_2$$

$$\hat{Y}_2 = 52,906 + 1,568 \times 64,25$$

$$\hat{Y}_2 = 52,906 + 100,744$$

$$\hat{Y}_2 = 153,650 \text{ homens/hora}$$

Interpretação: Quando o tamanho da base de dados (X_2) está no seu terceiro quartil (64,25), o esforço previsto é de 153,650 homens/hora.