

Cálculo Numérico

Aula 2 – Representação Numérica

Profa. Angela Leite Moreno

Bacharelado em Ciência da Computação

Representação Numérica

Nesta aula estudaremos como os números são **representados** e **armazenados** em sistemas computacionais, e de que forma essa representação influencia os erros nos cálculos numéricos.

Roteiro

- 1 Motivação: por que representação importa?
- 2 Sistemas de numeração e bases
- 3 Aritmética de ponto flutuante
- 4 Estudo dos erros numéricos

Motivação – Exemplo 1

Problema

Calcule a **área de uma circunferência** de raio 100 metros.

$$A = \pi r^2 = \pi \cdot (100)^2 = 10\,000\pi$$

Como o valor de π é **irracional**, sua representação no computador é sempre **aproximada**. Diferentes sistemas ou linguagens podem produzir resultados distintos.

Motivação – Exemplo 1: três respostas possíveis

31400

- Valor utilizado: $\pi = 3,14$.

31416

- Valor utilizado: $\pi = 3,1416$.

31416,92654

- Valor utilizado: $\pi = 3,141692654$.

Motivação – Exemplo 2

$$S = \sum_{i=1}^{3000} x_i$$

para $x_i = 0,5$ e para $x_i = 0,11$.

	S para $x_i = 0,5$	S para $x_i = 0,11$
Calculadora	15000	3300
Computador	15000	3299,99691

Por que ocorrem diferenças?

As diferenças podem ter ocorrido em função da **base utilizada**, da **forma como os números são armazenados**, ou em virtude dos **erros cometidos nas operações aritméticas**.

Para entender esse problema, precisamos estudar:

- Sistemas de numeração e bases
- Representação de ponto flutuante
- Tipos e fontes de erros numéricos

Sistemas de Numeração – Base Decimal

Normalmente utilizamos o sistema de numeração **decimal** para representar números. Nesse sistema, a posição que o dígito ocupa indica a potência de 10 que ele representa.

Exemplo:

$$649 = 6 \cdot 10^2 + 4 \cdot 10^1 + 9 \cdot 10^0 = 6 \text{ centenas} + 4 \text{ dezenas} + 9 \text{ unidades}$$

Sistemas de Numeração – Forma Geral

Em geral, qualquer número pode ser decomposto numa soma dos dígitos que o constitui (d) vezes potências da sua base β :

$$(N)_{\beta} = (d_n d_{n-1} \cdots d_1 d_0 . d_{-1} d_{-2} \cdots d_{-m})_{\beta}$$

$$(N)_{10} = d_n \beta^n + \cdots + d_1 \beta^1 + d_0 \beta^0 + d_{-1} \beta^{-1} + \cdots + d_{-m} \beta^{-m}$$

com cada dígito d_j satisfazendo:

$$0 \leq d_j < \beta$$

Sistema Decimal – Base 10

Todos os múltiplos e submúltiplos são escritos como potências de 10.

Exemplos:

$$(1834)_{10} = 1 \cdot 10^3 + 8 \cdot 10^2 + 3 \cdot 10^1 + 4 \cdot 10^0$$

$$(37,194)_{10} = 3 \cdot 10^1 + 7 \cdot 10^0 + 1 \cdot 10^{-1} + 9 \cdot 10^{-2} + 4 \cdot 10^{-3}$$

$$(6,032 \times 10^{23})_{10} = (\text{notação científica})$$

Sistema Binário – Base 2

Utiliza apenas os símbolos **0** e **1** (*bits*). Todos os múltiplos e submúltiplos são potências de 2.

Desenvolvido no século XVII por **Leibniz**; em 1814, **Boole** criou a álgebra booleana e, em 1935, **Shannon** a implementou em circuitos.

Exemplos:

$$(101101)_2 = 1 \cdot 2^5 + 0 \cdot 2^4 + 1 \cdot 2^3 + 1 \cdot 2^2 + 0 \cdot 2^1 + 1 \cdot 2^0 = (45)_{10}$$

$$(100,101)_2 = 1 \cdot 2^2 + 0 \cdot 2^1 + 0 \cdot 2^0 + 1 \cdot 2^{-1} + 0 \cdot 2^{-2} + 1 \cdot 2^{-3} = (4,625)_{10}$$

Sistema Hexadecimal – Base 16

Símbolos

0, 1, 2, 3, 4, 5, 6, 7, 8, 9, A, B, C, D, E, F

em que A= 10, B= 11, C= 12, D= 13, E= 14, F= 15.

Exemplos:

$$(AF83)_{16} = 10 \cdot 16^3 + 15 \cdot 16^2 + 8 \cdot 16 + 3$$

$$(1B3,E2)_{16} = 1 \cdot 16^2 + 11 \cdot 16 + 3 + 14 \cdot 16^{-1} + 2 \cdot 16^{-2}$$

$$(0,D4C)_{16} = 13 \cdot 16^{-1} + 4 \cdot 16^{-2} + 12 \cdot 16^{-3}$$

O sistema hexadecimal usa um número reduzido de símbolos para representar grandes quantidades – útil para **compactação, visualização e armazenamento** de dados.

Conversão de Bases: Decimal para Binária

Método

- **Parte inteira:** divisões sucessivas por 2
- **Parte fracionária:** multiplicações sucessivas por 2

Exemplos:

$$(71)_{10} = (1000111)_2$$

$$(23480)_{10} = (101101110111000)_2$$

$$(167,1875)_{10} = (10100111,0011)_2$$

$$(0,2)_{10} = (0,001100110011\dots)_2 \quad (\text{representação infinita!})$$

Um número sem representação finita em binário pode causar **erros aparentemente inexplicáveis** nos cálculos eletrônicos.

Conversão de Bases: Binária para Decimal

Exemplos:

$$(101101)_2 = 32 + 8 + 4 + 1 = (45)_{10}$$

$$(100,101)_2 = 4 + 0,5 + 0,125 = (4,625)_{10}$$

Um número inteiro decimal pode sempre ser representado exatamente em binário. **Isso não é verdade para os fracionários.**

Analise os casos:

$$(0,1)_{10} \longrightarrow (x)_2$$

$$(0,11)_{10} \longrightarrow (x)_2$$

Conversão: Hexadecimal $\Leftrightarrow$ Binária

Hexadecimal $\Rightarrow$ Binária

Como $16 = 2^4$, cada dígito hexadecimal corresponde a **4 bits** exatos.

Exemplos:

$$(A7C)_{16} = (1010\ 0111\ 1100)_2$$

$$(3D,F)_{16} = (0011\ 1101,1111)_2$$

Binária $\Rightarrow$ Hexadecimal

Agrupa-se os bits em grupos de quatro e converte-se cada grupo diretamente.

Exemplos:

$$(1000101001101110)_2 = (8A6E)_{16}$$

$$(100101001101110)_2 = (4A6E)_{16}$$

Agrupa-se os bits em grupos de quatro a partir da vírgula e converte-se cada grupo diretamente para o dígito hexadecimal correspondente.

Não há perda de dígitos significativos nessa conversão.

Aritmética de Ponto Flutuante – Representação

Representação

A representação de números reais mais utilizada em máquinas é a do **ponto flutuante**. Um número tem três partes:

$$\pm 0. d_1 d_2 \cdots d_t \times \beta^e$$


- d_i = dígitos da mantissa, com $1 \leq d_1 \leq \beta - 1$
- β = base (em geral 2, 10 ou 16)
- t = número de dígitos da mantissa
- e = expoente inteiro, $e_{\min} \leq e \leq e_{\max}$

Aritmética de Ponto Flutuante – Bits e Bytes

- Um dígito binário é denominado **bit** (*binary digit*).
- Um grupo de 8 bits corresponde a **1 byte**.
- A representação dos números num computador usa um número **finito de bits** – denominado *palavra de computador*.
- Microcomputadores tradicionais: palavras de **16** ou **32 bits**.
- Computadores modernos: palavras de **64 bits** ou mais.

Quanto maior o tamanho da palavra, mais **veloz** e mais **preciso** será o computador.

Aritmética de Ponto Flutuante – Estrutura



Expoente

Representa a ordem de grandeza (potência da base).

Mantissa

Contém os dígitos significativos do número.

Pesquise sobre os parâmetros de aritmética de ponto flutuante utilizados em diferentes computadores digitais.

Aritmética de Ponto Flutuante – Definição Formal

Definição

Uma aritmética de ponto flutuante F é caracterizada por quatro inteiros: $F(\beta, t, e_{\min}, e_{\max})$, com $F \subset \mathbb{R}$.

Exemplo: $F(2, 2, -1, 2)$ com número normalizado ($d_1 \neq 0$)

Os números representáveis são todos da forma:

$$\pm 0.d_1 d_2 \times 2^e, \quad d_1 \in \{1\}, \quad d_2 \in \{0, 1\}, \quad e \in \{-1, 0, 1, 2\}$$

Total de elementos de F

$$2(\beta - 1) \beta^{t-1} (e_{\max} - e_{\min} + 1) + 1$$

Para $F(2, 2, -1, 2)$: $2 \cdot 1 \cdot 2^1 \cdot 4 + 1 = \mathbf{17}$

Erros na Representação dos Números

O conjunto dos números reais é **infinito**, mas a representação em ponto flutuante é **limitada**. Essa limitação tem duas origens:

1. Faixa dos Expoentes Limitada

$$e_{\min} \leq e \leq e_{\max}$$

Fora desse intervalo ocorre **overflow** ou **underflow**.

2. Mantissa Finita

A mantissa representa apenas um número finito de dígitos significativos, causando **erros de arredondamento**.

Erros na Representação – Overflow e Underflow

Overflow

Operação produz número com expoente **superior** a $e_{\max}$.

$$e > e_{\max}$$

Underflow

Operação produz número com expoente **inferior** a $e_{\min}$.

$$e < e_{\min}$$

Exercício: $F(10, 2, -5, 5)$

- 1 Sejam $x = 875$ e $y = 3172$. Calcule $x \times y$.
- 2 Sejam $x = 0064$ e $y = 7312$. Calcule $x \div y$.

Erros na Representação – Mantissa Finita

Exemplo 1: Máquina com 6 dígitos na mantissa

$$m = \pm 0, d_1 d_2 d_3 d_4 d_5 d_6 \times 10^e$$

Como armazenar $(0,11)_{10}$?

$$(0,11)_{10} = 0,110000 \times 10^0 \Rightarrow \text{armazenado exatamente: } + 0,110000 \times 10^0$$

Exemplo 2: Representação binária – números sem fim

$$(0,6)_{10} = (0,1001100110011\dots)_2 \Rightarrow \text{representação infinita!}$$

$$(0,7)_{10} = (0,1011001100110\dots)_2 \Rightarrow \text{representação infinita!}$$

Com mantissa finita, esses valores são **truncados ou arredondados**, introduzindo erro de representação.

Truncamento e Arredondamento

Truncamento

Desprezam-se os algarismos acima da $(t + 1)$ -ésima casa decimal, onde t é o número de dígitos da mantissa.

$$0, d_1 d_2 \cdots d_t \underbrace{d_{t+1} d_{t+2} \cdots}_{\text{desprezados}}$$

Arredondamento – caso 1

Se $d_{t+1} < 5$:

despreza-se tudo após a t -ésima casa.

$$0, d_1 d_2 \cdots d_t \longleftarrow \text{mantém}$$

Arredondamento – caso 2

Se $d_{t+1} \geq 5$:

soma-se 1 a d_t e despreza-se o restante.

$$0, d_1 d_2 \cdots (d_t + 1) \longleftarrow \text{incrementa}$$

Truncamento e Arredondamento – Exercício

Sistema $F(10, 3, -4, 4)$

Dar a representação no formato $\pm 0, d_1 d_2 d_3 \times 10^e$ usando **arredondamento** e **truncamento**.

Números

1. 1,25

2. 10,053

3. -238,15

4. 2,71828...

5. 0,000007

6. 718235,82

Truncamento e Arredondamento – Exercício

Sistema $F(10, 2, -5, 5)$

Formato: $\pm 0, d_1 d_2 \times 10^e$, $d_1 \neq 0$, $-5 \leq e \leq 5$

1. $x = 4,32$ e $y = 0,064$

Calcule $x + y$

$$x = 0,43 \times 10^1 \quad y = 0,64 \times 10^{-1}$$

2. $x = 372$ e $y = 371$

Calcule $x - y$

$$x = 0,37 \times 10^3 \quad y = 0,37 \times 10^3$$

3. $x = 691$ e $y = 2,71$

Calcule $x + y$

$$x = 0,69 \times 10^3 \quad y = 0,27 \times 10^1$$

Estudo dos Erros

Nenhum resultado obtido através de cálculos eletrônicos ou métodos numéricos tem valor se não tivermos **conhecimento e controle** sobre os possíveis **erros** envolvidos no processo.

A análise dos resultados obtidos através de um método numérico representa uma **etapa fundamental** no processo das soluções numéricas.

Estudo dos Erros – Número Aproximado

Definição

Um número $\tilde{x}$ é dito uma **aproximação** para o número exato x se existe uma pequena diferença entre eles.

Aproximação por falta

$$\tilde{x} < x$$

O valor aproximado é **menor** que o exato.

Aproximação por excesso

$$\tilde{x} > x$$

O valor aproximado é **maior** que o exato.

Exemplo: $\sqrt{2}$ é irracional, logo só pode ser aproximado

$$\underbrace{1,41}_{\text{por falta}} < \sqrt{2} < \underbrace{1,42}_{\text{por excesso}}$$

Estudo dos Erros – Erro Absoluto e Relativo

Erro Absoluto

A diferença entre o valor exato x e a sua aproximação $\tilde{x}$:

$$EA_x = |x - \tilde{x}|$$

Mede o **tamanho** do erro em unidades do problema.

Erro Relativo

O erro absoluto normalizado pelo valor exato:

$$ER_x = \left| \frac{x - \tilde{x}}{x} \right|, \quad x \neq 0$$

Mede o erro em termos **proporcionais** ao valor exato.

Quando usar cada um?

- **Erro absoluto:** útil quando se conhece a escala do problema.
- **Erro relativo:** mais informativo para comparar aproximações de grandezas diferentes.

Estudo dos Erros – Exercício 1

Exemplo

Considere $x = 100$, $\tilde{x} = 100,1$, $y = 0,0006$ e $\tilde{y} = 0,0004$. Calcule e compare os erros absoluto e relativo de cada aproximação. O que você conclui?

$$EA_x = |x - \tilde{x}| = 0,1$$

$$EA_y = |y - \tilde{y}| = 0,0002$$

Erros absolutos similares – mas qual aproximação é melhor?

Mantissa de 4 dígitos com arredondamento

Uma calculadora armazena apenas **4 dígitos** na mantissa. Um agricultor registra:

$$x = 17534 \text{ (árvores)} \quad y = 21178 \text{ (frutas/árvore)}$$

- Como esses valores são armazenados na máquina?
- Calcule EA_x , ER_x , EA_y e ER_y .
- Qual dos dois valores sofre maior erro relativo?

Bibliografia

-  FRANCO, Neide M. B. *Cálculo numérico*. 1. ed. São Paulo: Pearson Prentice Hall, 2007.
-  RUGGIERO, Márcia A. G.; LOPES, Vera Lúcia da R. *Cálculo numérico: aspectos teóricos e computacionais*. 2. ed. São Paulo: Makron Books, 1997.
-  SPERANDIO, Décio; MENDES, João T.; SILVA, Luiz H. M. *Cálculo numérico: características matemáticas e computacionais dos métodos numéricos*. São Paulo: Prentice Hall, 2003.

Obrigada!

Cálculo Numérico — Aula 02

Bacharelado em Ciência da Computação
