

Ajuste de Curvas

Mínimos Quadrados: Teoria, Modelos e Aplicações

Profa. Angela Leite Moreno

Universidade Federal de Alfenas

UNIFAL-MG

Roteiro

- 1 Introdução e Motivação
- 2 Método dos Mínimos Quadrados
- 3 Regressão Linear Simples
- 4 Caso Geral: Funções Base Arbitrárias
- 5 Regressão Polinomial
- 6 Regressão Múltipla
- 7 Linearização de Modelos Não-Lineares
- 8 Implementação Computacional
- 9 Revisão do Capítulo

O que é Ajuste de Curvas?


Definição

Dados n pares experimentais (x_k, y_k) , encontrar

$$u(x) = a_1 g_1(x) + \cdots + a_m g_m(x)$$

que **melhor representa** a tendência dos dados, admitindo que $u(x_k) \neq y_k$ em geral.

- ▶ Dados podem conter **erros de medição**
- ▶ Curva **não precisa** passar pelos pontos
 - **Diferente** da interpolação!
- ▶ Modelo com $m \ll n$ parâmetros



Resíduos

$$e_k = y_k - u(x_k)$$

Interpolação vs. Ajuste de Curvas

Diferença fundamental

Na **interpolação**, a curva *passa exatamente* pelos pontos: $P(x_i) = y_i$.

No **ajuste**, a curva *aproxima* os dados minimizando um critério de erro global.

Quando usar interpolação?

- Dados **exatos** (sem ruído)
- Poucos pontos confiáveis
- Necessidade de passar pelos pontos
- Tabelas matemáticas precisas

Quando usar ajuste?

- Dados **experimentais** (com ruído)
- Muitos pontos ($n \gg m$)
- Identificar lei física ou tendência
- Extrapolação com margem de segurança

Diagrama de Dispersão — Primeiro Passo

Antes de qualquer cálculo, plota-se o **diagrama de dispersão** para identificar visualmente a tendência e propor um modelo.

Padrão visual	Modelo candidato	Exemplo
Nuvem linear	$u = a_0 + a_1x$	Lei de Hooke, lei de Ohm
Parábola	$u = a_0 + a_1x + a_2x^2$	Resistência ao vento
Crescimento acelerado	$u = ae^{bx}$	Crescimento populacional
Saturação	$u = a + b \ln x$	Crescimento bacteriano
Lei de potência	$u = ax^b$	Leis de escala física
Curva hiperbólica	$u = a/(b + x)$	Michaelis-Menten

Aplicações em Ciência da Computação e Engenharia

Aprendizado de Máquina

Regressão linear é a base de todo ML supervisionado.

`LinearRegression()` do `scikit-learn` resolve exatamente $A^T A a = A^T y$.

Ridge (ℓ_2 -reg.) adiciona λI à matriz de Gram.

Epidemiologia

Estimativa de taxa de crescimento r e tempo de duplicação $T_2 = \ln 2/r$ de surtos infecciosos.

Ajuste: $\ln C = \ln C_0 + rt$ sobre dados ruidosos.

Calibração de Sensores

Termistores, strain gauges, sensores de pressão têm resposta não-linear.

Ajuste gera a **curva de calibração**. r^2 quantifica a qualidade.

Exercícios Propostos — Introdução

EP 1.1

Classifique cada situação como **interpolação** ou **ajuste**, justificando:

- (a) Temperatura de um forno lida por termômetro de precisão em $t = 0, 1, 2, 3, 4$ s.
- (b) Lei de crescimento bacteriano obtida de 50 medidas com erros de pipetagem.
- (c) Estimativa de $\ln(1,5)$ a partir de tabela de logaritmos exatos.

EP 1.2

Para cada tabela, esboce o diagrama de dispersão e proponha um modelo adequado:

(a)

x	1	2	4	8	16
y	1,2	1,9	3,1	5,0	8,1

(b)

x	0	1	2	3
y	5,0	1,8	0,7	0,2

Por que Minimizar a Soma dos Quadrados?

O **resíduo** entre o valor real e o modelo é $e_k = y_k - u(x_k)$.

$$\min \sum e_k$$

Qualquer reta pelo ponto médio é mínimo.

Solução não única!

$$\min \sum |e_k|$$

Qualquer reta entre extremos é mínimo.

Solução não única!

$$\min \sum e_k^2$$

Função diferenciável e **estritamente convexa**.

Solução única!

Método dos Mínimos Quadrados

Encontrar $u(x) = a_1 g_1(x) + \dots + a_m g_m(x)$ que minimize

$$S_r(a_1, \dots, a_m) = \sum_{k=1}^n [y_k - u(x_k)]^2$$

Coefficiente de Determinação r^2

Definição

$$r^2 = 1 - \frac{S_r}{S_t} \quad \text{onde} \quad S_r = \sum_{k=1}^n (y_k - \hat{y}_k)^2, \quad S_t = \sum_{k=1}^n (y_k - \bar{y})^2$$

S_r : variância dos resíduos

S_t : variância total dos dados

$$r^2 \rightarrow 1$$

Excelente ajuste

Modelo explica quase toda a variância.

$$r^2 \approx 0,7$$

Ajuste razoável

Modelo explica 70% da variância.

$$r^2 \rightarrow 0$$

Ajuste ruim

Modelo não captura o padrão.

Atenção

r^2 alto **não garante** modelo correto — r^2 *sempre cresce* ao se adicionar parâmetros!
Analise sempre os resíduos graficamente.

Variância Residual σ^2 — Critério Complementar

Variância Residual

$$\sigma^2 = \frac{S_r}{n - p}, \quad p = m + 1 \text{ (número de parâmetros)}$$

$n - p$: graus de liberdade residuais — dados que sobram após estimar p parâmetros.

Por que σ^2 é mais informativo que r^2 sozinho?

- r^2 cresce *sempre* ao adicionar parâmetro
- σ^2 pode **aumentar** se o parâmetro for desnecessário
- **Grau ótimo**: minimiza σ^2 (*joelho* da curva)

Exemplo: população Brasil

Grau m	r^2	σ^2
1	0,96602	95,82
2	0,99776	7,59
3	0,99939	2,57
4	0,99940	3,43 ↑
5	0,99980	1,66
6	0,99998	0,42

Joelho: $m = 3$ (após isso, σ^2 sobe!)

Análise de Resíduos

O gráfico de resíduos $e_k = y_k - \hat{y}_k$ versus x_k é a ferramenta mais importante para diagnosticar a qualidade do ajuste.

Padrão nos resíduos	Interpretação
Aleatório, média zero, amplitude constante	Modelo adequado
Tendência crescente ou decrescente	Variável omitida ou modelo errado
Forma de U ou arco	Grau insuficiente (falta termo x^2)
Amplitude crescente com x	Heterocedasticidade

Princípio da Parcimônia

Entre modelos com desempenho similar em r^2 e σ^2 , prefira o **mais simples**. Use σ^2 para identificar o joelho e o gráfico de resíduos para confirmar.

Teoria — Dedução das Equações Normais

Modelo: $u(x) = a_0 + a_1x$ Minimizar: $S_r(a_0, a_1) = \sum_{k=1}^n (y_k - a_0 - a_1x_k)^2$

Condições de mínimo ($\nabla S_r = 0$):

$$\frac{\partial S_r}{\partial a_0} = -2 \sum_{k=1}^n (y_k - a_0 - a_1x_k) = 0 \Rightarrow na_0 + a_1 \sum x_k = \sum y_k$$

$$\frac{\partial S_r}{\partial a_1} = -2 \sum_{k=1}^n x_k (y_k - a_0 - a_1x_k) = 0 \Rightarrow a_0 \sum x_k + a_1 \sum x_k^2 = \sum x_k y_k$$


Equações Normais — reta

$$\underbrace{\begin{bmatrix} n & \sum x_k \\ \sum x_k & \sum x_k^2 \end{bmatrix}}_{\text{simétrica, pos. def.}} \begin{bmatrix} a_0 \\ a_1 \end{bmatrix} = \begin{bmatrix} \sum y_k \\ \sum x_k y_k \end{bmatrix}$$

Teoria — Fórmulas Explícitas e Propriedades

Solução das Equações Normais

$$a_1 = \frac{n \sum x_k y_k - \sum x_k \cdot \sum y_k}{n \sum x_k^2 - (\sum x_k)^2}$$



Propriedades importantes:

- A reta **sempre** passa pelo centróide $(\bar{x}, \bar{y})$
- $\det = n \sum x_k^2 - (\sum x_k)^2 > 0$
(por Cauchy-Schwarz, se x_k não iguais)
- a_0 : intercepto com eixo y
- a_1 : inclinação (taxa de variação)

Exemplo 1 — Resistência vs. Temperatura

Dados

Ajustar uma reta à resistência elétrica de um fio de platina ($n = 6$):

$T (C)$	20	40	60	80	100	120
$R (\Omega)$	77,2	84,5	91,8	98,3	105,7	113,1

Tabela de somas:

T_k	R_k	T_k^2	$T_k R_k$
20	77,2	400	1544,0
40	84,5	1600	3380,0
60	91,8	3600	5508,0
80	98,3	6400	7864,0
100	105,7	10000	10570,0
120	113,1	14400	13572,0
$\sum$	570,6	36400	42438,0

$$\bar{T} = 70; \bar{R} = 95,1; \Delta = 42000$$

$$a_1 = \frac{6(42438) - 420(570,6)}{42000} \approx 0,3566 \Omega/C$$

$$a_0 = 95,1 - 0,3566(70) \approx 70,14 \Omega$$

Resultado

$$u(T) \approx 70,14 + 0,3566 T$$

$$r^2 \approx 0,9997$$

Exercícios Propostos — Regressão Linear

EP 3.1

Ajuste uma reta aos dados abaixo, calcule r^2 e trace o gráfico de resíduos. O modelo linear é adequado?

x	5	10	15	20	30
y	1,8	3,9	5,1	7,2	10,1

EP 3.2

Prove que a reta de mínimos quadrados **sempre passa pelo centróide** $(\bar{x}, \bar{y})$. *Dica:* use a equação normal $na_0 + a_1 \sum x_k = \sum y_k$.

Framework Geral — Motivação

Os casos anteriores (reta, polinômio, múltipla) são instâncias de um framework mais geral: dado qualquer conjunto de funções base $g_1(x), \dots, g_m(x)$, busca-se a combinação linear ótima.

Problema Geral de Mínimos Quadrados

$$\text{Minimizar } S_r = \sum_{k=1}^n [y_k - (a_1 g_1(x_k) + \dots + a_m g_m(x_k))]^2$$

Framework Geral — Motivação

Exemplos de funções base:

Modelo	Funções base	Característica
Reta	$1, x$	Linear em a_0, a_1
Polinômio m	$1, x, x^2, \dots, x^m$	Linear em a_j
Misto	$1, x, e^{-x}$	Híbrido: linear + exp.
Fourier	$1, \cos \omega t, \sin \omega t, \dots$	Análise espectral

Atenção

O modelo deve ser **linear nos parâmetros** a_j , não necessariamente em x . Ex.: $u = ae^{bx}$ **não** é linear (entra no expoente) $\Rightarrow$ requer linearização.

Teoria — Equações Normais Gerais

Impondo $\partial S_r / \partial a_j = 0$ para $j = 1, \dots, m$:

Equações Normais Gerais (Matriz de Gram)

$$\underbrace{\begin{bmatrix} \sum g_1 g_1 & \sum g_1 g_2 & \cdots & \sum g_1 g_m \\ \sum g_2 g_1 & \sum g_2 g_2 & \cdots & \sum g_2 g_m \\ \vdots & & \ddots & \vdots \\ \sum g_m g_1 & \sum g_m g_2 & \cdots & \sum g_m g_m \end{bmatrix}}_{G=A^T A \text{ (simétrica, pos. def.)}} \begin{bmatrix} a_1 \\ a_2 \\ \vdots \\ a_m \end{bmatrix} = \begin{bmatrix} \sum g_1 y_k \\ \sum g_2 y_k \\ \vdots \\ \sum g_m y_k \end{bmatrix}$$

em que $g_i \equiv g_i(x_k)$, somas em $k = 1, \dots, n$

Teoria — Equações Normais Gerais

Existência e unicidade: se os vetores $\bar{g}_j = (g_j(x_1), \dots, g_j(x_n))^T$ são **linearmente independentes**, G é positiva definida e o sistema tem solução única.

Unificação:

- Reta: $g_1 = 1, g_2 = x$
- Polinômio: $g_j = x^{j-1}$
- Múltipla: $g_1 = 1, g_j = x_j$
- Misto: $g_1 = 1, g_2 = x, g_3 = e^{-x}$

Modelo Misto: Polinomial + Exponencial

Modelo: $u(x) = a_1 + a_2x + a_3e^{\beta x}$ (β fixo)

Com $\beta = -1$ (decaimento), as equações normais ficam:

$$\begin{bmatrix} n & \sum x_k & \sum e^{-x_k} \\ \sum x_k & \sum x_k^2 & \sum x_k e^{-x_k} \\ \sum e^{-x_k} & \sum x_k e^{-x_k} & \sum e^{-2x_k} \end{bmatrix} \begin{bmatrix} a_1 \\ a_2 \\ a_3 \end{bmatrix} = \begin{bmatrix} \sum y_k \\ \sum x_k y_k \\ \sum e^{-x_k} y_k \end{bmatrix}$$

Aplicações do Modelo Misto

- **Farmacologia:** $C(t) = Ae^{-\alpha t} + Be^{-\beta t}$ (modelo bicompartimental — padrão FDA com NONMEM/Monolix)
- **Análise de sinais:** séries de Fourier $u = a_0 + \sum [b_j \cos j\omega t + c_j \sin j\omega t]$
- **ECG:** decomposição do sinal cardíaco em componentes frequenciais

Exemplo 2 — Modelo Misto $u = a_1 + a_2x + a_3e^{-x}$ Dados experimentais ($n = 8$)

x_k	-1,0	-0,5	0,0	0,5	1,0	1,5	2,0	2,5
y_k	10,20	4,35	2,18	1,54	1,82	2,91	4,62	6,90

Somam auxiliares:

$$\begin{aligned}
 \sum x_k &= 6,0 & \sum e^{-x_k} &= 6,782 \\
 \sum x_k^2 &= 15,0 & \sum e^{-2x_k} &= 11,685 \\
 \sum x_k e^{-x_k} &= -2,261 & \sum y_k &= 34,52 \\
 \sum x_k y_k &= 21,07 & \sum e^{-x_k} y_k &= 40,53
 \end{aligned}$$

Sistema:

$$\begin{bmatrix} 8 & 6 & 6,782 \\ 6 & 15 & -2,261 \\ 6,782 & -2,261 & 11,685 \end{bmatrix} a = \begin{bmatrix} 34,52 \\ 21,07 \\ 40,53 \end{bmatrix}$$

Solução:

$$a_1 \approx -0,831, \quad a_2 \approx 2,014, \quad a_3 \approx 4,982$$

Resultado

$$u(x) \approx -0,831 + 2,014x + 4,982e^{-x}$$

$$r^2 \approx 0,996$$

$$\text{Ajuste linear puro: } r^2 \approx 0,73$$

O termo exponencial reduziu S_r em ≈ 99 vezes!

Exercícios Propostos — Caso Geral

EP 4.1

Derive explicitamente as equações normais para $u = a_1 + a_2x + a_3e^x$. Identifique cada elemento da Matriz de Gram e do lado direito.

EP 4.2

Para os dados do Exemplo 2, compare os ajustes:

- (a) $u = a_1 + a_2x + a_3e^{-x}$ (misto)
- (b) $u = a_1 + a_2x + a_3x^2$ (quadrático puro)

Calcule r^2 para cada um e trace os gráficos de resíduos. Qual é mais adequado?

Teoria — Equações Normais de Grau m

Modelo: $u(x) = a_0 + a_1x + \cdots + a_mx^m \quad (m \ll n)$

Condições $\partial S_r / \partial a_j = 0, j = 0, \dots, m$, levam à **Matriz de Gram**:

Equações Normais Polinomiais — grau m

$$\begin{bmatrix} n & \sum x_k & \cdots & \sum x_k^m \\ \sum x_k & \sum x_k^2 & \cdots & \sum x_k^{m+1} \\ \vdots & & \ddots & \vdots \\ \sum x_k^m & \sum x_k^{m+1} & \cdots & \sum x_k^{2m} \end{bmatrix} \begin{bmatrix} a_0 \\ \vdots \\ a_m \end{bmatrix} = \begin{bmatrix} \sum y_k \\ \vdots \\ \sum x_k^m y_k \end{bmatrix}$$

Observação importante


Para $m = n - 1$: $S_r = 0$ — o ajuste se reduz à **interpolação**. Em geral, exige-se $m \ll n$.

Seleção de Grau — r^2 e σ^2

Dados de arrasto aerodinâmico:

α	0	4	8	12	16	20
F	0,12	0,30	0,75	1,80	3,85	7,20

Grau	r^2	S_r	σ^2
1	0,961	6,764	1,691
2	0,992	1,408	0,469
3	0,995	1,051	0,525 $\uparrow$



Grau 2: σ^2 mínimo $\rightarrow$ modelo recomendado pelo princípio da parcimônia

Exercícios Propostos — Regressão Polinomial

EP 5.1

Para os dados abaixo, ajuste modelos de grau 1 e 2. Calcule r^2 e σ^2 para cada um e indique qual grau é mais adequado.

x	0	1	2	3	4	5	6
y	3,0	4,8	8,1	13,5	20,2	29,5	41,3

EP 5.2 — Variância Residual

Para $n = 10$ dados, dois modelos foram ajustados:

(a) Grau 2 ($p = 3$): $S_r = 8,4$; Grau 4 ($p = 5$): $S_r = 6,1$; $S_t = 120$.

Calcule r^2 e σ^2 para cada modelo. Qual é mais adequado? Os dois critérios concordam?

Teoria — Modelo e Formulação Matricial

Modelo: $y = a_0 + a_1x_1 + a_2x_2 + \cdots + a_px_p$

Minimizar $S_r = \sum_{k=1}^n (y_k - a_0 - a_1x_{1k} - \cdots - a_px_{pk})^2$

Sistema Normal em Forma Matricial

$$A^T A \vec{a} = A^T \vec{y}$$

em que A é a **matriz de projeto** ($n \times (p+1)$):

$$A = \begin{bmatrix} 1 & x_{11} & x_{21} & \cdots & x_{p1} \\ 1 & x_{12} & x_{22} & \cdots & x_{p2} \\ \vdots & & & & \vdots \\ 1 & x_{1n} & x_{2n} & \cdots & x_{pn} \end{bmatrix}, \quad \vec{y} = \begin{bmatrix} y_1 \\ \vdots \\ y_n \end{bmatrix}, \quad \vec{a} = \begin{bmatrix} a_0 \\ \vdots \\ a_p \end{bmatrix}$$

Teoria — Modelo e Formulação Matricial

Escala das variáveis

Variáveis em escalas diferentes **alteram os coeficientes** mas produzem o **mesmo ajuste** (mesmos valores $\hat{y}_k$). Verifique sempre a consistência de unidades!

Exemplo 3 — Consumo de Energia

Dados

Consumo mensal (kWh) estimado a partir de área útil x_1 (m²) e número de moradores x_2 :

k	x_1	x_2	y
1	45	2	180
2	60	3	240
3	80	4	310
4	55	1	200
5	90	5	380
6	70	3	270

Sistema $A^T A \vec{a} = A^T \vec{y}$:

$$\begin{bmatrix} 6 & 400 & 18 \\ 400 & 27850 & 1240 \\ 18 & 1240 & 64 \end{bmatrix} \vec{a} = \begin{bmatrix} 1580 \\ 107900 \\ 4580 \end{bmatrix}$$

Resultado

$$\hat{y} = 10,4 + 2,83 x_1 + 28,7 x_2$$

$$r^2 \approx 0,997$$

Cada m² adicional: +2,83 kWh/mês

Cada morador: +28,7 kWh/mês

Exercícios Propostos — Regressão Múltipla

EP 6.1

Monte a matriz de projeto A e resolva o sistema $A^T A \vec{a} = A^T \vec{y}$:

k	x_1	x_2	y
1	2	1	5,3
2	3	2	8,1
3	5	1	10,7
4	6	3	14,2
5	8	2	17,5

Calcule $\sum e_k^2$ e r^2 .

EP 6.2

Repita o Exemplo 3 convertendo x_1 de m^2 para dm^2 ($1 \text{ m}^2 = 100 \text{ dm}^2$). Verifique que os valores ajustados $\hat{y}_k$ são idênticos. Os coeficientes mudam? Discuta o impacto da escala na interpretação.

Estratégia de Linearização

Ideia

Aplicar uma **transformação algébrica** ao modelo não-linear para reduzi-lo a regressão linear, aplicar mínimos quadrados e **reverter** a transformação.

Modelo	Transformação	Forma linear
$y = ae^{bx}$	$\tilde{y} = \ln y$	$\tilde{y} = \ln a + bx$
$y = ax^b$	$\tilde{y} = \ln y, \tilde{x} = \ln x$	$\tilde{y} = \ln a + b\tilde{x}$
$y = a + b \ln x$	$\tilde{x} = \ln x$	$\tilde{y} = a + b\tilde{x}$
$y = ax^b e^{cx}$	$\tilde{y} = \ln y$	$\tilde{y} = \ln a + b \ln x + cx$
$y = \frac{a}{b + x}$	$\tilde{y} = \frac{1}{y}$	$\tilde{y} = \frac{b}{a} + \frac{1}{a}x$
$y = A \cos(\omega x + \varphi)$	—	$y = A \cos \varphi \cdot \cos \omega x - A \sin \varphi \cdot \sin \omega x$

Atenção

Linearização minimiza S_r no **espaço transformado**, não no original.

Modelo Exponencial $y = ae^{bx}$

Motivação: crescimento/decaimento com taxa proporcional ao valor atual ($y' = by$).



Linearização:

$$\ln y = \underbrace{\ln a}_{\bar{a}} + bx \Rightarrow \tilde{y} = \bar{a} + bx$$

Procedimento:

1. Calcular $\tilde{y}_k = \ln y_k$
2. Ajustar reta a $(x_k, \tilde{y}_k) \Rightarrow \bar{a}$ e b
3. Recuperar $a = e^{\bar{a}}$

Requisito

$$y_k > 0 \text{ para todos os } k$$


Exemplo 4 — Decaimento de Capacitor ($y = ae^{bx}$)

Dados

Tensão V (V) de um capacitor em descarga ($n = 6$):

t (s)	0	5	10	15	20	25
V (V)	12,00	7,35	4,50	2,76	1,69	1,03

Tabela transformada $\tilde{V}_k = \ln V_k$:

t_k	$\tilde{V}_k$	t_k^2	$t_k \tilde{V}_k$
0	2,485	0	0,000
5	1,995	25	9,974
10	1,504	100	15,041
15	1,015	225	15,228
20	0,525	400	10,494
25	0,030	625	0,740
	7,553	1375	51,477

$$\Delta = 6(1375) - 75^2 = 2625$$

$$b = \frac{6(51,477) - 75(7,553)}{2625} \approx -0,0981$$

$$\bar{a} = \frac{7,553 - (-0,0981)(75)}{6} \approx 2,486$$

Resultado

$$V_0 = e^{2,486} \approx 12,01 \text{ V}$$

$$V(t) \approx 12,01 e^{-0,0981 t}$$

$$\tau = -1/b \approx 10,19 \text{ s}$$

Modelo Logarítmico $y = a + b \ln x$



Motivação: crescimento com taxa decrescente (efeito de x diminuir à medida que cresce). **Linearização:** $\tilde{x} = \ln x$ — já é linear!

$$y = a + b\tilde{x}$$

Equações normais:

$$\begin{bmatrix} n & \sum \tilde{x}_k \\ \sum \tilde{x}_k & \sum \tilde{x}_k^2 \end{bmatrix} \begin{bmatrix} a \\ b \end{bmatrix} = \begin{bmatrix} \sum y_k \\ \sum \tilde{x}_k y_k \end{bmatrix}$$

Requisito

$$x_k > 0 \text{ para todos os } k$$


Exemplo 5 — Viscosidade de Óleo ($y = a + b \ln x$)

Dados

Viscosidade μ (Pa.s) de um óleo polimérico vs. temperatura ($n = 5$):

$T (C)$	30	50	80	120	200
$\mu (Pa \cdot s)$	8,40	5,20	2,95	1,60	0,70

Tabela com $\tilde{T}_k = \ln T_k$:

T_k	$\tilde{T}_k$	$\tilde{T}_k^2$	$\tilde{T}_k \mu_k$
30	3,401	11,568	28,570
50	3,912	15,304	20,342
80	4,382	19,202	12,927
120	4,788	22,920	7,660
200	5,298	28,072	3,709
	21,781	97,066	73,208

$$\Delta = 5(97,066) - (21,781)^2 = 10,918$$

$$b = \frac{5(73,208) - 21,781(18,85)}{10,918} \approx -4,079$$

$$a = \frac{18,85 - (-4,079)(21,781)}{5} \approx 21,54$$

Resultado

$$\mu(T) \approx 21,54 - 4,079 \ln T$$

$$r^2 \approx 0,991$$

Exercícios Propostos — Linearização

EP 7.1

Ajuste o modelo potencial $y = ax^b$ aos dados abaixo:

x	1	3	6	10	20
y	2,1	4,8	7,5	11,0	18,5

Linearize com $\tilde{y} = \ln y$, $\tilde{x} = \ln x$. Calcule a , b e r^2 no espaço original.

EP 7.2

Ajuste **dois modelos** aos dados abaixo e determine qual é mais adequado com base em $\sum e_k^2$ no espaço original:

x	0,5	1	2	4	8	16
y	5,8	4,3	3,1	2,2	1,6	1,1

Modelos: (a) $y = a + b \ln x$; (b) $y = ax^b$.

Implementação em Python — Visão Geral

```
import numpy as np

# ---- Framework geral: funcoes base arbitrariables ----
def ajuste_geral(xi, yi, funcoes_base):
    A = np.column_stack([g(xi) for g in funcoes_base])    # matriz de projeto
    a = np.linalg.solve(A.T @ A, A.T @ yi)               # sistema normal
    y_hat = A @ a
    Sr = np.sum((yi - y_hat)**2)
    St = np.sum((yi - yi.mean())**2)
    return a, 1.0 - Sr/St, y_hat

# ---- Modelo misto: u = a1 + a2*x + a3*exp(-x) ----
xi = np.array([-1., -.5, 0., .5, 1., 1.5, 2., 2.5])
yi = np.array([10.20, 4.35, 2.18, 1.54, 1.82, 2.91, 4.62, 6.90])
bases = [lambda x: np.ones_like(x), lambda x: x, lambda x: np.exp(-x)]
a, r2, _ = ajuste_geral(xi, yi, bases)
print(f"u(x)={a[0]:.3f}+{a[1]:.3f}x+{a[2]:.3f}exp(-x)   r^2={r2:.4f}")

# ---- Varredura de graus (r2 e sigma2) ----
x = np.array([0., 4., 8., 12., 16., 20.]); y = np.array([.12,.30,.75,1.80,3.85,7.20])
for m in range(1, 4):
```

Linearização e Regressão Múltipla em Python


```
import numpy as np

# ---- Ajuste exponencial:  $V = V0 \cdot \exp(b \cdot t)$  ----
t = np.array([0., 5., 10., 15., 20., 25.])
V = np.array([12.00, 7.35, 4.50, 2.76, 1.69, 1.03])
p_exp = np.polyfit(t, np.log(V), 1) # ajuste no espaço ln
b, ln_V0 = p_exp
print(f"V(t) = {np.exp(ln_V0):.3f} * exp({b:.4f}*t)")
print(f"Constante de tempo: tau = {-1/b:.2f} s")

# ---- Ajuste logaritmico:  $\mu = a + b \cdot \ln(T)$  ----
T = np.array([30., 50., 80., 120., 200.])
mu = np.array([8.40, 5.20, 2.95, 1.60, 0.70])
p_log = np.polyfit(np.log(T), mu, 1) # ajuste linear em ln(T)
b_log, a_log = p_log
print(f"mu(T) = {a_log:.4f} + {b_log:.4f}*ln(T)")

# ---- Regressao multipla: consumo = a0 + a1*x1 + a2*x2 ----
x1 = np.array([45., 60., 80., 55., 90., 70.])
x2 = np.array([ 2.,  3.,  4.,  1.,  5.,  3.])
y = np.array([180., 240., 310., 200., 380., 270.])
```

Mapa Conceitual do Capítulo



Quadro Comparativo dos Modelos

Modelo	Quando usar	Linearização	Sistema
$a_0 + a_1x$	Relação linear	Nenhuma	2×2
$\sum a_j x^j$	Curva com inflexões	Nenhuma	$(m+1) \times (m+1)$
$\sum a_j g_j(x)$	Bases arbitrárias	Nenhuma	Gram $m \times m$
$a_1 + a_2x + a_3e^{cx}$	Misto polin.+exp.	Nenhuma	3×3 via Gram
ae^{bx}	Crescimento/decaimento	$\tilde{y} = \ln y$	2×2
$a + b \ln x$	Saturação	$\tilde{x} = \ln x$	2×2
ax^b	Lei de potência	$\tilde{y}, \tilde{x} = \ln$	2×2
$\frac{1}{a_0 + a_1x}$	Hiperbólico	$\tilde{y} = 1/y$	2×2

Critério	Fórmula	Interpretação	Limitação
S_r	$\sum e_k^2$	Menor = melhor	Escala absoluta
r^2	$1 - S_r/S_t$	Fração explicada	Monotônico em m
σ^2	$S_r/(n - p)$	Penaliza extras	Identifica joelho
Resíduos	Gráfico	Padrão sistemático	Indispensável

Roteiro Prático de Ajuste de Curvas

1. **Plotar o diagrama de dispersão** — identificar tendência e propor candidatos ao modelo.
2. **Transformar os dados** (se modelo não-linear) — verificar linearidade no espaço transformado.
3. **Montar e resolver as equações normais** — calcular somas, sistema $A^T A \mathbf{a} = A^T \mathbf{y}$.
4. **Reverter a transformação** (se aplicável) — recuperar parâmetros originais.
5. **Calcular r^2 , $\sigma^2 = S_r/(n - p)$ e resíduos** — r^2 mede ajuste; σ^2 identifica joelho; resíduos detectam padrão sistemático.
6. **Princípio da parcimônia** — se r^2 similar e σ^2 não cai, preferir modelo mais simples.
7. **Interpretar parâmetros** no contexto físico do problema.

Exercícios de Revisão — Parte I

ER 1

Para cada modelo, identifique a transformação linearizante e escreva a forma linear:

(a) $y = \frac{a}{b+x}$ (b) $y = ax^b e^{cx}$ (c) $y = A \cos(\omega x + \varphi)$ (ω dado)

ER 2

Ajuste um modelo adequado aos dados de tensão e corrente de um resistor não-ôhmico:

$V(V)$	0,5	1,0	2,0	3,0	5,0	8,0
$I(mA)$	0,30	0,85	2,40	4,40	12,20	31,10

- (a) Plote o diagrama de dispersão e proponha um modelo.
 (b) Aplique a transformação linearizante e ajuste os parâmetros.
 (c) Calcule r^2 , σ^2 e estime I para $V = 4,0$ V.

Exercícios de Revisão — Parte II

ER 3

Compare os ajustes linear e quadrático para temperatura de uma chapa metálica:

$t(s)$	0	10	20	30	40	50
$T(^{\circ}C)$	22	35	55	83	120	163

- (a) Calcule r^2 e σ^2 para $m = 1$ e $m = 2$.
- (b) Qual modelo você recomendaria? Justifique com parcimônia e análise de resíduos.
- (c) Com o modelo escolhido, estime T para $t = 35$ s.

ER 4 — Demonstração

Prove que para $y = a + b \ln x$, a fórmula explícita de b é:

$$b = \frac{n \sum (\ln x_k) y_k - \sum \ln x_k \cdot \sum y_k}{n \sum (\ln x_k)^2 - (\sum \ln x_k)^2}$$

Referências

-  M. A. G. Ruggiero, V. L. R. Lopes. *Cálculo Numérico — Aspectos Teóricos e Computacionais*, 2^a ed. Pearson, 1996. Cap. 6.
-  R. L. Burden, J. D. Faires. *Numerical Analysis*, 10^a ed. Cengage, 2015. Cap. 8.
-  S. C. Chapra, R. P. Canale. *Numerical Methods for Engineers*, 7^a ed. McGraw-Hill, 2015. Cap. 17–18.
-  T. Hastie, R. Tibshirani, J. Friedman. *The Elements of Statistical Learning*, 2^a ed. Springer, 2009. Cap. 3.

Obrigada!

Profa. Angela Leite Moreno

UNIFAL-MG — Cálculo Numérico

“Dados sem um modelo são apenas barulho.”