

Pipeline de Machine Learning

Aula Aprendizado Supervisionado
Prof. Paulo Bressan

Objetivos de Aprendizagem

- Compreender pipeline completo
- Avaliar impacto das decisões
- Interpretar resultados

Formulação Formal

Definição do Problema

Conjunto de Dados

Hipótese (Modelo)

Função de Perda

Risco Empírico

Problema de Otimização

Risco Esperado

Generalização


Pipeline Formal

Definição do Problema

Objetivo: aprender uma função

$$f: \mathcal{X} \rightarrow \mathcal{Y}$$

1. $\mathcal{X} \subseteq \mathbb{R}^n$: espaço de entrada
2. $\mathcal{Y}$: espaço de saída
3. Classificação ou regressão



1. Entrada: vetor de características
2. Saída: rótulo ou valor
3. Problema = mapear dados $\rightarrow$ decisão

Conjunto de Dados

Dados disponíveis:

$$D = \{(x_1, y_1), \dots, (x_m, y_m)\}$$

- $x_i \in \mathcal{X}$
 - $y_i \in \mathcal{Y}$
 - Amostras i.i.d.
-
- Observações do mundo real
 - Base para aprendizado
 - Qualidade dos dados é crítica

Conjunto de Dados

Amostras independentes e identicamente distribuídas:

✓ **Independentes**

Cada amostra não depende das outras:

$$P(x_i, y_i \mid x_j, y_j) = P(x_i, y_i) \quad (i \neq j)$$

✓ **Identicamente distribuídas**

Todas vêm da mesma distribuição $P(x, y)$:

$$(x_i, y_i) \sim P(x, y)$$

Conjunto de Dados

“Machine Learning funciona bem quando o futuro se parece com o passado.”

■ Intuição

✓ Independência

- Um exemplo não influencia outro
- Não há “memória” entre observações

✓ Mesma distribuição

- Dados seguem o **mesmo padrão estatístico**
- Não há mudança no comportamento ao longo do tempo

■ Exemplo simples

Considere seu dataset de alunos:

- Cada linha = um aluno
- Todos os alunos seguem o mesmo processo (mesma disciplina, mesma avaliação)

👉 Aproximadamente i.i.d.

■ Contraexemplos

✗ Dados temporais

- Série temporal (ex: preços de ações)
- Hoje depende de ontem
- 👉 não independentes

✗ Mudança de distribuição

- Dados de anos diferentes (prova mais difícil, nova metodologia)
- 👉 não identicamente distribuídos

Hipótese (Modelo)

“Escolher o modelo é
escolher o conjunto
de hipóteses
possíveis.”

Uma **hipótese** é uma **função candidata** que o modelo usa para **mapear entradas em saídas**.

1. Forma formal

Uma hipótese é uma função:

$$h: \mathcal{X} \rightarrow \mathcal{Y}$$

- $\mathcal{X}$: espaço de entrada (features)
- $\mathcal{Y}$: espaço de saída

2. Hipótese parametrizada

Na prática, escrevemos:

$$h(x; \theta)$$

- x : entrada
- θ : parâmetros do modelo

👉 Aprender = encontrar bons valores de θ

Hipótese (Modelo)

“Escolher o modelo é
escolher o conjunto
de hipóteses
possíveis.”

3. Espaço de hipóteses

Não existe uma única hipótese — existe um conjunto:

$$\mathcal{H} = \{h(x; \theta)\}$$

👉 chamado de **espaço de hipóteses**

4. Intuição

- Cada hipótese = uma possível “explicação” dos dados
- O algoritmo escolhe a melhor hipótese dentro de $\mathcal{H}$

5. Exemplo concreto

Para o seu problema de alunos:

$$h(x) = w_1 \cdot \text{estudo} + w_2 \cdot \text{faltas} + \dots + b$$

ou, com probabilidade:

$$h(x) = \sigma(w \cdot x + b)$$

👉 essa é uma hipótese específica

Hipótese (Modelo)

“Escolher o modelo é
escolher o conjunto
de hipóteses
possíveis.”

6. Papel da hipótese no aprendizado

O processo de treinamento é:

$$\theta^* = \arg \min_{\theta} \hat{R}(\theta)$$

👉 ou seja: escolher a **melhor hipótese** dentro de $\mathcal{H}$

7. Insight importante

O algoritmo não “inventa qualquer função” — ele só escolhe dentro do espaço de hipóteses definido.

8. Consequência prática

Espaço de hipóteses simples:

- mais interpretável
- pode não capturar padrões (underfitting)

Espaço de hipóteses complexo:

- mais expressivo
- risco de overfitting

Função de Perda

“Quão errado estou neste exemplo?”

Erro entre previsão e valor real

$$\ell(y, h(x))$$

- Mede desempenho da previsão
- Define o que significa “errar”
- Penaliza erros
- Diferentes perdas → diferentes comportamentos
- Ex: erro quadrático, *log-loss*

$$RMSE = \sqrt{\sum_{i=1}^n \frac{(\hat{y}_i - y_i)^2}{n}}$$

$\hat{y}_1, \hat{y}_2, \dots, \hat{y}_n$ are predicted values

$y_1, y_2, \dots, y_n$ are observed values

n is the number of observations

Risco Empírico

“Quão errado estou, em média, nos dados?”

O Risco Empírico é a média do erro do modelo nos dados de treinamento.

Definição formal

$$\hat{R}(\theta) = \frac{1}{m} \sum_{i=1}^m \ell(y_i, h(x_i; \theta))$$

- m : número de amostras
- ℓ : função de perda
- $h(x_i; \theta)$: previsão do modelo
- y_i : valor real

“Treinar um modelo é minimizar o erro nos dados e esperar que isso funcione fora deles.”

Problema de Otimização

Encontrar os parâmetros que minimizam o erro médio nos dados

1. Formulação central

O objetivo do aprendizado é resolver:

$$\theta^* = \arg \min_{\theta} \hat{R}(\theta)$$

onde:

$$\hat{R}(\theta) = \frac{1}{m} \sum_{i=1}^m \ell(y_i, h(x_i; \theta))$$

2. Componentes do problema

✓ Variável de decisão

- θ : parâmetros do modelo
- Ex: pesos, vieses


✓ Função objetivo

$$\hat{R}(\theta)$$

- mede o erro médio
- depende da função de perda

✓ Espaço de busca

- todos os valores possíveis de θ
- pode ser contínuo ($\mathbb{R}^n$) ou discreto



Problema de Otimização

Encontrar os parâmetros que minimizam o erro médio nos dados

4. Exemplo concreto (regressão logística)

Modelo:

$$h(x) = \sigma(w \cdot x + b)$$

Parâmetros:


$$\theta = (w, b)$$

Função de perda (log-loss):

$$\ell(y, h(x)) = -[y \log h(x) + (1 - y) \log(1 - h(x))]$$

Problema:

$$\min_{w, b} \frac{1}{m} \sum_{i=1}^m \ell(y_i, h(x_i))$$



Problema de Otimização

Encontrar os parâmetros que minimizam o erro médio nos dados

■ 5. Natureza do problema


✓ Pode ser:

Convexo

- solução global garantida
- ex: regressão linear/logística

Não convexo

- múltiplos mínimos locais
- ex: redes neurais



Problema de Otimização

Encontrar os parâmetros que minimizam o erro médio nos dados

6. Métodos de solução

Como resolver:

✓ Métodos baseados em gradiente


- Gradiente descendente

$$\theta \leftarrow \theta - \eta \nabla \hat{R}(\theta)$$

- η : taxa de aprendizado

✓ Intuição

- seguir direção de maior descida
- iterativo



Risco Esperado

“Treinar é minimizar o erro no passado; aprender é funcionar no futuro.”

O risco esperado é o erro médio do modelo considerando toda a distribuição real dos dados

Definição formal

$$R(\theta) = \mathbb{E}_{(x,y) \sim P}[\ell(y, h(x; \theta))]$$

onde:

- $P(x, y)$: distribuição real (desconhecida) dos dados
- ℓ : função de perda
- $h(x; \theta)$: modelo



Intuição

- Imagine todos os possíveis exemplos do mundo real
- Calcule o erro em cada um
- Tire a média



isso é o risco esperado

Comparação com risco empírico

Conceito

Base

Risco Empírico

dados observados

Risco Esperado

distribuição real

Risco Esperado

“Treinar é minimizar o erro no passado; aprender é funcionar no futuro.”

■ Por que ele é importante?

Porque ele representa o **objetivo real do aprendizado**: queremos minimizar o erro em dados futuros, não só nos dados de treino

■ Problema fundamental

⚠ Não conseguimos calcular diretamente:

- não conhecemos $P(x, y)$
- temos apenas uma amostra (dataset)

■ Generalização

Um bom modelo satisfaz:

$$\hat{R}(\theta) \approx R(\theta)$$

👉 ou seja:

- vai bem no treino
- vai bem em dados novos

Risco Esperado

“Treinar é minimizar o erro no passado; aprender é funcionar no futuro.”

■ Exemplo intuitivo

Treino:

- alunos de um semestre

Risco esperado:

- todos os alunos possíveis (inclusive futuros)

■ Insight importante

“O modelo nunca vê o mundo — ele vê apenas uma amostra do mundo.”

■ Consequência prática

Se a amostra não for representativa:

- risco empírico é enganoso
- risco esperado será alto

Generalização

“Aprender não é memorizar — é capturar padrões que se repetem.”

Generalização é:

a capacidade de um modelo ter bom desempenho em dados novos, não vistos durante o treinamento

■ 1. Definição formal

Queremos que:

$$\hat{R}(\theta) \approx R(\theta)$$

onde:

- $\hat{R}(\theta)$: risco empírico (treino)
- $R(\theta)$: risco esperado (mundo real)

■ 2. Quando há boa generalização?

- erro baixo no treino
- erro baixo em dados novos

🧠 Intuição

- O modelo aprende com um conjunto finito de dados
 - Mas precisa funcionar em situações futuras
- 👉 generalizar = “funcionar fora do treino”

■ 3. Exemplo simples

Treino:

- dataset de alunos de um semestre

Generalização:

- prever corretamente alunos de outro semestre

Generalização

“Aprender não é memorizar — é capturar padrões que se repetem.”

■ 4. Quando NÃO há generalização?

✗ Overfitting

- memoriza o treino
- falha no teste

✗ Underfitting

- não aprende nem o padrão básico

■ 5. Ligação com risco esperado

Generalizar bem significa minimizar o **risco esperado**, não apenas o empírico.

■ 6. Por que isso é difícil?

- temos poucos dados
- não conhecemos a distribuição real
- dados podem ter ruído

■ 7. Fatores que influenciam

- quantidade de dados
- qualidade dos dados
- complexidade do modelo
- escolha da hipótese ($\mathcal{H}$)

■ 8. Intuição geométrica

- Treino → pontos conhecidos
- Generalização → comportamento fora desses pontos

■ 9. Relação com Machine Learning


Todo o objetivo da área é construir modelos que generalizam bem

Exemplo: Curva Ajustando Pontos

Dados de treino (pontos azuis) e modelos com diferentes níveis de complexidade

1. Underfitting

Modelo muito simples




— Modelo (linear)

- Não captura o padrão dos dados
- Erros altos no treino e no teste

Alto erro de treino
Alto erro de teste

2. Bom Ajuste

Modelo com complexidade adequada




— Modelo (polinomial grau 2)

- Captura o padrão dos dados
- Erros baixos no treino e no teste

Baixo erro de treino
Baixo erro de teste

3. Overfitting

Modelo muito complexo



— Modelo (polinomial grau 10)

- Captura o ruído dos dados
- Erro baixo no treino, alto no teste

Baixo erro de treino
Alto erro de teste



Objetivo: encontrar um modelo que generalize bem, ou seja, que tenha baixo erro em dados novos (teste).

Generalização = desempenho em dados não vistos.

Pipeline Formal

“Como transformar dados em um modelo matemático que generaliza?”

O pipeline formal em Machine Learning é a sequência de etapas teóricas que definem e resolvem um problema de aprendizado supervisionado.

Resumo do processo

1. Definir $\mathcal{X}, \mathcal{Y}$
2. Obter dataset D
3. Escolher hipótese $\mathcal{H}$
4. Definir perda ℓ
5. Minimizar o risco empírico

Diferença para pipeline prático

✓ Pipeline formal:

- matemático
- abstrato
- independente de tecnologia

✓ Pipeline prático:

- inclui:
 - coleta de dados
 - limpeza
 - engenharia de atributos
 - deploy