

Pipeline de Machine Learning

Aula Aprendizado Supervisionado
Prof. Paulo Bressan

Pipeline Formal

“Como transformar dados em um modelo matemático que generaliza?”

O pipeline formal em Machine Learning é a sequência de etapas teóricas que definem e resolvem um problema de aprendizado supervisionado.

Resumo do processo

1. Definir $\mathcal{X}, \mathcal{Y}$
2. Obter dataset D
3. Escolher hipótese $\mathcal{H}$
4. Definir perda ℓ
5. Minimizar o risco empírico

Diferença para pipeline prático

✓ Pipeline formal:


- matemático
- abstrato
- independente de tecnologia

✓ Pipeline prático:


- inclui:
 - coleta de dados
 - limpeza
 - engenharia de atributos
 - deploy

PIPELINE COMPLETO DE MACHINE LEARNING

Do problema aos resultados em produção – ciclo iterativo



CONEXÃO COM O PIPELINE FORMAL



PRINCÍPIOS-CHAVE

- Dados de qualidade são fundamentais
- Iterar é parte do processo
- Avaliar em dados não vistos
- Foco na generalização



FLUXO ITERATIVO

Insights em qualquer etapa podem levar a revisões nas etapas anteriores.



DICA

80% do tempo costuma estar nas etapas de dados (1-5).



OBJETIVO FINAL

Entregar valor real com modelos que generalizam bem, são confiáveis e geram impacto no negócio.

Pipeline Prática

“Treinar o modelo é só
uma pequena parte do
trabalho.”

1. Definição do problema

- O que queremos prever?
- Classificação ou regressão?
- Qual métrica usar?



Ex:

“Prever aprovação de alunos”

2. Coleta de dados

- Bases existentes
- APIs / sistemas
- Dados históricos



Qualidade dos dados é crítica

3. Exploração dos dados (EDA)

- Estatísticas básicas
- Visualizações
- Identificação de padrões



entender antes de modelar

Pipeline Prática

“Treinar o modelo é só
uma pequena parte do
trabalho.”

■ 4. Pré-processamento

- Limpeza de dados
- Tratamento de valores faltantes
- Normalização / padronização
- Codificação de variáveis

■ 5. Engenharia de atributos (feature engineering)

- Criar novas variáveis
 - Selecionar atributos relevantes
 - Reduzir dimensionalidade
- 👉 muitas vezes mais importante que o modelo

■ 6. Divisão dos dados

- Treino
 - Validação
 - Teste
- 👉 essencial para avaliar generalização

Pipeline Prática

“Treinar o modelo é só
uma pequena parte do
trabalho.”

7. Escolha do modelo

- Regressão
- Árvores
- Redes neurais
- etc.

👉 escolha define o espaço de hipóteses

8. Treinamento

- Ajustar parâmetros
- Minimizar erro (risco empírico)

9. Avaliação

- Métricas:
 - acurácia
 - precisão/recall
 - erro médio

👉 verificar desempenho real

Pipeline Prática

“Treinar o modelo é só uma pequena parte do trabalho.”

10. Ajuste (tuning)

- Hiperparâmetros
 - Seleção de modelo
 - Regularização
- 👉 processo iterativo

11. Deploy

- Colocar modelo em produção
- API, sistema, aplicação

12. Monitoramento

- Desempenho ao longo do tempo
- Mudança de dados (data drift)
- Re-treinamento

Pipeline como ciclo

- ⚠ Não é linear — é iterativo:
- erro alto → volta para dados
 - problema mal definido → recomeça

Problema

“O problema não é apenas prever evasão — é permitir intervenção antes que ela aconteça.”

Previsão de Evasão de Alunos

Contextualização

A evasão de alunos é um dos principais desafios enfrentados por instituições de ensino superior. Ela impacta diretamente:

- indicadores institucionais (taxa de conclusão)
- planejamento acadêmico
- alocação de recursos
- qualidade da formação oferecida

Além disso, a evasão representa uma perda significativa para o próprio aluno, tanto em termos educacionais quanto socioeconômicos.

Problema

“O problema não é apenas prever evasão — é permitir intervenção antes que ela aconteça.”

■ Definição do problema

O objetivo é construir um modelo capaz de prever, com base em dados históricos, se um aluno irá evadir ou não.

Formalmente:

$$y \in \{0, 1\}$$

onde:

- $y = 1$: aluno evade
- $y = 0$: aluno permanece

Cada aluno é representado por um vetor de atributos:

$$x = (x_1, x_2, \dots, x_n)$$

Exemplos de atributos:

- desempenho acadêmico (notas)
- frequência (faltas)
- engajamento (uso do ambiente virtual)
- condições externas (ex: trabalha ou não)

Problema

“O problema não é apenas prever evasão — é permitir intervenção antes que ela aconteça.”

Motivação

A previsão antecipada da evasão permite:

- identificar alunos em risco
- direcionar ações de intervenção
- reduzir taxas de abandono
- melhorar políticas institucionais



Ou seja:

transformar dados em ações preventivas

Natureza do problema

- Tipo: **classificação supervisionada**
- Saída: variável categórica binária
- Dados: históricos e observacionais

Problema

“O problema não é apenas prever evasão — é permitir intervenção antes que ela aconteça.”

Desafios

✓ Dados

- incompletos ou inconsistentes
- desbalanceamento (poucos casos de evasão)

✓ Modelagem

- escolha de atributos relevantes
- risco de overfitting

✓ Interpretação

- distinguir correlação de causalidade

✓ Operacional

- integração com sistemas institucionais
- uso efetivo das previsões

Problema

“O problema não é apenas prever evasão — é permitir intervenção antes que ela aconteça.”

■ Impacto dos erros

- **Falso negativo (grave):**
 - aluno em risco não identificado
- **Falso positivo:**
 - intervenção desnecessária



normalmente:
minimizar falsos negativos é prioridade

■ Objetivo final

Construir um modelo que:

- apresente boa generalização
- seja interpretável
- apoie decisões reais

Dataset

(20 registros)

ID	Horas Estudo	Faltas	Média Notas	Acessos Moodle	Engaja- mento	Trabalha	Evasão
1	12	2	8.5	35	0.80	0	0
2	5	10	5.0	10	0.30	1	1
3	15	1	9.0	40	0.90	0	0
4	3	15	4.5	5	0.20	1	1
5	8	6	6.5	20	0.50	0	0
6	2	18	3.0	2	0.10	1	1
7	10	4	7.5	30	0.70	0	0
8	6	8	6.0	15	0.40	1	1
9	14	2	8.8	38	0.85	0	0
10	4	12	5.2	8	0.30	1	1
11	9	5	7.0	25	0.60	0	0
12	1	20	2.5	1	0.05	1	1
13	11	3	8.0	32	0.75	0	0
14	7	7	6.2	18	0.50	1	1
15	13	2	9.2	42	0.90	0	0
16	5	9	5.5	12	0.35	1	1
17	10	4	7.8	28	0.65	0	0
18	3	14	4.8	6	0.25	1	1
19	16	1	9.5	45	0.95	0	0
20	6	10	5.8	14	0.40	1	1