

LISTA DE EXERCÍCIOS

Inteligência Artificial — Ciência da Computação

Árvores | RNN/LSTM | Técnicas de Melhoria | Transfer Learning & Transformers

Distribuição por tema:

Tema	Questões	Arquivo de Referência
Árvores de Decisão e Random Forest	Q1 – Q5	<code>aula_ia_arvores_random_forest.ipynb</code>
Redes Neurais Recorrentes: RNN e LSTM	Q6 – Q10	<code>aula_ia_rnn_lstm.ipynb</code>
Técnicas para Melhorar Algoritmos de ML	Q11 – Q15	<code>aula_ia_tecnicas_melhoria.ipynb</code>
Transfer Learning e Transformers	Q16 – Q20	<code>aula_ia_transfer_learning_transformers.ipynb</code>

Cada questão apresenta 4 afirmativas que devem ser julgadas como Verdadeiro (V) ou Falso (F). Assinale a alternativa que corresponde à sequência correta.

QUESTÕES

Q1

[Árvores de Decisão e Random Forest]

Sobre os critérios de divisão e o funcionamento interno das Árvores de Decisão, analise as afirmativas:

Afirmativas:

- (1) A impureza de Gini mede a probabilidade de classificar incorretamente um item escolhido ao acaso em um nó, valendo 0 quando o nó é completamente puro.
- (2) O Ganho de Informação é calculado como o aumento de Entropia obtido ao realizar uma divisão, indicando o quanto a divisão torna os subconjuntos mais heterogêneos.
- (3) Em cada nó, a Árvore de Decisão avalia todos os atributos e todos os pontos de corte possíveis, escolhendo a divisão que maximiza a pureza dos subconjuntos resultantes.
- (4) A Entropia é preferida em relação ao Gini por ser computacionalmente mais eficiente, já que não utiliza logaritmos no cálculo da impureza.

Assinale a alternativa correta:

- (A) V — V — V — F
- (B) V — F — V — V
- (C) V — F — V — F
- (D) V — V — V — V
- (E) F — F — F — F

Q2**[Árvores de Decisão e Random Forest]**

Sobre o controle de overfitting em Árvores de Decisão e o conceito de poda, analise as afirmativas:

Afirmativas:

- (1) Uma Árvore de Decisão treinada sem restrições de profundidade (`max_depth=None`) tende ao underfitting, pois não consegue capturar padrões suficientemente complexos.
- (2) Limitar a profundidade máxima da árvore (`max_depth`) e o número mínimo de amostras por folha (`min_samples_leaf`) são estratégias de pré-poda eficazes para controlar o overfitting.
- (3) Uma árvore que memoriza os dados de treino, atingindo acurácia de 100% neles mas desempenho baixo no teste, apresenta overfitting causado por excesso de complexidade.
- (4) A fronteira de decisão de uma Árvore de Decisão é composta por regiões circulares concêntricas no espaço de features, resultado dos cortes recursivos realizados em cada nó.

Assinale a alternativa correta:

- (A) V — V — V — F
- (B) F — V — V — V
- (C) V — V — V — V
- (D) F — F — F — F
- (E) F — V — V — F

Q3**[Árvores de Decisão e Random Forest]**

Sobre o algoritmo Random Forest e a técnica de Bagging, analise as afirmativas:

Afirmativas:

- (1) O Random Forest combina múltiplas Árvores de Decisão treinadas em subconjuntos aleatórios dos dados (bootstrap) e com subconjuntos aleatórios das features em cada divisão.
- (2) A importância de uma feature no Random Forest é estimada pela redução média de impureza que ela proporciona nas divisões ao longo de todas as árvores do ensemble.
- (3) No Random Forest, cada árvore é treinada sequencialmente, sendo que cada nova árvore foca nos exemplos que as anteriores classificaram incorretamente, em um processo similar ao Boosting.
- (4) A aleatorização das features em cada nó do Random Forest reduz a correlação entre as árvores individuais, o que melhora a capacidade de generalização do ensemble.

Assinale a alternativa correta:

- (A) V — V — V — V
- (B) V — V — F — V
- (C) F — V — F — V
- (D) V — V — V — F
- (E) F — F — F — V

Q4**[Árvores de Decisão e Random Forest]**

Sobre interpretabilidade, aplicações e limitações das Árvores de Decisão, analise as afirmativas:

Afirmativas:

- (1) Assim como as redes neurais profundas, as Árvores de Decisão individuais são consideradas modelos de caixa-preta devido à dificuldade de interpretar suas regras de decisão.
- (2) O dataset Titanic exemplifica um problema de classificação binária com features heterogêneas (numéricas e categóricas) onde Árvores de Decisão podem ser aplicadas diretamente.
- (3) Uma vantagem do Random Forest sobre uma única Árvore de Decisão é a redução da variância: ao combinar muitas árvores, erros individuais tendem a se cancelar, melhorando a generalização.
- (4) Adicionar um número excessivo de árvores ao Random Forest aumenta o risco de overfitting de forma proporcional, exigindo técnicas de regularização para conter esse efeito.

Assinale a alternativa correta:

- (A) V — V — V — F
- (B) F — V — V — V
- (C) V — V — V — V
- (D) F — V — V — F
- (E) F — F — F — F

Q5**[Árvores de Decisão e Random Forest]**

Sobre os critérios de avaliação e a comparação entre Árvore de Decisão individual e Random Forest, analise:

Afirmativas:

- (1) A validação cruzada estratificada (Stratified K-Fold) é mais confiável do que uma única divisão treino/teste para estimar o desempenho real de um modelo em dados não vistos.
- (2) A acurácia é sempre a métrica de avaliação mais adequada para comparar modelos de classificação, independentemente do balanceamento das classes no dataset.
- (3) O Random Forest geralmente supera uma única Árvore de Decisão em performance, ao custo de maior complexidade computacional e menor interpretabilidade individual das regras.
- (4) O processo de bootstrap no Random Forest consiste em amostrar os dados de treino SEM reposição, garantindo que cada árvore receba um subconjunto totalmente distinto dos dados originais.

Assinale a alternativa correta:

- (A) V — F — V — F

- (B) V — V — V — F
- (C) V — F — V — V
- (D) V — V — V — V
- (E) F — F — F — F

Q6

[Redes Neurais Recorrentes: RNN e LSTM]

Sobre as motivações para o uso de redes recorrentes em dados sequenciais, analise as afirmativas:

Afirmativas:

- (1) Uma MLP (rede densa) não possui memória de eventos anteriores: cada entrada é processada de forma independente, ignorando a ordem e o contexto das informações passadas.
- (2) Em tarefas com dados sequenciais, como previsão de preços de ações, a ordem dos exemplos é irrelevante, pois o modelo captura as dependências estatísticas entre os valores independentemente da posição temporal.
- (3) Ao contrário de MLPs e CNNs, uma RNN processa um elemento da sequência por vez, mantendo um estado oculto (hidden state) que resume a informação dos passos anteriores.
- (4) A fórmula de recorrência $h_t = \tanh(W_x \cdot x_t + W_h \cdot h_{t-1} + b)$ mostra que os mesmos pesos são compartilhados em todos os passos de tempo, permitindo processar sequências de qualquer tamanho.

Assinale a alternativa correta:

- (A) V — V — V — V
- (B) V — F — V — F
- (C) F — V — V — V
- (D) V — F — V — V
- (E) V — V — F — V

Q7

[Redes Neurais Recorrentes: RNN e LSTM]

Sobre o problema do gradiente desvanecente e suas consequências para RNNs simples, analise:

Afirmativas:

- (1) O problema do gradiente desvanecente ocorre em RNNs quando os gradientes se tornam exponencialmente pequenos ao serem propagados de volta por muitos passos de tempo, impedindo o aprendizado de dependências de longo prazo.
- (2) A arquitetura LSTM sofre do mesmo problema do gradiente desvanecente que as RNNs simples, sendo indicada apenas para sequências curtas onde esse problema é menos pronunciado.
- (3) O mecanismo de porta (gate) da LSTM permite que a rede aprenda a selecionar quais informações manter na memória de longo prazo e quais descartar, controlando explicitamente o fluxo de gradientes.

- (4) A GRU (Gated Recurrent Unit) é uma variante da LSTM com mais parâmetros, pois adiciona portas extras para controlar a memória de curto prazo com maior precisão.

Assinale a alternativa correta:

- (A) V — F — V — F
- (B) V — V — V — F
- (C) V — F — V — V
- (D) V — V — V — V
- (E) F — F — F — F

Q8

[Redes Neurais Recorrentes: RNN e LSTM]

Sobre o pré-processamento de séries temporais para uso em redes recorrentes, analise:

Afirmativas:

- (1) Ao dividir uma série temporal em treino e teste, os dados devem ser embaralhados aleatoriamente para garantir que ambos os conjuntos representem igualmente todas as fases da série.
- (2) A normalização com MinMaxScaler é recomendada para séries temporais usadas em RNN/LSTM pois funções como tanh saturam para valores grandes, prejudicando o treinamento.
- (3) A técnica de janela deslizante (sliding window) transforma a série temporal em pares (X, y) onde X contém os últimos N valores e y é o valor seguinte a ser previsto.
- (4) Para evitar data leakage em séries temporais, o MinMaxScaler deve ser ajustado (fit) nos dados de teste e depois aplicado ao treino, garantindo que a escala de normalização represente os dados futuros.

Assinale a alternativa correta:

- (A) V — V — V — F
- (B) F — V — V — V
- (C) V — V — V — V
- (D) F — F — F — F
- (E) F — V — V — F

Q9

[Redes Neurais Recorrentes: RNN e LSTM]

Sobre a arquitetura LSTM e suas portas (gates), analise as afirmativas:

Afirmativas:

- (1) A LSTM possui três portas principais — forget gate, input gate e output gate — que controlam, respectivamente, o que esquecer da memória, o que adicionar e o que expor como saída.
- (2) A porta de esquecimento (forget gate) usa uma função sigmoid que produz valores entre 0 e 1, onde 0 significa 'esquecer completamente' e 1 significa 'manter totalmente' o estado da célula.

- (3) O estado da célula (cell state) da LSTM é reiniciado a cada passo de tempo, funcionando apenas como memória de curtíssimo prazo que não atravessa múltiplos passos da sequência.
- (4) Em uma LSTM, o valor passado diretamente como saída para a camada seguinte em cada passo de tempo é o estado da célula (cell state c_t), não o estado oculto (hidden state h_t).

Assinale a alternativa correta:

- (A) V — V — V — F
- (B) V — V — F — V
- (C) V — V — F — F
- (D) V — V — V — V
- (E) F — F — F — F

Q10 [Redes Neurais Recorrentes: RNN e LSTM]

Sobre avaliação e comparação de modelos RNN, LSTM e GRU em previsão de séries temporais, analise:

Afirmativas:

- (1) Acurácia e F1-score são as métricas mais adequadas para avaliar modelos de previsão de séries temporais contínuas, como a previsão do preço de fechamento de ações.
- (2) O RMSE (Root Mean Squared Error) penaliza erros maiores com mais intensidade que o MAE, sendo útil quando grandes desvios de previsão têm impacto desproporcional no problema.
- (3) Modelos LSTM e GRU geralmente superam RNNs simples em séries com dependências de longo prazo, ao custo de maior número de parâmetros e tempo de treinamento.
- (4) Na avaliação de modelos para séries temporais, a divisão aleatória dos dados em treino e teste é equivalente à divisão cronológica, pois o modelo aprende padrões estatísticos sem distinção de ordem.

Assinale a alternativa correta:

- (A) V — V — V — F
- (B) F — V — V — F
- (C) F — V — V — V
- (D) V — V — V — V
- (E) F — F — F — F

Q11 [Técnicas para Melhorar Algoritmos de ML]

Sobre normalização, padronização e qualidade dos dados como técnicas de melhoria, analise:

Afirmativas:

- (1) Modelos baseados em distância ou gradiente, como SVM, KNN e Regressão Logística, são sensíveis à escala das features e se beneficiam significativamente da normalização.
- (2) Para evitar data leakage, o StandardScaler deve ser ajustado (fit) no conjunto completo de dados antes da divisão treino/teste, garantindo uma escala global consistente.
- (3) O Min-Max Scaling transforma as features para o intervalo [0,1] e é sensível a outliers, enquanto o Z-Score (StandardScaler) produz média 0 e desvio padrão 1, sendo mais robusto.
- (4) O SMOTE (Synthetic Minority Over-sampling Technique) gera exemplos sintéticos da classe minoritária interpolando entre exemplos reais, sendo uma alternativa ao simples undersampling.

Assinale a alternativa correta:

- (A) V — V — V — V
- (B) V — F — V — F
- (C) F — V — V — V
- (D) V — V — F — V
- (E) V — F — V — V

Q12 [Técnicas para Melhorar Algoritmos de ML]

Sobre validação cruzada e estimativas robustas de desempenho, analise as afirmativas:

Afirmativas:

- (1) A Stratified K-Fold garante que a proporção das classes seja preservada em cada fold, sendo especialmente importante em datasets desbalanceados.
- (2) Na validação cruzada K-Fold, o conjunto de teste é incluído nas K iterações para melhorar a estimativa de desempenho, já que mais dados levam a estimativas mais precisas.
- (3) Uma única divisão treino/teste com proporção 80/20 fornece uma estimativa tão confiável quanto a validação cruzada K-Fold, desde que os dados sejam embaralhados antes da divisão.
- (4) O modelo baseline é definido antes da aplicação de qualquer técnica de melhoria, servindo como ponto de referência para avaliar o ganho real de cada otimização posterior.

Assinale a alternativa correta:

- (A) V — F — F — V
- (B) V — V — F — V
- (C) V — F — V — V
- (D) V — V — V — V
- (E) F — F — F — F

Q13 [Técnicas para Melhorar Algoritmos de ML]

Sobre regularização L1/L2 e o dilema viés-variância, analise as afirmativas:

Afirmativas:

- (1) Um modelo com underfitting apresenta baixo viés e alta variância, errando de forma consistente nos dados de treino por ser simples demais para capturar os padrões relevantes.
- (2) A regularização L1 (Lasso) penaliza a soma dos valores absolutos dos coeficientes, podendo zerar coeficientes de features irrelevantes e realizando, assim, seleção automática de features.
- (3) A regularização L2 (Ridge) penaliza a soma dos quadrados dos coeficientes, reduzindo seus valores sem zerá-los completamente, o que resulta em modelos mais estáveis e com menor variância.
- (4) A poda de uma Árvore de Decisão (pruning) aumenta a profundidade máxima permitida da árvore para incluir mais exemplos de treino nas folhas, reduzindo assim a variância do modelo.

Assinale a alternativa correta:

- (A) V — V — V — F
- (B) F — V — V — V
- (C) F — V — V — F
- (D) V — V — V — V
- (E) F — F — F — F

Q14

[Técnicas para Melhorar Algoritmos de ML]

Sobre otimização de hiperparâmetros com Grid Search, Random Search e Otimização Bayesiana, analise:

Afirmativas:

- (1) O Grid Search avalia todas as combinações possíveis de hiperparâmetros dentro de um grid predefinido, garantindo encontrar o melhor ponto do grid mas com custo computacional exponencialmente crescente.
- (2) O Random Search é menos eficiente que o Grid Search para o mesmo número de iterações, pois ao amostrar aleatoriamente o espaço de busca corre o risco de não cobrir regiões importantes.
- (3) O Optuna implementa Otimização Bayesiana usando o algoritmo TPE (Tree-structured Parzen Estimator), que concentra as tentativas nas regiões do espaço de hiperparâmetros que mostraram resultados mais promissores.
- (4) Para garantir uma avaliação justa do modelo final, a busca de hiperparâmetros deve ser realizada diretamente no conjunto de teste durante a validação cruzada, otimizando os parâmetros para a distribuição real dos dados.

Assinale a alternativa correta:

- (A) V — V — V — F
- (B) V — F — V — F
- (C) V — F — V — V

- (D) V — V — V — V
(E) F — F — F — F

Q15 [Técnicas para Melhorar Algoritmos de ML]

Sobre Boosting e o algoritmo XGBoost como técnica de ensemble, analise as afirmativas:

Afirmativas:

- (1) O Bagging e o Boosting são técnicas de ensemble que treinam os modelos base de forma sequencial, sendo a principal diferença o critério de ponderação dos modelos na combinação final.
- (2) No Boosting, cada novo modelo é treinado para corrigir os erros cometidos pelo modelo anterior, atribuindo maior peso aos exemplos que foram classificados incorretamente.
- (3) O XGBoost implementa Gradient Boosting com regularização L1 e L2 nativas, tratamento de valores ausentes e paralelização do cálculo dos gradientes, tornando-o eficiente para datasets de grande porte.
- (4) Aumentar o número de estimadores ($n_{\text{estimators}}$) no XGBoost sem qualquer regularização nunca causa overfitting, pois o mecanismo de boosting é intrinsecamente resistente ao sobreajuste.

Assinale a alternativa correta:

- (A) V — V — V — F
(B) F — V — V — V
(C) V — V — V — V
(D) F — V — V — F
(E) F — F — F — F

Q16 [Transfer Learning e Transformers]

Sobre o conceito de Transfer Learning e suas estratégias de aplicação, analise as afirmativas:

Afirmativas:

- (1) No Transfer Learning, uma rede treinada em um dataset grande (ex: ImageNet) já aprendeu características genéricas como bordas, texturas e formas, úteis para qualquer tarefa de visão computacional.
- (2) Na estratégia de feature extraction, os pesos da rede pré-treinada são completamente descongelados e retreinados junto com o novo classificador, aproveitando os pesos iniciais como ponto de partida.
- (3) O fine-tuning consiste em descongelar as camadas finais da rede pré-treinada e retreiná-las com uma taxa de aprendizado muito baixa, para não destruir o conhecimento geral já acumulado.
- (4) O catastrophic forgetting é o risco de destruir o conhecimento pré-treinado ao usar uma taxa de aprendizado muito alta durante o fine-tuning, motivando o uso de learning rates da ordem de $1e-5$.

Assinale a alternativa correta:

- (A) V — V — V — V
- (B) V — F — V — V
- (C) F — F — V — V
- (D) V — V — V — F
- (E) V — V — F — V

Q17

[Transfer Learning e Transformers]

Sobre a MobileNetV2 e a aplicação prática de Transfer Learning em visão computacional, analise:

Afirmativas:

- (1) A MobileNetV2 é carregada sem a camada de classificação original (`include_top=False`) para que um novo classificador específico para a tarefa-alvo possa ser adicionado no topo.
- (2) A feature extraction é indicada para datasets grandes, pois exige muitos exemplos para ajustar todos os pesos da rede pré-treinada ao novo domínio de forma eficaz.
- (3) O GlobalAveragePooling2D mantém as dimensões espaciais do tensor de features, apenas normalizando os valores para facilitar a conexão com camadas densas subsequentes.
- (4) As camadas iniciais de uma CNN pré-treinada detectam características de baixo nível (bordas, cantos), enquanto as camadas finais capturam padrões mais abstratos e específicos da tarefa original.

Assinale a alternativa correta:

- (A) V — V — F — V
- (B) V — F — V — V
- (C) V — V — V — V
- (D) V — F — F — V
- (E) F — F — F — F

Q18

[Transfer Learning e Transformers]

Sobre o mecanismo de atenção (self-attention) e sua vantagem sobre RNNs, analise as afirmativas:

Afirmativas:

- (1) O mecanismo de self-attention permite que cada elemento de uma sequência calcule diretamente sua relevância em relação a todos os outros elementos, sem precisar processar a sequência passo a passo.
- (2) Os vetores Query (Q), Key (K) e Value (V) são obtidos multiplicando a entrada por matrizes de pesos aprendíveis, e a atenção é calculada como uma média ponderada dos Values pelas similaridades Query-Key.

- (3) Na fórmula $\text{Attention}(Q,K,V) = \text{softmax}(QK^T / \sqrt{d_k})V$, o fator $\sqrt{d_k}$ é usado para amplificar os produtos internos, garantindo que a atenção seja mais sensível a pequenas diferenças entre queries e keys.
- (4) Uma vantagem do self-attention sobre RNNs é a capacidade de capturar dependências de longo alcance em uma única operação, sem o problema do gradiente desvanecente que afeta RNNs simples.

Assinale a alternativa correta:

- (A) V — V — F — V
- (B) V — V — V — V
- (C) F — V — F — V
- (D) V — V — V — F
- (E) F — F — F — V

Q19

[Transfer Learning e Transformers]

Sobre a arquitetura Transformer e suas vantagens em relação às RNNs, analise as afirmativas:

Afirmativas:

- (1) O Transformer processa a sequência de entrada passo a passo, assim como a RNN, mas usa múltiplos mecanismos de atenção em paralelo para capturar dependências de diferentes sub-espacos.
- (2) O Positional Encoding é necessário nos Transformers porque o mecanismo de self-attention, por si só, é invariante à ordem dos elementos, não distinguindo a posição de cada token na sequência.
- (3) A Multi-Head Attention aplica múltiplos mecanismos de atenção em paralelo, cada um em um sub-espaco diferente, permitindo capturar diferentes tipos de relações entre os elementos da sequência.
- (4) Uma limitação dos Transformers em relação às RNNs é a dificuldade em capturar dependências de longo alcance na sequência, sendo mais eficazes apenas para relações entre elementos próximos.

Assinale a alternativa correta:

- (A) V — V — V — F
- (B) F — V — V — V
- (C) V — V — V — V
- (D) F — F — F — F
- (E) F — V — V — F

Q20

[Transfer Learning e Transformers]

Sobre modelos pré-treinados da Hugging Face e o uso prático de Transformers em NLP, analise:

Afirmativas:

- (1) A biblioteca Hugging Face Transformers permite usar modelos como BERT e GPT em poucas linhas de código via pipelines, abstraindo a complexidade da arquitetura para tarefas como análise de sentimento e tradução.
- (2) O BERT (Bidirectional Encoder Representations from Transformers) é pré-treinado para entender o contexto de uma palavra levando em conta tanto o que vem antes quanto o que vem depois dela na sequência.
- (3) Fazer fine-tuning de um modelo pré-treinado como o BERT exige tantos dados e tempo de treinamento quanto treinar um Transformer do zero, pois todos os pesos precisam ser reaprendidos.
- (4) O Transfer Learning é igualmente eficaz independentemente da similaridade entre a tarefa original de pré-treinamento e a nova tarefa, pois os pesos aprendidos capturam características universais aplicáveis a qualquer domínio.

Assinale a alternativa correta:

- (A) V — V — V — F
 - (B) V — V — F — V
 - (C) V — V — F — F
 - (D) V — V — V — V
 - (E) F — F — F — F
-

GABARITO

Q1: C	Q2: E	Q3: B	Q4: D	Q5: A
Q6: D	Q7: A	Q8: E	Q9: C	Q10: B
Q11: E	Q12: A	Q13: C	Q14: B	Q15: D
Q16: B	Q17: D	Q18: A	Q19: E	Q20: C

CORREÇÃO DAS SENTENÇAS FALSAS

Para cada questão são apresentadas as sentenças falsas com a justificativa e a versão correta da afirmativa.

Q1

[Árvores de Decisão e Random Forest] Resposta:
Alternativa C

Sequência: V — F — V — F

Sentença (2) FALSA

Como estava (errado):

O Ganho de Informação é calculado como o aumento de Entropia obtido ao realizar uma divisão, indicando o quanto a divisão torna os subconjuntos mais heterogêneos.

Versão correta:

O Ganho de Informação é a REDUÇÃO de Entropia obtida ao realizar uma divisão — quanto mais ele reduz a heterogeneidade dos subconjuntos, melhor é a divisão.

Sentença (4) FALSA

Como estava (errado):

A Entropia é preferida em relação ao Gini por ser computacionalmente mais eficiente, já que não utiliza logaritmos no cálculo da impureza.

Versão correta:

O Gini é computacionalmente mais eficiente do que a Entropia pois não utiliza logaritmos. Na prática, os dois critérios produzem resultados muito similares.

Q2

[Árvores de Decisão e Random Forest] Resposta:
Alternativa E

Sequência: F — V — V — F

Sentença (1) FALSA

Como estava (errado):

Uma Árvore de Decisão treinada sem restrições de profundidade ($max_depth=None$) tende ao underfitting, pois não consegue capturar padrões suficientemente complexos.

Versão correta:

Uma Árvore de Decisão sem restrições de profundidade tende ao OVERFITTING: ela cresce até classificar corretamente cada exemplo de treino individualmente, memorizando ruído e perdendo capacidade de generalização.

Sentença (4) FALSA

Como estava (errado):

A fronteira de decisão de uma Árvore de Decisão é composta por regiões circulares concêntricas no espaço de features, resultado dos cortes recursivos realizados em cada nó.

Versão correta:

A fronteira de decisão de uma Árvore de Decisão é formada por regiões RETANGULARES paralelas aos eixos, resultado de cortes perpendiculares a um único eixo por vez em cada nó.

Q3

[Árvores de Decisão e Random Forest] Resposta:
Alternativa B

Sequência: **V — V — F — V**

Sentença (3) FALSA

Como estava (errado):

No Random Forest, cada árvore é treinada sequencialmente, sendo que cada nova árvore foca nos exemplos que as anteriores classificaram incorretamente, em um processo similar ao Boosting.

Versão correta:

No Random Forest, cada árvore é treinada de forma INDEPENDENTE E PARALELA sobre uma amostra bootstrap dos dados (Bagging). A estratégia de treino sequencial com foco nos erros é característica do Boosting, não do Bagging.

Q4

[Árvores de Decisão e Random Forest] Resposta:
Alternativa D

Sequência: **F — V — V — F**

Sentença (1) FALSA

Como estava (errado):

Assim como as redes neurais profundas, as Árvores de Decisão individuais são consideradas modelos de caixa-preta devido à dificuldade de interpretar suas regras de decisão.

Versão correta:

Ao contrário das redes neurais profundas, as Árvores de Decisão individuais são modelos de CAIXA-BRANCA (white-box): suas regras de decisão podem ser visualizadas e explicadas facilmente. O Random Forest, por combinar muitas árvores, perde parcialmente essa interpretabilidade.

Sentença (4) FALSA

Como estava (errado):

Adicionar um número excessivo de árvores ao Random Forest aumenta o risco de overfitting de forma proporcional, exigindo técnicas de regularização para conter esse efeito.

Versão correta:

Aumentar o número de árvores no Random Forest NÃO causa overfitting — a performance tende a se estabilizar após certo ponto. Diferente da profundidade de cada árvore, o número de estimadores é um hiperparâmetro que pode ser aumentado sem risco de overfitting crescente.

Q5**[Árvores de Decisão e Random Forest]** Resposta:
Alternativa ASequência: **V — F — V — F****Sentença (2) FALSA****Como estava (errado):**

A acurácia é sempre a métrica de avaliação mais adequada para comparar modelos de classificação, independentemente do balanceamento das classes no dataset.

Versão correta:

A acurácia pode ser enganosa em datasets desbalanceados: um modelo que sempre prediz a classe majoritária obtém alta acurácia sem aprender nada útil. Métricas como AUC-ROC, F1-score e Recall são mais adequadas nesses casos.

Sentença (4) FALSA**Como estava (errado):**

O processo de bootstrap no Random Forest consiste em amostrar os dados de treino SEM reposição, garantindo que cada árvore receba um subconjunto totalmente distinto dos dados originais.

Versão correta:

O bootstrap amostra os dados COM reposição: cada árvore recebe uma amostra do mesmo tamanho do dataset original, mas com repetições — em média, cerca de 63% dos exemplos únicos são incluídos, e o restante (out-of-bag) pode ser usado como validação natural.

Q6**[Redes Neurais Recorrentes: RNN e LSTM]** Resposta:
Alternativa DSequência: **V — F — V — V****Sentença (2) FALSA****Como estava (errado):**

Em tarefas com dados sequenciais, como previsão de preços de ações, a ordem dos exemplos é irrelevante, pois o modelo captura as dependências estatísticas entre os valores independentemente da posição temporal.

Versão correta:

Em dados sequenciais, a ordem é FUNDAMENTAL: o preço de amanhã depende dos preços dos dias anteriores, e trocar a ordem temporal destrói o padrão que o modelo deve aprender. Essa dependência temporal é exatamente o que motiva o uso de RNNs.

Q7**[Redes Neurais Recorrentes: RNN e LSTM]** Resposta:
Alternativa ASequência: **V — F — V — F****Sentença (2) FALSA****Como estava (errado):**

A arquitetura LSTM sofre do mesmo problema do gradiente desvanecente que as RNNs simples, sendo indicada apenas para sequências curtas onde esse problema é menos pronunciado.

Versão correta:

A LSTM foi projetada especificamente para RESOLVER o problema do gradiente desvanecente: sua célula de memória e suas portas permitem preservar gradientes ao longo de centenas de passos de tempo, viabilizando o aprendizado de dependências de longo prazo.

Sentença (4) FALSA

Como estava (errado):

A GRU (Gated Recurrent Unit) é uma variante da LSTM com mais parâmetros, pois adiciona portas extras para controlar a memória de curto prazo com maior precisão.

Versão correta:

A GRU é uma variante SIMPLIFICADA da LSTM com MENOS parâmetros: usa apenas 2 portas (reset e update) em vez das 3 da LSTM (input, forget, output), sendo computacionalmente mais eficiente com desempenho comparável em muitas tarefas.

Q8

[Redes Neurais Recorrentes: RNN e LSTM] Resposta:
Alternativa E

Sequência: F — V — V — F

Sentença (1) FALSA

Como estava (errado):

Ao dividir uma série temporal em treino e teste, os dados devem ser embaralhados aleatoriamente para garantir que ambos os conjuntos representem igualmente todas as fases da série.

Versão correta:

Em séries temporais, a divisão treino/teste NUNCA deve embaralhar os dados: o treino deve ser o passado e o teste o futuro. Embaralhar introduziria data leakage (o modelo veria informações futuras durante o treino) e violaria a estrutura temporal dos dados.

Sentença (4) FALSA

Como estava (errado):

Para evitar data leakage em séries temporais, o MinMaxScaler deve ser ajustado (fit) nos dados de teste e depois aplicado ao treino, garantindo que a escala de normalização represente os dados futuros.

Versão correta:

Para evitar data leakage, o scaler deve ser ajustado (fit) APENAS no conjunto de TREINO e depois aplicado (transform) tanto ao treino quanto ao teste. Ajustar no teste introduz vazamento de informação futura para o processo de treinamento.

Q9

[Redes Neurais Recorrentes: RNN e LSTM] Resposta:
Alternativa C

Sequência: V — V — F — F

Sentença (3) FALSA

Como estava (errado):

O estado da célula (cell state) da LSTM é reiniciado a cada passo de tempo, funcionando apenas como memória de curtíssimo prazo que não atravessa múltiplos passos da sequência.

Versão correta:

O cell state da LSTM é exatamente o oposto: ele PERSISTE e flui ao longo de todos os passos de tempo com modificações controladas, funcionando como a memória de LONGO PRAZO. É essa persistência que permite à LSTM capturar dependências distantes na sequência.

Sentença (4) FALSA

Como estava (errado):

Em uma LSTM, o valor passado diretamente como saída para a camada seguinte em cada passo de tempo é o estado da célula (cell state c_t), não o estado oculto (hidden state h_t).

Versão correta:

Em cada passo de tempo, a LSTM expõe o HIDDEN STATE (h_t) como saída para a próxima camada — não o cell state diretamente. O h_t é calculado aplicando tanh ao cell state filtrado pelo output gate, e também é repassado ao próximo passo como contexto de curto prazo.

Q10

[Redes Neurais Recorrentes: RNN e LSTM] Resposta:
Alternativa B

Sequência: F — V — V — F

Sentença (1) FALSA

Como estava (errado):

Acurácia e F1-score são as métricas mais adequadas para avaliar modelos de previsão de séries temporais contínuas, como a previsão do preço de fechamento de ações.

Versão correta:

Acurácia e F1-score são métricas de CLASSIFICAÇÃO. Para previsão de séries temporais contínuas, as métricas adequadas são MAE (Mean Absolute Error) e RMSE (Root Mean Squared Error), que medem a distância entre o valor previsto e o valor real.

Sentença (4) FALSA

Como estava (errado):

Na avaliação de modelos para séries temporais, a divisão aleatória dos dados em treino e teste é equivalente à divisão cronológica, pois o modelo aprende padrões estatísticos sem distinção de ordem.

Versão correta:

A divisão cronológica é OBRIGATÓRIA em séries temporais: o conjunto de treino deve ser o passado e o de teste o futuro. A divisão aleatória cria data leakage, permitindo que o modelo use informações futuras para prever o passado, inflando artificialmente a performance avaliada.

Q11

[Técnicas para Melhorar Algoritmos de ML] Resposta:
Alternativa E

Sequência: V — F — V — V

Sentença (2) FALSA

Como estava (errado):

Para evitar data leakage, o StandardScaler deve ser ajustado (fit) no conjunto completo de dados antes da divisão treino/teste, garantindo uma escala global consistente.

Versão correta:

Para evitar data leakage, o StandardScaler deve ser ajustado (fit) SOMENTE no conjunto de TREINO e depois aplicado (transform) ao treino e ao teste separadamente. Ajustar no conjunto completo vaza estatísticas do teste para o treino, inflando artificialmente a performance medida.

Q12

[Técnicas para Melhorar Algoritmos de ML] Resposta:
Alternativa A

Sequência: **V — F — F — V**

Sentença (2) FALSA

Como estava (errado):

Na validação cruzada K-Fold, o conjunto de teste é incluído nas K iterações para melhorar a estimativa de desempenho, já que mais dados levam a estimativas mais precisas.

Versão correta:

Na validação cruzada K-Fold, o conjunto de TESTE final é mantido completamente separado e nunca utilizado nas iterações. Os K folds são criados a partir do conjunto de TREINO, e o teste final só é usado após a seleção do modelo para medir a generalização real.

Sentença (3) FALSA

Como estava (errado):

Uma única divisão treino/teste com proporção 80/20 fornece uma estimativa tão confiável quanto a validação cruzada K-Fold, desde que os dados sejam embaralhados antes da divisão.

Versão correta:

A validação cruzada K-Fold é MAIS confiável do que uma única divisão: ela reduz a variância da estimativa ao avaliar o modelo em K divisões diferentes, aproveitando todos os dados para validação de forma rotativa, ao contrário da divisão única que depende da escolha aleatória.

Q13

[Técnicas para Melhorar Algoritmos de ML] Resposta:
Alternativa C

Sequência: **F — V — V — F**

Sentença (1) FALSA

Como estava (errado):

Um modelo com underfitting apresenta baixo viés e alta variância, errando de forma consistente nos dados de treino por ser simples demais para capturar os padrões relevantes.

Versão correta:

Underfitting é caracterizado por ALTO VIÉS e baixa variância: o modelo é simples demais e erra tanto no treino quanto no teste de forma sistemática. É o overfitting que apresenta baixo viés e ALTA variância (boa performance no treino, ruim no teste).

Sentença (4) FALSA

Como estava (errado):

A poda de uma Árvore de Decisão (pruning) aumenta a profundidade máxima permitida da árvore para incluir mais exemplos de treino nas folhas, reduzindo assim a variância do modelo.

Versão correta:

A poda REDUZ a complexidade da árvore, removendo nós ou limitando a profundidade. Isso AUMENTA o viés (menos expressividade) mas REDUZ a variância (menos memorização), combatendo o overfitting — exatamente o oposto de aumentar a profundidade.

Q14 [Técnicas para Melhorar Algoritmos de ML] Resposta:
Alternativa B

Sequência: **V — F — V — F**

Sentença (2) FALSA

Como estava (errado):

O Random Search é menos eficiente que o Grid Search para o mesmo número de iterações, pois ao amostrar aleatoriamente o espaço de busca corre o risco de não cobrir regiões importantes.

Versão correta:

O Random Search é MAIS eficiente que o Grid Search: ao amostrar aleatoriamente, ele explora regiões diversas do espaço em poucas iterações e geralmente encontra soluções muito próximas do ótimo com cerca de 10 vezes menos avaliações que o Grid Search exaustivo.

Sentença (4) FALSA

Como estava (errado):

Para garantir uma avaliação justa do modelo final, a busca de hiperparâmetros deve ser realizada diretamente no conjunto de teste durante a validação cruzada, otimizando os parâmetros para a distribuição real dos dados.

Versão correta:

A busca de hiperparâmetros deve ser feita EXCLUSIVAMENTE no conjunto de TREINO (usando validação cruzada interna). Usar o conjunto de teste no tuning causa data leakage, produzindo uma estimativa de performance artificialmente otimista que não reflete a generalização real.

Q15 [Técnicas para Melhorar Algoritmos de ML] Resposta:
Alternativa D

Sequência: **F — V — V — F**

Sentença (1) FALSA

Como estava (errado):

O Bagging e o Boosting são técnicas de ensemble que treinam os modelos base de forma sequencial, sendo a principal diferença o critério de ponderação dos modelos na combinação final.

Versão correta:

Bagging treina os modelos em PARALELO, de forma independente, sobre amostras bootstrap. O Boosting treina os modelos SEQUENCIALMENTE, onde cada novo modelo foca nos erros do anterior. Essa diferença na estratégia de treinamento é fundamental, não apenas o critério de ponderação.

Sentença (4) FALSA

Como estava (errado):

Aumentar o número de estimadores ($n_{\text{estimators}}$) no XGBoost sem qualquer regularização nunca causa overfitting, pois o mecanismo de boosting é intrinsecamente resistente ao sobreajuste.

Versão correta:

Ao contrário do Random Forest, o XGBoost SEM regularização pode sofrer overfitting ao aumentar `n_estimators` indefinidamente. Por isso ele inclui regularização L1/L2, além de parâmetros como `learning_rate` e `subsample` para controlar a complexidade e prevenir o sobreajuste.

Q16

[Transfer Learning e Transformers] Resposta:
Alternativa B

Sequência: **V — F — V — V**

Sentença (2) FALSA

Como estava (errado):

Na estratégia de feature extraction, os pesos da rede pré-treinada são completamente descongelados e retreinados junto com o novo classificador, aproveitando os pesos iniciais como ponto de partida.

Versão correta:

Na feature extraction, os pesos da base pré-treinada são CONGELADOS (`trainable=False`): apenas o novo classificador no topo é treinado. É o fine-tuning que descongela (parcialmente) os pesos da base para ajustá-los ao novo domínio com uma taxa de aprendizado baixa.

Q17

[Transfer Learning e Transformers] Resposta:
Alternativa D

Sequência: **V — F — F — V**

Sentença (2) FALSA

Como estava (errado):

A feature extraction é indicada para datasets grandes, pois exige muitos exemplos para ajustar todos os pesos da rede pré-treinada ao novo domínio de forma eficaz.

Versão correta:

A feature extraction é indicada para datasets PEQUENOS: como os pesos da base ficam congelados, poucos exemplos são suficientes para treinar apenas o novo classificador no topo. Para datasets maiores e problemas mais distantes do original, o fine-tuning (descongelar camadas) é mais apropriado.

Sentença (3) FALSA

Como estava (errado):

O GlobalAveragePooling2D mantém as dimensões espaciais do tensor de features, apenas normalizando os valores para facilitar a conexão com camadas densas subsequentes.

Versão correta:

O GlobalAveragePooling2D REDUZ as dimensões espaciais calculando a média de cada mapa de features, produzindo um vetor 1D. Isso elimina a estrutura espacial e permite conectar a saída a camadas densas sem a necessidade de um Flatten explícito.

Q18

[Transfer Learning e Transformers] Resposta:
Alternativa A

Sequência: **V — V — F — V**

Sentença (3) FALSA

Como estava (errado):

Na fórmula $\text{Attention}(Q, K, V) = \text{softmax}(QK^T / \sqrt{d_k})V$, o fator $\sqrt{d_k}$ é usado para amplificar os produtos internos, garantindo que a atenção seja mais sensível a pequenas diferenças entre queries e keys.

Versão correta:

O fator $\sqrt{d_k}$ é usado para ESCALAR (dividir) os produtos QK^T , evitando que eles se tornem muito grandes quando a dimensão d_k é alta. Produtos grandes levam a gradientes muito pequenos após o softmax, prejudicando o treinamento — a divisão por $\sqrt{d_k}$ estabiliza o treinamento.

Q19

[Transfer Learning e Transformers] Resposta:
Alternativa E

Sequência: F — V — V — F

Sentença (1) FALSA

Como estava (errado):

O Transformer processa a sequência de entrada passo a passo, assim como a RNN, mas usa múltiplos mecanismos de atenção em paralelo para capturar dependências de diferentes sub-espacos.

Versão correta:

O Transformer processa TODA a sequência DE UMA VEZ em paralelo, ao contrário das RNNs que operam passo a passo. O self-attention calcula as relações entre todos os pares de elementos simultaneamente, o que elimina o gargalo sequencial das RNNs e permite paralelização massiva no treinamento.

Sentença (4) FALSA

Como estava (errado):

Uma limitação dos Transformers em relação às RNNs é a dificuldade em capturar dependências de longo alcance na sequência, sendo mais eficazes apenas para relações entre elementos próximos.

Versão correta:

Capturar dependências de LONGO ALCANCE é exatamente uma das VANTAGENS do Transformer: o self-attention calcula diretamente a relação entre qualquer par de posições com custo constante, independentemente da distância, enquanto RNNs sofrem do gradiente desvanecente justamente nesse cenário.

Q20

[Transfer Learning e Transformers] Resposta:
Alternativa C

Sequência: V — V — F — F

Sentença (3) FALSA

Como estava (errado):

Fazer fine-tuning de um modelo pré-treinado como o BERT exige tantos dados e tempo de treinamento quanto treinar um Transformer do zero, pois todos os pesos precisam ser reaprendidos.

Versão correta:

O fine-tuning requer MUITO MENOS dados e tempo do que treinar do zero: os pesos pré-treinados já codificam conhecimento geral de linguagem, e apenas um ajuste fino (com uma fração dos dados e épocas) é necessário para adaptar o modelo à tarefa específica.

Sentença (4) FALSA

Como estava (errado):

O Transfer Learning é igualmente eficaz independentemente da similaridade entre a tarefa original de pré-treinamento e a nova tarefa, pois os pesos aprendidos capturam características universais aplicáveis a qualquer domínio.

Versão correta:

A eficácia do Transfer Learning DEPENDE da similaridade entre as tarefas: transferir de ImageNet para classificar raios-X médicos é mais eficaz do que transferir para classificar padrões de áudio, pois as características visuais aprendidas são mais relacionadas. Tarefas muito distintas se beneficiam menos ou exigem fine-tuning mais extenso.
