

UNIVERSIDADE FEDERAL DE ALFENAS – UNIFAL-MG
BACHARELADO EM CIÊNCIA DA COMPUTAÇÃO

JEANN VICTOR BATISTA

**RESUMO DO ARTIGO “A NEW HUMAN-BASED METAHEURISTIC
OPTIMIZATION METHOD BASED ON MIMICKING COOKING TRAINING”**

ALFENAS – MG
2026

JEANN VICTOR BATISTA

**RESUMO DO ARTIGO “A NEW HUMAN-BASED METAHEURISTIC
OPTIMIZATION METHOD BASED ON MIMICKING COOKING TRAINING”**

Relatório apresentado à disciplina DCE770 – Heurísticas e Metaheurísticas, do curso de Bacharelado em Ciência da Computação da Universidade Federal de Alfenas, como requisito da primeira etapa do Trabalho Final.

Professor: Prof. Dr. Iago Augusto de Carvalho.

ALFENAS – MG

2026

SUMÁRIO

1	Identificação e contextualização do artigo	3
2	Problema estudado e motivações	3
3	Contribuições apresentadas	3
4	Meta-heurística proposta	4
5	Resultados obtidos	4
6	Conclusões	5
	REFERÊNCIAS	6

1 IDENTIFICAÇÃO E CONTEXTUALIZAÇÃO DO ARTIGO

O artigo *A new human-based metaheuristic optimization method based on mimicking cooking training*, de Eva Trojovská e Mohammad Dehghani, foi publicado em 2022 no periódico de acesso aberto *Scientific Reports*. O trabalho apresenta o *Chef-Based Optimization Algorithm* (CBOA), uma meta-heurística populacional inspirada no processo de formação de cozinheiros em cursos de culinária. O CBOA integra, portanto, a categoria das meta-heurísticas baseadas em atividades humanas, ao lado de métodos como o TLBO e o WSO. Sua finalidade é resolver problemas de otimização nos quais métodos determinísticos podem ser inadequados em razão de não linearidade, não convexidade, alta dimensionalidade, descontinuidade ou grande número de ótimos locais (Trojovská; Dehghani, 2022).

2 PROBLEMA ESTUDADO E MOTIVAÇÕES

O problema geral considerado é encontrar, em um espaço de busca limitado, os valores das variáveis que minimizam uma função objetivo. Em aplicações reais, enumerar todas as soluções pode ser inviável e técnicas baseadas em gradientes nem sempre podem ser empregadas. As meta-heurísticas utilizam busca estocástica para produzir soluções próximas do ótimo global sem exigir derivadas. Contudo, nenhum algoritmo é superior em todas as classes de problemas, conforme o teorema *No Free Lunch* (Wolpert; Macready, 1997). Essa ausência de um otimizador universal constitui a motivação apresentada pelos autores para desenvolver uma nova estratégia que equilibre exploração global e exploração intensiva das regiões promissoras.

3 CONTRIBUIÇÕES APRESENTADAS

A contribuição central é a formulação matemática do CBOA, que associa cada solução candidata às habilidades de uma pessoa em treinamento culinário. A população é reordenada a cada iteração e dividida entre chefs instrutores, que correspondem aos indivíduos mais bem avaliados, e estudantes. Os autores formalizam duas estratégias para atualizar os instrutores e três estratégias para atualizar os estudantes. Também apresentam fluxograma, pseudocódigo, análise de complexidade, análise de sensibilidade e uma avaliação experimental contra doze meta-heurísticas conhecidas. Por fim, testam o método em quatro problemas de projeto de engenharia e disponibilizam publicamente sua implementação em MATLAB (Trojovská; Dehghani, 2022).

4 META-HEURÍSTICA PROPOSTA

Inicialmente, o CBOA gera aleatoriamente uma matriz com N soluções, cada uma formada por m variáveis dentro dos respectivos limites. Após calcular a função objetivo, as soluções são ordenadas: as N_C melhores tornam-se chefs instrutores e as demais tornam-se estudantes. O melhor indivíduo da população é denominado melhor chef.

Na primeira fase, cada instrutor tenta melhorar sua solução de duas maneiras. Na estratégia de exploração, ele se desloca em função da posição do melhor chef, com perturbações aleatórias. Na estratégia de aproveitamento, realiza uma busca local ao redor da própria posição. Os limites dessa vizinhança diminuem com o número da iteração, produzindo passos progressivamente menores. Uma nova posição somente substitui a anterior se melhorar o valor da função objetivo.

Concluída a atualização dos instrutores, o processo avança para a segunda fase, dedicada aos estudantes, que escolhem aleatoriamente um instrutor e atualizam sua posição seguindo três estratégias. Primeiro, aproxima todas as suas variáveis das habilidades do instrutor selecionado. Depois, copia apenas uma variável, interpretada como o aprendizado integral de uma habilidade. Por fim, realiza uma pequena busca local em uma coordenada escolhida aleatoriamente. Também nesse grupo prevalece uma regra gulosa: apenas mudanças que melhoram a solução são aceitas. Ao final da iteração, toda a população é novamente classificada e os papéis de instrutor e estudante podem mudar. O processo é repetido por um número fixo de iterações. A complexidade total do algoritmo depende do tamanho da população, do número de instrutores e do número de iterações, sendo apresentada pelos autores em notação O grande (Trojovská; Dehghani, 2022).

5 RESULTADOS OBTIDOS

O estudo empregou 23 funções clássicas: sete unimodais para avaliar aproveitamento, seis multimodais de alta dimensão para avaliar exploração e dez multimodais de dimensão fixa para avaliar o equilíbrio entre ambas. O CBOA e os concorrentes foram executados vinte vezes, com mil iterações por execução. Os indicadores foram média, melhor valor, desvio-padrão, mediana, tempo de execução e posição no ranking. As comparações incluíram GA, PSO, GSA, TLBO, GWO, MVO, WOA, TSA, MPA, HBA, DE e CMA.

Nos testes unimodais, o CBOA alcançou o ótimo global em cinco das sete funções e obteve a primeira colocação geral. Nas funções multimodais de alta dimensão, atingiu exatamente o ótimo em F9 e F11 e voltou a apresentar o melhor ranking geral. Nas funções multimodais de dimensão fixa, também ficou em primeiro lugar pela média das posições. O teste de soma de postos de Wilcoxon, com nível de significância de 5%, produziu valores de p inferiores a 0,05 contra os doze concorrentes, resultado interpretado pelos autores como superioridade

estatisticamente significativa (Wilcoxon, 1945; Trojovská; Dehghani, 2022).

O algoritmo também foi avaliado nas 29 funções da competição CEC 2017 (Awad et al., 2016), obtendo a primeira colocação pelo ranking médio. Na análise de sensibilidade, populações de 20, 30, 50 e 100 indivíduos produziram resultados semelhantes em muitas funções, enquanto o aumento de 200 para mil iterações geralmente melhorou as soluções. Nas aplicações reais — projeto de vaso de pressão, redutor de velocidade, viga soldada e mola de tração/compressão — o CBOA recebeu a primeira posição entre os algoritmos comparados nos quatro casos.

6 CONCLUSÕES

Os autores concluem que a combinação das cinco estratégias permite ao CBOA equilibrar a exploração de novas regiões com o refinamento local das soluções. Os experimentos indicam desempenho competitivo em funções com características distintas e em problemas restritos de engenharia. Entretanto, por ser um método estocástico, o CBOA não garante o ótimo global e pode falhar em classes de problemas não contempladas nos testes. Como trabalhos futuros, o artigo sugere desenvolver versões binária e multiobjetivo e aplicar o algoritmo em outros domínios. Assim, a principal conclusão é que o CBOA constitui uma alternativa geral e relativamente simples para otimização contínua, embora sua eficácia deva ser verificada experimentalmente para cada nova aplicação (Trojovská; Dehghani, 2022).

REFERÊNCIAS

AWAD, N. H.; ALI, M. Z.; LIANG, J. J.; QU, B. Y.; SUGANTHAN, P. N. **Evaluation criteria for the CEC 2017 special session and competition on single objective real-parameter numerical optimization**. Daegu: Kyungpook National University, 2016.

TROJOVSKÁ, Eva; DEHGHANI, Mohammad. A new human-based metaheuristic optimization method based on mimicking cooking training. **Scientific Reports**, [s. l.], v. 12, art. 14861, 2022. DOI: 10.1038/s41598-022-19313-2.

WILCOXON, Frank. Individual comparisons by ranking methods. **Biometrics Bulletin**, [s. l.], v. 1, n. 6, p. 80–83, 1945.

WOLPERT, David H.; MACREADY, William G. No free lunch theorems for optimization. **IEEE Transactions on Evolutionary Computation**, [s. l.], v. 1, n. 1, p. 67–82, 1997.